



Programa Profesional en Inteligencia Artificial y Data
Science

Módulo 4. Analítica Escalable

Índice

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- 1.1. Conceptos básicos de matemática discreta, lógica algorítmica y complejidad computacional para análisis de datos
- 1.2. Técnicas y procesos de extracción de la información de los datos. Sistemas de Big Data
- 1.3. Modelado, razonamiento y solución de problemas

Tema 2. Configuración de cuadros de mando en entornos computacionales

- 2.1. Representación de información: arquitecturas, técnicas y herramientas
- 2.2. Metodologías para la minería de datos
- 2.3. Métodos y algoritmos de minería de datos

Tema 3. Gestión y almacenamiento de datos. Búsqueda de respuestas en grandes conjuntos de datos

Objetivos

- 3.1. Sistemas de gestión almacenamiento. HDFS
- 3.2. Sistemas de gestión de almacenamiento. Bases de datos NoSQL
- 3.3. Importación: Flume, Sqoop, Apache NiFi
- 3.4. Sistemas de almacenamiento publicador/subscriptor y motores de búsqueda
- 3.5. Referencias bibliográficas

Tema 4. Aplicación de herramientas para la visualización de datos

Objetivos

- 4.1. Datos no estructurados: fuentes, tipología
- 4.2. Inteligencia artificial en el análisis de datos
- 4.3. Clúster de máquinas información distribuida y redundante
- 4.4. Herramientas de visualización de datos
- 4.5. Tendencias en visualización de datos
- 4.6. Referencias bibliográficas

A fondo

Storytelling with Data: A Data Visualization Guide for Business Professionals

Storytelling with Data

¿Qué son los KPI's? Explicación de los indicadores a través del fútbol

Análisis de KPIS con dashboards: de los datos al conocimiento

Storytelling: el arte de contar historias

El storytelling y ejemplos de comunicación a través de esta técnica

Introducción a SEMMA de SAS®

IBM SPSS Modeler Cookbook

A Visual Guide to Crisp-DM Methodology

Metodología Crisp-DM

Metodología Crisp-DM en adictos al trabajo

Python Data Mining Quick Start Guide

Minería de datos: modelos y algoritmos

Data Mining: Practical Machine Learning Tools and Techniques

Basic Statistics and Data Mining for Data Science

Minería de datos

Algoritmos de minería de datos

D3 for the Impatient: Interactive Graphics for Programmers and Scientists

Mastering Qlik Sense

Tableau: Create and Learn

Visual Data Storytelling with Tableau

Introducing Microsoft Power BI

Applied Microsoft Power BI: Bring your data to life!

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

1.1. Conceptos básicos de matemática discreta, lógica algorítmica y complejidad computacional para análisis de datos

Objetivos

Este tema desarrolla los conceptos básicos de matemática discreta, lógica algorítmica y complejidad computacional para análisis de datos y sistemas de Big Data.

Los objetivos son:

- ▶ Que el estudiante comprenda los elementos esenciales de la teoría de conjuntos.
- ▶ Que se entiendan y apliquen las operaciones entre conjuntos.
- ▶ Que se puedan identificar de manera clara las características que diferencian a los conjuntos finitos e infinitos numerables.
- ▶ Que el estudiante entienda el concepto de función.
- ▶ Comprender la dependencia entre variables.
- ▶ Que el estudiante entienda los conceptos fundamentales de la complejidad computacional, el análisis de algoritmos y su construcción.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Introducción

Toda la matemática moderna y gran parte de la ciencia de la computación se ha erigido sobre los pilares de la teoría de conjuntos. Esta teoría fue desarrollada por George Cantor. Matemático alemán de origen ruso, nacido en San Petersburgo, en 1845 que murió en 1918. Esta teoría ha servido como base para la formalización de casi toda la matemática y muchos de los conceptos matemáticos se han definido según la teoría de conjuntos como el concepto de función. Esta teoría permitió, de alguna forma, unificar las matemáticas y comprender algunos conceptos nuevos.

El concepto central de toda la teoría de conjuntos es precisamente este, el de conjunto, por eso comenzaremos esta introducción a la matemática discreta estudiando en que consiste y sus principales propiedades y las operaciones que se pueden realizar sobre ellos.

Conjuntos y sus elementos

Una definición rigurosa de este concepto es escurridiza y es complicada hasta para el mismo campo de estudio de la teoría, por tanto usaremos aquí, con el ánimo de que se entienda, la más común de las definiciones:

Definición 1. Un conjunto es una colección bien definida de objetos. A estos objetos se les denominan elementos del conjunto. Los conjuntos son denotados, normalmente, por letras mayúsculas tales como A, B, X, mientras que sus elementos son denotados por minúsculas tal como a, b, x, y.

Que un elemento a pertenezca al conjunto A se denota como:

$$a \in A$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Y se lee, el elemento a , pertenece, al conjunto A . De esta misma forma si tenemos dos elementos que sabemos pertenecen a un conjunto podemos denotarlo de la misma forma:

$$a, b \in A$$

Y se lee, los elementos a y b , pertenecen al conjunto A .

Hay dos formas de especificar un conjunto, en la primera se pueden especificar cada uno de los componentes separados por comas, siempre que sea posible. En la segunda se especifican las propiedades que deben cumplir los elementos para pertenecer al conjunto, por ejemplo:

$$A = (2, 4, 6, 8) \text{ o } A = \{a \mid a \text{ es par y } a < 10\}$$

Que se puede leer como A , es el conjunto de los números pares menores que 10.

$$A = \{a \mid a \text{ es par y } 0 < a < 10\}$$

Es importante que se entienda la manera en que se lee la expresión anterior, en la cual la barra horizontal $|$ significa “tal que”, es decir, esta expresión se debe leer como “ A es el conjunto de todos los a , tal que a , es par y a está entre 0 y 10”.

Por otro lado, cuando deseamos denotar que un elemento no pertenece a un conjunto usamos la siguiente notación:

$$a \notin A \text{ o } A \not\ni a$$

Esto se puede leer como, el elemento a no pertenece al conjunto A y el otro se lee como el conjunto A no contiene al elemento a .

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Subconjuntos

Supongamos ahora que tenemos el siguiente conjunto:

$$A = \{a \mid a \text{ es par y } 0 < a < 20\}$$

Es decir, tenemos el conjunto de todos los pares mayores que 0 y menores que 20. Ahora bien, de la misma manera que agrupamos a estos elementos por la propiedad de que son pares, puede que los elementos del conjunto tengan otras propiedades por las cuales se les pueda agrupar y en ese caso les llamamos subconjuntos de A . Por ejemplo, los enteros pares mayores que cero y menores que 10 del conjunto A es un subconjunto de A al que llamaremos B y esta relación se denota como:

$$B \subset A \text{ o } A \supset B$$

Es decir, B es un subconjunto de A o se puede decir, como a la derecha, que A es un súper conjunto de B .

Ahora, es importante que nos percatemos que todos los elementos de B también son elementos de A , sin embargo, pueden existir elementos en A que no forman parte de B . Y si no hay elementos en A que no sean elementos de B entonces $A = B$.

Esto es: Si $B \subset A$ y $A \subset B$ entonces $A = B$

Cuando hay elementos en A , que no forman parte de B , entonces a B se le llama subconjunto propio de A .

Definición 2. Se le denomina subconjunto propio, a un subconjunto B de A , tal que hay en A , elementos que no están en B . ($A \neq B$) Y se denota como:

$$B \subsetneq A$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Veamos un ejemplo:

Si $A = \{1, 2, 3, 4, 5\}$ entonces:

$$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{1, 2\}, \{1, 3\}, \{1, 4\}, \{1, 5\}, \{2, 3\}, \{2, 4\}, \{2, 5\}, \dots, \{2, 3, 4, 5\}$$

Todos los anteriores son subconjuntos propios de A .

Definición 3: se llama Conjunto Potencia de A , al conjunto de todos los posibles subconjuntos de A . Al cual denotaremos como sigue:

$$\wp(A)$$

Por ejemplo, supongamos que nuestro conjunto A , es el siguiente:

$$A = \{a, b\}$$

Entonces el Conjunto Potencia de A sería:

$$\wp(A) = \{\emptyset, \{a\}, \{b\}, \{a, b\}\}$$

El conjunto vacío, denotado por $\emptyset$, es un subconjunto de cualquier conjunto y se define como $\emptyset = \{\}$. Pues no tiene ningún elemento. Por tanto, el conjunto A , también puede representarse como $A = \{\emptyset, a, b\}$. Sabiendo que $\emptyset \subseteq A$.

El conjunto potencia de un conjunto A , también puede expresarse como:

$$\wp(A) = \{B \mid B \subseteq A\}$$

Esto se lee, el conjunto potencia de A es el conjunto de todos los conjuntos B , tal que B es un subconjunto propio de A .

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Hay varios conjuntos que son de especial interés para toda las matemáticas y las ciencias conexas. Estos son:

- ▶ El conjunto de los número naturales o enteros positivos y que se denota por N .

- ▶ $N = \{1, 2, 3, \dots, n\}$

- ▶ El conjunto de los números enteros y que se denota por Z :

$$Z = \{-n, \dots, -3, -2, -1, 0, 1, 2, 3, \dots, n\}$$

- ▶ El conjunto de los números Racionales y que se denota por Q .

- ▶ El conjunto de los números Reales y que lo denotaremos como R .

- ▶ El conjunto de los números Complejos y que en lo adelante denotaremos por C .

Es importante comprender que:

$$N \subseteq Z \subseteq Q \subseteq R \subseteq C$$

Definición 4: se llama Cardinalidad de un conjunto, por ejemplo A , a la cantidad de elementos distintos que contiene y se denota por $|A|$.

Por ejemplo:

Si $A = \{1, 2, 3, 4, \dots, n\}$ entonces $A \vee n$

Si $A = \{1, 2, 3\}$ entonces $A \vee 3$

Si $A = \{\{1, 2\}, \{3, 5, 7\}\}$ entonces $A \vee 2$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Operaciones entre conjuntos

De la misma manera en que se pueden realizar operaciones sobre números, naturales por ejemplo, como la suma o resta, sobre los conjuntos también se pueden realizar algunas operaciones.

Unión. La unión de dos conjuntos A y B, es un conjunto C, que contendrá todos los componentes de A y los componentes de B. El operador que representa esta operación es $\cup$.

$$C = A \cup B$$

Ejemplo:

$$\text{Si } A = \{1, 2, 3, 4, 5\} \text{ y } B = \{6, 7, 8, 9, 10\}$$

Entonces la unión de los conjuntos, sería:

$$C = A \cup B = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$$

Intersección. La intersección entre dos conjuntos A y B es el conjunto que contiene los elementos comunes a los conjuntos A y B. El símbolo que representa la operación de intersección es $\cap$.

$$C = A \cap B$$

Ejemplo:

$$\text{Si } A = \{1, 2, 3, 4, 5\} \text{ y } B = \{4, 5, 6, 7, 8\}$$

Entonces su intersección sería:

$$C = A \cap B = \{4, 5\}$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Si por el contrario, los conjuntos fueran los siguientes:

$$A = \{1, 2, 3, 4, 5\} \text{ y } B = \{6, 7, 8, 9, 10\}$$

Entonces su intersección sería:

$$C = A \cap B = \{\emptyset\}$$

Y esto se debe a que A y B no tienen ningún elemento en común y se dice que los conjuntos son disjuntos.

Diferencia. La diferencia entre dos conjuntos A y B es el conjunto que contendrá los elementos que están A pero que no están en B. Esta operación se representa como:

$$C = A - B = \{a \mid a \in A \text{ y } a \notin B\}$$

Ejemplo:

$$\text{Si } A = \{1, 2, 3, 4, 5\} \text{ y } B = \{4, 5, 6, 7, 8\}$$

Entonces:

$$C = A - B = \{1, 2, 3\}$$

Esto quiere decir que la diferencia entre dos conjuntos, son aquellos elementos que están en el primer conjunto pero no están en el segundo. Es importante destacar que esta operación no es simétrica y por tanto:

$$A - B \neq B - A$$

Para resolver el problema de la simetría de la operación aparece lo que se llama diferencia simétrica y se denota con el símbolo $\oplus$.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Diferencia Simétrica. La diferencia simétrica entre dos conjuntos A y B es el conjunto que contendrá la diferencia entre la unión de los conjuntos A y B y la intersección entre ellos. Es decir, contendrá aquellos elementos de los dos conjuntos que no sean comunes a ambos. Esta operación se representa de la siguiente forma:

$$C = A \oplus B = (A \cup B) - (A \cap B)$$

Ejemplo:

Si $A = \{1, 2, 3, 4, 5\}$ y $B = \{4, 5, 6, 7, 8\}$

Entonces, la diferencia simétrica entre estos dos conjuntos es:

$$C = A \oplus B = \{1, 2, 3, 6, 7, 8\}$$

Ahora podemos ver que:

$$A \oplus B = B \oplus A$$

Propiedades de las operaciones

Al igual que las operaciones matemáticas tienen algunas propiedades, las operaciones sobre los conjuntos también las tienen y en esta sección veremos algunas de ellas:

- ▶ Ley conmutativa para la unión: $A \cup B = B \cup A$.
- ▶ Ley conmutativa para la intersección: $A \cap B = B \cap A$.
- ▶ Ley asociativa para la unión: $A \cup (B \cap C) = (A \cup B) \cap C$.
- ▶ Ley asociativa para la intersección: $A \cap (B \cup C) = (A \cap B) \cup C$.
- ▶ Ley distributiva para la unión: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$.
- ▶ Ley distributiva para la intersección: $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

► Ley de Morgan 1: $(A \cup B)^C = A^C \cap B^C$

► Ley de Morgan 2: $(A \cap B)^C = A^C \cup B^C$

Propiedad/Operación	Unión	Intersección
Conmutativa	SI	SI
Asociativa	SI	SI
Distributiva	SI	SI

Esto quiere decir que ambas operaciones son tanto Conmutativas, Asociativas como Distributivas.

Conjunto Infinitos e infinitos contables

Determinar el tamaño de dos conjuntos A y B de manera comparativa, es cuestión de establecer una “correspondencia biunívoca”, entre ellos, veamos esto.

Establecer una correspondencia biunívoca es: Dados dos conjuntos A y B, se dice que existe correspondencia biunívoca o correspondencia uno a uno entre ellos, si entre los elementos de A y los de B, es posible hacer corresponder sus elementos de tal manera que para cada par de elementos diferentes de A, existen también, un par de elementos diferentes en B.




Figura 1. Correspondencia Biunívoca. a) Si existe, b) si existe, c) no existe.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Teniendo en cuenta lo anterior, entonces podemos establecer el concepto de conjunto Finito.

Conjunto Finito: Se dice que el conjunto A es finito si al hacerlo corresponder con otro de la forma $\{1, 2, 3, \dots, n\}$, dicha correspondencia es biunívoca. Entonces se puede afirmar que el tamaño del conjunto es $|A|=n$ y por tanto Finito.

Usando este mismo razonamiento puede decirse que entonces un conjunto **finito contable** o numerable es aquel que al ponerse en correspondencia con el conjunto de los naturales, esta también es biunívoca. Recordemos que $N = \{1, 2, 3, \dots\}$. Es decir que hay una correspondencia uno a uno entre los elementos del conjunto y los elementos del conjunto de números naturales.

Por ejemplo:

Si tomamos como conjunto $A = \{2, 4, 6, \dots\}$ el conjunto de todos los naturales pares mayores que cero, se puede decir que este es infinito contable, pues puede establecerse una correspondencia uno a uno entre los naturales y los elementos de A .




Figura 2. Correspondencia uno a uno entre los pares positivos y los naturales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Funciones

Uno de los conceptos que son fundamentales en la matemática y la ciencia de la computación es el de función. Y es que las funciones aparecen en todas las esferas de la vida cotidiana, por ejemplo, en su desempeño profesional un biólogo, necesitaría saber cómo crece un cultivo de bacterias en función del tiempo y un químico podría necesitar saber cuál es la velocidad inicial de la reacción de una sustancia en función de la cantidad usada. Estas son relaciones entre las cantidades que se describen y es a lo que se denominan funciones pues una cantidad varía en función de otra.

Por generalidad se puede considerar una **función** como una correspondencia entre un conjunto X a otro conjunto Y , y se representa como $f: X \rightarrow Y$. A f se le puede entender como el procedimiento por el cual se relaciona un elemento $x \in X$ a otro elemento $y \in Y$.

Por tanto, dada una función $f: X \rightarrow Y$, al conjunto de todos los elementos $x \in X$, que f puede asociar sin ambigüedad a otro elemento $y \in Y$, se le denomina dominio de f y se denota por $\text{dom}\{f\}$. Por otra parte, al conjunto de todos los elementos $y = f(x)$ que se obtiene al recorrer el $\text{dom}\{f\}$, se les llama imagen de f y se denota como $\text{Im}\{f\}$.

Por ejemplo:

Para la función f definida en $\mathbb{R}$ por $f(x) = \frac{1+x}{2x}$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

El dominio de la función son todos los números reales excepto $x = 0$, ya que dicho valor es el único que no tiene correspondencia con un valor real, pues la división por cero no está definida. Por tanto, podemos escribir:

$$\text{dom}(f) = \{x \in \mathbb{R}, x \neq 0\}$$

Que se lee: El dominio de la función es el conjunto de todos los reales diferentes de cero.

Hay dos tipos de funciones que son de especial interés para análisis de algoritmos, que estudiaremos más adelante y que estudiaremos aunque lo haremos de manera superficial y solo con el objetivo de que se conozcan sus gráficas, pues ellas darán alguna luz de como varía la complejidad de los algoritmos según el tamaño de la entrada. Estas funciones son las funciones exponenciales y las funciones logarítmicas.

Funciones Exponenciales. Una función exponencial es aquella que a cada valor real x le asigna la potencia a^x con $a > 0$ y diferente de 1. Esta función se expresa:

$$f(x) = a^x$$

A la a dentro de la función se le conoce como base de la función.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La gráfica de esta función es la que se muestra a continuación:




Figura 3. Gráfica de $f(x) = a^x$

A continuación mostramos la gráfica de $f(x) = \left(\frac{1}{a}\right)^x$ con el fin de que se pueda comparar con la anterior y luego listamos algunas de las propiedades de estas funciones.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 4. Gráfica de $f(x) = \left(\frac{1}{a}\right)^x$




Figura 5. Gráfica de $f(x) = \left(\frac{1}{a}\right)^x$ vs. $f(x) = a^x$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Hay una función exponencial que es de especial interés y se le suele llamar función exponencial natural y se denota de la siguiente forma:

$$f(x) = e^x$$

Dónde:

$$e = \lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n$$

Esta notación fue introducida por Leonhard Euler hacia 1730, al descubrir muchas propiedades de este número. El número e , es irracional y sus primeras diez cifras decimales son 2. 7182818284.

Algunas propiedades de las funciones exponenciales:

- ▶ Su dominio: $\mathbb{R}$
- ▶ Su imagen: $(0, \infty)$
- ▶ Es una función continua.
- ▶ Es creciente si $a > 1$.
- ▶ Es decreciente si $0 < a < 1$.
- ▶ Como se puede ver en la gráfica 5, las funciones de $f(x) = \left(\frac{1}{a}\right)^x$ y $f(x) = a^x$ son simétricas respecto al eje y .
- ▶ La función exponencial $f(x) = a^x$ crece eventualmente más rápido que la función potencia x^n para cualquier $n \in \mathbb{N}$.
- ▶ La función inversa de la $f(x) = a^x$ es $f^{-1}(x) = \log_a x$ la función inversa de $f(x) = e^x$ es $f(x) = e^x$.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Funciones logarítmicas. Antes de intentar explicar las funciones logarítmicas es preciso que expliquemos que es el logaritmo.

Primero que todo, el logaritmo de un número, en una base dada, es el exponente al que hay que elevar la base para obtener dicho número.

$$y = \log_a x : x = a^y$$

.∴ : este símbolo significa “por tanto”.

Hay dos casos especiales de logaritmos que es necesario que tengan en cuenta, que son el llamado logaritmo natural y el logaritmo decimal o logaritmo común.

Se le llama logaritmo natural a aquel cuya base es el número de Euler, e y se denota como:

$$y = \ln x = \log_e x$$

Con esto ya explicado podemos explicar qué es una función logarítmica. Una función logarítmica es aquella en que la variable independiente forma parte del argumento de un logaritmo. Y toma la forma siguiente:

$$f(x) = \log_a x$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La gráfica de la función logarítmica se muestra a continuación:




Figura 6. Gráfica de la función logarítmica. $f(x) = \log_a x$

A lo que el análisis de algoritmos respecta, y lo que se pretende con introducirla aquí es la forma en que esta crece. Es importante recordar que esta función es la inversa de la función exponencial. En la siguiente gráfica mostramos las dos funciones con el fin de que se tenga una imagen clara de cómo crecen ambas funciones y su significado quedará claro cuando más adelante introduzcamos el tema de la complejidad computacional y el análisis de algoritmos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 7. Gráfica de la función logarítmica vs. exponencial.

Las propiedades de la función logarítmica son las siguientes:

- ▶ Dominio: $\mathbb{R}$
- ▶ Su imagen: $\mathbb{R}$
- ▶ Es una función continua.
- ▶ Es creciente si $a > 1$.
- ▶ Es decreciente si $0 < a < 1$.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 8. Gráfica de la función logarítmica.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Introducción a la complejidad computacional

En muchos textos suele tratarse el tema de la complejidad computacional de forma independiente o luego de tratar los temas de diseño de algoritmos. Sin embargo en esta introducción tocaremos inicialmente el tema de la complejidad computacional y complejidad algorítmica para luego tocar el tema de los métodos de diseño. Esto tiene la ventaja de que a la hora de enfrentarnos a la tarea de la solución de problema tengamos claro cuáles son los elementos que pueden presentarse y como entenderlos.

Con lo anterior explicado podemos comenzar a esbozar de qué trata la complejidad computacional. Todo de lo que trata esta teoría es de problemas, sus soluciones y de la dificultad de resolverlos.

Para entender esto pongamos dos problemas:

- ▶ Multiplicación de dos números.
- ▶ El problema del viajero vendedor.

Revisemos las posibles soluciones al primer problema, la multiplicación de dos números. Para su solución rápidamente podemos imaginar tres procedimientos: Podemos hacer una multiplicación por una suma repetida, podemos hacerlo por el método tradicional o lo podemos hacer por el método llamado del “campesino ruso”.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Supongamos que queremos multiplicar 11×32 . Resolvámoslo por el primer método, el de las sumas repetidas, entonces:

$$11 \times 32 = 32 + 32 + 32 + 32 + 32 + 32 + 32 + 32 + 32 + 32 = 352$$

Esta solución necesita 10 operaciones de sumas para completarse.

Veamos la siguiente solución, para la cual haremos los siguientes pasos:

$$\begin{array}{r} 11 \times 32 \\ \hline 32 \\ 32 \\ \hline 352 \end{array}$$

Tomamos el dígito de las unidades del primero de los números, el multiplicando, el 1 y lo multiplicamos por 32 y colocamos el resultado debajo de la línea, luego tomamos el dígito de las decenas y multiplicamos por 32 y el resultado lo colocamos debajo del resultado anterior pero corrido a la izquierda un dígito. Luego sumamos las columnas y colocamos las sumas debajo de la siguiente línea. Esto resultaría en dos operaciones de multiplicación y tres operaciones de suma, lo cual arroja 5 operaciones en total.

Revisemos ahora, el método de multiplicación llamado del “campesino ruso”, este método funciona de la siguiente manera, colocamos el multiplicador y el multiplicando en sobre una línea.

$$\begin{array}{r} 1132 \\ \hline 5 \quad 64 \\ 2 \quad 128 \\ 1 \quad 256 \\ \hline 352 \end{array}$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Y debajo de cada uno de ellos como si fuera una columna, se van ubicando la mitad del multiplicando y el doble del multiplicador, hasta que el valor del multiplicando se haga uno y luego se suman las columnas incluyendo el valor del multiplicador que está encima de la línea, donde el valor del multiplicador sea impar. En este caso, las filas que utilizamos son las correspondientes al 5 y el 1. De esta forma, la suma sería:

$$32 + 64 + 256 = 352$$

Con este método tendríamos que hacer tres divisiones entre 2, tres multiplicaciones por 2 más sumas, en total 8 operaciones.

Está claro que si los multiplicandos y multiplicador fueran de más dígitos el número de estas operaciones serían mucho mayores.

Revisemos ahora el problema del viajero vendedor, ¿en qué consiste dicho problema? Pues un viajero que es comerciante necesita visitar, digamos 10 ciudades, sin repetir ninguna y escoger el camino más corto posible entre todas y regresar al punto de origen.

Para resolver este problema, el enfoque más sencillo es el comparar todos los recorridos posibles y escoger el que menos valor nos arroje. Sin embargo habría que evaluar $(n - 1)!$ Recorridos.

¿Qué significa esto de $(n - 1)!$? Este es, el factorial de n-1 y para el caso que nos ocupa, que dijimos que tenemos 10 ciudades, entonces, el factorial sería:

$$(n - 1)! = (9)! = 9 * 8 * 7 * 6 * 5 * 4 * 3 * 2 * 1 = 362880$$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Expliquemos un poco esto, sería tomar una ciudad cualquiera y trazamos una ruta desde ella pasando por cada una de las restante 9, solo una vez y esto lo debemos repetir 362880 veces, solo con 10 ciudades. Si aumentamos en una la cantidad de ciudades habría que comparar 3 millones 628 mil 800 recorridos posibles.

$$(11 - 1)! = (10)! = 10 * 9 * 8 * 7 * 6 * 5 * 4 * 3 * 2 * 1 = 3628800$$

El aumento en una ciudad nos llevó de 362 mil recorridos a más de 3 millones de ellos. Impresionante ¿verdad?

Comparemos las soluciones a ambos problemas. En el primero de los problemas tenemos un conjunto de pasos bien establecidos que nos permite obtener el resultado, unos con más pasos que otro; pero siempre es un número pequeño. En el segundo caso, sin embargo, tengo que trazar 362880 recorridos entre las 10 ciudades y luego compararlos para encontrar el menor de ellos. Ahora la pregunta inicial que les haría es ¿Cuál de ellos es más fácil de resolver?

La respuesta a la pregunta puede que sea evidente; pero sirve perfectamente para el propósito de demostrar la necesidad de una rama de la matemática computacional que agrupe los métodos y herramientas que permita la investigación de los problemas y la complejidad de sus soluciones y aquí es donde entra la Complejidad Computacional.

Por tanto:

La **Complejidad Computacional** es el área o rama de la ciencia de la computación o matemática computacional que se dedica al estudio y categorización de los problemas computacionales por su complejidad intrínseca, así como la relación entre dichas categorías.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Es importante entonces que nos demos cuenta que la solución a los problemas computacionales son, cuando es posible encontrarlos, un conjunto de pasos bien definidos que nos llevan a ella. Es a este conjunto de pasos a lo que se llama Algoritmo.

Entonces podemos definir Algoritmo como:

Algoritmo: es un conjunto de pasos bien definidos y finitos que permite solucionar un problema.

Ahora bien, conociendo lo anterior es justo preguntarse ¿Qué hace que un problema computacional sea más o menos complejo de solucionar? Bien, la complejidad de un problema a la hora de solucionarlo, siempre se valora en términos de si hay o no un algoritmo que lo solucione y de la cantidad de recursos que son necesarios para llegar a dicha solución.

Pero ahora ¿Qué se entiende por recursos en este contexto? ¿A que nos referimos con eso de recursos? En ciencia de la computación e informática hay muchos tipos de recursos, sin embargo los más preciados son: El tiempo de procesamiento y el espacio de memoria que requieren los algoritmos para obtener soluciones.

Hay varias otras ramas que están relacionadas con la Complejidad Computacional como el análisis de algoritmos y la teoría de la computabilidad. Mientras que la Complejidad Computacional se dedica al estudio de la complejidad inherente e intrínseca de los problemas y sus posibles soluciones el análisis de algoritmo se centra en el análisis de la complejidad de una solución algorítmica.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La complejidad de un algoritmo se da, en términos del consumo de los dos principales recursos computacionales, como dijimos anteriormente, tiempo y espacio. A dicha complejidad se le llama, complejidad espacio-temporal de un algoritmo. La complejidad espacial estudia el consumo de recursos de memoria para llegar a la solución mientras que la complejidad temporal estudia el consumo de tiempo en función de la entrada del algoritmo.

Con el fin de evaluar la complejidad de los algoritmos es necesario hacer suposiciones sobre las características de las plataformas que los ejecutarán. Los algoritmos computacionales pos supuesto que deberán ser ejecutados en alguna parte y por tanto es necesario, que esas partes o plataformas sean caracterizadas y por esto la teoría de complejidad computacional introduce el concepto de modelo de computación.

El modelo más conocido es el modelo nombrado Máquina de Turing y que explicaremos más adelante.

Modelo computacional (Maquina de Turing)

En esta subsección tocaremos el modelo teórico más conocido de la ciencia de la computación, el llamado Máquina de Turing. Este modelo fue propuesto por el matemático inglés Alan Turing en 1936.

Una máquina de Turing consiste en una **cinta** continua infinita dividida en celdas cuadradas que contienen símbolos. Un **cabezal** de lectura y escritura que opera sobre la cinta y puede moverla a la izquierda o la derecha una celda a la vez. Un **registro de estado** que almacena el estado de la MT. Una **tabla de instrucciones** que basado en el estado en que está la máquina y el símbolo leído de la cinta por el cabezal determina la próxima acción.

No ahondaremos en el modelo y sus interioridades.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Las Maquinas de Turing tiene varias modificaciones que les son equivalentes tales como la MT con movimiento de espera, MT con cinta infinita, MT con cinta multipista, MT con varias cintas, entre otras modificaciones.

Las Máquinas de Turing son clasificadas en MT determinista y MT No determinista.

- ▶ **MT determinista:** Se denomina MT determinista a aquella a la que al par (estado, símbolo) le corresponde solo una acción. Por ejemplo, mover la cinta a la derecha, leer un símbolo o escribirlo en la cinta.
- ▶ **MT No determinista:** Se denomina MT no determinista a aquella a la que al par (estado, símbolo) le corresponden dos o más acciones.

Mientras que una máquina determinista sigue un único "camino computacional", una máquina no determinista tiene un "árbol computacional". Si cualquiera de las ramas del árbol finaliza en un estado de aceptación, se dice que la máquina acepta la entrada.

Ahora vemos los resultados esenciales y que son nuestro interés en lo que respecta a la complejidad computacional.


Esta teoría agrupa los problemas computacionales de algunas maneras y según algunos criterios, la primera clasificación es:

- ▶ Problemas indecidibles: Aquellos que no se pueden resolver por medio de un algoritmo.
- ▶ Problemas decidibles: Aquellos que cuentan al menos con un algoritmo para resolverlo.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Que un problema sea decidable no implica de forma directa que su solución se pueda encontrar y entonces estos se dividen en:

- ▶ Tratables: Aquellos para los que existe al menos un algoritmo para su solución y que es capaz de resolverlo en un tiempo razonable.
- ▶ Intratables: Aquellos para los que no es factible encontrar una solución.



Clases de complejidad (P y NP)

Aunque la teoría de la complejidad computacional incluye varias clases de complejidad, a lo que nosotros respecta en esta lección nos interesan las clases P y NP.




Figura 9. Clase de Complejidad NP.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Dentro de la clase de complejidad llamada P se agrupan aquellos problemas que al menos tienen un algoritmo que lo soluciona sobre una MT determinista y lo hace en tiempo polinomial.

Mientras que en la clase de complejidad NP se agrupan aquellos cuya solución se obtiene en tiempo polinomial pero sobre una máquina de Turing no determinista.

Los problemas NP-completos pueden ser descritos como los problemas en NP que tienen menos posibilidades de estar en P. Actualmente los investigadores piensan que las clases cumplen con el diagrama mostrado por lo que P y NP-completo tendrían intersección vacía.

¿Qué se considera como tiempo polinomial? Bueno, es un algoritmo cuyo tiempo de ejecución para n elementos de entrada, puede calcularse por medio de formas polinomiales tales como:

- ▶ $2n^2 + 4n$

- ▶ $5n^2 + 3n + 2$

Sin embargo $2n$ no se considera polinómico.

Explicaremos con algún ejemplo el tema de complejidad temporal de los algoritmos. Con el fin de que se entendiera esta parte se introdujeron al principio las funciones exponenciales y logarítmicas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Veamos cómo crece el tiempo necesitado por un algoritmo cuando su complejidad es exponencial, por ejemplo:




Figura 10. Complejidad temporal exponencial.

Miremos la gráfica de la Figura 10 y tomamos como tamaño de la entrada al algoritmo los valores del eje de las x y como el tiempo necesitado para procesarlas en el eje y. Está claro en la gráfica que a medida que crece el valor n el tiempo necesitado se hace demasiado grande, hasta el punto de que se hace imposible usarlo para un tamaño de la entrada mayor que 3, por ejemplo en esta gráfica. Por eso es preferible algoritmos que tengan cuando mucho una complejidad de la forma de la gráfica 10. Analicemos esta gráfica.

Lo que se necesita es un algoritmo que siga un comportamiento cercano a la gráfica de la Figura 11, es decir, que siga una función de complejidad logarítmica.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 11. Complejidad temporal logarítmica.

Este es un tipo de comportamiento de la complejidad temporal de un algoritmo que es polinómica. En la gráfica es sencillo notar que en la medida que el tamaño de la entrada aumenta el tiempo necesitado por el algoritmo se va estabilizando, hasta el punto en que un aumento considerable en el tamaño de la entrada apenas repercute en el tiempo de procesamiento.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 12. Algunas gráficas de complejidades.

Si revisamos la gráfica de la Figura 12, podremos ver y comparar como crecen algunas de las funciones de complejidad. De todas las que representamos en ella la peor, es decir la que crece más rápidamente es la factorial $n!$ y cuando tratamos de construir soluciones y algoritmos debemos, al menos, tratar de que no sean peores $n \log_2 n$.

Por tanto, de los ejemplos que pusimos al principio, el primero pertenece a los problemas que tienen solución polinomial y pertenece a la clase de complejidad P, mientras que el segundo tiene una complejidad factorial y por tanto pertenece a la clase de complejidad NP.

Con estos elementos a mano, debe ser más sencillo que se entienda el tema del análisis de algoritmos. Aunque como la complejidad computacional y el resto de las ramas conexas, el análisis de algoritmos es un tema basto y complejo que en una lección como esta es imposible presentar, ni siquiera en un tercio de su profundidad, sin embargo pensamos que podemos hacer una introducción al tema, mostrando los elementos esenciales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Análisis de Algoritmos

La esencia para análisis de algoritmos es entender que lo importante es la cantidad de pasos u operaciones elementales que se necesitan para una solución y no el tiempo que tarda en ejecutarse el algoritmo en un ordenador particular.

Explicemos estos conceptos. Y el más importante es el de “operaciones elementales”. ¿Qué es una operación elemental? Cuando escribimos algoritmos aunque sea en pseudocódigo, usamos operaciones como suma, multiplicación, división, en fin las operaciones lógicas y matemáticas a las que estamos acostumbrado más operaciones como las de asignación o incremento. Son estas a las que se denominan operaciones elementales. Veamos un ejemplo:

Supongamos que deseamos desarrollar un algoritmo que sume una cantidad de números que se le pasa como argumento:

- ▶ Suma: ($A = \{1, 3, 5, 6, 8, 3, \dots, n\}$)
- ▶ $S = 0$
- ▶ Para cada x en A
- ▶ $S = S + x$
- ▶ Terminar
- ▶ Retornar S

Veamos cómo se encuentra la cantidad de operaciones elementales. Iniciamos en la línea 2, en esta solo se hace una operación, la de asignar 0 a la variable S . esta se realiza una sola vez. En la línea 3 se asigna el valor tomado de A a la variable x , esta operación se ejecutará n veces. En la línea 4, se ejecutan dos operaciones, una de suma y la otra de asignación que también se ejecutan n veces y en la línea 6 se retorna el resultado y se ejecuta una vez.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Por tanto nuestro algoritmo se ejecutará en la siguiente cantidad de pasos:

$$1 + (1 * n) + (2 * n) + 1 = 2n + n + 2 = 3n + 2$$

Por tanto nuestro algoritmo tiene complejidad $3n + 2$. Esto dice que nuestro algoritmo de suma tiene complejidad temporal lineal. Esto significa que el tiempo necesitado por nuestro algoritmo crece en la medida que crece el tamaño de la entrada n . Si nos fijamos en la gráfica de la figura 11, esta complejidad sería cercana a la línea verde. Este problema por tanto cae dentro de la clase de complejidad P.

Ahora bien, en análisis de algoritmos es usual hacer explorar la complejidad en tres escenarios distintos: Análisis del peor de los casos, el caso medio y el mejor de casos. El análisis del peor de los casos es el cual el tamaño de la entrada es la más grande posible.

- ▶ **Mejor caso:** es la función definida por el número mínimo de pasos dados en cualquier instancia de tamaño n . Representa la curva más baja en el gráfico (verde) y se denomina cota inferior.
- ▶ **Caso promedio:** es la función definida por el número promedio de pasos dados en cualquier instancia de tamaño n .
- ▶ **Peor caso:** es la función definida por el número máximo de pasos dados en cualquier instancia de tamaño n . Esto representa la curva que pasa por el punto más alto en el gráfico (rojo) y se denomina cota superior.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 13. Casos de análisis en un algoritmo.

Notación asintótica

En análisis de algoritmos rara vez tengamos que tener una la caracterización exacta de la complejidad computacional de un algoritmo. En la mayoría de las ocasiones necesitamos saber los límites de ella. Eso nos lo permite la llamada notación asintótica.

En matemática una asíntota, es una línea que se aproxima infinitamente a una curva sin tocarla y en lo que se refiere al análisis de algoritmo por medio de esta notación podemos expresar los límites teóricos dentro de los que se mueve la complejidad de un algoritmo.

De esta forma, dentro de esta notación se encuentran tres funciones, llamadas Big O, omega y Theta, que representan el límite superior que podría alcanzar la complejidad de mi algoritmo, el límite inferior de dicha complejidad y el caso medio, respectivamente.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Por tanto, cuando se dice que el algoritmo x que resuelve tal problema tiene una complejidad de $O(n \log n)$ lo que se está indicando es que el tiempo que consume el algoritmo para procesar n entrada estará limitado por encima por una función del tipo $n \log n$. Es decir, nunca llegará a ser peor que eso o al menos estará en ese orden.

Con el paso del tiempo y la experiencia acumulada se han ido concretando órdenes de complejidad que acotan por encima a muchos algoritmos:

Por ejemplo:

ITEM	DETALLES
$O(1)$	Constante
$O(n)$	Lineal
$O(n^2)$	Cuadrática
$O(n^3)$	Cúbico
$O(nm)$	Polinomio
$O(\log(n))$	Logarítmico
$O(n \log(n))$	$n \log(n)$
$O(mn)$	Exponencial
$O(n!)$	Factorial

Para entender esto, usemos el ejemplo que hicimos anteriormente, si ya sabemos que nuestro algoritmo tiene una complejidad $3n + 2$, significa que este tiene una cota superior $O(n)$, pues en el 3 multiplicando a n no cambia la linealidad de la función. Esta notación informa que nuestro algoritmo tiene complejidad lineal.

Algoritmia, nociones básicas

Luego de estudiar las nociones básicas de los algoritmos, la complejidad de los problemas a los que da solución y su clasificación, así como la manera que se evalúa la complejidad del propio algoritmo, estamos en condiciones de revisar las nociones básicas de cómo se desarrollan.

Hemos visto ya la definición de algoritmo y quedamos que le llamábamos Algoritmo, a un conjunto de pasos, ordenados y finitos con el fin de solucionar algún problema. Las principales características que nos interesan de ellos son: Que sea correcto y que sea eficiente.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Para expresar la lógica detrás de un algoritmo es necesario un lenguaje que lo permita, por eso podemos definir esto para ir concretando conceptos y entonces:

Un **lenguaje algorítmico** es un conjunto de reglas y símbolos que se utilizan para describir de manera explícita un proceso.

Ejemplo de estos lenguajes están, por ejemplo, los diagramas de flujo, el pseudocódigo o los lenguajes de programación de ordenadores.

De forma más general se pueden dividir en dos grandes grupos:

- ▶ Gráficos.
- ▶ No Gráficos.

Dentro de los gráficos se encuentran los diagramas de flujo, el cual mostramos en la siguiente imagen.




Figura 14. Ejemplo de Diagrama de Flujo.

Por otro lado están los pseudocódigos, que también mostramos en la siguiente imagen.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

```
Procedimiento Ordenar ( L )
//Comentario : L = (L1, L2, ..., Ln) es una lista con n elementos//
k ← 0;
Repetir
    intercambio ← Falso;
    k ← k + 1;
    Para i ← 1 Hasta n - k Con Paso 1 Hacer
        Si Li > Li+1 Entonces
            intercambiar ( Li, Li+1 )
            intercambio ← Verdadero;
        Fin Si
    Fin Para
Hasta Que intercambio = Falso;
Fin Procedimiento
```

Figura 15. Ejemplo de pseudocódigo.

Como es lógico pensar el desarrollo de soluciones por medio de ordenadores tiene una metodología que es preciso seguir. Básicamente, esta consiste en los siguientes pasos:

- ▶ Definición del problema que se pretende resolver.
- ▶ Análisis del problema.
- ▶ Diseño del algoritmo y evaluación.
- ▶ Implementación del algoritmo.

Definición del problema: Se dice que un problema bien definido constituye la mitad de la solución. Por eso es preciso que se plantee de la forma correcta y con todos los elementos.

Análisis del problema: El análisis es una parte esencial, pues se separa el problema en sus componentes y las relaciones entre ellas y se hace coincidir con los requisitos para la solución. De este análisis parten las primeras ideas de solución. En esta

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

etapa se definen los datos sobre los que operamos, los métodos que usaremos y la información que debemos retornar, si es necesario.

Diseño del Algoritmo y evaluación: En esta etapa tendremos en cuenta la complejidad computacional de la solución si es que existe para el problema que tratamos de resolver y si no existe alguna se inicia su construcción.

Es importante recordar que un algoritmo debe tener algunas características que definen su calidad sin entrar a considerar su complejidad.

- ▶ Debe tener un punto particular de inicio.
- ▶ Debe ser definido, no debe permitir dobles interpretaciones.
- ▶ Debe ser general, es decir, soportar la mayoría de las variantes que se puedan presentar en la definición del problema.
- ▶ Debe ser finito en tamaño y tiempo de ejecución.

Implementación del algoritmo: En esta etapa evaluamos el algoritmo y hasta hacemos pruebas de escritorio que permitan revisar su comportamiento.

Estructuras básicas para la construcción de algoritmos

Los algoritmos, al igual que la más fina pieza de ingeniería necesitan determinados componentes para poder construirse, la materia prima. Estas componentes son las instrucciones, las estructuras de datos y los datos simples.

Todos los datos tienen un tipo asociado con ellos. Un dato puede ser un simple carácter, tal como 'b', un valor entero tal como 35. El tipo de dato determina la naturaleza del conjunto de valores que puede tomar una variable.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Tipos de datos:



► Tipos de datos simples:

- Datos numéricos: Permiten representar valores escalares de forma numérica, esto incluye a los números enteros y los reales. Este tipo de datos permiten realizar operaciones aritméticas comunes.
 - Datos lógicos: Son aquellos que solo pueden tener dos valores (cierto o falso) ya que representan el resultado de una comparación entre otros datos (numéricos o alfanuméricos).
 - Datos alfanuméricos (Cadenas): Es una secuencia de caracteres alfanuméricos que permiten representar valores identificables de forma descriptiva, esto incluye nombres de personas, direcciones, etc. Es posible representar números como alfanuméricos, pero estos pierden su propiedad matemática, es decir no es posible hacer operaciones con ellos. Este tipo de datos se representan encerrados entre comillas.
- Operadores y operandos: los operadores son elementos que relacionan de forma diferente, los valores de una o más variables y/o constantes. Es decir, los operadores nos permiten manipular valores.
- ARITMÉTICOS: $a + b$
 - RELACIONALES: $a > b$
 - LÓGICOS: $a \text{ OR } b$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- **Operadores aritméticos:** Los operadores aritméticos permiten la realización de operaciones matemáticas con los valores (variables y constantes). Los operadores aritméticos pueden ser utilizados con tipos de datos enteros o reales. Si ambos son enteros, el resultado es entero; si alguno de ellos es real, el resultado es real.

+	Suma
-	Resta
*	Multiplicación
/	División
mod	Módulo (resto de la división entera)

- **Precedencia de los operadores Aritméticos:** Todas las expresiones entre paréntesis se evalúan primero. Las expresiones con paréntesis anidados se evalúan de dentro a fuera, el paréntesis más interno se evalúa primero. Dentro de una misma expresión los operadores se evalúan en el siguiente orden:
 - Exponenciación: ^
 - Multiplicación, división y módulo: *, /, mod
 - Suma y resta: +, -
- **Operadores relacionales:** se utilizan para establecer una relación entre dos valores. Luego compara estos valores entre si y esta comparación produce un resultado de certeza o falsedad (verdadero o falso). Los operadores relacionales comparan valores del mismo tipo (numéricos o cadenas). Estos tienen el mismo nivel de prioridad en su evaluación. Los operadores relacionales tienen menor prioridad que los aritméticos.
 - Mayor que: >

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- Menor que: <
- Mayor o igual: >=
- Menor o igual: <=
- Diferente: <>
- Igual: =
- ▶ **Operadores lógicos.** Estos operadores se utilizan para establecer relaciones entre valores lógicos. Estos valores pueden ser resultado de una expresión relacional.
- AND: Y
- OR: O
- NOT: Negación.

Dentro de las estructuras básicas que permiten construir algoritmos, también se encuentran las llamadas estructuras de control. Estas estructuras de control permiten, a partir del uso de operadores, controlar el flujo de ejecución del algoritmo.

Aunque existen otras, la más común es la conocida como: Si-Entonces.

Este tipo de estructura funcione a partir de una pregunta y si es verdadera ejecuta una acción o continua el flujo por una parte y si es false ejecuta otra parte.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Veamos un ejemplo

Si $a > 0$ entonces $x = 21$

Otra de las estructuras básicas en la construcción de algoritmos son las llamadas estructuras repetitivas. En este caso hay dos variantes claras que explicaremos.

La primera es la del tipo, Hacer-desde-hasta mientras que la segundo es Hacer-mientras-condición verdadera.

La diferencia entre una y la otra es que en la primera se conoce de antemano la cantidad de repeticiones que necesitamos realizar, por ejemplo:

Hacer desde 1 hasta 100

Suma = Suma+1

Terminar

Esta estructura repite 100 veces a instrucción de asignación presente en el cuerpo de la estructura.

El otro tipo, en cambio el control de la repetición lo hace por medio de una condición, veamos:

Mientras Suma<100

Suma=Suma+1

Terminar

En cada iteración se evalúa la condición y mientras sea verdadera se continúa con la próxima.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Conclusiones

Hasta este punto hemos hecho un recorrido por los elementos que creemos son básicos para comprender la complejidad algorítmica y computacional, así como los algoritmos. Estos campos son bastos y complejos y podrían, fácilmente tomar cientos de páginas hacer una introducción decente a los temas tratados, sin embargo, para una lección de introducción hemos intentado abarcar lo que creemos que es esencial para desarrollar la intuición y que se comience el largo viaje de dominar estas materias.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

1.2. Técnicas y procesos de extracción de la información de los datos. Sistemas de Big Data

Introducción

Estamos viviendo en la era del Big Data o de grandes volúmenes de datos. La humanidad ha generado más datos en solo unos años que todos los que se han generado en toda la historia.

Datos, Información y Conocimiento

Antes que comencemos cualquier discusión acerca del tema que nos ocupa en esta lección, es sumamente importante que aclaremos la diferencia entre Datos, Información y Conocimiento. Es usual confundir dichos conceptos en las conversaciones informales y por eso es preciso que lo hagamos antes de iniciar el camino que nos llevará hasta las técnicas y procesos de extracción de información.

Una primera aproximación en la explicación de estos conceptos, sería pensar en que los datos son mediciones o hechos ubicados en el mundo real, el conocimiento se encuentra en la “mente” de un agente o individuo, mientras que la información sirve de mediadora entre ambos. Sin embargo, existe una conexión directa entre ellos, pues la información se basa en los datos, mientras que el conocimiento se basa en la información.

Esto nos lleva directamente a lo que se conoce como jerarquía del conocimiento y ha sido presentada en forma de pirámide, donde los datos forman la base y el conocimiento y la sabiduría en la punta.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información



Figura 16. Jerarquía del Conocimiento. (Tomada de <https://thevalley.es/blog/cuantos-mas-datos-mas-conocimiento-no/>)



Figura 17. Cómo se integran los datos y la información. Fuente: Weller, K. (2010).

Para comprender mejor estos conceptos, pongamos como ejemplo lo siguiente, se nos dan los siguientes valores: 2.6, 3.7, 4.2. Estos números son datos. Y si se nos dan de esta forma, no aportan nada, no nos dicen nada. Sin embargo, cuando se les pone en contexto, comienzan a aportarnos información, por tanto, si decimos que estos números representan las ventas de la empresa X en millones de euros en los años 2013, 2014 y 2015 vemos que nos aporta alguna información. Esto indica que los datos por si solos no tienen significado alguno.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En la Wikipedia se nota:

“Un dato es una representación simbólica (numérica, alfabética, algorítmica, espacial, etc.) de un atributo o variable cuantitativa o cualitativa. Los datos describen hechos empíricos, sucesos y entidades”

En <https://www.emagister.com/blog/datos-informacion-conocimiento/>:

«Los datos son la mínima unidad semántica. Se pueden ver como un conjunto discreto de valores, que no dicen nada sobre el porqué de las cosas y no son orientativos para la acción. Los datos se corresponden con elementos primarios de información que por sí solos son irrelevantes como apoyo a la toma de decisiones».

Generalmente los datos representan una codificación estructurada de entidades primarias simples, así como transacciones que envuelven a dos o más de estas entidades primarias.

Estas entidades primarias hacen referencia, por ejemplo, a consumidores, puntos de ventas, artículos o a mediciones de alguna variable o propiedad de un objeto o cosa y a hechos de la vida real.

Nosotros asumiremos que los datos son la materia prima que usamos para obtener información y por tanto es susceptible de ser, como cualquier otra materia prima, preparada y procesada.

Por otro lado, la Información, es el resultado que se obtiene de la preparación y el procesamiento de los datos al ponerlos en contexto o relacionarlos con otros. Esta información es relevante en un contexto dado.

En <https://www.emagister.com/blog/datos-informacion-conocimiento/>: «la información es el conjunto de datos procesados, que tienen un significado (relevancia, propósito y contexto), y que por lo tanto son de utilidad para quién debe tomar decisiones, al disminuir su incertidumbre».

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Mientras en Wikipedia se define como: «información es el nombre por el que se conoce un conjunto organizado de datos procesados que constituyen un mensaje que cambia el estado de conocimiento del sujeto o sistema que lo recibe».

La información tiene las siguientes propiedades:

- ▶ **Significación semántica:** Del significado extraído de ella puede depender la conducta posterior de un agente o individuo.
- ▶ **Importancia:** Esta se refiere al grado en que esta es capaz de cambiar el estado cognitivo de un individuo, modificando su conducta. Si reduce el nivel de incertidumbre. Esta importancia es relativa al individuo.
- ▶ **Vigencia:** Se refiere a si está actualizada o desfazada en una escala temporal.
- ▶ **Validez:** Se refiere a si el que emite la información es una fuente fiable o no o si es obtenida por medios o procedimientos válidos.
- ▶ **Valor:** Se refiere al valor que tiene para el individuo u organización que la consume.

El conocimiento, se forma, a partir de la información cuando esta es asentada en nuestro sistema de conocimientos por medio de la acción de las funciones básicas del pensamiento: el análisis, la síntesis, la generalización y la abstracción.

Una vez que esta se convierte en conocimiento, nos permite actuar y tomar decisiones. En la Figura 2 mostramos que el resultado del conocimiento es la integración entre los datos y la información.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Clasificación de los datos

Los datos pueden clasificarse de muchas maneras, sin embargo, nos referiremos a una de ellas en específico por el impacto directo en las técnicas que se usan para procesarlos y porque agrega una nueva dimensión en la complejidad de la gestión de estos. Nos referimos a la clasificación según su estructura.



Figura 18. Clasificación de los datos según su estructura.

Según esta clasificación, los datos pueden ser: Estructurados o No estructurados.




Figura 19. Modelo de Datos Relacional

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

El tipo de datos Estructurado es muy común en los sistemas de gestión transaccionales tradicionales y su característica principal es que se representa por medio de n-tuplas. Esto significa aproximadamente, que toman la forma de tablas, constituidas por filas y columnas. Básicamente, esta estructura es impuesta por el llamado modelo entidad-relación. Los sistemas que implementan este tipo de modelo se les llama Sistemas de Gestión de Bases de Datos Relacionales. En la Figura 19. Se muestra un modelo entidad relación.

En este modelo cada una de las entidades está contenida en una tabla que se relaciona con las otras por medio de llaves. Tanto a las tablas como las relaciones entre ellas es lo que recibe el nombre de “estructura de la base de datos” y de ahí el nombre de datos estructurados. A cada una de las filas en una tabla se le llama record y a las llaves que las unen se les llaman relaciones.

Por otro lado, los datos no estructurados toman su nombre del simple hecho de carecer de una estructura como la que caracteriza a los anteriores. Básicamente, este tipo de datos está compuesto por textos, cuyo contenido es imposible de estructurar, videos, audio y otros tipos que suman una gran cantidad en las organizaciones modernas. En los datos estructurados cada record tienen que tener la misma estructura, debe estar compuesto por las mismas columnas, en los datos no estructurados esto no es un requerimiento. Por otro lado, las tablas no tienen que estar relacionadas con otras.

Es sabido, que en la mayoría de organizaciones, se generan diariamente cientos de documentos y que los correos electrónicos y los videos se producen a gran velocidad. Las redes sociales son una fuente común de datos que aporta información sobre los clientes y no pueden ser estructurados de la misma manera que se hacía con los datos tradicionales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Por tanto, asumiremos que los datos estructurados son aquellos que se almacenan en Sistemas de Gestión de Bases de Datos Relacionales y los Almacenes de Datos de las organizaciones y como datos no estructurados a los textos, videos, audios que son necesario manejar en la organización.

Los datos no estructurados necesitan herramientas diferentes para su almacenamiento y gestión. Esto es importante que se tenga en cuenta, pues existen Sistemas de Gestión de Bases de Datos NoSQL que estaremos viendo constantemente. El movimiento NoSQL está directamente asociado a la gestión de datos no estructurados y significa "No solo SQL". Esto hace que en una organización aparezcan ahora un nuevo sistema de gestión además de los relacionales, los no relacionales.

```
{
  hey: "guy",
  anumber: 243,
  - anobject: {
    whoa: "nuts",
    - anarray: [
      1,
      2,
      "thr<h1>ee"
    ],
    more: "stuff"
  },
  awesome: true,
  bogus: false,
  meaning: null,
  japanese: "明日がある。",
  link: http://jsonview.com,
  notLink: "http://jsonview.com is great"
}
```

Figura 20. Json. Formato de archivo y modelo de datos no estructurado.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 21. Gestión de Datos Estructurados y No Estructurados en una Organización.

Small Data, Big Data, Too big or Not too big

Vivimos en un mundo en el cual la información se genera a tal velocidad y en tal volumen que nos es imposible mantenernos al tanto de cualquier tópico de interés.

En uno de sus artículos Gabriel Zaid ha escrito:

«Los libros se publican a un ritmo tan rápido que nos hacen exponencialmente más ignorantes. Si una persona leyera un libro al día, estaría descuidando otros cuatro mil, publicados el mismo día. En otras palabras, los libros que no leyó se acumularían cuatro mil veces más rápido que los libros que leyó, y su ignorancia crecería cuatro mil veces más rápido que su conocimiento»

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 22. Proyección de cantidad de datos creados, capturados, copiados y consumidos hasta el 2025.

(Publicado por Statista Research Department, Mar 18, 2022).

De igual manera la cantidad de datos creados, capturados y consumidos por la humanidad ha tenido un comportamiento exponencial, proyectándose que para el 2025 alcanzaremos la cifra de 181 Zetabytes (Ver Fig. 22).

En la tabla que corresponde con la Figura 23, mostramos las unidades de medida de la información.

Sin embargo, la información que hemos consumido, no ha crecido de igual manera cuando distinguimos entre estructurada y no estructurada. En el 2020 cerca del 80 % de la información que se produjo y se consumió fue de naturaleza no estructurada y solo el 20 de información estructurada (ver gráfica de la Figura 24).

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Medida	Simbología	Equivalencia
byte	b	8 bits
kilobyte	Kb	1024 bytes
megabyte	MB	1024 KB
gigabyte	GB	1024 MB
terabyte	TB	1024 GB
Petabyte	PB	1024 TB
Exabyte	EB	1024 PB
Zetabyte	ZB	1024 EB
Yottabyte	YB	1024 ZB
Brontobyte	BB	1024 YB
Geopbyte	GB	1024 BB

Figura 23. Unidades de Medida de Información.

Entre los factores que ha disparado la producción y consumo de datos, ha sido internet y sus servicios, así como el abaratamiento de los recursos computacionales y la aparición de técnicas y tecnologías para su gestión. Y se le suma el advenimiento de las tecnologías móviles e Internet de las Cosas. (IoT)

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 24. Información producida hasta el 2020 por estructura.

Dentro de los servicios que aportan cantidades ingentes de datos en formato no estructurado están las redes sociales. Para que se tenga una idea, Twitter, mantiene 1300 millones de cuentas, 211 millones de usuarios activos monetizables diarios y se producen cerca de 500 millones de tweets diarios.

Por otra parte, YouTube, la principal plataforma para compartir videos, reporta unos 2000 millones de usuarios activos al mes que consumen unas, 2000 millones de horas de video y se suben más de 300 horas de video por minuto. Más de la mitad de estas horas se consumen desde dispositivos móviles. Facebook, por su parte, la más usada de las redes sociales mantiene 1900 millones de usuarios activos diariamente y almacena, en sus servidores, unos 300 petabytes que aumentan en unos 600 terabytes diariamente. Utiliza Hive, como Almacén de Datos. Netflix, uno de los servicios de streaming más famosos, por otra parte, mantiene 209 millones de usuarios con presencia en 190 países y su contenido representa el 8% del consumo mundial de video.

Ahora bien, preguntas tales como ¿Todas las empresas necesitan manejar estas ingentes cantidades de datos? ¿Cuáles son los límites que debemos considerar small data o big data? ¿Qué tecnologías usamos para manejar estos, increíbles, volúmenes de datos? Son todas preguntas válidas que responderemos a continuación.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La respuesta a la primera pregunta es no, no necesariamente todas las empresas tienen que enfrentarse al problema de manejar volúmenes de datos que pueden considerarse grandes. Para la segunda pregunta habría que definir que consideramos por un conjunto de datos grande, si o Big Data. Hay una definición bastante trivial que permite al menos esbozar una primera separación entre lo que se conoce como Big y Small Data, pues es un término muy relativo.

Se dice que usamos Big Data cuando la cantidad de datos que necesitamos procesar es tal que es imposible hacerlo por medio de las tecnologías tradicionales. El límite más o menos manejado por los sistemas tradicionales no supera los cientos de Terabytes y a lo sumo unos pocos Petabytes.

La solución que han encontrado las empresas y los investigadores para lidiar con los requerimientos que impone el manejo de estos grandes datos ha sido el procesamiento masivamente paralelo y la plataforma de software que los soporta. Apache Hadoop y Spark son las principales plataformas de software específicamente desarrolladas para manejar los requerimientos de Big Data.

¿Cuáles son entonces, las propiedades de este tipo de datos que fue necesario desarrollar tecnología adicional para manejarlos? Básicamente, resulta que este tipo de datos se genera a tal velocidad que es prácticamente imposible lidiar con ellos con las tecnologías tradicionales. Por otro lado, son datos que pueden ser de distintos formatos y proceder de fuentes diferentes, por lo que es importante tener las tecnologías correctas para hacerlo y se generan en un volumen nunca antes visto. Estas propiedades son a las que se les denominan las V del Big Data.

Las 5 V del Big Data:

- ▶ Volumen.
- ▶ Velocidad.
- ▶ Variedad.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ Valor
- ▶ Veracidad.



Figura 25. Las 5 V del Big Data.

Volumen

Las organizaciones tienen que lidiar con miles de Megabytes y Terabytes. Estamos en la era de los Exa y los Zetabytes. Las recomendaciones en tiempo real de productos en las tiendas de internet. La gestión de los Logs de acceso a los Servidores y los streams de clics para seguimiento de la conducta de los Visitantes. Las mediciones de los sensores y dispositivos IoT, los datos recopilados por los centros de meteorología para la predicción de las variables climáticas.

Imagina, 500 millones de tweets al día, 211 millones de usuarios que consumen 2000 millones de videos diariamente. Hoy en día, hay aproximadamente 2.53 mil millones de teléfonos inteligentes en uso en el mundo. Asombroso, 85% de los propietarios de teléfonos inteligentes utilizan la aplicación de Facebook. En el 2015 WalMart anunciaba que necesitaba manejar 2.5 Petabytes por hora, mientras las ventas de la semana anterior se almacenaban en una Base de Datos de 40 Petabytes.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Velocidad

La velocidad a la que se actualizan nuestros datos provoca que, si no lo manejamos adecuadamente, cuando generemos algún conocimiento, será erróneo, pues los datos de origen ya cambiaron. Desde la perspectiva de la organización, la velocidad se refiere al tiempo que demora en procesarse una vez que está dentro del perímetro. Solo imagine que se producen unos 20 millones de tweets cada una hora.

Variedad

Esta cualidad se refiere a la cantidad de formatos y tipos de datos que las organizaciones ahora tienen que manejar. Lo que hace que estas se enfrenten a grandes retos a la hora de integrar, transformar, procesar, almacenarlos y analizarlos.



Veracidad

Este tipo de cualidad se refiere a que los datos que se procesen con estas tecnologías tienen que ser de calidad. Y esto, por ejemplo, en caso que las señales provengan de Sensores, pues será más verás en cuanto esté más limpia, con menos ruido. La relación Señal a ruido es más alta. La Norma ISO-8000 establece las normas de calidad de datos.

Valor

El valor puede definirse como la utilidad de los datos para la empresa. Esto quiere decir que podemos procesar los datos en volúmenes increíbles y además lo hacemos a altas velocidades, pero de nada vale si no es de valor para la empresa. Para mí este es un elemento vital. Necesitamos muchos datos, pero, sobre todo los datos correctos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Todo esto hace que muchas organizaciones se enfrenten al dilema Big Data/Small Data.



Figura 26. Clúster de Meta.

Hasta aquí hemos visto que las empresas han tenido que enfrentarse a una primera dicotomía, la del tipo de datos a manejar: estructurados/no estructurados y ahora a una segunda: Small Data/Big Data. Y estas no son las dos únicas, las empresas se tienen que enfrentar a una tercera dicotomía: On Premise/On Cloud, que tocaremos en la próxima sección y que tiene que ver en donde radicarán los datos de la empresa.

¿Datos Locales o Datos en la Nube? (On Premise/On Cloud)

Con el desarrollo de la Internet se han hecho posibles servicios como IaaS (Infraestructura como un servicio), SaaS (Software como un servicio) y otros más conocidos como “Nube” que permiten disminuir o eliminar por completo los Datacenter que antes eran mantenidos por las empresas, eliminando los costes de mantenimiento y explotación. Esta ha provocado que muchas empresas migren sus plataformas de datos a la Nube o desarrollen infraestructuras híbridas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Esta es otra de las dicotomías a la que tiene que enfrentarse las organizaciones modernas y deben decidir cuándo mover o implementar toda su plataforma de datos en la nube o sobre servidores locales o incluso construir una plataforma híbrida que contemple servidores locales y espacio en la nube.

Aunque hay varios proveedores de servicio en la nube, los tres principales contendientes son Amazon, con su plataforma AWS, Microsoft con su plataforma Azure y Google con Google Cloud.

Cuando hablamos de On Premise, hablamos de que la organización mantiene ya sea ella misma o por medio de terceros todo el datacenter, lo que implica el costo de la electricidad consumida, el costo de salarios de personal y todo lo que conlleva. Por el contrario, cuando hablamos de Cloud o Nube, hablamos que un proveedor pone a nuestra disposición toda la capacidad de almacenamiento y cómputo necesario para desarrollar nuestra plataforma de datos a un precio que puede ser, por medio de una tarifa plana o basada en el consumo de recursos; pero que es él, el que corre con los gastos correspondientes al mantenimiento y operación del datacenter.




Figura 27. Distinción entre On- Premise, Cloud público y Cloud privado. (Imagen tomada de <https://www.ebcgroup.co.uk/news-insights/on-premises-vs-cloud>)

Entonces, básicamente la distinción entre On-Premise y On-Cloud radica en donde residen su Hardware, el Software y sus Datos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Plataformas de Datos tradicionales vs Plataformas Big Data

Antes de intentar entender las técnicas y el proceso de extracción de la información es sumamente importante que entendamos las plataformas donde tiene lugar dicho proceso.

Inicialmente explicaremos, de forma breve en que consistían estas plataformas y las tareas de sus componentes y para ello usaremos la imagen en la Figura 28.

Veamos algunas de las siglas que se usan en la figura, con el fin de aclarar su significado y que puedan entender.

- **OLTP.** Son las siglas en inglés de On Line Transaction Processing. Es decir, procesamiento de transacciones en línea. Este es el nombre que se les da a los sistemas que gestionan de manera automática transacciones de diferente naturaleza. Una transacción es un conjunto de operaciones sobre una base de datos que deben ejecutarse todas y si una falla se revierte todas. Por ejemplo, supongamos que ejecutamos una operación de compra en línea. Esta transacción debe comprender: Verificar que el que compra tiene el saldo suficiente, si tiene el saldo, debemos debitarlo de esa cuenta, luego acreditarlo a la cuenta del vendedor. Si una de estas operaciones falla, se revierte la transacción completa.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 28. Esquema de una plataforma de datos tradicional típica.

- ▶ **CRM:** Son las siglas de Customer Relationship Management: Administración de Relaciones con los Consumidores.
- ▶ **ERP:** En este caso son las siglas de Enterprise Resources Planning: Son los sistemas de gestión de las empresas que los usan.
- ▶ **SCM:** Supply Chain Management: Sistemas de gestión de la cadena de suministro.
- ▶ **ETL:** Este proceso se llama Extraction, Transform and Load: Este es el nombre del proceso de Extracción, transformación y carga de los datos de los sistemas OLTP al Datawarehouse. Más adelante veremos en más detalles en que consiste este proceso.
- ▶ **EDW:** Son las siglas de Enterprise Datawarehouse: Se traduce como Almacén de Datos Empresariales.
- ▶ **OLAP:** Son las siglas de Online Analytical Processing: Y su traducción es Procesamiento analítico en línea.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La idea, a grandes rasgos, de los sistemas tradicionales de gestión de datos, como el que se presenta en la imagen de la Figura 28, es que los sistemas de gestión tácticos-operativos, mostrados a la izquierda de la imagen, gestionan las operaciones de la organización de manera inmediata mientras que los sistemas de gestión estratégica, situados a la derecha, soportan a la dirección de la organización en la toma de decisiones.




Figura 29. Proceso de Extracción, Transformación y Carga. (ETL)

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En este tipo de sistema, los datos captados por los sistemas de gestión se extraen de las sus bases de datos, se limpian, se transforman y luego se cargan en las bases de datos multidimensionales de un Datawarehouse y los Data Mart departamentales desde donde se generan la mayoría de los reportes e informes o los cuadros de mandos para la ayuda a la toma de decisiones. El proceso de ETL, de forma muy general se muestra en la imagen de la Figura 29.

Sin embargo, aunque estos sistemas pueden manejar algún tipo de datos no estructurados, su capacidad para manejar ingentes cantidades de datos está limitada por su diseño interno y la infraestructura que los soporta y por tanto había que encontrar otras soluciones.




Figura 30. Aproximación a lo que es un Sistema de Gestión da datos modernos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La solución a la incapacidad de manejar grandes volúmenes de datos por parte de los sistemas tradicionales de gestión de datos fue Apache Hadoop. Ahora una misma plataforma puede manejar datos estructurados, semi estructurados y no estructurados y sin límite de volumen.

El corazón de esta nueva arquitectura es el HDFS o Hadoop File System, un sistema de ficheros distribuidos que corre sobre clústeres de ordenadores de bajo costo. Esto permite que, si nos quedamos cortos de capacidad de almacenamiento, con solo añadir más ordenadores al clúster resolvemos.




Figura 31. Arquitectura general de Apache Hadoop.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Una de las cosas interesantes de esta arquitectura es que añadir o eliminar nodos del clúster es transparente al usuario pues siempre el cliente se conecta con el Master node. En esta arquitectura, tanto el almacenamiento como el procesamiento tiene lugar en los nodos y por tanto de manera distribuida a través del clúster.

Sin embargo, Hadoop nació en un contexto diferente, este fue escrito por Doug Cutting y Mike Cafarella en el 2005 cuando trabajaban para Yahoo, con el fin de soportar el desarrollo del motor de búsqueda Nutch.

El núcleo de Hadoop está formado por el HDFS, YARN y MAPREDUCE. El primero es el sistema de Ficheros distribuido, Yarn es el administrador de recursos del Clúster y Mapreduce es un esquema de programación distribuido para el procesamiento de datos a gran escala.

Sin embargo, Hadoop está acompañado por un importante número de proyectos que de alguna manera lo complementan y suplen sus deficiencias iniciales. Por ejemplo, Spark. Hadoop, todo el procesamiento lo hace sobre ficheros almacenados en HDFS y por tanto limita su velocidad de procesamiento, pues aparece Apache Spark que todo el procesamiento lo hace en memoria, haciendo posible ahora el procesamiento a velocidades cercanas a tiempo real de datos a gran escala.

A todos estos proyectos que acompañan a Hadoop se les denomina Hadoop Ecosystem.

Hasta aquí, debemos tener claro que el procesamiento de los datos, se haría sobre dos tipos de plataformas distintas, o en una basada en Small data y otras veces en plataformas Big Data como Hadoop/Spark y por tanto tendríamos que adoptar algunas técnicas diferentes.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Descubrimiento de Conocimiento en Bases de Datos, Data Analytic, Data science y otros sabores

Está claro que el tema principal que trataremos en esta lección es el de las técnicas de extracción de información a partir de datos; sin embargo, vamos por la sección 7 y no comenzamos con el tema y es que este tema no se entendería completamente si no exponemos los elementos que le agregan comprensión o complejidad al tema.

A lo largo del tiempo y basado en el desarrollo de las técnicas y tecnologías de gestión de datos en las organizaciones que los consumen han aparecido términos y áreas de investigación que tratan de alguna manera de aglutinarlas o explicarlas; pero que agregan incertidumbre y complejidad a aquellos que tratan de iniciarse en el campo. Por eso esta sección tiene como objetivo definir algunos de estos y compararlos entre sí con el fin de que se entienda en que consiste y en el contexto que aparecieron o se usan.

Por ejemplo, términos como Data Mining, KDD, Data Analytic, Ciencia de los Datos, Extracción de información o Recuperación de Información, Inteligencia de Negocios o tienen diferencias sustanciales, sutiles o no tienen nada que ver unos con otros. Por eso es imprescindible que los analicemos uno a uno.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 32. Relación entre Data Mining y Ciencia de Datos.

Con el fin de poder comparar estos términos y lo que representan es necesario comenzar por definir cada una de ellas de la mejor manera posible, veamos.

KDD (Knowledge Discovery from Databases) o Descubrimiento de Conocimiento en Bases de Datos, es definido por algunos autores como el proceso de identificar patrones válidos, nuevos, útiles y comprensibles a partir de grandes volúmenes de datos.

«Proceso no trivial de identificar patrones válidos, novedosos, potencialmente útiles y en última instancia comprensibles a partir de los datos». Fayyad et al. 1996

El término KDD fue acuñado en 1989 por Gregory Piatetsky-Shapiro. Aquí es importante hacer notar en el contexto que **este proceso tiene lugar**, es decir en **Bases de Datos relacionales**.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Por otra parte, **Data Mining o Minería de Datos** es el proceso que permite descubrir patrones en grandes conjuntos de datos usando métodos tomados de la estadística, el aprendizaje automático y los sistemas de gestión de datos. Esta disciplina tiene un papel central en el proceso de Descubrimiento de Conocimiento en Bases de Datos. (KDD) El término Mining, es, por tanto, una alusión clara al objetivo de “extraer” conocimiento de los conjuntos de datos.




Figura 33. Proceso de KDD. (Descubrimiento de Conocimiento en Bases de Datos).

Sin embargo, cuando los datos de donde debemos extraer el conocimiento no son bases de datos relacionales, las técnicas clásicas de Minerías no nos son de utilidad y ese es el caso de cuando el conocimiento que necesitamos está contenido en documentos de texto escritos en lenguaje natural. Para tratar este tipo de situaciones aparece lo que se llama **Minería de Textos**.

Este tipo de Minería permite analizar grandes colecciones de datos textuales (datos no estructurados) con el objetivo de identificar y extraer la información relevante. Este tipo de Minería puede considerarse parte de la Minería de Datos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Sin embargo, esta área puede verse como contenida en una que tienen propósitos aún más amplios y que se denomina **Extracción de Información**.

A continuación, mostramos la definición dada por Marie-Francine Moens, en el libro *Information Extraction: Algorithms and Prospects in a Retrieval Context*.

«La extracción de información es la identificación, clasificación y estructuración consecuente o concurrente en clases semánticas, de información específica encontrada en fuentes de datos no estructurados tales como textos en lenguaje natural, haciendo dicha información más adecuada para las tareas de procesamiento de información».

En otro extremo se encuentra la **Recuperación de Información**, que permite recuperar documentos desde un cuerpo de documentos gigante o de la Web haciendo uso de solicitudes basadas en términos que consideramos identifican nuestras necesidades de información. Estas técnicas de recuperación de información construyen índices a partir de los documentos con el fin de acelerar las búsquedas. Quizás el producto más reconocido de esta área de investigación y disciplina es el motor de búsqueda de Google.

La extracción de información juega un papel central en la Recuperación de Información y por tanto es una de las áreas, al igual que el resto de las que hemos mencionado, que se benefician del uso de las técnicas de aprendizaje automático y la estadística.

Por otro hilo de la historia del desarrollo de los datos como materia prima del conocimiento y su procesamiento, en 1962, John Tukey, proponía un nuevo campo llamado “análisis de datos” y que ha sido, desde alguna perspectiva, el precursor directo de lo que se conoce hoy como **Ciencias de Datos**, pasando por intentos de renombrar la estadística como **ciencia de datos** en el 1997 por Jeff Wu, mientras que en 1998, Chikio Hayashi proponía a la ciencia de datos como un nuevo campo interdisciplinario, que cubría el diseño, la recopilación y el análisis de datos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En definitiva, algunos autores definen la Ciencia de Datos de la siguiente forma:

«La Ciencia de Datos es un campo interdisciplinario que usa el método científico, procesos, algoritmos y sistemas para extraer información y conocimiento a partir de datos estructurado y no estructurados. La Ciencia de Datos, está relacionada a la Minería de Datos, al Aprendizaje Profundo y al Big Data».

«La ciencia de datos es un campo interdisciplinario de la informática que utiliza una combinación de herramientas, algoritmos y principios de máquinas para extraer información útil de datos estructurados y no estructurados. Es un campo de estudio emergente que se enfoca en comprender el complejo mundo de los datos».

Todas estas áreas, Minería de Datos, de Textos, Extracción de Información, Inteligencia de Negocios entre otras que no hemos mencionado, tienen en común que usan las técnicas y los algoritmos desarrollados por la Estadística, el Análisis de Datos y el Aprendizaje Automático como núcleo para extraer información y conocimiento a partir de los datos. Por tanto, con el fin de estudiar y comprender estas técnicas, lo haremos usando el enfoque de la Ciencia de Datos y en el contexto de lo que entendemos como Big Data.

El área que se dedica al proceso de extracción de información y conocimiento dentro del contexto del Big Data se conoce como Big Data Analytic y tiene la característica que las técnicas y algoritmos para el procesamiento de los datos y la extracción de información son implementados en un entorno de computación paralelo.

El proceso y las técnicas de extracción de información en el contexto de Big Data

El proceso de extracción de información en el contexto de Big Data tiene lugar, como ya hemos explicado en la sección anterior, en un contexto de computación paralela que puede usar como plataformas Apache Hadoop o Apache Spark, que son las preferidas para el manejo de grandes volúmenes de datos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Con el fin de explicar las técnicas de extracción de información en este contexto usaremos Apache Spark y pyspark, que es la interfase Python para Spark.

Una introducción compacta a Spark y PySpark

Apache Spark inició como un proyecto de investigación en el laboratorio AMPLap de la Universidad de Berkeley en 2014. El objetivo de su desarrollo era mantener los beneficios del modelo de programación distribuido MapReduce, tolerancia a fallas y escalabilidad, mientras se hacía más eficiente y fácil de usar.

Spark es un motor de analítica rápido y eficiente para el procesamiento de datos a gran escala. Este tiene la ventaja de que corre sobre clúster Apache Hadoop, Apache Mesos, Kubernetes, de manera completamente independiente o sobre la nube. Spark ofrece operadores de alto nivel que hacen más fácil desarrollar aplicaciones paralelas. Estas aplicaciones pueden desarrollarse en Scala, Python, R o SQL.




Figura 34. Arquitectura de alto nivel de Apache Spark.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La columna vertebral de Spark es el llamado Spark Core, que es el núcleo sobre el cual corren las librerías para SQL, DataFrame, Machine Learning, GraphX y Streaming. Estas librerías se pueden usar sobre conjuntos de datos masivo y gigantes que pueden proceder de diversas fuentes, tales como, HDFS, Apache Cassandra, Apache Hbase o Apache Hive.

Las aplicaciones Spark corren dentro de procesos llamados Ejecutores desplegados en los nodos de un Clúster, cuya ejecución es coordinada por el objeto SparkSession en el Driver y el Cluster Manager. Este Cluster Manager puede ser Mesos, YARN, Kubernetes o el propio Cluster Manager de Spark.




Figura 35. Ejecución de una aplicación en Apache Spark.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Spark también puede correr en un modo llamado modo local, en el cual el Driver y las tareas corren en diferentes hilos dentro de la JVM. (Java Virtual Machine) Esto permite que las aplicaciones desarrolladas en este modo, puedan desplegarse a un Cluster sin, prácticamente, ninguna modificación.

Este modo local se establece a la hora de construir el objeto Spark Session de la siguiente manera:

```
spark_session=SparkSession.builder.master("local[4]").appName('data_processing').getOrCreate()
```

Con el método `.master("local")` se establecería que el programa Driver va a correr en modo local y hará uso de un solo hilo. En cambio, pasándole como argumento `"local[4]"` significa que correrá en modo local pero lo hará en 4 hilos, uno en cada core de nuestro procesador.

PySpark, por otro lado, es uno de los 4 lenguajes con los que podemos desarrollar aplicaciones en Spark, los otros son Scala, R y Java.

PySpark, está ahora disponible en Pypi y puede instalarse de la siguiente forma:

```
pip install pyspark
```

Esto nos permitiría correr PySpark en modo local y conectarse al clúster para desplegar aplicaciones. Es importante notar, como ya se explicó antes, que las aplicaciones desarrolladas en modo local pueden correr en el clúster, prácticamente, sin cambio alguno.

También es importante tener en cuenta que, aunque, pandas es la librería más usada en ciencia de datos, no está implementada para correr de manera paralela, por tanto, cuando usamos pyspark sería necesario usar la implementación de `pyspark.pandas`.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Spark, expone cuatro librerías básicas:

- ▶ **Pyspark.SQL:** Usado para manejar datos estructurados y leer desde cualquier fuente en formatos tales como csv, texto, json, parquet, etc.
- ▶ **Pyspark.MLlib:** Esta es la librería de Aprendizaje Automático de Spark. Aunque en realidad, la funcionalidad de Machine Learning está dividida en dos módulos `pyspark.MLlib` y `pyspark.ml`. El primer paquete contiene la API de programación con RDD. (Resilient Distributed Dataset) mientras que la segunda contiene la API que corresponde a `DataFrame`.
- ▶ **Pyspark.Streaming:** Provee la API necesaria para el manejo de Stream de datos procedentes de motores como Kafka u otras fuentes de Streaming.
- ▶ **Pyspark.GraphX:** Implementa la API de manejo de grafos en Spark. Por ejemplo, grafos de redes sociales o grafos de topología de redes, etc. Entre los algoritmos incluidos se encuentran PageRank, Componentes conectados y Conteo de Triángulos.

También se encuentran disponibles para `pyspark` librerías de terceros que implementan Deep Learning y una de las más usadas es `TensorFlowOnSpark`. Esta librería está disponible en `Pypi` y se puede instalar con `pip`.

Antes de concentrarnos en el proceso y las técnicas de extracción de información usando como soporte `pyspark`, sería de ayuda mostrar un primer programa que ayude a revisar la estructura general que se sigue en las aplicaciones de `PySpark`. Así que en la próxima imagen lo mostramos y luego iremos explicando cada una de las acciones que ejecutamos en él.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Para la demostración hemos usado un dataset, publicado en un portal Open Data, del gobierno de Nueva Zelanda, sobre el Índice de Precios al Consumidos en ese país comprendido entre 1914 y diciembre de 2021.

Una aplicación pyspark, se inicia como cualquier aplicación Python, incluyendo las librerías que necesitaremos en nuestra aplicación. En este caso, inicialmente importamos la librería pyspark.

Luego, importamos matplotlib para la visualización de los datos y siguiente importamos pandas, sin embargo, importamos la implementación de pandas de pyspark. Como ya explicamos, la versión original de pandas no está pensada para operar en paralelo sobre los datos, mientras que la versión de pyspark.pandas está optimizada para el manejo de grandes volúmenes de datos y para correr sobre un clúster Spark.

```
import pyspark
import matplotlib.pyplot as plt
import pyspark.pandas as pd
from pyspark.sql import SparkSession
from pyspark.mllib.regression import LabeledPoint, LinearRegressionWithSGD, LinearRegressionModel

# Abrimos una sesión con Spark
spark_session=SparkSession.builder.master("local[4]").appName('data_processing').getOrCreate()

# Lee un conjunto de datos y retorna un DataFrame de PySpark
# Este dataset contiene los valores del índice de precios al consumidor de nueva zelanda desde el 1914 hasta
# Diciembre de 2021.
df=spark_session.read.csv('C:\\Modelos\\Datasets\\consumers-price-index-december-2021-index-numbers.csv',header=True)
# En esta parte exploraremos el conjunto de datos con el fin de ver las posibilidades de DataFrame de PySpark
df.describe().show()
print('Cantidad de Records en el dataset:', df.count())
print('Cantidad de Columnas:', len(df.columns))
df.printSchema()

# Filtramos los datos pues solo mostraremos la serie CPIQ.SE9A y los años entre 2015 y el 2021
# Convertimos el DataFrame de PySpark a un DataFrame de Pandas
P_CPI_2021 = df.filter((df['Series_reference']=='CPIQ.SE9A') & (df['Period']>='2015.03'))\
                .select('Period','Data_value').toPandas()
P_CPI_2021['Data_value'] = P_CPI_2021['Data_value'].astype(float)
P_CPI_2021.info()

# Graficamos los datos usando Matplotlib
plt.plot(P_CPI_2021.Period,P_CPI_2021.Data_value)
plt.gcf().set_size_inches(14,8)
plt.title("Índice de Precios al Consumidor(CPI) Nueva Zelanda 2015-2021")
plt.xticks(rotation=90)
plt.show()

# Cerramos la sesión con Spark
spark_session.stop()
```

Figura 36. Ejemplo de aplicación en PySpark.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Luego, como verán en cada una de las aplicaciones de PySpark es necesario que importemos `SparkSession` desde el paquete `pyspark.sql`. El objeto `SparkSession` es el punto de entrada de todas las aplicaciones PySpark. Por último, importamos algunas de la funcionalidad de la librería `MLlib`, solo con el fin de ilustrar el tema, pero que no usaremos en este ejemplo.

Luego que se importan las librerías que usaremos a través de la aplicación, el primer paso y obligado en cada una de las aplicaciones `pyspark` es instanciar o crear una sesión `pyspark`. Esto se hace por medio de `SparkSession.builder`.

`.master("local[4]")` especifica que la sesión tendrá lugar en modo local y que correrá sobre 4 hilos, que corresponden a cada uno de los núcleos del Microprocesador. `appName()` especifica el nombre que le damos a nuestra aplicación y `.getOrCreate()` construye el objeto `SparkSession`.

Una vez que hemos instanciado el objeto `SparkSession` podemos comenzar con las tareas habituales que ejecutamos cuando hacemos análisis de datos o en los proyectos de Aprendizaje Automático. Lo primero que hacemos, normalmente, cargar el conjunto de datos. Esto se hace por medio de la siguiente línea de código:

```
df=spark_session.read.csv('C:\\Modelos\\Datasets\\consumers-price-index-december-2021-index-numbers.csv',header=True)
```

Esta línea de código, lee un conjunto de datos en formato `.csv`, o valores separados por coma y retorna un `DataFrame` de `pyspark`. Esta estructura de datos opera de manera completamente diferente del `DataFrame` de `pandas`, recuerden que esta estructura en `pyspark` está optimizada para manejar grandes volúmenes de datos en forma paralela.

Ya también había comentado que este dataset contiene el Índice de Precios al Consumidor de Nueva Zelanda en el periodo comprendido entre 1914 y 2021.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Veamos ahora una descripción estadística del DataFrame, al igual que en pandas, esto se hace por medio del método `describe()`, sin embargo, a diferencia de pandas este retorna otro DataFrame y por eso no se imprime de forma automática, sino que hay que usar el método `show()` para verlo.

```
df.describe().show()
```

El resultado es el que se muestra en la imagen a continuación, veamos:

summary	Series_reference	Period	Data_value	STATUS	UNITS	Subject	Group	Series_title_1
count	19755	19755	19755	19755	19755	19755	19755	19755
mean	null	2003.8182298154193	925.6065542668225	null	null	null	null	null
stddev	null	14.586873233139652	1361.9761534949466	null	null	null	null	null
min	CPIQ_SE901	1914.06	0	FINAL	Index	CPI CPI All Groups fo...	Accommodation ser...	
max	CPIQ_SE9A	2021.12	NA	FINAL	Index	CPI CPI Level 3 Class...	Women's footwear	

Como puede verse, a partir de la imagen resultante, el dataset tiene 8 columnas o atributos, como prefieran llamarle y vemos también que tiene 19755 casos, sin embargo, no podemos ver los tipos de datos que contiene cada una de ellos, por tanto, tenemos que usar otro método para ello y eso hacemos a continuación con la siguiente línea de código:

```
df.printSchema()
```

Este método muestra los tipos de datos de cada una de las columnas del DataFrame, el resultado lo vemos en la imagen a continuación:

```
root
|-- Series_reference: string (nullable = true)
|-- Period: string (nullable = true)
|-- Data_value: string (nullable = true)
|-- STATUS: string (nullable = true)
|-- UNITS: string (nullable = true)
|-- Subject: string (nullable = true)
|-- Group: string (nullable = true)
|-- Series_title_1: string (nullable = true)
```

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Aquí nos damos cuenta que todos los rasgos, atributos son de tipo cadena (string), sin embargo, el valor del CPI no debe ser de tipo cadena, este debe ser de tipo Float y por tanto debemos convertirlo. Este dataset, contiene varias series de datos que constituyen detalles de este, tal como el costo de muchos productos, pero eso no nos interesa, solo nos interesa el CPI total y este se encuentra en la serie "CPIQ.SE9A". Tampoco nos interesa todo el periodo contenido en el dataset, solo nos interesa el periodo posterior al 2015 y por tanto tenemos que filtrar el dataset y solo obtener los valores que nos interesan. Esto se logra por medio de las siguientes líneas de código:

```
P_CPI_2021 = df.filter((df['Series_reference']=="CPIQ.SE9A") &&
(df['Period']>='2015.03'))\

                .select('Period','Data_value').toPandas()

P_CPI_2021['Data_value'] = P_CPI_2021['Data_value'].astype(float)
```

En un DataFrame de PySpark hay varias formas de filtrar, sin embargo nos parece muy sencillo y cómodo el método filter(). En este caso filtramos por dos criterios combinados por medio de un AND, representado por el símbolo &. El primero de los criterios es que solo nos retorne la serie "CPIQ.SE9A" y el segundo, que nos retorne solo los valores de la columna Period mayores que '2015.03'. Luego, con el método select(), seleccionamos solamente las columnas "Period" y "Data_value" y finalmente el resultado será retornado en formato de pandas.

En la siguiente línea de código se convierte la columna Data_value a float, como ya habíamos comentado.

La variable P_CPI_2021, es un DataFrame de pandas y por tanto lo podemos tratar de la manera en que estamos acostumbrados, ahora podemos, con el método info() conocer las características de esta variable y lo hacemos de la siguiente forma:

```
P_CPI_2021.info()
```

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Esta línea de código nos retorna la siguiente información:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 28 entries, 0 to 27
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Period      28 non-null    object
1   Data_value  28 non-null    float64
dtypes: float64(1), object(1)
memory usage: 576.0+ bytes
```

En la imagen se puede ver, que el DataFrame contiene 28 casos, que contiene solo dos columnas y que Period, es de tipo object, mientras que Data_value es de tipo float como necesitábamos.

Bueno, ya vimos las transformaciones elementales que necesitábamos al conjunto de datos y ahora falta graficar los datos para inspeccionar un poco como lucen, ¿verdad?

Para graficar los datos, vamos a usar nuestro aliado y viejo conocido matplotlib y su ahojado pyplot. Veamos como lo hacemos en algún detalle y luego veremos la gráfica.

```
# Graficamos los datos usando Matplotlib

plt.plot(P_CPI_2021.Period,P_CPI_2021.Data_value)

plt.gcf().set_size_inches(14,8)

plt.title("Indice de Precios al Consumidor(CPI) Nueva Zelanda 2015-2021")

plt.xlabel('Fecha')


plt.ylabel('Valor del CPI')

plt.xticks(rotation=90)

plt.show()
```


Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En la primera línea definimos que Period, será mostrado en el eje x y que Data_value se mostrará como valores de la gráfica en el eje y. A continuación, establecemos el tamaño que queremos para la gráfica. En las siguientes líneas establecemos el título y las etiquetas de los ejes y establecemos que las marcas de fechas del eje x que corresponden a la variable Period, se muestren rotadas 90 grados y por último mostramos la gráfica, la cual mostramos en la siguiente imagen.



Y por último, tenemos que detener la sesión llamando el método stop() de el objeto Spark_Session, de la siguiente manera:

```
spark_session.stop()
```

Hasta aquí esta breve introducción a PySpark.

El Proceso y las Técnicas de extracción de información en Big Data

En esta sección estaremos mostrando, tanto el proceso de extracción de la información como las técnicas más usadas y en tipos de datos estructurados y no estructurados. Nos concentramos en las técnicas del modelado predictivo y no contemplamos la etapa de despliegue al no aportar el proceso de extracción.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

El proceso de Extracción de información

El enfoque que usamos en estas lecciones es el de Ciencia de Datos, el cual entendemos como evolución de otros enfoques como el de Descubrimiento de Conocimiento en Bases de Datos y Minería de Datos. Y, por tanto, entendemos como campo de actividad al conjunto de principios, algoritmos y procesos para extraer patrones útiles y no obvios a partir de grandes conjuntos de datos. Como ya habíamos comentado, la ciencia de datos, Aprendizaje automático y Minería de Datos, están íntimamente relacionados y en muchos casos se usan de manera intercambiable, sin embargo, la ciencia de datos va mucho más lejos que el resto de ellos; pero usa el aprendizaje automático y la estadística como parte inseparable.




Figura 37. Relación de la Ciencia de Datos con otras disciplinas o áreas. (imagen tomada de <https://iaarbook.github.io/datascience/>)

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Ahora bien, si analizamos el proceso de extracción de información a partir de datos, veremos que coincide con el proceso que ya vimos en el módulo de Aprendizaje Automático y que mostramos en la imagen correspondiente a la Figura 38.

Aunque, en esencia, la imagen corresponde a un proceso CRISP-DM adaptado a proyectos de Aprendizaje automático, incluye lo que a nuestro concepto son las etapas que hoy día constituyen el proceso general de extracción de información a partir de datos que se usa en Ciencias de Datos, sin embargo, añadiríamos en la etapa de modelado la distinción entre desarrollo de modelos y análisis de los datos. Esto se justifica por el simple hecho de que en muchos proyectos la idea no es generar un modelo de los datos propiamente dicho, sino, generar una explicación o descripción de cierto fenómeno. Esto hace que en la etapa de despliegue añadamos también una etapa de Storytelling donde presentamos los resultados.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 38. Proceso de la Ciencia de Datos para extraer información a partir de los datos. (Tomado de <https://towardsdatascience.com/crisp-dm-ready-for-machine-learning-projects-2aad9172056a>)

Las etapas de Data Understanding y Data Preparation, suelen estar contenidas en lo que en Aprendizaje Automático vimos como Etapa de Preprocesamiento y Análisis Exploratorio de Datos. Básicamente en estas etapas nos familiarizamos con los datos y decidimos las operaciones de limpieza y preparación de los datos antes de usarlos en la etapa de modelado o análisis.

En la imagen de la Figura 38. Se muestran las actividades que de forma general se ejecutan en cada una de estas fases. Veamos en algún detalle cada una de las etapas que se muestran y las correspondientes actividades, aunque no profundizaremos en ellas en aras de poder centrarnos en las técnicas de extracción correspondientes.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Business Understanding: En esta etapa se trata de obtener una profunda comprensión de las necesidades de negocios y traducirlo a requerimientos que servirán de guía para resto del proceso. Las actividades usuales se muestran en la Fig. 38 y la Fig. 39. Por eso no profundizaremos en esta etapa.

En esta etapa, normalmente se entrenan muchos modelos y se escogen los que mejores resultados arrojen y luego se optimizan sus hiperparámetros. En este proceso, puede que sea necesario regresar a la etapa anterior a sintonizar los datos en función de la calidad de los modelos.




Figura 39. Proceso de la Ciencia de Datos propuesto por otros autores. (Tomado de Introducing Data Science de los autores: Davy Cielen, Arno D. B. Meysman, Mohamed Ali)

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Despliegue/Administración: En esta etapa, ya hemos escogido uno de los modelos o varios y tiene como fin poner en producción, hacer pruebas del tipo A/B o simplemente crear los gráficos necesarios que expliquen un determinado comportamiento. Esta es una etapa sumamente importante pues en la mayoría de los casos los modelos que se entrenan no se despliegan, en gran parte producto a la brecha entre IT y negocios o por carencias a la hora de plantear el proyecto. Es importante destacar que una vez que el modelo se despliega no es la última etapa, pues comienza otra aún más importante, lo que en el gráfico de la Fig. 38 se le llama Model Management. En Fig. 38, aparecen estas dos etapas, la de despliegue y la de administración de los modelos como etapas separadas, sin embargo, las actividades que se dan en ellas, a los efectos prácticos, pueden realizarse de manera conjunta y por eso la hemos unido.

A esta etapa también se le conoce como etapa de Operacionalización.

En esta etapa, es necesario un monitoreo constante de las métricas resultante de la operación de los modelos. Esta etapa es crítica, pues el modelo tiene que satisfacer de manera simultánea requerimientos distintos, por ejemplo, Operaciones estará pendiente de la cantidad de memoria y del tiempo de respuesta del modelo, mientras que el equipo de negocios estará pendiente si cumple con lo que ellos especificaron como requisitos y funciones y el equipo de datos tiene que estar pendiente de las métricas de calidad del modelo. Es sencillo ver porqué es tan importante esta etapa.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Hasta aquí llegamos con lo que corresponde al proceso de extracción de información y nos concentraremos, ahora, en las técnicas que se usan en cada una de estas etapas con el fin de extraer la información. Sin embargo, antes de terminar, es importante tener en cuenta que este proceso puede variar en función del tipo de analítica que se va a realizar. Por ejemplo, si el propósito del proyecto es describir la situación actual de una organización a partir de la información de operaciones, usaríamos Analítica descriptiva y todo el proceso cambiaría. Este proceso está descrito pensando en el uso de Analítica Predictiva.

Técnicas de extracción de información en datos estructurados y no estructurados

Hasta el día de hoy, se han desarrollado cientos de técnicas de extracción de información en diferentes ámbitos, no es nuestro interés hacer un compendio exhaustivo de ellas y por tanto nos concentraremos en aquellas que son cubiertas en la librería `pyspark.ml` y algunas otras librerías con el fin de ilustrar como operar sobre datos, tanto estructurados como no estructurados.


En la primera parte de esta sección trataremos las técnicas utilizadas para extraer información y conocimiento de los datos estructurados y en la segunda veremos algunas técnicas de extracción en datos no estructurados, tales como documentos, imágenes y audio.

Hasta el día de hoy, se han desarrollado cientos de técnicas de extracción de información en diferentes ámbitos, no es nuestro interés hacer un compendio exhaustivo de ellas y por tanto nos concentraremos en aquellas que son cubiertas en la librería `pyspark.ml` y algunas otras librerías con el fin de ilustrar como operar sobre datos, tanto estructurados como no estructurados.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En la primera parte de esta sección trataremos las técnicas utilizadas para extraer información y conocimiento de los datos estructurados y en la segunda veremos algunas técnicas de extracción en datos no estructurados, tales como documentos, imágenes y audio.

Cuando tratamos con técnicas de extracción de información, es muy conveniente tener claro, que al proceso mismo suele denominarse por varios nombres, nosotros usaremos Analítica y en dependencia de las preguntas que queramos responder será el apellido que tome. Cuando queremos responder preguntas tales como ¿Cuáles son las ventas de la empresa en los últimos 10 meses? ¿Cuál es el costo total de una determinada campaña de marketing? Entonces estamos usando lo que se denomina **Analítica Descriptiva** y se basa en los datos de lo que ha estado aconteciendo en la organización. Sin embargo, cuando necesitamos responder preguntas tales como ¿Cuáles serán las ventas de la empresa en los próximos tres meses? ¿Cuántos consumidores dejarán de usar nuestros servicios en los próximos 10 meses? ¿Cuántos segmentos de clientes tengo si tomo en cuenta la edad de ellos? Entonces estaría usando lo que se llama **Analítica Predictiva**. Este tipo de analítica trata con eventos que aún no han sucedido. De esta forma podemos dividir la Analítica en:



Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Es evidente que las técnicas varían en dependencia del tipo de analítica que estemos usando. Cuando necesitamos responder preguntas sobre ¿qué ha pasado en nuestra organización? Haremos uso de técnicas estadísticas que permiten por ejemplo sumarizar datos o explicar tendencias, hacer análisis de causa/efecto o de correlación y visualizar los resultados. En cambio, cuando usamos analítica predictiva y necesitamos responder preguntas sobre eventos que no ha sucedido es necesario usar técnicas de modelado predictivo y aprendizaje automático.

Podemos concluir, entonces, que la técnica a usar depende del tipo de analítica que necesitamos emplear.

Otra situación que es importante que destaquemos y que los analistas de datos y científicos de datos continuamente enfrentamos es la del tamaño de los datos que necesitamos manejar. Tomando en consideración esta situación, nos podemos enfrentar a tres situaciones diferentes: Los datos son de un tamaño que puede ser manejado completamente por nuestro ordenador, es decir, caben en la memoria de nuestro ordenador, El tamaño de los datos no cabe en la memoria de nuestro ordenador, pero pueden ser manejados usando técnicas adecuadas, por último, los datos tienen un tamaño tan brutal que no pueden ser manejados por nuestro ordenador.

En el primero de los casos no hay ninguna complicación, los datos son manejables y si desarrollamos algún modelo esto se hace de manera sencilla desde nuestra estación de trabajo. En el tercero de los casos, no hay modo, solo podemos hacerlo desde un clúster, probablemente usando Hadoop o Apache Spark, ya sea on-premise o en la nube.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En el caso intermedio debemos elegir técnicas que nos permitan manejar los datos sin que tengamos los molestos mensajes de “out of memory” en el mejor de los casos y en el peor, ciclos interminables que no nos dejan otro camino que matar los procesos o reiniciar el ordenador.

Con el fin de ejemplificar esta situación, hagamos un ejemplo:

Para ello usaremos un caso de uso en el que queremos predecir si un sitio en internet es malicioso o no, con este fin se han recopilado 2 400 000 url y de ellas se han medido más de 3 200 000 rasgos.

A ver, repitamos, para que tengan una idea del tamaño del conjunto de datos, tenemos dos millones cuatrocientos mil casos, cada uno con más de tres millones doscientos mil atributos, brutal, ¿cómo manejamos semejante dataset? ¿podemos hacerlo en nuestra estación de trabajo? Pues sí, si podemos si usamos la técnica adecuada y para esto hagamos la siguiente prueba:

- ▶ Descargue el dataset desde la siguiente dirección:
<http://www.sysnet.ucsd.edu/projects/url/#datasets>
- ▶ Luego descomprímalo en una carpeta y ejecute el código mostrado en la siguiente imagen.

```
import pyspark
import pyspark.pandas as pd
from pyspark.sql import SparkSession
#*****
# Abrimos una sesión con Spark
spark=SparkSession.builder.master("local[4]").appName('data_processing').getOrCreate()
training = spark.read.format("libsvm").load("C:\\Modelos\\Datasets\\url_svmlight\\*.svm")
training.show(10)
```

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Probablemente, su ordenador se demore muchísimo para ejecutar este código, si es que lo llega a hacer.

Sin embargo, probemos el código que se muestra en la imagen siguiente.

```
import tarfile
from sklearn.linear_model import SGDClassifier
from sklearn.metrics import classification_report
from sklearn.datasets import load_svmlight_file
import numpy as np
uri = "C:\\Modelos\\Datasets\\url_svmlight.tar.gz"
tar = tarfile.open(uri, "r:gz")
max_obs = 0
max_vars = 0
classes = [-1, 1]
sgd = SGDClassifier(loss="log")
n_features = 3231970
split = len(tar.getnames()) - 2
print('Split:', split)
print('*****')
i = 0
for tarinfo in tar:
    if i > split:
        break
    if tarinfo.isfile():
        print("%s extrayendo %s, tamaño: %s" % (i, tarinfo.name, tarinfo.size))
        if tarinfo.name != "url_svmlight/FeatureTypes":
            f = tar.extractfile(tarinfo.name)
            X, y = load_svmlight_file(f, n_features=n_features)
            if i < split:
                print('*****|Entrenando|*****')
                print('n casos:', X.shape[0])
                print('*****|Fin|*****')
                sgd.partial_fit(X, y, classes=classes)
            if i == split:
                print('*****|Testing|*****')
                print('n casos:', X.shape[0])
                print('*****|Fin|*****')
                print(classification_report(sgd.predict(X), y))
            i += 1
```

En este código, usamos una técnica sencilla que ilustra como podemos manejar un conjunto de datos que no cabe en la memoria del ordenador. Como ya habíamos dicho, este conjunto contiene dos millones cuatrocientos mil casos y cada uno de ellos con más de tres millones doscientos mil atributos. Sin embargo en este código aprovechamos que están divididos en ficheros de textos con 20000 casos cada uno y comprimidos en formato .tar.gz.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Así que vamos extrayéndolos uno a uno y entrenando un clasificador de forma parcial y eso hace que podamos manejarlo de manera adecuada.

Técnicas de extracción de información sobre datos estructurados

Quizás, de las técnicas de extracción de información las más conocidas sean la media, la mediana y la moda. Sin embargo, a pesar de ser tan conocidas no siempre entendemos como usarlas de forma apropiada.

Técnica #1. Media: La media o esperanza representa el valor promedio o valor esperado de una variable aleatoria y se expresa matemáticamente de la siguiente forma:

Técnica #1. Media: La media o esperanza representa el valor promedio o valor esperado de una variable aleatoria y se expresa matemáticamente de la siguiente forma:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Esta medida nos permite sumarizar un conjunto de datos en un solo número, esta se obtiene, en palabras claras sumando todos los valores y dividiéndolo por la cantidad de ellos.

La información que nos arroja es el valor medio de entre todos los valores en el conjunto de datos, es decir el valor que con mayor probabilidad podemos esperar de esa variable. Sin embargo, esta medida es muy sensible a valores extremos y por eso se debe usar solo con variables cuyos valores estén normalmente distribuidos.

Cuando los valores no están normalmente distribuidos es mejor usar la mediana o la moda. Ojo y anote esto, **en un conjunto de datos normalmente distribuido, la media, la mediana y la moda coinciden.**

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En la Figura 40 se muestra el código de como se calcula la media o promedio de un atributo o columna. Para este ejemplo usamos el Dataset de la relación entre la talla de los hijos teniendo en cuenta el de los padres recopilado por Galton.

Técnica #2. Mediana:

```
import pyspark
import pyspark.pandas as pd
from pyspark.sql import SparkSession
from pyspark.sql.functions import *
from pyspark.sql.types import *
import matplotlib.pyplot as plt
import seaborn as sns
#*****
# Abrimos una sesión con Spark
spark=SparkSession.builder.master("local[4]").appName('data_processing').getOrCreate()
df = spark.read.csv("C:\\Modelos\\Datasets\\galton_height.csv",header=True)
df1 = df.select(col('Father').cast(DoubleType()).alias('Father'),col('Mother').cast(DoubleType()).alias('Mother'),\
               col('Height').cast(DoubleType()).alias('Height'))
#Encuentra la moda en las tallas de los padres, las madres y los hijos
Father_Mode = df.groupby("Father").count().orderBy("count", ascending=False).first()[0]
Mother_Mode = df.groupby("Mother").count().orderBy("count", ascending=False).first()[0]
Child_Mode = df.groupby("Height").count().orderBy("count", ascending=False).first()[0]
#*****
print('El tamaño promedio de los padres es %s pulgadas'% df1.agg({'Father': 'mean'}).collect()[0])
print('La desviación estandar en el tamaño de los padres es de %s pulgadas'% df1.agg({'Father': 'stddev'}).collect()[0])
print('La talla que más se repite entre los padres es %s'% Father_Mode)
print('*****')
print('El tamaño promedio de las Madres es %s pulgadas'% df1.agg({'Mother': 'mean'}).collect()[0])
print('La desviación estandar en el tamaño de las Madres es de %s pulgadas'% df1.agg({'Mother': 'stddev'}).collect()[0])
print('La talla que más se repite entre las Madres es %s'% Mother_Mode)
print('*****')
print('El tamaño promedio de los Hijos es %s pulgadas'% df1.agg({'Height': 'mean'}).collect()[0])
print('Desviación Estandar en el tamaño de los Hijos es de %s pulgadas'% df1.agg({'Height': 'stddev'}).collect()[0])
print('La talla que más se repite entre los hijos es %s'% Child_Mode)
print('*****')
sns.displot(data=df.select('Father').toPandas(), x='Father', kde=True);
plt.gcf().set_size_inches(10,8)
plt.xlabel('Talla (pulgadas)')
plt.ylabel('Frecuencia')
plt.title('Distribución de la talla de los padres(Galton Dataset)')
plt.xticks(rotation=90)
plt.show()
print('*****')
#*****
```

Figura 40. Código que calcula la media, la desviación estándar y la moda de las columnas Father, Mother y Height del dataset de Galton.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

```
sns.displot(data=df.select('Mother').toPandas(), x='Mother', kde=True);
plt.gcf().set_size_inches(10,8)
plt.xlabel('Talla (pulgadas)')
plt.ylabel('Frecuencia')
plt.title('Distribución de la talla de las Madres(Galton Dataset)')
plt.xticks(rotation=90)
plt.show()
print('*****')
#*****
sns.displot(data=df.select('Height').toPandas(), x='Height', kde=True);
plt.gcf().set_size_inches(12,8)
plt.xlabel('Talla (pulgadas)')
plt.ylabel('Frecuencia')
plt.title('Distribución de la talla de los Hijos(Galton Dataset)')
plt.xticks(rotation=90)
plt.show()
print('*****')
```

El tamaño promedio de los padres es 69.23285077950997 pulgadas
La desviación estándar en el tamaño de los padres es de 2.470255810710908 pulgadas
La talla que más se repite entre los padres es 70.0

El tamaño promedio de las Madres es 64.08440979955456 pulgadas
La desviación estándar en el tamaño de las Madres es de 2.307025221001858 pulgadas
La talla que más se repite entre las Madres es 65.0

El tamaño promedio de las Hijos es 66.76069042316252 pulgadas
Desviación Estándar en el tamaño de los Hijos es de 3.5829184699727876 pulgadas
La talla que más se repite entre los hijos es 65.0

Figura 41. Código que calcula la media, la desviación estándar y la moda de las columnas Father, Mother y Height del dataset de Galton. (Continuación)




Figura 42. Histograma de la columna Father con curva de densidad.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 43. Histograma de la columna Mother con densidad.




Figura 44. Histograma de la columna Height con densidad.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

1.3. Modelado, razonamiento y solución de problemas

Objetivos

En esta lección tocaremos conceptos que son importantes en el ámbito de la ciencia de la computación y todas las ciencias conexas. Hablamos de conceptos como Modelo, Razonamiento y hablaremos sobre las técnicas de solución de problemas en el ámbito de la Inteligencia Artificial.

Creemos que el dominio de estos conceptos aporta una visión necesaria en el camino de dominar las habilidades necesarias para tener éxito en el complejo mundo de la aplicación de la ciencia a los problemas del mundo real.

Por tanto, al terminar esta lección usted debe estar equipado con las nociones necesarias para entender la esencia de los modelos y su clasificación básica, así como las principales técnicas de solución de problemas en el ámbito de la inteligencia artificial.

Introducción

Es usual y muy común escuchar, en cualquiera de las áreas de la ciencia en que nos desarrollemos, el término “modelo”. De la misma forma escuchamos y usamos el término “Razonamiento”, sin embargo, en la mayoría de los casos no tenemos una definición concreta de estos términos o concepto que juegan un papel central en toda la ciencia.

De esta forma, los matemáticos hablan de modelos matemáticos (Modelos Lineales o Modelos Gaussianos, etc) y de modelado matemáticos, los físicos de modelos físicos, por ejemplo, el modelo atómico de Bor, los ingenieros civiles, hablan de modelos estructurales y así todas las áreas usan los modelos como objetos esenciales en su quehacer.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Lo mismo sucede cuando le ponemos atención al uso del término “razonamiento”.

Modelos y su clasificación

Una de las actividades básicas de la ciencia es la elaboración de teorías y la creación de modelos. Si bien hay reglas generales que guían la construcción de modelos, cada una de las ciencias tiene sus propios métodos que son de alguna manera aceptados por la gran mayoría y que se adecúan al método científico.

Existe una relación estrecha entre teoría y modelo, sin embargo, a los efectos de esta lección, nos interesa solo lo que se refiere a los modelos, su uso y clasificación en la ciencia de computación y la inteligencia artificial.

Si buscamos la definición de modelo debemos diferenciar entre muchas de las interpretaciones del término, sin embargo, la Real Academia de la Lengua, lo define de la siguiente forma:

- ▶ Arquetipo o punto de referencia para imitarlo o reproducirlo.
- ▶ En las obras de ingenio y en las acciones morales, ejemplar que por su perfección se debe seguir e imitar.
- ▶ Representación en pequeño de alguna cosa.
- ▶ Esquema teórico, generalmente en forma matemática, de un sistema o de una realidad compleja, como la evolución económica de un país, que se elabora para facilitar su comprensión y el estudio de su comportamiento.
- ▶ Objeto, aparato, construcción, etc., o conjunto de ellos realizados con arreglo a un mismo diseño. Auto modelo 1976. Lavadora último modelo.
- ▶ Vestido con características únicas, creado por determinado modista, y, en general, cualquier prenda de vestir que esté de moda.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ En empresas, u. en aposición para indicar que lo designado por el nombre anterior ha sido creado como ejemplar o se considera que puede serlo. Empresa modelo. Granjas modelo.
- ▶ Esc. Figura de barro, yeso o cera, que se ha de reproducir en madera, mármol o metal.
- ▶ Cuba. impreso (|| hoja con espacios en blanco).
- ▶ Persona que se ocupa de exhibir diseños de moda.
- ▶ Persona u objeto que copia el artista. modelo vivo. Persona, por lo común desnuda, que sirve para el estudio en el dibujo.

Sin embargo, tenemos una definición que hace referencia a los modelos en la ciencia específicamente y reza como sigue:

«Es una representación abstracta, conceptual, gráfica o visual, (por ejemplo, un mapa conceptual), física de un fenómeno, sistemas o procesos a fin de analizar, describir, explicar, simular en general, explorar, controlar y predecir esos fenómenos o procesos»

Podemos definir, entonces, a los modelos, como instrumentos conceptuales que se construyen para facilitar el estudio y comprensión de la realidad, y que se supone que representan, de modo más o menos simbólico y con alguna aproximación, ciertos aspectos de los sistemas reales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Los científicos dedican mucho tiempo a construir, probar, comparar y revisar modelos; a su vez, numerosos artículos de ciencia introducen, aplican e interpretan estos instrumentos valiosos. Por tanto, una parte significativa de la investigación científica se centra en los modelos más que en la realidad misma, porque al estudiar un modelo se pueden determinar hechos y descubrir rasgos del sistema que el propio modelo representa.

El significado de modelo científico ha sido discutido -y se sigue debatiendo aún- por filósofos de la ciencia, psicólogos, científicos y educadores, entre otros. Por ejemplo, los filósofos de la ciencia reconocen la importancia de los modelos cada vez más e investigan sus diversas funciones en la práctica científica. Como resultado de esta labor se citan distintos tipos de modelos -no excluyentes entre sí- en la bibliografía de filosofía de la ciencia, tales como: teóricos, exploratorios, explicativos, idealizados, heurísticos, instrumentales, imaginarios, fenomenológicos, icónicos, matemáticos, computacionales, formales, analógicos, etc.

Sin embargo, a lo que a la ciencia de la computación se refiere, nos centramos en los modelos Matemáticos y Computacionales.

Dentro de estos tipos de modelos, por tanto, nosotros distinguiremos dos tipos de modelos básicos:

- ▶ Modelos Analíticos.
- ▶ Modelos Experimentales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En los Modelos Analíticos, se conoce perfectamente la relación entre las variables que conforman un problema y esta se pueden expresar por una fórmula analítica. Uno de los modelos más conocidos en la física es el modelo que relaciona la Energía con la masa y la velocidad de la luz:

$$E = mc^2$$

Donde m es la masa y c la velocidad de la luz.

En cambio, hay veces que no conocemos la formulación matemática exacta de las relaciones que se establecen entre las variables de un fenómeno, sin embargo, hemos medido con alguna exactitud las variables y disponemos de una data que por algún método experimental podemos estimar dicha relación. Es a este tipo de modelo al que se les llama modelos experimentales.

Un ejemplo interesante de modelo experimental, el modelo desarrollado por Sir Francis Galton que relaciona las características hereditarias entre padres e hijos. Exactamente, la talla de los hijos a partir de la talla de los padres.

Ahora bien, veamos otros aspectos interesantes de estos tipos de modelos. Note que, en el primer tipo de modelo, en los analíticos y en concreto en el que mostramos, donde se relaciona la masa y la energía, para cada valor de masa, existe solo un valor de energía y siempre corresponderá un valor con el otro. A este tipo de modelos se les llama modelos deterministas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Sin embargo, a los modelos como el de Galton, si revisamos el resultado del coeficiente de determinación o R^2 , nos damos cuenta de que arroja un 72 % si usamos como variables predictoras el alto de los padres. Eso implica que este modelo solo puede explicar el 72 % de la varianza mostrada en el alto de los hijos cuando se usa, solo, el alto de los padres y el resto de la varianza que no puede ser explicada por este modelo, debe estar relacionada con factores que no incluimos en él y por tanto nos son desconocidos y debemos englobar en una variable ϵ .

Cuando esta variable se considera una variable aleatoria, entonces, incluso para valores de tallas iguales de los padres, en dos familias diferentes nunca nos arrojará el mismo valor de talla en los hijos. A estos tipos de modelos se les llama modelos no deterministas o modelos estocásticos.

Por tanto, otra clasificación importante de los modelos es el siguiente:

- ▶ Modelos Deterministas.
- ▶ Modelos No Deterministas o Estocásticos.

La diferencia esencial entre los modelos deterministas o no es que en los primeros para cada valor igual de las variables del modelo, este siempre arrojará el mismo resultado.

Ahora bien, hay otra distinción interesante en lo que respecta a los modelos y es si incluyen el tiempo en consideración o no. En caso de que consideran el tiempo como una variable que determina el resultado, nos referimos a ellos como Modelos Dinámicos y si por el contrario no dependen de una variable de tiempo los llamamos Modelos Estáticos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 44. Proceso de modelado. (Tomado de

<https://www.madrimasd.org/blogs/universo/2008/05/10/91441>)

A manera de conclusión de esta sección debemos resumir que los tipos básicos de modelos con los que estaremos tratando en Ciencia de la computación son, entre otros:

- ▶ Modelos Analíticos o Modelos Experimentales.
- ▶ Modelo Deterministas o No Deterministas (Estocásticos)
- ▶ Modelos Dinámicos o Modelos Estáticos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Razonamiento

«Pienso, luego existo» (*Cogito ergo sum*), quizás sea una de las frases más famosas de las que conozco y que aparece en la obra *Discurso del método* (1637) del matemático y filósofo francés, René Descartes. Esta frase, pone de relieve una profunda lucha entre los que defienden que el pensamiento está antes que el ser material y los que defienden lo contrario. Sin embargo, dejando de lado esa lucha filosófica también subraya un hecho no menos importante y es la importancia del Pensamiento, en nuestro devenir histórico.

El pensamiento, sus componentes y las leyes que lo rigen han fascinado a generaciones de pensadores y lo sigue haciendo.

Por alguna extraña razón y dejando de lado las diferencias, la mayoría de las personas usan de manera indistinta los términos, inteligencia, pensamiento y razonamiento para referirse a situaciones comunes.

Es común encontrar frases como: No estás pensando claramente, o No razones o Eres poco inteligente en situaciones en que alguien comete errores inesperados. Y por error, aquí se entiende como una desviación de la conducta que se espera por todos y que de alguna manera denotaría lo que es actuar inteligentemente o razonar de manera correcta.

Sin embargo, estos términos, aunque se asocian tienen diferencias concretas. Mientras que el pensamiento y el razonamiento son procesos la Inteligencia se considera una capacidad. Algunos investigadores exponen que la inteligencia está condicionada por el conocimiento. De esta forma cabe esperar que si aumento la cantidad de conocimiento aumenta mi capacidad para actuar de manera inteligente.

Este proceso de aumentar el conocimiento para aumentar la capacidad de actuar inteligentemente, nos lleva al proceso del pensamiento en su naturaleza más amplia y por tanto también al razonamiento. Pues, este, es un proceso que permite llegar a

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

conclusiones a partir del conocimiento existente y dichas conclusiones se integran en calidad de nuevas premisas para posteriores razonamientos.

En la Inteligencia Artificial, el concepto de razonamiento juega un papel vital al permitir que las máquinas piensen racionalmente como un cerebro humano y les da la capacidad de actuar como humanos. En general, hay 5 tipos comunes de razonamiento que tienen un papel crucial en el proceso de pensamiento en un sistema artificialmente inteligente. Analicemos brevemente los 5 tipos comunes de razonamiento a continuación:

- **Razonamiento deductivo:** utiliza todos los datos existentes para producir una suposición válida. No saca ninguna conclusión antes de echar un vistazo estratégico a la información y los hechos ya disponibles. Se utiliza un enfoque de arriba hacia abajo para verificar si los argumentos son válidos o no en función del valor de las premisas. Si se encuentra que el valor de las premisas es verdadero, entonces la suposición también se considera verdadera. Por lo tanto, el razonamiento deductivo juega un papel clave para convertir una afirmación generalizada en una conclusión válida.

Por ejemplo

Premisa 1: todos los animales viven en el bosque.

Premisa 2: el tigre es un animal.

Conclusión: por lo tanto, Tiger vive en el bosque.

Es importante, subrayar el hecho de que este tipo de razonamiento parte de premisas que son generales y llega a conclusiones muy específicas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- **Razonamiento inductivo:** el razonamiento inductivo es un enfoque de abajo hacia arriba en el que se genera una hipótesis en lugar de producir una conclusión válida a partir de la información existente al principio. Es capaz de producir generalizaciones a partir de ciertos hechos y conocimientos. En este tipo de lógica proposicional, las premisas producen un apoyo a la conclusión que es de naturaleza probabilística. Como resultado, el hecho de que las premisas sean verdaderas no siempre garantiza que la conclusión también lo sea.

Premisa: todos los gatos que hemos visto en las calles son de color blanco. Conclusión: por lo tanto, todos los gatos son blancos.

El aprendizaje supervisado utiliza este concepto para razonar y generalizar a partir de datos existentes. Por lo tanto, necesitamos más datos para producir mejores generalizaciones a partir de nuestro conocimiento existente. De lo contrario, la falta de hechos y cifras podría producir conclusiones que no son válidas, como la suposición de que todos los gatos son blancos.

- **Razonamiento abductivo:** es una forma de lógica proposicional en la que comienza con uno o más ejemplos u observaciones para encontrar la suposición más probable para la observación. Comienza con un poco de información y gradualmente acumula información para llegar a la mejor solución. Las premisas en este razonamiento no garantizan la conclusión, pero tienen un gran papel en el proceso de toma de decisiones de la vida diaria de los seres humanos. Por ejemplo, un médico que saca una conclusión de los informes de las pruebas sobre la salud de un paciente.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ **Razonamiento de sentido común:** este es un tipo de razonamiento muy importante para los seres humanos que ayuda a tomar decisiones todos los días. Este tipo de razonamiento se desarrolla a lo largo del tiempo a partir de las experiencias acumuladas por un ser humano mientras se enfrenta a diferentes circunstancias de la vida. Cuando alguien se enfrenta a circunstancias similares en el futuro, utiliza su conocimiento previo para llegar a una conclusión sobre lo mejor que se puede hacer en esa situación.
- ▶ **Razonamiento monotónico:** en el razonamiento monotónico, utiliza información y hechos para llegar a una conclusión que permanece fija y nunca cambia, ya que agregar conocimiento o hechos adicionales no cambiará la verdad. Esto es más como un hecho universal como: Rusia es el país más grande del mundo por área.
- ▶ **Razonamiento no monótono:** en este tipo de razonamiento, la conclusión a la que se llega no siempre es fija como el razonamiento monótono, puede ser invalidada en cualquier momento para sacar una nueva conclusión. Podría cambiar si se agrega alguna información apropiada a la base de conocimiento.

Estas formas de razonamiento y sus leyes han sido estudiados por muchos siglos y dio origen a marcos formales o disciplinas que tratan de establecer los criterios que hagan estos razonamientos completamente válidos. Así nació la Lógica, que es una ciencia formal que estudia la estructura o formas del pensamiento humano (como proposiciones, conceptos y razonamientos) para establecer leyes y principios válidos para obtener criterios de verdad.

Como adjetivo, 'lógico' o 'lógica' significa que algo sigue las reglas de la lógica y de la razón. Indica también una consecuencia esperable natural o normal.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La lógica se estructura en cálculos. Un cálculo es una mera estructura sintáctica. Un primer criterio de clasificación de la lógica viene determinado en función de cómo sean estos cálculos. La lógica formal moderna puede caracterizarse como una especie de cebolla, en donde sobre un cálculo base se monta otro que contiene más recursos expresivos y que necesita de nuevos elementos, sobre esta segunda capa se puede montar otras nuevas según sigamos ampliando recursos o quitando restricciones del uso de estos recursos. Teniendo esto presente la Lógica se estructura de la siguiente manera:

- ▶ **Lógica de Proposiciones o de Enunciados:** el cálculo básico de la lógica formal es el cálculo de enunciados o proposicional, cuyas fórmulas son proposiciones, oraciones o enunciados sin analizar internamente. La relación lógica a estudiar es la que se establece entre oraciones que constituyen la unidad mínima de significación lógica. Este cálculo es un cálculo hipotético, porque la deducción se establece en una relación condicional entre las premisas y la conclusión (si ocurren las premisas, entonces ocurre la conclusión).
- ▶ **Lógica de Predicados o Cuantificacional:** Sobre este cálculo básico se desarrolla el siguiente nivel que serán los cálculos de predicados o cuantificacionales, que se caracterizan por analizar las oraciones en sus componentes, sujeto y predicado, y porque se puede cuantificar sobre individuos, es decir podemos tratar con todos o con algunos de los elementos que pueden ser sujetos de una oración. Es fundamentalmente una lógica de clases donde la relación lógica que se estudia es la pertenencia a un conjunto o la posesión de propiedades por los distintos individuos de los que se habla. De esta manera, a diferencia de la lógica de proposiciones, la lógica de predicados es una lógica categorial, porque la deducción se efectúa según se puedan establecer o no relaciones de pertenencia o de posesión de propiedades de los individuos con las categorías en lo que se agrupan.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ **Lógica de Primer Orden:** A la unión del cálculo proposicional y del cálculo de predicados es a lo que llamamos lógica de 1er orden. Este cálculo tiene la restricción de que sólo podemos utilizar los cuantificadores con elementos individuales. Es decir, no podemos hablar de todas o de algunas de las clases de algún tipo.
- ▶ **Lógica de 2º (3º,4º...n) Orden:** Sobre la lógica de primer orden, según admitamos cuantificar sobre propiedades o predicados, o predicados de predicados, iremos subiendo de orden. Por ejemplo, si permitimos utilizar oraciones como "Hay un rasgo que todos los problemas filosóficos tienen en común", entonces, porque estamos cuantificando sobre una propiedad, estaríamos en una lógica de 2º orden y así sucesivamente.

Resumamos gráficamente esta estructura de cálculos anidados con la que se organiza la lógica. Esto debe interpretarse de una forma monótona ascendente, es decir, que todo lo que vale en un nivel inferior vale para el nivel superior, aunque no al revés:




Figura 45. Clasificación general de la lógica.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Todo sistema lógico tendrá esta estructura de cebolla que hemos visto, pero, desde el punto de vista semántico, podemos establecer otro criterio de clasificación dentro de los sistemas lógicos.

Un segundo criterio de clasificación será el número de valores de verdad que se acepten en los cálculos.

Hablamos de Lógica clásica cuando los cálculos lógicos son bivalentes, es decir, que sus fórmulas pueden ser verdaderas o falsas y no puede ocurrir que lo sean a la vez. Si en los cálculos lógicos se contemplan más valores de verdad que lo verdadero y lo falso u otros recursos expresivos entonces hablamos de Lógica no-clásica.

Respecto a las lógicas no clásicas podemos decir, introductoriamente, que surgen por la limitación expresiva de la lógica de 1er orden. Esto es, el cálculo de 1er orden es un cálculo construido con muchas restricciones para poder satisfacer ciertas propiedades metalógicas y en consecuencia su capacidad expresiva también resulta muy limitada. Se han desarrollados estos otros cálculos lógicos como herramientas de análisis de ámbitos temporales, modales, probabilísticos o inciertos.

Por ejemplo:

- ▶ La Lógica trivalente contempla tres valores de verdad, lo verdadero, lo falso y lo que no es verdadero ni falso, por desconocido o incierto.
- ▶ Las lógicas polivalentes son fundamentalmente lógicas probabilísticas en las que los valores de verdad se corresponden con el intervalo $[0,1]$.
- ▶ La lógica modal incorpora como operadores los modificadores lo necesario y lo posible.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ La Lógica temporal incorpora parámetros temporales. Para muchas oraciones su verdad depende del momento en que se produce.
- ▶ La lógica epistémica es una lógica intensional que pretende formalizar enunciados de creencia, opinión, etc.
- ▶ La lógica nomonotónica pretende formalizar situaciones reales en las que decidimos sin una total información y que posteriormente admite, conforme se prueben o refuten creencias, revisar el sistema total de creencia.

Existen muchas otras lógicas que pretenden estudiar los razonamientos en todos los ámbitos de la vida humana, pero nos tomaría al menos 100 páginas solo mencionarlos.




Figura 46. Otra clasificación de la lógica.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Solución de Problemas

Una de las características que define el conocimiento y la inteligencia es la capacidad para resolver problemas. Existe una idea intuitiva, en que asociamos a las personas con mayor capacidad para resolver problemas como más inteligentes o con el simple hecho de que poseen más conocimiento. Por tanto, una de las cosas que nos distingue de otras especies animales es la capacidad de resolver problemas usando el razonamiento.

Por tanto, si queremos dotar a las máquinas con inteligencia, también habría que dotarlas con la capacidad de resolver problemas. Ahora bien, es importante hacer notar que no todos los problemas son iguales, hay problemas, que por su naturaleza pueden ser resueltos por medio de un conjunto finito de pasos y en un tiempo también finito. Esto quiere decir que estos problemas pueden ser resueltos por un algoritmo. Por otro lado, hay problemas que no tienen una solución algorítmica conocida y es a este tipo de problemas a los que se dedica el área de Solución de Problemas de la Inteligencia Artificial.

A partir del estudio de la manera que los humanos resolvemos problemas, se han ido identificando patrones que terminan condensándose en técnicas que luego han sido adaptadas por la Inteligencia Artificial para la solución de problemas por medio de ordenadores.

Uno de los primeros de estos patrones es a lo que se le llama “Búsqueda por prueba y error” y a partir de esto se han encontrado varios métodos que han desembocado en lo que se ha dado en llamar “Métodos de solución de problemas” y que estudiaremos, aunque de manera sucinta en esta sección.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La búsqueda como fundamento de la IA

Los investigadores pioneros en I.A. tuvieron como su primer objetivo la solución de problemas que fueron difícil de resolver mediante las técnicas computacionales existentes. Como se dijo antes, estos problemas generalmente no tienen solución algorítmica conocida o esta es tan compleja que no tiene una implementación práctica computacional.

La respuesta fue desarrollar nuevas técnicas de solución de problemas, similares a las humanas, una de las más importantes fue la búsqueda.

La búsqueda en I.A. difiere de la búsqueda convencional sobre estructuras de datos esencialmente en que se busca en un espacio problema, no en una pieza de dato particular. Se busca un camino que conecte la descripción inicial del problema con una descripción del estado deseado para el problema, es decir, el problema resuelto. Este camino representa los pasos de solución del problema.

El proceso de buscar una solución a un problema produce un espacio solución, o sea, la parte del espacio problema que se examina realmente. A diferencia de las estructuras de datos que están predefinidas y ya existen cuando comienza la búsqueda, los espacios problema son generalmente definidos proceduralmente, es decir, el espacio problema es creado a medida que es explorado. Se usan procedimientos para definir los siguientes estados posibles en el espacio a través de los cuales la búsqueda puede continuar desde el estado actual. Solamente los caminos explorados tienen que estar definidos explícitamente.

Hay diferentes alternativas para realizar la búsqueda. Desde un punto de vista podemos apreciar tres alternativas: aleatoria, a ciegas y dirigida. Con el siguiente ejemplo se ilustran estos.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Supóngase que está en París sin un mapa y no habla francés ¿Cómo llegar hasta la torre Eiffel?

Un método podía ser tomar aleatoriamente una calle esperando que más pronto que tarde se llegará a la torre. Esta búsqueda aleatoria puede llevar a encontrar la torre, pero puede requerir una cantidad infinita de tiempo por la forma arbitraria en la cual seleccionamos un camino (el mismo puede tomarse múltiples veces).

Otra alternativa es seguir exhaustivamente cada calle de inicio a fin. Cuando se alcanza un final se busca una calle paralela y se sigue esta, en dirección opuesta independientemente de si nos acercamos o alejamos del objetivo. Eventualmente esta variante consideraría todas las posiciones de nuestro espacio problema. Este tipo de búsqueda se llama a ciegas, ya que no usa conocimiento de cuan cerca estamos de la solución para tomar un determinado camino.

Alternativamente, podemos usar nuestro conocimiento sobre la torre para mejorar la eficiencia de la búsqueda. Suponiendo que el extremo superior de la torre puede ser visto desde cualquier lugar del espacio problema, podemos tomar la calle que nos parezca nos lleve en esa dirección. Esta es llamada una búsqueda dirigida. La búsqueda dirigida es la base de la I.A.

Otro aspecto a considerar es la dirección de la búsqueda. Puede ser dirigida por dato (forward) o dirigida por objetivo (backward).

Una búsqueda dirigida por dato comienza a partir de la información (o hechos) y trata de extraer conclusiones. Una búsqueda dirigida por objetivo comienza a partir de expectativas de lo que es el objetivo o lo que sucederá, entonces busca las evidencias que soportan o contradicen esas expectativas (o hipótesis).

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Definición formal de la solución de problemas en la IA

Considérese un agente quien actúa como resolutor de problemas. Un problema es realmente una colección de información que el agente usará para decidir qué hacer.

Los elementos básicos de la definición de un problema son los estados y las acciones. Los elementos son los siguientes:

- ▶ El estado inicial donde se encuentra el agente.
- ▶ El conjunto de acciones posibles disponibles al agente. El término operador se usa para denotar la descripción de una acción en términos de cual estado será alcanzado ejecutando la acción en un estado particular. Una formulación alternativa es usar una función sucesor S ; dado un estado particular x , $S(x)$ retorna al conjunto de estados alcanzables desde x mediante una acción simple.

El espacio de estado del problema es el conjunto de todos los estados alcanzables a partir del estado inicial mediante una secuencia de acciones cualquiera.

Un camino en el espacio de estado es una secuencia de acciones que conduce de un estado a otro.

El criterio objetivo es el criterio que el agente usa para aplicarlo a la descripción de un estado para determinar si este es un estado objetivo (lo que se desea obtener). Algunas veces hay un conjunto explícito de posibles objetivos y el criterio simplemente consiste en chequear si se ha alcanzado uno de ellos. Otra variante es especificar el objetivo por una propiedad abstracta, por ejemplo, el criterio de jaque mate del ajedrez.

El costo de un camino es una función que asigna un costo a un camino.

Una **solución** es un camino desde el estado inicial a un estado que satisface el criterio objetivo.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Otro concepto importante es el de **costo de la búsqueda** asociado con el tiempo y la memoria requisitos para encontrar una solución.

El **costo total** de la búsqueda es la suma del costo del camino y el costo de la búsqueda.

Ejemplos

El rompecabezas de 8 piezas (8 – puzzle). Consiste en un tablero de 9 casillas (3x3), en 8 de ellas se colocan fichas numeradas del 1 al 8 y una queda en blanco. El juego consiste en alcanzar una posición dada del tablero usando como regla que solo se puede mover una ficha a una casilla adyacente que este vacía. La esencia del rompecabezas es dada cualquier numeración de las casillas obtener una con un orden específico, por ejemplo:



La formulación del problema es:

- ▶ Estados: La descripción de un estado especifica la localización de cada ficha y la del espacio en blanco.
- ▶ Operadores: una ficha se mueve a la izquierda, derecha, arriba o abajo.
- ▶ Criterio objetivo: Los 8 números quedan en un orden especificado.
- ▶ Costo del camino: Cada paso cuesta una unidad.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Este problema a pesar de parecer simple tiene $9! = 362880$ diferentes ordenamientos de los números en blanco, por lo que el método de simplemente generar estados y probar si cumplen el criterio objetivo lleva a una explosión combinatorial.

Búsqueda de soluciones: procedimiento general de búsqueda

Dada la formulación de un problema la próxima acción es encontrar una solución, lo cual como ya se vio, consiste en generar nuevos estados a partir del estado donde se encuentra el agente. El proceso consiste en generar nuevos estados a partir del estado donde se encuentra el agente. Este proceso se denomina expandir el estado. La expansión puede producir uno o varios nuevos estados. En el primer caso se toma este y se continúa, en el otro caso existen múltiples posibilidades para continuar la búsqueda por lo que es necesario una selección.

Esta es la esencia de la búsqueda, seleccionar una opción y poner las otras alternativas a un lado para retomarla más tarde si la primera selección no conduce a una solución. La selección de cual estado expandir primero se determina por la estrategia de búsqueda.

La búsqueda consiste en ir construyendo un espacio de búsqueda (la parte del espacio de estado que deja de ser abstracta). La raíz del espacio de búsqueda se corresponde con el estado inicial.

Los nodos hojas del árbol corresponden a estados que no tienen sucesores en el árbol porque no han sido expandidos o porque no tienen sucesores. En cada paso el algoritmo de búsqueda selecciona un nodo hoja a expandir.

Debe distinguirse entre el espacio de estado y el espacio de búsqueda. Por ejemplo en el problema del viajero vendedor (considerando 20 ciudades) hay solamente 20 estados en el espacio de estado, uno por cada ciudad. Pero hay un número grande de caminos en el espacio de estado de modo que había una gran cantidad de nodos en el espacio de búsqueda.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Un algoritmo de búsqueda general (informal) es el siguiente:

```
function General_Search(Problem, Strategy) return Solucion:
```

```
  Inicializar el árbol de búsqueda usando el estado inicial o Fallar
```

```
  Loop do
```

```
    if no hay nodo que expandir then return Falla
```

```
      Seleccionar un nodo hoja a expandir de acuerdo a la estrategia.
```

```
      if el nodo contiene un estado objetivo
```

```
        then return Solucion
```

```
      else expandir el nodo y añadir los nodos resultantes al espacio de búsqueda.
```

```
    end loop.
```

```
End
```

Representación de los nodos y del espacio de búsqueda

Los nodos pueden ser interpretados de tres formas: como estados del problema simplemente, como subproblemas o como posiciones de un juego. En el segundo caso el espacio se denomina espacio de reducción de problemas y en el tercer caso espacio de juego.

En un espacio de reducción de problemas los nodos representan subproblemas completos. El nodo raíz representa el problema original a ser resuelto y los nodos terminales (hojas) representan problemas que pueden ser resueltos por una primitiva simple, en este caso las acciones son operadores de reducción los cuales descomponen un problema dado en un conjunto de problemas. Un ejemplo es el proceso de integración. Dada la integral:

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

$$\int (x + 2) dx$$

Aplicando el operador que dice: la integral de la suma es la suma de las integrales; se obtienen los nodos sucesores:

$$\int x dx \text{ y } \int 2 dx$$

En un espacio de juego los nodos representan situaciones particulares del juego. El nodo raíz representa la situación inicial del juego y las hojas representan situaciones que son ganadoras, perdedoras o tablas. Las acciones son movimientos o jugadas legales del juego.

El espacio de búsqueda puede representarse mediante un grafo, un árbol o un esquema AND/OR.

Como es conocido el árbol difiere del grafo en que no tiene ciclos, pero esta propiedad lleva a que existan nodos repetidos ocasionalmente. El árbol de búsqueda es la forma más usual de representación.

En el esquema AND/OR las ramas de un nodo a sus sucesores pueden representar dos o más caminos alternativos a subobjetivos. Cuando uno u otro de los caminos conduce al objetivo se denomina al nodo como nodo OR. Sin embargo, en algunos problemas los nodos sucesores representan estados del problema que tienen que ser todos resueltos para alejar el objetivo, estos se denominan nodos AND.

Estrategias de búsqueda

La estrategia de búsqueda define el criterio para seleccionar el siguiente nodo a expandir. La estrategia se evalúa atendiendo a cuatro aspectos:

- ▶ Completitud: ¿Garantiza la estrategia encontrar una solución cuando esta exista?
- ▶ Complejidad del tiempo: ¿Cuánto tiempo requiere encontrar una solución?

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ Complejidad del espacio: ¿Cuánta memoria se necesita para realizar la búsqueda?
- ▶ Optimalidad: ¿Encuentra la estrategia la solución de mayor calidad cuando haya varias soluciones diferentes?

En general y con mucha frecuencia las estrategias de búsqueda son:

- ▶ Búsqueda exhaustiva.
- ▶ Búsqueda a ciegas.
- ▶ Búsqueda informada.



En la búsqueda exhaustiva la idea es examinar el espacio de estado completamente de una manera ordenada, usando todos los operadores y generando todos los sucesores posibles para encontrar la solución deseada.


La búsqueda a ciegas es aquella donde no existe ninguna información para decidir qué nodo expandir, no se conoce la cantidad de pasos o el costo del camino desde el estado actual hasta el objetivo. También se denomina búsqueda no informada. En el otro caso, cuando existe información para decidir, la búsqueda se denomina informada o heurística.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información


El conjunto de métodos que utilizan la estrategia de búsqueda a ciegas se consideran métodos débiles pues imponen restricciones mínimas a la búsqueda y su alta generalidad implica cierta debilidad. Los métodos con estrategia informada se llaman métodos fuertes, ellos son más dependientes del dominio.

Los dos métodos básicos de la búsqueda a ciegas son la búsqueda primero a lo ancho (breadthfirst search) y la búsqueda primero en profundidad (depth-first search).

Una búsqueda primero a lo ancho comienza por generar todos los sucesores de la raíz del nodo. Luego la búsqueda continúa expandiendo todos los nodos de cada nivel. La esencia del método es examinar todas las soluciones potenciales a un nivel antes de pasar al nivel inferior.



La búsqueda primero en profundidad procede generando primeramente un sucesor del nodo raíz y luego un sucesor de este, y continúa extendiendo este camino solamente hasta que termina o se realiza un corte a alguna profundidad, si no se ha alcanzado el objetivo se realiza un retroceso al nivel anterior para generar otro camino.



Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Relación entre la estrategia y la dirección de la búsqueda

Las estrategias y las direcciones de la búsqueda se pueden combinar pues la estrategia define que nodo generar y la dirección determina que contiene cada nodo. En la búsqueda dirigida por datos los nodos contienen los hechos dados como datos iniciales y los que se van infiriendo, mientras en la búsqueda dirigida por objetivos los nodos contienen los objetivos y subobjetivos.

A continuación, se ilustra cómo combinar la búsqueda primero a lo ancho y primero en profundidad con las direcciones dirigida por dato y dirigida por objetivo, a partir del problema siguiente:

Información conocida: a, f.
Objetivo: e.
Acciones:
1: a, b $\rightarrow$ c.
2: c, d $\rightarrow$ e.
3: c, f $\rightarrow$ e.
4: a, f $\rightarrow$ d.
5: a, e $\rightarrow$ b.
6: f $\rightarrow$ c.

Búsqueda bidireccional

La idea principal es realizar simultáneamente dos búsquedas, una dirigida por dato y otra por objetivo y parar cuando ambas se encuentren. Entonces el camino desde el estado inicial se concatena con el inverso del camino desde el estado objetivo para formar el camino solución.

La complejidad en tiempo y espacio de esta búsqueda es $O(b^{(d/2)})$. La búsqueda bidireccional puede reducir enormemente la complejidad en tiempo (para $b=10$ y $d=6$ una búsqueda primero a lo ancho genera 1 111 111 nodos mientras que la bidireccional 2222), pero no siempre es aplicable. Sus requerimientos de memoria pueden ser altos y exige operadores invertibles.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Métodos de solución de problemas a ciegas

Búsqueda primero a lo ancho (breadth-First)

En esta estrategia se expande primero el nodo raíz, luego todos los nodos generados se expanden y así sucesivamente con sus sucesores. En general todos los nodos a la profundidad d en el árbol de búsqueda son expandidos antes de los del nivel $d+1$. Es una estrategia de búsqueda sistemática porque considera todos los caminos de longitud 1 primero, luego todos los de longitud 2, etc. Si existe una solución este método garantiza encontrarla y si hay varias soluciones siempre encontrará la menos profunda en el árbol de búsqueda. En términos del cuarto criterio este método es completo.

Para analizar su costo en tiempo y memoria considerese un espacio de estado donde todo estado puede ser expandido en b nuevos estados, se dice que el factor de ramificación de estos estados (y del árbol de búsqueda) es b . Luego se tendrá b nodos en el primer nivel, b^2 en el segundo, hasta b^d en el nivel d donde se halla la solución, de modo que el número máximo de nodos expandidos antes de encontrar una solución es:

$$1 + b + b^2 + b^3 + \dots + b^d$$

Luego la complejidad es exponencial $O(b^d)$. La complejidad del espacio es la misma que la de tiempo porque todos los nodos hojas del árbol tienen que ser mantenidos en memoria.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Suponiendo $b = 10$, que se pueden chequear y expandir por segundo mil nodos y que un nodo requiere 100 bytes se tiene:

Profundidad	Nodos	Tiempo	Memoria
0	1	1 Milisegundo	100 Bytes
2	111	.1 Segundo	11 Kilobytes
4	11,111	11 Segundos	1 Megabyte
6	10^6	18 Minutos	111 Megabytes
8	10^8	31 Horas	11 Gigabytes
10	10^{10}	128 Días	1 Terabyte
12	10^{12}	35 Años	111 Terabytes
14	10^{14}	3500 Años	11,111 terabytes

De esta tabla se extraen dos conclusiones. Primero, los requerimientos de memoria son mayores que el tiempo de ejecución. Una persona puede esperar 18 minutos por una búsqueda a profundidad 6 pero muchos no tienen los 111 megabytes de memoria que son requeridos.

Segundo, el costo en tiempo es también significativo, pues si la solución está a nivel 12 serían necesarios 35 años.

Este método puede describirse como sigue:

- ▶ P1. Formar una cola de un elemento que contiene el nodo raíz.
- ▶ P2. Iterar a través de (a) a (c) hasta que la cola esté vacía.
 - Chequear si el primer elemento de la cola es una solución.
 - Salir con Exito si el elemento chequeado es una solución.
 - Si no es solución añadir sus hijos al final de la cola.
- ▶ P3. Salir con Fallo si no se encuentra solución.


Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Un medio para implementar este método es usar un conjunto de caminos candidatos.

El procesamiento es:

- ▶ Si el primer camino contiene un nodo objetivo como camino entonces esta es la solución, en otro caso.
- ▶ Remove el primer camino desde el conjunto candidato y generar el conjunto de todas las posibles extensiones de un paso de este camino, añadiendo este conjunto de extensiones al final del conjunto candidato, y ejecutar la búsqueda sobre este conjunto actualizado.

El procesamiento se ilustra con el ejemplo siguiente. Sea el árbol de búsqueda de la figura:



Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

a. Conjunto de camino candidato inicial (CCC)

[[a]]

b. Extensiones

[[b,a] , [c,a]]

c. Remover el primer candidato y generar las extensiones

[[d,b,a] [e,b,a]]

d. CCC

[[c,a] [d,b,a] [e,b,a]]

e. Remover y generar

[[f,c,a] [g,c,a]]

f. CCC

[[d,b,a] [e,b,a] [f,c,a] [g,c,a]]

g. Después de remover y generar [d,b,a] y [e,b,a] se obtiene el CCC.

[[f,c,a] [g,c,a] [h,d,b,a] [j,e,b,a]]

En este Conjunto de Caminos Candidatos el camino inicial tiene como cabeza un estado objetivo, por lo que el proceso termina.

El árbol de búsqueda para el juego de las ocho piezas creado usando la búsqueda primero a lo ancho se muestra en la figura.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Búsqueda con costo uniforme

La búsqueda primero a lo ancho encuentra el estado objetivo menos profundo, pero este no siempre es la solución de menos costo. La búsqueda con costo uniforme modifica la búsqueda primero a lo ancho expandiendo siempre el nodo de menor costo en lugar del nodo menos profundo usando una función $g(n)$ que calcula el costo de un nodo. La búsqueda primero a lo ancho es justamente la búsqueda de costo uniforme cuando:

$$g(n) = Depth(n)$$

Véase el ejemplo siguiente. Se desea encontrar el camino que conduce de S a G. Al expandir S se tiene: A con costo 1, B con costo 5 y c con costo 15. Como A es el más barato este se expande y se obtiene G con costo 11.

Aunque se alcanzó una solución ésta no se reconoce como tal pues existe otro camino con menor costo (S B) todavía no expandido. Se expande B, generándose G con costo 10. Este si se reconoce como solución pues el nodo C no expandido ya tiene un costo superior a este. Ahora se reconoce como solución el camino S B G.

La búsqueda con costo uniforme encuentra la solución más barata bajo el requerimiento: El costo de un camino nunca decrece al alargarse el camino, es decir:

$$g(sucesor(n)) \geq g(n) + cost(n, sucesor(n))$$

Si algún operador tiene costo negativo (si el costo de un nodo se calcula como la suma de los costos de los operadores que sirven para construirlo) sólo una búsqueda exhaustiva podría hallar la solución óptima. Si todos los operadores tienen un costo no negativo la búsqueda con costo uniforme puede encontrar el camino más barato sin explorar el árbol de búsqueda completamente.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Búsqueda primero en profundidad. (Depth-First)

Este método siempre expande uno de los nodos del nivel más profundo del árbol. Solamente cuando la búsqueda alcanza un nodo muerto (nodo no objetivo que no se puede expandir) la búsqueda va a atrás y expande nodos de niveles inferiores.

Esta búsqueda tiene requerimientos de memoria modestos. Solamente almacena un camino de la raíz a un nodo hoja junto con los hermanos de los nodos de este camino a cada nivel. Para un espacio de estado con factor de ramificación b y profundidad máxima m se requiere solamente $b \cdot m$ nodos.

Este método se describe por el siguiente algoritmo:

- ▶ P1. Formar una pila de un elemento que contiene el nodo raíz.
- ▶ P2. Iterar a través de (a) a (c) hasta que la pila esté vacía.
 - Chequear si el elemento del top de la pila es una solución.
 - Salir con Éxito si el elemento chequeado es una solución.
 - Si no es solución añadir sus hijos al tope de la pila.
- ▶ P3. Salir con Fallo si no se encuentra solución.

La principal ventaja de este método es que sus requerimientos de memoria son linealmente proporcionales a la profundidad del árbol. La cantidad de tiempo que consume es la misma que en primero a lo ancho.

Su principal problema es que puede tomar un camino equivocado que, si es muy largo, quizás infinito, no permite encontrar una solución nunca. Muchos problemas tienen árboles de búsquedas muy profundos o incluso infinitos, en cuyo caso este método nunca se podrá recuperar de una selección equivocada en uno de los nodos cercanos a la raíz del árbol.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Otra situación en la que puede caer el método es encontrar una solución con un camino más largo que la solución óptima, es decir, el método no es ni completo, ni óptimo. Este método debe evitarse para árboles de búsquedas muy profundos.

Es un método apropiado cuando los estados objetivos se encuentran a la izquierda del árbol de búsqueda o cuando los caminos son cortos. En la figura 4.3 se muestra su aplicación al juego de las 8 piezas.

Modificaciones a la búsqueda primero en profundidad

Para superar el problema de la búsqueda primero en profundidad dado porque puede tomar un camino que no le permita hallar nunca una solución se han propuesto dos variantes: La búsqueda limitada en profundidad y la búsqueda iterativa primero en profundidad (depth-first iterative-deepening).

La búsqueda limitada en profundidad impone un corte a una profundidad dada del árbol, en el caso de un grafo habrá que añadir un detector de ciclos. Si la profundidad de corte seleccionada es menor que la profundidad de la solución nunca se hallará esta, mientras que si es mayor se paga un precio en memoria y tiempo por esta diferencia. Hay problemas donde resulta claro cuál debe ser la profundidad del corte; por ejemplo, en el problema de hallar un camino entre veinte ciudades si hay solución el camino tendrá menos de veinte pasos obviamente. En casos como el ejemplo anterior este método es completo, pero no óptimo, en otro caso no es ni completo ni óptimo. La complejidad en espacio y tiempo de este método es similar a la búsqueda primero en profundidad. Toma $O(b^l)$ tiempo y $O(b \cdot l)$ espacio, donde l es la profundidad de corte.

Como es difícil seleccionar la profundidad de corte adecuada, incluso conociendo un mapa de las veinte ciudades en el problema anterior podría ser que el corte se pudiera realizar a una profundidad mucho menor, es necesario buscar otro camino para mejorar la búsqueda primero en profundidad.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

La búsqueda iterativa primero en profundidad ofrece este camino manejando la profundidad de corte dinámicamente. Primero realiza una búsqueda a profundidad uno, luego a profundidad dos, y continúa incrementando la profundidad de corte en uno en cada iteración hasta llegar a una solución.

El algoritmo de esta búsqueda es:

- ▶ P1: formar una pila de un elemento consistente en el nodo raíz.
- ▶ P2: iterar de (a) hasta (c) incrementando en uno el nivel del árbol hasta que la pila este vacía.
 - Chequear si el elemento del tope de la pila es una solución.
 - Salir con éxito si el elemento chequeado es solución.
 - Si no es solución, añadir sus hijos solamente al tope de la pila y retornar el nodo raíz.
- ▶ P3: Salir con fallo si no se halla solución.

Este método combina los beneficios de la búsqueda primero en profundidad y primero a lo ancho. Es óptimo y completo como primero a lo ancho y tiene modestos requerimientos de memoria como primero en profundidad. El orden de expansión de los estados es similar a la búsqueda primero a lo ancho, excepto que algunos estados son expandidos múltiples veces, esto puede llevar a pensar que este método es muy gastador, sin embargo, para la mayoría de los problemas esto no es así. Intuitivamente la razón es que en un árbol de búsqueda exponencial casi todos los nodos están en el nivel más bajo de modo que no es significativo que los niveles superiores sean expandidos múltiples veces. En esta búsqueda los nodos del nivel más bajo son expandidos una vez, los del nivel anterior dos veces, y así sucesivamente hasta la raíz del árbol la cual se expande $d + 1$ veces. De modo que la cantidad de expansiones es:

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

$$(d+1)1 + (d)b + (d-1)b^2 + \dots + 3b^{d-2} + 2b^{d-1} + 1b^d$$

Para $b = 10$ y $d = 5$ el número es 123,456.

Este método tiene complejidad de tiempo $O(b^d)$ y de espacio (Ob^d) . En general esta búsqueda es adecuada cuando tenemos un espacio de búsqueda grande y la profundidad de la solución no es conocida.

En la tabla siguiente se muestra una comparación de los MSP estudiados.

Criterio	Primero a lo ancho	Costo uniforme	Primero en profundidad	Limitado en profundidad	Iterativo a profundidad	Bidireccional
Tiempo	b^d	b^d	b^n	b^l	b^d	$b^{d/2}$
Espacio	b^d	b^d	$b \cdot m$	$b \cdot l$	$b \cdot d$	$b^{d/2}$
¿Óptimo?	si	si	no	no	si	Si
¿Completo?	si	si	no	Si si $l \geq d$	si	si

Evitar nodos repetidos

Una de las más importantes complicaciones del proceso de búsqueda es la posibilidad de perder tiempo expandiendo estados que ya han sido encontrados y expandidos antes. Para algunos problemas esta posibilidad no existe pues cada estado puede ser solamente alcanzado por un camino. La formulación eficiente del problema de las ocho reinas es eficiente en gran parte por eso. Sin embargo, para muchos problemas los estados repetidos son inevitables. Esto incluye todos los problemas donde los operadores son reversibles, tales como el problema de las carreteras y el problema de misioneros o caníbales.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Los árboles de búsqueda para estos últimos problemas son infinitos, pero si eliminamos algunos de los estados repetidos podemos cortar el árbol de búsqueda a un tamaño finito. Hay tres alternativas para atacar los estados repetidos, en orden creciente de efectividad y costo computacional son:

- ▶ No retornar al estado de donde se viene, es decir, no generar ningún sucesor que sea el mismo estado que el nodo padre.
- ▶ No crear caminos con ciclos. No generar ningún sucesor de un nodo que coincida con alguno de sus antecesores.
- ▶ No generar ningún estado que haya sido generado antes. Esto requiere mantener en memoria todo estado generado, resultando en una complejidad potencial del espacio de $O(b^d)$

Para implementar esta última opción los algoritmos de búsqueda fundamentalmente hacen uso de una tabla hash que almacena todos los nodos que son generados. Esto hace el chequeo de estados repetidos razonablemente eficiente.

Búsqueda de soluciones múltiples

Encontrar todas las soluciones a un problema garantiza encontrar la solución óptima, pero requiere una búsqueda exhaustiva, por lo que generalmente lo que se hace es buscar más de una solución. Dos formas de implementar la búsqueda de más de una solución son:

- ▶ a) Remover el camino de búsqueda.
 - i. Se calcula una solución por algún método de búsqueda
 - ii. Se elimina del árbol de búsqueda todos los nodos que forman parte del camino de la solución encontrada en (i.).
 - iii. Repetir desde (i.)

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ b) Remover el último nodo del camino.

La única diferencia respecto al anterior es que en (ii.) sólo se elimina del árbol de búsqueda el último nodo del camino de la solución encontrada en (i.).

Una vía para implementar la eliminación de nodos es añadir a cada operador una bandera de usado o no. Para la variante (a) eso significa marcar como usados todos los operadores que fueron aplicados para generar todos los nodos desde la raíz hasta el objetivo alcanzado y luego desarrollar un nuevo proceso de búsqueda. Una variante puede ser sólo marcar el operador que generó el sucesor del nodo raíz incluido en la solución. Para la variante (b) significa marcar como usado el operador que fue aplicado al penúltimo nodo del camino solución y repetir la búsqueda desde ese nodo.

La elección de cuál de las dos variantes tomar se puede basar en el valor del factor de ramificación b . Si b es pequeño la variante (b) puede llevar a muchos retrocesos perdidos, por el contrario, para b grande puede ser efectiva. Como b es un valor promedio de todo el árbol de búsqueda es posible que se pueda determinar su comportamiento en secciones del árbol, por ejemplo, en el juego del ajedrez el comportamiento de b es:

- ▶ En las aperturas: pequeño.
- ▶ En el medio juego: enorme
- ▶ En los finales: pequeño

Esto indica que la búsqueda de caminos alternativos se podría hacer marcando como usados los operadores que están al final del juego, es decir reiniciando la partida del medio juego en lo adelante. Nótese que la búsqueda de soluciones múltiples puede ser útil sobre todo en la búsqueda a ciegas o en métodos heurísticos que no garanticen encontrar la solución óptima.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Métodos de Solución de Problemas con información adicional. Búsqueda por diferencias

El proceso de análisis por reducción de diferencias (*means-end analysis* MEA) consiste en detectar diferencias entre el estado actual y el estado meta; una vez que se ha aislado una diferencia debe encontrarse un operador que pueda reducirla. Pero quizás el operador no pueda aplicarse al estado actual, por tanto, se establece un subproblema que consiste en llegar a un estado en que pueda aplicarse dicho operador. Quizás el operador no produzca exactamente el estado objetivo deseado, en cuyo caso se tiene el segundo subproblema de llegar desde el estado producido por el operador hasta la meta. Si la diferencia se ha escogido correctamente y el operador es realmente efectivo en la reducción de la diferencia debe ser más fácil resolver los dos subproblemas que el problema original. El proceso de reducción de diferencias puede tratarse recursivamente. Las diferencias deben ser atendidas en orden de prioridad.

El primer programa de I.A. que explotó el análisis de diferencias fue el Solucionador General de Problemas de Newell y Simon en 1963.

Para desarrollar la búsqueda es necesario un conjunto de reglas que puedan transformar un estado del problema en otro. En la condición de las reglas se establecen las condiciones que deben verificarse para poder aplicar la regla, en el consecuente de la regla se definen aquellos aspectos del estado del problema que cambiarán al aplicar la regla. Además, se usa una tabla de diferencias que describe cuando es apropiado cada operador. Una diferencia puede ser resuelta por más de un operador y un operador puede reducir más de una diferencia.

La reducción de diferencias se puede ilustrar con el ejemplo del trabajo del robot.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Operator	Preconditions	Results
PUSH(obj,loc)	At(robot,obj) $\wedge$ Large(obj) $\wedge$ Clear(obj) $\wedge$ Armempty	At(obj,loc) $\wedge$ At(robot,loc)
CARRY(obj,loc)	At(robot,loc) $\wedge$ Small(obj)	At(obj,loc) $\wedge$ At(robot,loc)
WALK(loc)		At(robot,loc)
PICKUP(obj)	At(robot,obj)	Holding(obj)
PUTDOWN(obj)	Holding(obj)	$\neg$ holding(obj)
PLACE(obj1,obj2)	At(robot,obj2) $\wedge$ Holding(obj1)	On(obj1,obj2)

	Push	Carry	Walk	Pickup	PutDown	Place
Move object	*	*				
Move robot			*			
Clear object				*		
Get object on object						*
Get arm empty					*	*
Be holding object				*		

Supongamos que estando el robot en su dominio se le plantea el problema de mover un escritorio, con dos cosas encima, de una habitación a otra. Los dos objetos también deben moverse. La principal diferencia entre el estado inicial y el objetivo es la situación del escritorio. Para reducir esta diferencia se pueden usar los operadores PUSH y CARRY. Para aplicar CARRY es necesario reducir dos diferencias para establecer sus condiciones: la localización del robot y el tamaño del escritorio. La primera se resuelve con el operador WALK. Pero no tenemos operadores para reducir la segunda. Luego es necesario aplicar PUSH. Para aplicar este operador es necesario que el robot este junto al escritorio (para lo cual se usa WALK), el objeto tiene que ser grande (lo cual se tiene), el objeto tiene que estar libre (para lo cual se aplican dos veces PICKUP y PUTDOWN) y el brazo del robot debe estar libre (lo cual se tiene). La secuencia de operadores a aplicar:

- ▶ WALK
- ▶ PICKUP
- ▶ PUTDOWN

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ PICKUP
- ▶ PUTDOWN
- ▶ PUSH
- ▶ PLACE

Un procedimiento para la búsqueda por diferencias es el siguiente:

Algoritmo MEA (Current, Goal)

- ▶ Comparar Current con Goal. Si no hay diferencias entre ellos entonces return.
- ▶ En otro caso, seleccionar la diferencia más importante y reducir esta haciendo los siguiente hasta alcanzar éxito o falla
- Seleccionar un operador O que es aplicable a la diferencia actual. Si no existe tal operador entonces retornar con falla.
- Intentar aplicar O a Current. Generar las descripciones de dos estados: O_Start, un estado en el cual se satisfacen las condiciones del operador O y O_Result, el estado resultante de aplicar el operador O al estado O_Start.
- Si First_Part := MEA(Current, O_Start) y Last_Part := MEA(O_Result, Goal) son exitosos entonces retornar éxito y el resultado de concatenar First_Part, O y Last_Part

El procedimiento **Solucionador General de Problemas** (General Problem Solving o GPS) se basa en este método. Dadas las variables globales S y G, las cuales contienen las descripciones del estado inicial y objetivo respectivamente el procedimiento GPS se formula recursivamente de la forma siguiente:

Recursive procedure GPS(S)

- ▶ **Until** S sea equivalente a G, **do**

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

► Begin

- $D :=$ Una diferencia entre S y G
- $F :=$ una regla relevante para reducir D
- $P :=$ Condición de F
- GPS(P)
- $S :=$ Resultado de aplicar F a S

► End.

Posteriormente se verá como los métodos de planificación son una variante de la reducción por diferencias.

Satisfacción de restricciones

Un problema de satisfacción de restricciones (PSR) es una clase especial de problema que satisface algunas propiedades estructurales más allá de los requerimientos básicos para problemas en general. Muchos problemas de la I.A. pueden observarse como problemas de satisfacción de restricciones en donde la meta es descubrir algún estado del problema que satisfaga un conjunto dado de restricciones. Los problemas de satisfacción de restricciones (Constraint Satisfaction Problem) no requieren un método de búsqueda propio; pueden resolverse usando otras estrategias de búsqueda.

En los PSR los estados se definen por los valores de un conjunto de variables y el criterio objetivo especifica un conjunto de restricciones que los valores tienen que cumplir. Una solución a un PSR da valores para todas las variables de modo que se satisfacen las restricciones.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Formalmente un PSR se describe mediante tres componentes: las variables, un dominio para cada variable y las restricciones. Las restricciones pueden ser absolutas o de preferencia; en el primer caso no se pueden violar, en el otro resulta conveniente que se cumplan.

En una búsqueda para un PSR el estado inicial contiene todas las variables desvalorizadas, con excepción quizás de aquellas valorizadas como datos iniciales. Usando los operadores se irán asignando valores a cada variable a partir del dominio definido para esta. Note que la profundidad máxima del árbol de búsqueda es n , la cantidad de variables, y todas las soluciones están a profundidad n .

La búsqueda primero en profundidad para un PSR se desarrolla de la forma siguiente:

- ▶ P1. Establecer como estado inicial aquel donde todas las variables están desvalorizadas (excepto los datos iniciales).
- ▶ P2. Generar un nuevo estado aplicando uno de los operadores posibles. Si no hay operadores posibles terminar con Fallo si el estado actual es el inicial, sino retroceder al padre de este.
- ▶ P3. Chequear si el estado generado cumple las restricciones. Si no cumple alguna restricción retornar al paso anterior.
- ▶ P4. Si cumple las restricciones y todas las variables tienen valor retornar Éxito, si no hacer este estado actual y regresar a P2.

Un PSR puede terminar en tres situaciones:

- ▶ Se encontró una solución que satisface todas las restricciones.
- ▶ No es posible hallar una solución pues se llega a un estado en que sólo cambiando los datos iniciales es posible encontrar una solución.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ No es posible hallar una solución pues se llega a un estado en que no se puede avanzar más pues no hay operadores aplicables al tener operandos sin valor (lo cual indica que faltan datos iniciales).

Búsqueda Heurística

Los métodos de búsqueda heurísticas están orientados a reducir la cantidad de búsqueda requerida para encontrar una solución. Cuando un problema es presentado como un árbol de búsqueda el enfoque heurístico intenta reducir el tamaño del árbol cortando nodos pocos prometedores. Estos métodos se llaman métodos fuertes porque ellos son más poderosos que los estudiados hasta aquí al incorporar conocimiento heurístico o heurística. Hay una contradicción entre generalidad y potencia en el sentido que los métodos débiles son esencialmente aplicables universalmente mientras que los fuertes son menos universales en su aplicabilidad y el conocimiento o heurística usado en un problema dado puede no ser totalmente aplicable o ser inaplicable en otro dominio o tarea.

Feigenbaum y Feldman definen la heurística como sigue: “Una heurística es una regla para engañar, simplificar o para cualquier otra clase de ardid el cual limita drásticamente la búsqueda de soluciones en grandes espacios de estados”. En esencia una heurística es simplemente un conjunto de reglas que evalúan la posibilidad de que una búsqueda va en la dirección correcta. Generalmente los métodos de búsqueda heurísticas se basan en maximizar o minimizar algunos aspectos del problema. Un ejemplo sencillo de heurística es el siguiente:

Un hombre se encuentra en una extensa llanura y tiene sed, en ese momento ha llegado a una pequeña elevación que es la única en esa región y se sube a ella. Desde la elevación el hombre observa el cuadro siguiente:

- ▶ NORTE: vegetación verde y movimiento de animales
- ▶ SUR: vegetación amarilla

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ ESTE: vegetación amarilla
- ▶ OESTE: vegetación verde

Evidentemente la vegetación verde es un indicio de que hay humedad, luego es muy probable que exista agua en la superficie o subterránea. El movimiento de animales puede indicar que ellos se dirigen allí a beber, lo cual sugiere que el agua está en la superficie. Esta información le dice al hombre que debe dirigirse al norte, constituye una heurística.

La Heurística no garantiza que siempre se tome la dirección de la búsqueda correcta, por eso este enfoque no es óptimo sino suficientemente bueno. Frecuentemente son mejores los métodos heurísticos que los métodos de búsquedas a ciegas. Las desventajas y limitaciones principales de la heurística son:

- ▶ La flexibilidad inherente de los métodos heurísticos puede conducir a errores o a manipulaciones fraudulentas.
- ▶ Ciertas heurísticas se pueden contradecir al aplicarse al mismo problema, lo cual genera confusión y hacen perder credibilidad a los métodos heurísticos.
- ▶ Soluciones óptimas no son identificadas. Las mejoras locales determinadas por las heurísticas pueden cortar el camino a soluciones mejores por la falta de una perspectiva global. La brecha entre la solución óptima y una generada por heurística puede ser grande.

El significado técnico de la palabra heurística ha variado en la historia de la Inteligencia Artificial. En 1957, George Polya en su libro "How to solve it" usó este término para referirse al estudio de métodos para descubrir e inventar técnicas de solución de problemas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

En otras ocasiones se ha usado como un término opuesto a algorítmico. Por ejemplo, Newell, Shaw y Simon plantearon en 1993 “Un proceso que puede resolver un problema dado, pero no ofrece garantía de hacerlo, es llamado una heurística para ese problema”.

Actualmente, la heurística es más frecuentemente usada como un adjetivo para referirse a cualquier técnica que mejore la media del proceso de solución de problemas.

Según Shapiro, uno de los resultados empíricos de los últimos treinta años de la Inteligencia Artificial es que para muchos problemas la relación (balance) entre conocimiento, tiempo de cálculo y calidad de la solución es bastante favorable. Es decir, el uso de una pequeña cantidad de conocimiento específico del problema puede mejorar significativamente la calidad de la solución o el costo del proceso de búsqueda.

Funciones de evaluación heurística

Una función de evaluación heurística es una función que hace corresponder situaciones del problema con números. Es decir, da una medida conceptual de la distancia entre un estado dado y el estado objetivo. Estos valores son usados para determinar cuál operación ejecutar a continuación, típicamente seleccionando la operación que conduce a la situación con máxima o mínima evaluación.

Algunas consideraciones sobre las funciones heurísticas son:

- ▶ La función debe dar un estimado útil y realista del mérito de un estado particular.
- ▶ La evaluación de la función en general no debe requerir un gran cálculo en su aplicación. Si la evaluación de la función es computacionalmente compleja puede ser más eficiente hacer una búsqueda a ciegas en lugar de gastar recurso (tiempo y memoria) en el cálculo de la función.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información


- ▶ Frecuentemente el costo de una solución exacta a un problema flexibilizado es una buena heurística para el problema original. Un problema flexibilizado es uno obtenido a partir del problema original simplificando las restricciones sobre los operadores. La idea es que el número exacto de movimientos requeridos para resolver un problema más simple puede ser fácil de calcular y puede servir como un estimado de la cantidad de movimientos necesarios para resolver el problema original.
- ▶ Es siempre mejor usar una función heurística con valores más altos que otras, siempre que esta no este sobreestimada. Para un problema puede haber una colección de heurísticas admisibles $h_1, \dots, h_m$. Si una de ellas domina a las otras, es decir alcanza valores mayores para todos los nodos, se debe seleccionar esta. Si ninguna es dominante lo mejor es definir una heurística compuesta de la forma siguiente: $h(n) = \max(h_1(n), \dots, h_m(n))$. De esta forma h dominará todas la heurísticas individuales.
- ▶ Otra forma de inventar una buena heurística es usar información estadística. Esto puede ser hecho realizando una búsqueda sobre una cantidad de problemas de entrenamiento, por ejemplo, en el juego de las ocho piezas cien configuraciones generadas aleatoriamente.
- ▶ Frecuentemente es posible seleccionar rasgos de un estado que contribuyen a su evaluación heurística. La función de evaluación heurística puede ser construida como una combinación lineal de estos rasgos. Los rasgos pueden tener un peso que indique su importancia.
- ▶ Otro tipo de modelo flexibilizado para un problema son los modelos analógicos. Aquí el modelo auxiliar flexibilizado extrae su potencia no de simplificar la estructura del problema a resolver sino de usar procesos de búsqueda que fueron empleados con éxito en problemas análogos. Esto se retoma posteriormente al estudiar el razonamiento por analogía.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Ejemplos de heurísticas en la solución de problemas

El problema de las ocho reinas:

Asumiendo la variante incremental del juego, es decir poner las reinas una a una de modo que no se ataquen mutuamente, supóngase que se tienen situadas tres reinas y tenemos que decidir dónde colocar la cuarta. El papel de la heurística aquí sería ofrecer un criterio para decidir cuál de las tres posiciones indicadas es la más promisoría de conducir a una solución satisfactoria.



Al deducir una heurística para este problema podemos razonar que para poder colocar las ocho reinas tenemos que dejar libres la mayor cantidad de opciones como sea posible para futuras adiciones de reinas.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Esto significa determinar la cantidad de casillas en las filas no utilizadas que quedarían no atacadas al colocar la cuarta reina en A, B o C. Una casilla candidata será preferida si deja la mayor cantidad de casillas no atacadas en el resto del tablero. Consecuentemente el número de casillas no atacadas constituye una medida de su mérito, es decir, es la función de evaluación heurística para este problema.

Al calcular la función heurística para las posiciones A, B y C se tiene:

$$f(A) = 8$$

$$f(B) = 9$$

$$f(C) = 10$$

Otra alternativa o enfoque heurístico es el siguiente. Las filas no usadas no tienen igual estatus ya que aquellas con pocas casillas no atacadas tienden a quedar bloqueadas más rápidamente que filas con muchas casillas no atacadas. Consecuentemente, si queremos minimizar la posibilidad de un futuro bloqueo debemos focalizar nuestra atención sobre la fila con menor número de casillas no atacadas, sea f' esta heurística. Para esta función tenemos:

$$f'(A) = 1$$

$$f'(B) = 1$$

$$f'(C) = 2$$

Nótese que con esta heurística C también es la alternativa preferida. Además, si alguna opción candidata toma valor cero para f o f' no tiene sentido considerarla pues eventualmente será un nodo muerto, la función f' supera a f en que esta detecta todos los nodos muertos predichos por f y muchos más.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información


Algoritmo *Best-First*

La búsqueda por el mejor nodo es una forma de combinar las ventajas de las búsquedas en profundidad y a lo ancho en un único método. En cada paso del proceso de búsqueda se selecciona el más prometedor de aquellos nodos que se han generado hasta el momento. Entonces este se expande usando los operadores para generar sus sucesores. Si uno de ellos es una solución se termina. Si no, todos esos nuevos nodos se añaden al conjunto de nodos generados hasta ese momento. Se selecciona de nuevo el nodo más prometedor y el proceso continúa. La selección del nodo a expandir es independiente de la posición en que nos encontramos en el árbol de búsqueda y de la posición del nodo más prometedor. Lo que sucede usualmente es que se realiza un poco de búsqueda a profundidad mientras se explora una rama prometidora. En un momento dado esa rama comienza a ser menos prometidora que otras de más alto nivel que se han ignorado hasta ese momento.

El nombre de búsqueda primero el mejor (Best-First Search) es impreciso. Si realmente pudiéramos expandir el mejor nodo primero no sería una búsqueda sino un procedimiento directo al estado objetivo. Este método se describe de la forma siguiente:

- ▶ P1: Formar una pila de un elemento consistente en el nodo raíz.
- ▶ P2: Iterar a través de (a) a (c) hasta que la pila sea vacía.
 - (a) Chequear si el elemento en el Top de la pila es solución.
 - (b) Salir con éxito si es solución.
 - (c) Si no es solución, añadir sus sucesores a la pila y reordenar la pila por el estimado de la distancia al objetivo desde cada nodo.
- ▶ P3: Salir con falla si no se encuentra solución.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información



Donde i denota el orden de generación, j el orden de procesamiento y k el costo.

Realmente la búsqueda primero el mejor es una familia de métodos de solución de problemas heurísticos que se distinguen por su función objetivo.

La descripción siguiente para el algoritmo Best-First es común a todos los miembros de esta familia.

- ▶ P1: Poner el nodo inicial S sobre una lista llamada Open de nodos no expandidos.
- ▶ P2: Si Open es vacía salir con fallo.
- ▶ P3: Remover de Open un nodo n para el cual f es mínima y colocar este sobre una lista llamada Closed de nodos expandidos.
- ▶ P4: Expandir el nodo n , generar todos sus sucesores colocándoles apuntadores a n
- ▶ P5: Si alguno de los sucesores de n es un nodo objetivo, salir con éxito construyendo la solución mediante los enlaces establecidos del objetivo hasta S
- ▶ P6: Para cada sucesor n' de n :
 - a) calcular $f(n')$
 - b) si n' no está en Open ni en Closed añadirlo a Open. Colocar un puntero desde n' a n . Asignar $f(n')$ al nodo n' .

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- c) Si n' está en Open o en Closed, comparar el nuevo valor $f(n')$ con el valor previamente asignado a n' . Si el viejo valor es menor, ignorar el nodo recién generado. Si el nuevo valor es menor sustituir el viejo por este (ahora n' debe apuntar a n en lugar de a su predecesor previo). Si el nodo n' residía en Closed pasarlo para Open.

► P7: Ir a P2.

En el paso 6c se evitan los nodos repetidos. Todos los nodos interiores del árbol de búsqueda están en Closed.

Una de las formas más simples para la función f es el costo estimado para alcanzar el objetivo desde el nodo que se evalúa. Es decir, la estrategia es expandir primero el nodo cuyo estado se valora como más próximo al estado objetivo.

La búsqueda golosa frecuentemente trabaja bastante bien. Ella tiende a encontrar soluciones rápidamente, aunque no siempre encuentre la óptima como se mostró en el ejemplo anterior. Esta búsqueda sufre de los mismos defectos que la búsqueda primero en profundidad, no es óptima y es incompleta. En el peor caso su complejidad en tiempo es $O(b^m)$ donde m es la máxima profundidad del espacio de búsqueda. Como mantiene todos los nodos en memoria su complejidad en espacio es la misma que respecto al tiempo. Estas complejidades se reducen sustancialmente con una buena función heurísticas.

Búsqueda A*

La variante anterior minimiza el costo estimado al objetivo, $h(n)$ y reduce el costo de la búsqueda considerablemente, pero no es ni óptima ni completa. Por otro lado, si recordamos la búsqueda con costo uniforme estudiada antes, vemos que ella minimiza el costo del camino hasta el nodo n desde el nodo inicial S , $g(n)$; Ella es óptima y completa, pero puede ser muy ineficiente. Una buena alternativa es combinar ambas estrategias para tomar sus ventajas. Eso puede hacerse

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

simplemente combinando las dos funciones de evaluación mediante la suma, así se obtiene: $f(n) = g(n) + h(n)$

Como $g(n)$ da el costo del camino del nodo inicial al nodo n , y $h(n)$ es el estimado del costo del camino más barato desde n hasta el nodo objetivo, entonces $f(n)$ es el costo estimado de la solución más barata a través de n . Se puede probar que esta estrategia es completa y óptima siempre que la función h nunca sobrestime el costo de alcanzar el objetivo. En este caso h se denomina una heurística admisible. Las heurísticas admisibles son por naturaleza optimistas porque ellas piensan que el costo de resolver el problema es menor que lo que es realmente. Este optimismo se transfiere a la función f ; si h es admisible $f(n)$ nunca sobrestimará el costo real de la mejor solución a través de n .

La búsqueda primero el mejor que usa f como función de evaluación y una función h admisible se conoce como búsqueda A^* . La distancia aérea (equivalente a la distancia en línea recta entre dos puntos del mapa) es un ejemplo de heurística admisible.

Algoritmo A^*

- ▶ P1: Colocar el nodo inicial S en Open
- ▶ P2: Si Open es vacío salir con fallo.
- ▶ P3: Remover de Open y Colocar en Closed un nodo n para el cual f es mínimo.
- ▶ P4: Si n es un nodo objetivo salir con éxito con la solución obtenida a partir de los enlaces desde n hasta S .
- ▶ P5: En otro caso expandir n generando todos su sucesores, y asignándoles punteros hacia n . Para todo sucesor n' de n :
 - a) si n' no está ni en open ni en closed estimar $h(n')$ (un estimado del costo del mejor camino desde n' a algún nodo objetivo), y calcular $f(n') = g(n') + h(n')$ donde $g(n') =$

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

$$g(n) + c(n, n'), \text{ y } g(S) = 0$$

- b) si n' está en Open o Closed entonces dirigir sus apuntadores al camino que produce el menor $g(n')$
 - c) si n' requirió ajustar los apuntadores y fue encontrado sobre closed entonces reabrirlo.
- P6: Ir a P2.

Ascensión de colinas. (Hill Climbing)

Existe un conjunto de problemas para los cuales el camino que conduce a la solución es irrelevante. Usualmente esto ocurre en aquellos problemas en los que la descripción del estado contiene toda la información necesaria para una solución. La idea general es comenzar con una configuración completa y hacer modificaciones para mejorar su calidad. Por ejemplo, en el juego de las 8 reinas a partir de una distribución de estas sobre el tablero las mismas se van moviendo tratando de reducir el número ataques.

El método de búsqueda conocido por ascensión de colinas (hill-climbing) toma su nombre de la semejanza que tiene con un alpinista quien desea alcanzar rápidamente el pico de una montaña, este selecciona la dirección de ascenso mayor a partir de la posición actual.

Con este método la estrategia es repetidamente expandir un nodo, inspeccionar sus sucesores recién generados, y seleccionar y expandir el mejor entre los sucesores sin mantener referencias a los padres.

Este método es una variación de la búsqueda primero en profundidad en la cual se usa la función heurística para estimular la distancia entre el nodo actual y el nodo objetivo. Por ejemplo, la distancia área en el problema del mapa. La siguiente descripción del método muestra la semejanza con la búsqueda en profundidad:

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ P1. Formar una pila de un elemento consistente del nodo raíz.
- ▶ P2. Iterar de (a) a (c) hasta que la pila este vacía.
 - a. Chequear si el elemento del top de la pila es una solución.
 - b. SALIR con ÉXITO si el elemento chequeado es solución.
 - c. Si el primer elemento no es solución ordenar los descendientes del mismo según la distancia restante al objetivo y luego añadir el hijo al top de pila.
- ▶ P3. Salir con Falla.

Como se aprecia la diferencia entre la descripción de ambos métodos radica en el paso 2c.

Otra descripción es la siguiente:

- ▶ P1. Evaluar el estado inicial. Si es objetivo SALIR con ÉXITO.
- ▶ P2. Iterar hasta encontrar una solución o hasta que no haya nuevos operadores aplicables al estado actual.
 - a. Seleccionar un operador todavía no aplicado al estado actual y aplicarlo para producir un nuevo estado.
 - b. Evaluar el nuevo estado. i. Si es objetivo SALIR con ÉXITO. ii. Si es mejor que el estado actual hacerlo estado actual. iii. Si no es mejor que el actual continuar en el lazo.

Algunas observaciones sobre el método son:

- ▶ Cuando se llega a un nodo muerto no hay forma de hacer retroceso (salvo generar otro nodo raíz).
- ▶ Es usado cuando existe una buena función heurística.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

- ▶ La estrategia es llamada irrevocable porque el proceso no nos permite virar la atención hacia alternativas previamente suspendidas.
- ▶ La estrategia es también útil en problemas donde los operadores poseen un cierto tipo de independencias llamada conmutatividad, una condición en la cual la aplicación de un operador no afecta la aplicabilidad de otros operadores.

Recocido simulado. (Simulated annealing)

El recocido simulado (simulated annealing) es una variación del método hill climbing el cual al inicio del proceso puede realizar algunos movimientos de descenso. La idea es hacer una exploración que permita que la solución final sea relativamente insensible al estado inicial. Esto también disminuye la posibilidad de caer en un máximo local, una meseta o una cresta.

Este método está inspirado en el proceso físico de recocido, en el cual las sustancias físicas tales como los metales son fundidos (elevando su temperatura) y luego se enfrían gradualmente hasta alcanzar el estado sólido. El objetivo de este proceso es producir un estado final de mínima energía. En este proceso los cambios son graduales usualmente hacia abajo, pero pueden ocurrir movimientos de ascensos de la energía con probabilidad: $P = e^{-\Delta E/kT}$ donde ΔE es el cambio positivo en el nivel de energía, T es la temperatura y k la constante de Boltzmann. La probabilidad de que ocurra un movimiento de ascenso de la energía decrece a medida que la temperatura decrece. Por eso tales movimientos son más posibles al inicio del proceso cuando la temperatura es alta y menos probable al final.

Una característica de este proceso es que en cualquier momento pueden ocurrir movimientos de ascenso, aunque con menos probabilidad y magnitud al final del proceso hasta que finalmente el proceso converge a un mínimo.

El proceso es gobernado por el parámetro T. El plan de cómo variar T se denomina esquema de recocido. Un enfriamiento demasiado rápido puede llevar a regiones

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

estables de alta energía (mínimos locales en lugar de globales). Un enfriamiento lento propicia alcanzar con más seguridad una estructura uniforme (mínimo global), pero si es demasiado lento se pierde tiempo. El esquema de recorrido óptimo para cada problema particular tiene que ser descubierto empíricamente.

Se puede establecer una analogía de este proceso físico con un proceso de búsqueda hill-climbing. En él ΔE representa el cambio en la función heurística, y el término kT se integra sólo en T . La diferencia principal de este algoritmo con respecto al hill-climbing es que se admite con cierta probabilidad movimiento a estados peores que el actual.

Algoritmo:

- ▶ P1. Evaluar el estado inicial. Si es objetivo SALIR con ÉXITO, sino hacerlo estado actual.
- ▶ P2. Asignar a BEST-SO-FAR el estado actual.
- ▶ P3. Inicializar T según el esquema de recocido.
- ▶ P4. Iterar hasta encontrar una solución o hasta que no haya nuevos operadores aplicables al estado actual.
 - a) Seleccionar un operador no usado y aplicarlo al estado actual para producir un nuevo estado.
 - b) Evaluar el nuevo estado. Calcular: $\Delta E = (\text{valor del estado actual}) - (\text{valor del nuevo estado})$. Si el nuevo estado es objetivo, SALIR con ÉXITO. Si no es objetivo, pero es mejor que el actual, hacerlo actual. Asignarlo a BEST-SO-FAR. Si no es mejor entonces calcular $P' = e^{-\Delta E/T}$ Generar un número aleatorio a en el rango $[0,1]$. Si $a < p'$ entonces hacer el movimiento.
 - c) Revisar T de acuerdo con el esquema de recorrido.
- ▶ P5. Retornar BEST-SO-FAR como la respuesta.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

El esquema de recorrido tiene tres componentes. La primera es el valor inicial para T. El segundo el criterio para decidir cuándo reducir la T. El tercero es la cantidad para la cual T debe ser reducida cada vez que sea cambiada.

El recorrido simulado también ha servido para construir modelos de redes neuronales artificiales, como la Máquina de Boltzmann.

Hasta aquí hemos visto los métodos que se consideran clásicos en la solución de problemas en Inteligencia Artificial y veremos a continuación algunos ejemplos de como lucen en la práctica resolviendo problemas llamados modelos, tales como el “Problema del Viajero Vendedor” y el “Problema de la Mochila”.

Solución al problema del viajero vendedor usando Hill-Climbing

El problema del viajero vendedor, consiste en que tenemos un vendedor que necesita visitar varias ciudades exactamente una vez, después de lo cual regresa a la primera ciudad. Se conocen las distancias entre cada par de ciudades y necesitamos encontrar la ruta más corta. Como puede imaginar, hay una gran cantidad de posibles soluciones (rutas) para un problema específico del viajero vendedor; el objetivo es encontrar la mejor solución (es decir, la más corta).

Si, tenemos 8 ciudades, entonces habrán $(8 - 1)! = 5040$ posibles soluciones, que se lee, el factorial de 8-1. En Python este se calcula de la siguiente forma:

```
import math

print(math.factorial(9))
```

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información




Figura 47. Representación gráfica del problema del viajero vendedor, para 4 ciudades.

Hill Climbing intenta encontrar la mejor solución a este problema comenzando con una solución aleatoria y luego generando vecinos: soluciones que solo difieren ligeramente de la actual. Si uno de los vecinos es mejor (es decir, más corto) que el actual, reemplaza la solución actual con esta mejor solución. Luego repite el proceso creando nuevamente vecinos. Si en algún momento ningún vecino es mejor que la solución actual, devuelve la solución actual. ¡Eso es todo! El algoritmo es bastante simple, pero hay que decir que no siempre encuentra la mejor solución. Puede atascarse en un máximo local: un lugar donde la solución actual no es la mejor solución al problema, pero donde ninguno de los vecinos directos de la solución actual es mejor que la solución actual. Como se describe, el algoritmo se detendrá en ese punto, desafortunadamente sin devolver la mejor solución. Existen algoritmos más complicados que tienen una mayor probabilidad de encontrar la mejor solución, pero a menudo requieren más recursos computacionales.

Para implementar esta solución en Python, debemos iniciar codificando los valores de las distancias entre cada una de las ciudades en forma de matriz.

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

```
tsp
= [
    [0, 400, 500, 300],
    [400, 0, 300, 500],
    [500, 300, 0, 400],
    [300, 500, 400, 0]
]
```

Crear un generador de soluciones aleatorias

Para que Hill Climbing funcione, tiene que comenzar con una solución aleatoria a nuestro problema del viajero vendedor. A partir de ahí, puede generar soluciones vecinas e iniciar el proceso de optimización. ¿Cómo debemos diseñar tal solución? Bueno, una solución al problema del viajero vendedor podría ser simplemente una lista de identificadores de todas las ciudades, en el orden en que el vendedor debería visitarlas. Cada ciudad tiene que ser visitada exactamente una vez. Por lo tanto, primero creemos una lista de identificadores de todas las ciudades (llamadas ciudades en el código a continuación) y, a partir de ahí, elijamos iterativamente una ciudad de esa lista al azar y agréguela a nuestra solución. La función de rango de Python es excelente para crear ciudades, ya que crea un rango de todos los números desde 0 hasta el argumento dado, que en este caso es la longitud del problema en sí, ya que el problema en sí contiene una entrada para cada ciudad.

Dado que cada ciudad solo se puede visitar una, después de agregar su identificador a nuestra solución, eliminamos el identificador de esa ciudad de la lista de identificadores de ciudades. Nuestra función necesita el propio problema del viajero vendedor para obtener información sobre las distancias entre ciudades. Vea el código a continuación (tenga en cuenta que necesitará importar `random` para que esto funcione):

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

```
#####
def randomSolution(tsp):
    cities = list(range(len(tsp)))
    solution = []

    for i in range(len(tsp)):
        randomCity = cities[random.randint(0, len(cities) - 1)]
        solution.append(randomCity)
        cities.remove(randomCity)

    return solution
```

Crear una función que calcule la longitud de una ruta

Como queremos que nuestro algoritmo encuentre la solución más corta, necesitamos una función que calcule la longitud de una solución específica. Esta función necesita el problema del viajero vendedor en sí (para obtener información sobre las distancias entre ciudades) y, por supuesto, cuya solución necesitamos la longitud de la ruta. Dado que una solución es una lista de todas las ciudades en un orden específico, podemos iterar sobre una solución y usar el argumento tsp para agregar la distancia a cada nueva ciudad a la longitud total de nuestra ruta. El iterador *i* “visita” cada ciudad, por lo que *i*-1 está “en” la ciudad anterior o la última ciudad cuando *i* es igual a 0 (que es exactamente lo que queremos, ya que queremos terminar de nuevo en la primera ciudad). `solution[i]` nos da la ciudad actual, y `solution[i-1]` nos da la anterior. Luego, simplemente usamos el `tsp` para obtener la distancia entre estas ciudades, que sumamos a la longitud total de la ruta (`routeLength`).

```
def routeLength(tsp, solution):
    routeLength = 0
    for i in range(len(solution)):
        routeLength += tsp[solution[i - 1]][solution[i]]
    return routeLength
#####
```

Crear una función que genere todos los vecinos de una solución

Como se explicó anteriormente, Hill Climbing funciona en parte al generar todas las soluciones vecinas a la solución actual. Vamos a crear una función que haga exactamente eso. Una solución vecina es una solución que es solo ligeramente diferente de la solución actual. Tenga en cuenta también que un vecino aún debe ser

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

una solución correcta: cada ciudad aún debe visitarse exactamente una vez. Podemos lograr ambos creando un vecino de la siguiente manera: copie la solución actual y luego haga que dos ciudades intercambien lugares. De esta manera, creamos una solución ligeramente diferente que sigue siendo correcta. Dado que queremos crear todos los vecinos de una solución y necesitamos que las ciudades intercambien lugares, necesitamos crear dos bucles for, uno anidado en el otro, ambos iterando la solución actual. Dado que intercambiar la ciudad A con la ciudad B es lo mismo que intercambiar la ciudad B con la ciudad A, nuestro segundo ciclo solo necesita recorrer aquellas ciudades que el primer ciclo aún no ha recorrido. Dentro del segundo bucle, creamos nuestro vecino con las ciudades intercambiadas y lo agregamos a nuestra lista de vecinos.

```
def getNeighbours(solution):
    neighbours = []
    for i in range(len(solution)):
        for j in range(i + 1, len(solution)):
            neighbour = solution.copy()
            neighbour[i] = solution[j]
            neighbour[j] = solution[i]
            neighbours.append(neighbour)
    return neighbours
```

Crear una función para encontrar el mejor vecino

Ahora que tenemos una función que genera todos los vecinos de una solución, es hora de que creamos una que encuentre lo mejor de estos vecinos. Esta es una función bastante sencilla: primero establece bestNeighbour al primer vecino en la lista de vecinos (y bestRouteLength a la longitud de su ruta), y luego itera sobre todos los vecinos; cuando un vecino tiene una longitud de ruta más corta, se actualizan tanto bestNeighbour como bestRouteLength. De esta manera, se encuentra el mejor vecino:

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

```
def getBestNeighbour(tsp, neighbours):
    bestRouteLength = routeLength(tsp, neighbours[0])
    bestNeighbour = neighbours[0]
    for neighbour in neighbours:
        currentRouteLength = routeLength(tsp, neighbour)
        if currentRouteLength < bestRouteLength:
            bestRouteLength = currentRouteLength
            bestNeighbour = neighbour
    return bestNeighbour, bestRouteLength
```

Crear el algoritmo de Hill Climbing

¡Es hora de la función central! Después de crear las funciones anteriores, este paso se ha vuelto bastante fácil:

```
def hillClimbing(tsp):
    currentSolution = randomSolution(tsp)
    currentRouteLength = routeLength(tsp, currentSolution)
    neighbours = getNeighbours(currentSolution)
    bestNeighbour, bestNeighbourRouteLength = getBestNeighbour(tsp, neighbours)

    while bestNeighbourRouteLength < currentRouteLength:
        currentSolution = bestNeighbour
        currentRouteLength = bestNeighbourRouteLength
        neighbours = getNeighbours(currentSolution)
        bestNeighbour, bestNeighbourRouteLength = getBestNeighbour(tsp, neighbours)

    return currentSolution, currentRouteLength

print(hillClimbing(tsp))
print('Cantidad de soluciones posibles con 4 ciudades:', math.factorial(3))

([2, 3, 0, 1], 1400)
Cantidad de soluciones posibles con 4 ciudades: 6
```

Primero, hacemos una solución aleatoria y calculamos la longitud de su ruta. Luego creamos las soluciones vecinas y encontramos la mejor. A partir de ahí, siempre que el mejor vecino sea mejor que la solución actual, repetimos el mismo patrón con la solución actual cada vez que se actualiza con el mejor vecino. Cuando este proceso se detiene, devolvemos la solución actual (y la longitud de su ruta).

Aunque es un problema bastante sencillo, perfectamente ilustra la manera en que se puede usar este tipo de método en problemas de optimización y solución de problemas.

Conclusiones

Tema 1. Aplicación de técnicas de integración, procesamiento y análisis de información

Hasta aquí hemos tratado los elementos que creemos son esenciales en cuanto al tema de modelado, sin embargo, por la premura y el espacio nos vemos en la necesidad de dejar fuera temas que son completamente fascinantes en ese ámbito. En lo que respecta al razonamiento y sus tipos y usos nos pasa igual, hay muchas cosas que tocar; pero, necesitaríamos mucho espacio y tiempo.

Nos hemos detenido un poco más en los métodos de solución de problemas, dado su carácter más práctico y la posibilidad de usarlos de manera inmediata en sus propios proyectos y es lógica nos ha llevado a usar gran parte de la lección a ellos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

2.1. Representación de información: arquitecturas, técnicas y herramientas

Para estudiar este tema lee las Ideas Clave que se presentan a continuación y revisa los contenidos adicionales para mejorar la comprensión y aumentar los conocimientos sobre las materias tratadas.

Este tema comienza con un primer acercamiento al mundo de la analítica empresarial, objetivo de los procesos ETL (Extracción, Transformación y Carga - Load) con los datos. Se trata de un proceso clásico que con la irrupción de las tecnologías big data, ha permitido también el desarrollo de nuevas formas de obtención de información, generando una nueva disciplina como es la visualización de datos o dataviz.

Con las nuevas posibilidades de conseguir datos, veremos distintas formas de interpretar y representar esos datos con el objetivo de proporcionar información y conocimiento a la empresa. Además, el gran número de herramientas específicas de visualización se ve complementado con diferentes librerías ampliamente utilizadas.

Por último, repasaremos los cuadros de mando como sistema de comunicación de resultados que permiten mantener un sistema de comunicación continuo sobre el estado de nuestro negocio.

Los apartados de los que consta este tema son:

- ▶ La visualización de la información con big data
- ▶ Técnicas y formas de representar la información.
- ▶ Los cuadros de mando.

Tema 2. Configuración de cuadros de mando en entornos computacionales

La visualización de datos con big data

Como iréis viendo, el mundo big data ha permitido desarrollar uno de los procesos más interesantes que existía en el mundo de los datos. Se ha pasado de disponer de un conjunto de datos procesados de forma 'trabajosa' a unificar un sistema de disponibilidad de información visual en tiempo real.

Esto ha hecho que la visualización no sólo sea un medio para trabajar con los datos y mejorar lo extraído de fuentes de datos, sino que ha mejorado y enriquecido las herramientas utilizadas para la toma de decisiones, la minería de datos y el proceso de trabajo de dirección y negocio sobre el estado real de nuestra empresa.

Visualización en la analítica clásica

El mundo de la visualización clásico estaba centrado en la creación del 'Data WareHouse' como potente herramienta para desnormalizar los datos que estaban principalmente en fuentes relacionales. El mundo de las bases de datos, transforma la información que recibe a un modelo, denominado entidad-relación, que lo aleja de la comprensión básica de negocio. Es decir, genera una estructura de almacenamiento que nos obliga a reestructurar la información para adaptarla a las herramientas que lo guardarán; este proceso se llama normalización.

Tendremos una unidad que nos introducirá en el mundo de la inteligencia de negocio o *Business Intelligence*, así que el objetivo de esta lección es el de realizar un acercamiento a los beneficios que tiene para la generación de componentes de decisión y visualización de la información.

Tema 2. Configuración de cuadros de mando en entornos computacionales

El mundo de la inteligencia de negocio desarrolló técnicas para devolver esos datos a un estado en el que podamos trabajar de forma más intuitiva con ellos. Básicamente lo prepara para que puedan generarse todo tipo de informes, alarmas, paneles o formatos que sean fácilmente legibles por los diferentes estamentos de una empresa: dirección, jefes de equipo, usuarios e incluso clientes/proveedores. Este proceso lo denominamos desnormalización.

En este punto hay que destacar 2 componentes principales:

- ▶ **El proceso ETL (Extracción, Transformación y Carga-Load)** es el encargado de desnormalizar los datos con diferentes técnicas y herramientas, para hacer disponible esos
- ▶ **El Data Warehouse (DWH).** El DWH es la herramienta base para el almacenamiento de información que pueda ser consumida por las áreas básicas y de negocio de la empresa. Es un "seguro de vida" para proteger la información de la organización, de forma que ésta quede **accesible, entendible, estructurada y completa.**

Proceso ETL (Extracción, Transformación y Carga)

Los datos son extraídos desde aplicaciones, bases de datos, archivos e incluso otros sistemas de gestión de datos. Esta información generalmente reside en diferentes tipos de sistemas, orígenes y arquitecturas y tienen formatos muy variados.

Con el proceso ETL los datos son integrados, transformados y limpiados, para luego ser cargados en el DWH.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En realidad, se trata de subprocesos altamente especializados en descomponer la información y crear la base que alimentará ese DWH. Estos procesos permiten a las empresas u organizaciones mover datos desde múltiples orígenes o fuentes, cambiarlos de formato y limpiarlos, y volverlos a cargar en **otra base de datos, datamart, o DWH para analizar, o en otro sistema operacional para apoyar un proceso de negocio.**

Aunque lo nombramos en base a 3 procesos, la realidad es que el proceso ETL se divide en 5 subprocesos:

- ▶ **Extracción:** Este proceso recupera los datos físicamente de las distintas fuentes de información. En este momento disponemos de los datos en bruto.
- ▶ **Limpieza:** Este proceso recupera los datos en bruto y comprueba su calidad, elimina los duplicados y, cuando es posible mediante técnicas analíticas, corrige los valores erróneos y completa los valores vacíos, es decir se transforman los datos -siempre que sea posible- para reducir los errores de carga. Aquí ya disponemos de datos limpios y de alta calidad.
- ▶ **Transformación:** Este proceso recupera los datos limpiados y con la calidad necesaria, los estructura y agrega en los distintos modelos de análisis. El resultado de este proceso es la obtención de datos limpios, consistentes, agregados y útiles.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **Integración:** Este proceso valida que los datos que cargamos en el DWH son consistentes con las definiciones y formatos del DWH; los integra en los distintos modelos de las distintas áreas de negocio que hemos definido en el mismo. Estos procesos pueden llegar a ser bastante complejos.
- ▶ **Actualización:** Este proceso aparece en el mantenimiento evolutivo de esos datos y es el que nos permite añadir los nuevos datos al DWH ya construido.

Data Warehouse o DWH

Principalmente, la información del DWH se estructura en cubos multidimensionales, ya que estos preparan esta información para responder a consultas dinámicas y modificables en tiempo real con un rendimiento muy bueno. Pero también pueden utilizarse otros tipos de estructuras de datos para representar la información del DW, como por ejemplo Modelos de Negocio.

Los analistas o usuarios acceden a los cubos multidimensionales, Business Models (u otro tipo de estructura de datos) del DWH utilizando diversas herramientas de consulta, exploración, análisis, reportes, etc. que serán nuestro objetivo técnico para facilitar el trabajo analítico y de conocimiento del negocio.

Ya hemos comentado que un DWH es nuestro seguro para proteger toda la información de la organización, y su proceso de creación debe tener en cuenta:

- ▶ La creación de **modelos centralizados de información** para la toma de decisiones, partiendo de datos distribuidos en innumerables bases de datos, ficheros, fuentes externas, etc.
- ▶ El aseguramiento de la optimización de rendimientos y tiempos de acceso ya que determinarán la capacidad y velocidad en conocer el estado de nuestra empresa.

Tema 2. Configuración de cuadros de mando en entornos computacionales

La modelización de toda la información dispersa en una organización en un DWH centralizado, ofrece información consistente y homogénea para la toma de decisiones.

Podemos ver el DWH como el pilar para la toma de decisiones: El DWH tiene los datos adecuados para llevar a cabo el proceso de toma de decisión. El nombre original inicialmente empleado para hacer referencia a lo que hoy en día conocemos como DWH era Sistemas de Ayuda a la Toma de decisión (decisión support system, DSS), y muestra claramente cuál es el objetivo de estos sistemas.

El **objetivo fundamental del DataWarehouse** es el acceso a la información corporativa: Los contenidos del DWH deben ser entendibles, navegables y no debe penalizarse el acceso lo que implica mantener alto rendimiento:

- ▶ **Entendible** significa correctamente etiquetado.
- ▶ **Navegable** significa que el destino deseado se encuentra localizable en la pantalla y que este se encuentre a un solo "clic de distancia".
- ▶ **Alto rendimiento** en el acceso significa que el tiempo de espera es casi nulo.

El DWH no sólo controla el acceso a los datos de manera efectiva, sino que suministra a los propietarios de la información el mayor control posible así como un gobierno eficiente para conocer quién los utiliza y cómo lo hace.

Arquitectura clásica en alto nivel

Veremos en este apartado la arquitectura, de alto nivel, que da soporte a la capacidad de desarrollar un sistema de inteligencia de negocio y que permite la posibilidad de incluir una gran variedad de sistemas de conocimiento del negocio: alertas, cuadros de mando o *dashboards*, *Scorecards*, informes o reportes, etc.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Veamos el proceso. En las empresas encontramos entidades que representan los elementos sobre las que están operando: **pedidos, clientes, productos, materias primas, facturas proveedores, etc.**

Gracias a las aplicaciones de empresa ERP, CRM, etc. estas entidades y sus relaciones se almacenan en bases de datos relacionales. La información se estructura y se normaliza.

Estas aplicaciones y sus bases de datos (normalmente bajo modelos relacionales) están pensadas para reflejar las transacciones de las empresas.



Figura 1. Punto de partida: fuentes de datos transaccionales

Pero las empresas se dan cuenta que necesitan analizar las transacciones para poder tomar decisiones, surge la Inteligencia de Negocio o *Business Intelligence* (BI). Aunque en algunos casos se puede obtener directamente, hay motivos de impacto en el rendimiento y coste de acceso que hacen necesario economizar el uso directo en estas herramientas. Pero esta necesidad hay que estructurarla de otra manera.

El **objetivo final**, como hemos comentado ya, es el de disponer de los datos expuestos de la forma más asequible y fiable posible para su **análisis**.

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 2. Inicio y final: resolver el gap intermedio.

El proceso intermedio que permite pasar de unos sistemas transaccionales, vitales para nuestro negocio, hasta el análisis y la información se realiza en varios pasos:

- ▶ Lo primero que debemos hacer es **Extraer** la información de las bases de datos (BBDD) relacionales en donde se almacenan.
- ▶ La información extraída se almacena en otra base de datos de almacenamiento (denominada Staging Area) para poder **Transformarla**, es decir, para adecuarla a realizar análisis no transacciones.
- ▶ Finalmente **cargamos (Load)** la información en elementos que representan procesos de negocio de la empresa, llamados **Data Mart** (datos específicos para áreas de negocio como marketing, ventas, compras, dirección, etc.).

De esta forma tenemos la información estructurada para su análisis representando procesos de negocio sobre los que podemos decidir. El resultado es una arquitectura lineal:

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 3. Arquitectura de alto nivel de un DWH tradicional.

Al conjunto de **datos origen**, **ETL** (Extracción-Transformación-Carga) y **Data Mart** lo llamamos **Data Warehouse** (almacén de datos) y hablamos de **BI tradicional**.

Arquitectura con tecnología big data

En el nuevo contexto de disrupción digital, aparecen nuevas fuentes de datos que no están representados en las entidades de las aplicaciones. ¿Cómo proveer a la empresa con Información a partir de esas fuentes? Además, surgen nuevas necesidades de negocio que pueden ser respondidas al contar con tecnología que trabaja con inmensos volúmenes de datos, de muchas fuentes de variedades distintas y a velocidad igual o cercana al tiempo real.

La solución que se planteó anteriormente era la de reducir la cantidad de datos y hacer aproximación. La otra solución que tenían las empresas era la de invertir en productos altamente costosos y con limitaciones.

Si reducir los datos no es una opción y seguimos teniendo necesidades de análisis debemos emplear otra forma de obtener los resultados (de forma **veloz**, **variable** y para grandes **volúmenes**). Es cuando aparece la tecnología big data que estamos trabajando en este módulo para dar una solución a la generación y enriquecimiento del análisis.

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 4. Cuadro general de analítica avanzada: el DWH 'actual'

Estas arquitecturas son complementarias. La tecnología big data no es un sustituto, sino que da solución a problemas no resueltos por el DWH tradicional, se integra perfectamente y además enriquece de forma inmediata el sistema existente.

Como consecuencia de esto, hay soluciones inmediatas que nos permiten dar respuesta a problemas de forma asequible como, por ejemplo:

- ▶ **Visualizar** en qué posición se encuentran todos los aviones que sobrevuelan un país, región o, incluso, el planeta en cada instante.
- ▶ **Predecir**, en las marquesinas de los autobuses públicos, cuántos minutos faltan para que llegue el siguiente.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Ofrecer** a cada internauta productos **basados en sus propias búsquedas** de Google.
- **Allanar** el camino para ganar unas elecciones **conociendo** los mensajes que más calan entre el electorado en cada momento.

Aunque trabajaremos con más detalle las arquitecturas que encajan en nuestro nuevo entorno analítico, presentamos a continuación ejemplos sencillos que de forma inmediata permiten dar respuesta a nuevos retos.




Figura 5. Primeros pasos con ecosistemas big data.

La inclusión de sistemas de almacenamiento como por ejemplo HDFS o motores de búsqueda como Elastic Search, con visualizadores con Graphana, Kibana o los entornos PoweBI, Qlik y Tableau. En definitiva, se construye un ecosistema nuevo preparado para el nuevo entorno.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En la imagen vemos una solución que ya en 2015 permitió a Zoosk Analytics disponer de un entorno en el que el mundo big data complementaba una arquitectura basada en sistemas OLAP (Online Analytical Processing).




Figura 6. Unión OLAP con Big Data. Fuente: Cloudera.

Podemos ver en el **punto 1**, cómo la arquitectura tiene varios factores de mejora exponencial para la analítica de la empresa. Por un lado, disponemos de entornos que permiten tener un *staging* área (**punto 3**) que trabaja directamente con datos de logs web o *Scribe* (log de sistemas con alto nivel de escritura).

El entorno compuesto por almacenamiento big data (e incluso un procesamiento tipo Map Reduce) permitió la obtención de datos con herramientas como hive que dan la capacidad de integrarlo con sistemas ya existentes BI (**punto 4**) como la realización de presentaciones de datos a medida para la explotación de datos (**punto 7**).

El resultado es claro: tenemos mucha más información y de forma más rápida del estado de nuestro negocio.

Tema 2. Configuración de cuadros de mando en entornos computacionales

El siguiente paso fue el de ir incorporando herramientas y lenguajes que muchas posibilidades a la generación de un entorno analítico altamente eficiente como vemos en la figura.




Figura 7. Productos big data. Fuente: <http://vision.cloudera.com/wp-content/uploads/2015/09/zoosk-1.png>

En la actualidad, en este flujo dentro de un entorno paralelizable más concreto de extracción, procesamiento y almacenamiento aparece una industria para la integración que nos proporciona multitud de herramientas.

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 8. El mercado de la analítica avanza.

El resultado en pocos años ha sido un cambio de paradigma. El **enfoque tradicional** para el análisis de datos da respuesta a un análisis estructura y repetido, pero con el **enfoque big data** conseguimos las ventajas que da un análisis exploratorio e iterativo. Ya no es el departamento de IT el que genera una arquitectura para resolver consultas de los usuarios, sino que se enfoca en crear una plataforma que facilite la capacidad de descubrimiento de información por parte de los usuarios: área de analítica, área comercial, dirección, consultores de negocio, marketing, etc.

Esto debe llevarse a cabo acompañando el cambio hacia una cultura del dato en la empresa, en la que todos los usuarios puedan hacer uso, en la medida de su trabajo, de los datos obtenidos.

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 9. Cambio de enfoque: mundo big data.

En este nuevo escenario, disponemos de herramientas en todos los puntos del proceso, generando incluso nuevas formas de crear DWH con procesos ELT (ya no ETL) que cubren multitud de posibilidades; estos procesos han construido los Datalakes que cubren otras necesidades de acceso a dato también muy interesantes. En este caso, los datos se almacenan sin procesar (Nair, 2018).

A modo introductorio en esta tecnología, podemos acercarnos de forma comparativa a ambos procesos con la tabla elaborada por Ladrero, 2020.

Tema 2. Configuración de cuadros de mando en entornos computacionales

	ETL	ELT
Procesamiento	Los datos se transforman en un servidor de almacenamiento intermedio antes de subirse al <i>data warehouse</i> .	Los datos se suben al <i>data lake</i> y allí permanecen. Las transformaciones se realizan en el sistema de destino.
Tiempo de carga	Los datos se cargan en un almacén intermedio y luego se mueven al sistema destino objetivo. Tiempo de carga intensivo.	Los datos se cargan una sola vez. Tiempo de carga muy rápido.
Tiempo de mantenimiento	Altos niveles de mantenimiento.	Bajo nivel de mantenimiento.
Complejidad de implementación	Lo complejo es tener la estructura y los procesos que llenarán esa estructura.	Se debe tener claro qué herramientas se van a utilizar y los <i>skills</i> necesarios.
Madurez	Este proceso se utiliza desde hace más de dos décadas, bien documentado y mejores prácticas disponibles fácilmente.	Es nuevo y complejo de implementar.

Figura 10. ETL vs ELT. Fuente: adaptado de Ladrero, 2020.

A continuación, nos introduciremos en los diferentes sistemas de representación de la información de forma que completemos el objetivo de todo este procesamiento previo: analizar los datos e información de que disponemos.

Dataviz o Business Visualization

Vamos a revisar diferentes formas de visualización de datos de hoy. Las herramientas actuales van mucho más allá de los gráficos estándar y son más sofisticadas, como la infografía, los diales y medidores, mapas geográficos, mini gráficos, mapas de calor.

Incluso aquellas herramientas clásicas como pueden ser los informes disponen actualmente de capacidades interactivas lo que permite a los usuarios manipular y profundizar en los datos para realizar consultas y análisis personalizados.

Revisaremos en primer lugar unas técnicas esenciales para la representación de la información, para luego disponer 5 grandes tipos de análisis y visualización de datos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Conceptos básicos: Métricas y medidas

A la hora de presentar información clave que permita mejorar la toma de decisiones, debemos conocer primero una serie de conceptos ampliamente utilizados en los informes y que tienen especial importancia en la presentación de conclusiones y medidas:

- ▶ Las **medidas** son variables objetivas que aportan datos sobre el funcionamiento de un aspecto determinado del negocio. Se pueden clasificar a su vez como **aditivas**, **semiaditivas** y **no aditivas** según si se pueden sumar a lo largo de todas las dimensiones, solo para algunas o para ninguna. Igualmente, las medidas son **derivadas** cuando se calculan a partir de los valores de otras medidas o indicadores.
- ▶ **Indicadores clave:** entendemos por este concepto, valores correspondientes que hay que alcanzar, y que suponen el grado de asunción de los objetivos. Estas medidas proporcionan información sobre el rendimiento de una actividad o sobre la consecución de una meta.
- ▶ **Indicador clave de rendimiento o KPI** (Key Performance Indicator): son una serie de métricas que se utilizan para tener un mejor conocimiento de la productividad de las acciones que estamos haciendo con la finalidad de poder medir, comparar y decidir qué tipo de acciones son las mejores para los objetivos marcados. Más allá de la eficacia, se definen unos valores que nos explican en qué rango óptimo de rendimiento nos deberíamos situar al alcanzar los objetivos. Son métricas del proceso. A veces se les etiqueta como indicadores clave de desempeño.
- ▶ **Indicador clave de metas o KGI** (Key Goal Indicator): Aquí podríamos incluir, por ejemplo, el objetivo de rentabilidad del proceso de negocio de ventas.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Métodos de elaboración

Es importante considerar una serie de parámetros que deben fijarse para cada KPI que se desea crear, entre ellos:

- ▶ Definición.
- ▶ Actividad que evalúa.
- ▶ Unidades de medida.
- ▶ Forma de medirlo – ratio.
- ▶ Periodicidad

Ejemplos de KPIs para diferentes aspectos de la actividad empresarial, siempre y cuando sean medibles, entre ellos tenemos:

- ▶ **Indicadores económicos:** permiten medir ingresos, costes, rentabilidad, gastos, beneficios, etc.
- ▶ **Indicadores financieros:** permiten medir niveles de deuda, capacidad de endeudamiento, liquidez, solvencia, payback, entre otros.
- ▶ **Indicadores de producción:** permiten evaluar niveles de producción, eficiencia de procesos, materiales utilizados en el proceso de producción, etc.
- ▶ **Indicadores de calidad:** permiten medir porcentaje de defectos que se presenta en el proceso de producción, nivel de calidad de los productos, cantidad de fallas en equipos y procesos, interrupciones inesperadas o forzadas, etc.
- ▶ **Indicadores de logística:** con ellos se puede medir cantidad de pedidos, de entregas, stock, rotación de inventarios tiempos de entrega y tiempos de reposición.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Indicadores de atención y servicio:** permiten medir tiempos medios de atención personal o telefónica, pedidos sin atender, cantidad o porcentaje de devoluciones, cantidad de reclamos, cantidad de clientes nuevos, etc.

Los KPIs deben medirse durante intervalos de tiempo previamente definidos y deben estar asociados a unas unidades de medida específicas. También es habitual que en las empresas cada una de las unidades modulares o departamentos creen sus propios indicadores clave de desempeño en muchas empresas existen áreas o departamento que se encargar de brindar apoyo especializado para este proceso.




Figura 11. ejemplos de KPIs del área de ventas de una empresa.

Mecanismos de elección de KPI

Una buena mecánica de construcción de un KPI es plantearse la pregunta que quiero responder y ajustar la métrica con la que mediría la respuesta.

- **¿Qué metas y qué objetivos perseguimos?** Debemos tener claros los objetivos que persigue la empresa, ya que será un punto fundamental en nuestra estrategia u objetivo de medición.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **¿Influyen dichos KPI elegidos en las metas de la empresa?** Una vez elegidos los objetivos empresariales, habrá que ver si los KPI miden dichos objetivos.
- ▶ **¿Son comparables?** Estos KPI tendremos que compararlos con algo, alguna referencia, alguna meta perseguida etc.
- ▶ **¿Nos servirán de ayuda para calcular retornos de inversión u otras medidas de estado?** Calcular el retorno de nuestra inversión requiere un esfuerzo que los KPI ayudan a reducir.
- ▶ **¿Qué responsable de la empresa recibirá tus KPI?** Otra parte fundamental es saber a qué responsable de la empresa vamos a presentar los resultados. En función del departamento, área e incluso dirección al que nos dirijamos le interesarán más unas métricas que otras.
- ▶ **¿Cada cuánto vamos a mostrar los avances?** La supervisión debe ser en la mayoría de los casos diaria, pero debemos saber qué períodos evaluaremos en nuestros informes finales. Esto puede definir un poco más que tipo de KPI serán más relevantes que otros.
- ▶ **¿Quiénes van a medir los KPI y con qué herramientas?** Parece obvio, pero es fundamental saber qué nivel profesional y qué recursos tiene el responsable de medirlos. No tiene sentido que diseñemos una tabla de KPI dirigida a alguien que o bien no sabe qué está midiendo o no dispone de los medios necesarios para hacerlo.
- ▶ **¿Qué personal tomará las acciones derivadas del resultado de los KPI?** Similar al punto anterior, dependiendo de a quienes vayan dirigidos o qué responsable será el encargado de tomar acciones, deberemos filtrar qué KPI podemos darles.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Estas son algunas preguntas que debemos hacer para empezar a desarrollar y crear KPI. A medida que entramos en la comprensión del negocio de una empresa u organización aparecerán nuevas preguntas, matices o personalizaciones que deben enriquecer nuestra forma de trabajarlas.

Analítica: objetivos y visualización

Vamos a revisar 5 grandes tipologías de herramientas para la interpretación de los datos. Estos tipos han evolucionado por el incremento de tipologías usuarios y la necesidad de análisis más avanzados.

Cuadros de mando o Dashboards y Scorecards

Ambas son herramientas que nos permiten resumir enormes cantidades de datos en indicadores sencillos o métricas, con gran adaptación visual que otorga información inmediata y coherente sobre la situación de la empresa. Permiten mostrar a primera vista un conjunto de KPI's relativos a procesos de negocio como puede ser marketing, ventas, proyectos, RRHH, etc.

Muchas veces los informes proporcionan mucha información y no son adecuados para tomar decisiones de manera rápida a partir de los mismos. Para facilitar la toma de decisiones de alto nivel se desarrollan los cuadros de mando que se centran en:

Se trata de herramientas diferentes, aunque en ocasiones las vemos usadas indistintamente e incluso unificadas en la primera, los cuadros de mando.

En común tienen que:

- ▶ Ambas representan una forma de hacer seguimiento de resultados.
- ▶ Utilizan los mismos elementos gráficos y visuales, como los semáforos.
- ▶ Incluyen objetivos, umbrales y alertas.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ Proporcionan navegación hacia otras métricas o reportes, incluidos los más detallados (dril down) para potenciar el análisis en profundidad y la comprensión de la información.
- ▶ Presentan una cantidad reducida de aspectos de negocio.

Además, el proceso de creación es similar, aunque los

- ▶ Identificar la necesidad de negocio y los potenciales usuarios del cuadro de mando.
- ▶ Elegir los datos que mostrar en el cuadro de mando o en el scorecard.
- ▶ Elegir el formato de presentación.
- ▶ Combinar datos y presentación conjuntamente.
- ▶ Planificar la interactividad del usuario (modelo pirámide).
- ▶ Implementar el cuadro de mando o dashboard.

Cuadros de mando o Dashboards

Se les llama cuadro de mando o dashboard, y a modo de relación comparativa con los scorecards, vamos a ver sus objetivos y características:

- ▶ Es una herramienta que **reporta lo que uno puede medir**. El cuadro de mando no es más que un conjunto de métricas que uno ya tiene.
- ▶ Requieren de una actualización muy frecuente de los datos.
- ▶ Puede no tener los valores esperados.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Monitoriza y mide procesos** de negocio. Es totalmente operacional. Muestra una gran cantidad de mediciones de uso cotidiano, indicadores de actividad o performance indicators (PI), sin reflejar objetivos estratégicos.

El cuadro de mando permite entender muy rápidamente la situación de negocio y resulta muy atractivo visualmente. Se permite el análisis visual de la información en tiempo real: visual analytics.




Figura 12. Cuadro de mando de ejemplo. Fuente: <https://commons.wikimedia.org/wiki/>

Scorecards

Los Scorecards son herramientas estratégicas. Vamos a ver sus objetivos y características:

- Es una herramienta que **reporta lo que uno debería medir (estrategia)**. Incluyen el resultado del análisis y definición de objetivos estratégicos.
- Tienen una actualización periódica marcada que generalmente es mensual, trimestral o cuatrimestral.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ Debe tener valores esperados.
- ▶ **Muestra la relación con un objetivo estratégico** de negocio. Muestra el estado de los indicadores clave de actividad (KPI o Key Performance Indicators), congelados por periodos y que siempre están asociados a los objetivos estratégicos definidos inicialmente por la empresa.

En la ilustración siguiente podemos ver un ejemplo con la presentación de las 4 pestañas que nos dan información: a) todos los indicadores estratégicos de forma conjunta; b) Las medidas del total de los 10 indicadores estratégicos que estableció la empresa; c) mapa estratégico global y d) detalle para cada uno.




Figura 13. Scorecard con semáforos, gráficas y visualización de 10 indicadores estratégicos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En este ejemplo, se hace un seguimiento preciso, con gran capacidad visual y con la posibilidad de ver los datos globales y a su vez profundizar en el detalle de cada uno.

Informes corporativos

Los informes corporativos o de empresa son recopilaciones de datos muy detallados que permiten disponer de la mayor información posible, aunque pueda resumirse, acerca de cualquier proceso de la empresa.

Tienen una disposición altamente estructurada, con mucha información, pueden tener varias páginas y el diseño tiene como objetivo transmitir grandes cantidades de información, con datos, del rendimiento operativo.

Están, a menudo, organizados jerárquicamente y pueden utilizar grafismos para que sean más legibles.

Su estructura ha estado determinada por la necesidad de estar impresos, aunque actualmente existe una tendencia a disponerlos para dispositivos electrónicos como son las tablets, portátiles e incluso móviles. Esto implica una capacidad para adaptarse a cualquier soporte.

Eso sí, se mantiene la capacidad de disponer de formato específico para la impresión de alta producción como con las cuentas y estados.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Una clasificación informal puede ser:

► Informe operacional (Reports):

- Impresos o vía web
- Fácil navegación a través de cientos de páginas de informe
- Acceso al contenido parametrizable

► Informes de negocio con un formato concreto:

- Creados por usuarios de negocio (no IT).
- Compuestos por tablas y gráficos
- Su objetivo son presentaciones o publicaciones

► Impresión documentos legales y/o tributarios:

- Facturación on line
- Declaraciones
- Otros documentos y formularios

Análisis OLAP

El análisis OLAP (On Line Analytic Processing) es una herramienta de procesamiento analítico en tiempo real sobre bases de datos específicamente diseñadas para hacerlo. Su objetivo es agilizar la consulta de grandes cantidad de datos con lenguaje natural por lo que es utilizada por negocio.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Sus características principales son:

- ▶ **Orientada a temas o negocio**, a diferencia de los sistemas orientados a procesos u operación.
- ▶ En su **uso predomina la consulta** y por ello hace uso de muchos datos históricos.
- ▶ Ejecuta **procesos masivos** ya que accede a enormes cantidades de registros.
- ▶ Hace uso de datos **desnormalizados** que suelen venir de procesos ETL.
- ▶ Dispone de una estructura multidimensional, los denominados '**cubos OLAP**'.
- ▶ **Origina respuestas masivas** lo que genera tiempos de respuesta con cierta latencia.
- ▶ Reposa en una **estructura dinámica sujeta a abundantes cambios**.

En resumen, el análisis OLAP te permite navegar fácilmente por la información, solicitándola con el detalle preciso y con los filtros adecuados, haciéndolo de manera dinámica, fácil, ad hoc, sobre la marcha, sin necesitar asistencia, rápido, y utilizando el lenguaje de negocio.

A la hora de aplicarlo a la empresa dispondremos de un ciclo iterativo (o método) que nos llevará a tener equipos de alto rendimiento como podemos ver en la ilustración:

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 14. Ciclo de análisis OLAP.

El objetivo es el descubrimiento de datos que permite a nuestros expertos y gente de negocios llevar a cabo su propio análisis sin la ayuda de TI (autoconsumo).

Se empieza con la preparación de los datos. Estos datos pueden ser gestionados de TI datos de la base de datos, DWH o puede ser sus propios datos en hojas de cálculo. El proceso a seguir es:

- ▶ Comenzar por familiarizarse con los datos. Con la observación minuciosa de los datos se empiezan a entender las relaciones.
- ▶ A continuación, podemos aplicar las visualizaciones de los datos para ayudar a discernir patrones, problemas y tendencias.
- ▶ Ahora es importante aplicar nuestro propio análisis con ayuda del filtrado de los datos, la creación de nuevos cálculos o agregaciones, y la adición de puntos de vista de los datos.
- ▶ En cualquier momento dentro del proceso de descubrimiento de datos podemos agregar nuevas visualizaciones, añadir nuevas combinaciones de datos, y perfeccionar su análisis de los datos. No se trata de un proceso lineal.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ Hasta que no llegue al conocimiento del negocio y conclusiones seguiremos con la mecánica de un **proceso exploratorio e iterativo**, con alto componente visual de exploración.

Data Mining & Análisis predictivo

Aunque lo veremos en las siguientes lecciones, otras de las formas más interesantes de trabajar con datos es la analítica avanzada de la que podemos destacar la minería de datos y el análisis predictivo.

La **minería de datos (Data Mining)**, es un campo de la informática referido al proceso que intenta descubrir patrones en grandes volúmenes de conjuntos de datos.

El **aprendizaje automático (Machine Learning)** es una parte de la inteligencia artificial (IA) que se define como el conjunto de técnicas y algoritmos que tratan de extraer información de forma automática, sin necesidad de una guía previa humana, a partir de un conjunto de datos especialmente preparado.

Storytelling y otras nuevas tendencias

Por último, y con un desarrollo muy importante en los últimos años, nos encontramos con nuevas tendencias en el ámbito del análisis de la información que se orientan a la comunicación y transmisión de forma asequible de grandísimas cantidades de datos e información.

Nos referimos en este apartado a técnicas como el storytelling, las infografías, la generación de contenido multidispositivo o incluso las alarmas (tan usadas en el mundo IoT).

Tema 2. Configuración de cuadros de mando en entornos computacionales

El Story Telling se trata de una técnica de presentación de datos, integrada en muchos casos dentro de las herramientas más utilizadas para BI (PowerBI, Tableau o Qlik). Está basada en el uso de técnicas de relatos o composición de cortometrajes que presentan la información en forma de historia con la intención de acercar el análisis a la audiencia. Tiene un esfuerzo importante creativo y hace uso de recursos muy visuales para amplificar la capacidad de comunicación.

Toda historia suele llevar el siguiente diagrama de



Figura 15. Curva de construcción de guión y su equivalente de Storytelling.

Como podemos ver, usa ritmos similares en la construcción del relato, de forma que aprovecha el interés que tenemos en las historias de forma equivalente a como lo haríamos con un guión de una película:

- ▶ La **exposición** clásica es nuestra presentación del **problema**.
- ▶ El **impedimento** del storytelling asemeja a la **acción ascendente** al inicio de la película.
- ▶ En el momento **clímax**, presentamos nuestra **solución**.
- ▶ El resto del desarrollo con la **acción descendente** y el **desenlace** final nos lleva a presentar nuestras **acciones** y el **resultado final**.

Tema 2. Configuración de cuadros de mando en entornos computacionales

A continuación, presentamos una serie de ideas clave para la creación de Storytelling:

- ▶ Claridad y concisión: **¡Menos es Más!**
- ▶ Combinación de palabras con imágenes. La memoria se activa de forma más profunda cuando ve imágenes.
- ▶ Identificación de insights. Debe existir una relación clara del mensaje con lo que interesa al cliente.
- ▶ Crear historias atractivas. Aquí hay multitud de posibilidades, pero también anclajes muy potentes como el uso de historias con personas que representen mejor todo el ciclo anterior pero aplicado a nuestra realidad.

Tema 2. Configuración de cuadros de mando en entornos computacionales

2.2. Metodologías para la minería de datos

Para estudiar este tema lee las Ideas Clave que se presentan a continuación y revisa los contenidos adicionales para mejorar la comprensión y aumentar los conocimientos sobre las materias tratadas.

En este tema nos introducimos en los principales métodos utilizados en minería de datos que nos permiten disponer de pasos reglados sobre cómo hacer un proyecto. Estas metodologías no sólo se utilizan en minería de datos sino en cualquier proyecto del 'dato'.

Nos encontraremos algunos modelos conocidos como metodologías que son en realidad un modelo de proceso: un conjunto de actividades y tareas organizadas para llevar a cabo un trabajo.

La diferencia fundamental entre metodología y modelo de proceso radica en que el modelo de proceso establece qué hacer, y la metodología especifica cómo hacerlo. Una metodología no solo define las fases de un proceso sino también las tareas que deberían realizarse y cómo llevar a cabo las mismas.

Las técnicas de Data Science o Data Analytics usaban el término KDD (Knowledge Discovery in Databases) para referirse al concepto de hallar conocimiento en los datos.

En un intento de normalización de este proceso de descubrimiento de conocimiento, de forma similar a como se hace en ingeniería software para normalizar el proceso de desarrollo software, surgieron a finales de los 90 dos metodologías principales y que estudiaremos en esta lección:

- ▶ Metodología CRISP-DM (Cross Industry Standard Process for Data Mining).
- ▶ Metodología SEMMA (Sample, Explore, Modify, Model, and Assess).

Tema 2. Configuración de cuadros de mando en entornos computacionales

Dedicaremos un mayor detalle a conocer CRISP-DM por su mayor alcance e independencia de herramientas.

Metodologías de minería de datos

La sistematización del proceso de minería de datos es un punto importante para la planificación y ejecución de este tipo de proyectos relacionados con el dato. Además, estos procesos metodológicos son perfectamente aplicables a todo el campo de la analítica de datos.

En el ámbito del dato, algunas organizaciones y empresas implementan el proceso KDD, mientras que otras aplican un estándar más específico como CRISP-DM. Si la organización ha adquirido productos de la empresa SAS, tiene a su disposición una metodología especialmente desarrollada para los mismos, la metodología SEMMA.

Como alternativas, nos encontramos con la metodología Catalyst (conocida como P3TQ) que goza de menor penetración, pero aporta completitud y flexibilidad para adaptarse en distintos escenarios.

La minería de datos es un proceso de explotación de información para extraer conocimiento útil, comprensible y novedoso de grandes volúmenes de datos, como sucede en el mundo big data, y su principal objetivo es encontrar información oculta o implícita, que no es posible obtener mediante métodos estadísticos convencionales.

Los proyectos de explotación de información pueden ser llevados a cabo en distintos escenarios. Según el punto de partida del proceso, podríamos clasificarlos en:

- **Escenarios donde se aborda desde la minería de datos una situación organizacional** (un problema o una oportunidad), buscando patrones y relaciones que puedan colaborar con la misma. Este escenario es el más frecuente en el ámbito de las empresas y organizaciones.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Escenarios donde el proyecto comienza con un conjunto de datos y el objetivo es explorarlos** para encontrar relaciones interesantes o realizar procesos de aprendizaje automático que puedan ser útiles en el dominio de aplicación. En estos casos, no recomiendan trabajar directamente con los datos sin establecer de antemano la situación actual (problemática, intervinientes, así como las expectativas y necesidades de los usuarios). Este punto resulta de gran importancia para justificar la realización del proyecto, ya que ninguna organización realizará una inversión si no sabe la función y los beneficios que aportará.

Algunos modelos profundizan en mayor detalle sobre las tareas y actividades a ejecutar en cada etapa del proceso de minería de datos (como CRISP-DM), mientras que otros proveen sólo una guía general del trabajo a realizar en cada fase (como el proceso KDD o SEMMA).

Un proceso de **análisis de datos** conlleva una serie de etapas que van desde la extracción de la información, su validación, exploración, preparación, aplicación de modelos y obtención de resultados. A menudo este proceso puede ser cíclico y necesitar de sucesivas iteraciones para su depuración.

Presentaremos a continuación ambas metodologías. Veremos cómo especifican las tareas a realizar en cada fase descrita por el proceso, asignando tareas concretas y definiendo lo que es deseable obtener tras cada fase.

Esta sucesión de fases no es necesariamente rígida y cada fase es estructurada en varias tareas generales de segundo nivel. Estas tareas generales se proyectan a tareas específicas, donde finalmente se describen las acciones que deben ser desarrolladas para situaciones específicas.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Metodología SEMMA

SEMMA, creada por el SAS Institute, se define como “el proceso de selección, exploración y modelado de grandes volúmenes de datos para descubrir patrones de negocio desconocidos”. El nombre de esta terminología es el acrónimo correspondiente a las cinco fases básicas del proceso: *Sample* (Muestreo), *Explore* (Exploración), *Modify* (Modificación), *Model* (Modelado), *Assess* (Valoración).

La metodología **SEMMA** está enfocada principalmente en aspectos técnicos, excluyendo actividades de análisis y comprensión del problema que se está abordando. Su origen procede de una propuesta para trabajar con el software de minería de datos de la compañía SAS. Este producto organizaba sus herramientas (llamadas “nodos”) en base a las distintas fases que componen la metodología. Es decir, el software proporciona un conjunto de herramientas especiales para la etapa de muestreo, otras para la etapa de exploración, y así sucesivamente. Eso sí, el usuario podía hacer uso del mismo siguiendo cualquier otra metodología de minería de datos y por eso CRISP-DM puede usarse con ella.

SEMMA se compone de las fases que podemos ver en la figura siguiente:

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 16. Ciclo metodológico SEMMA. Fuente: <https://documentation.sas.com/?docsetId=emref&docsetTarget=n061bzurmej4j3n1jn8bbj1a2.htm&docsetVersion=14.3&locale=en>

[docsetId=emref&docsetTarget=n061bzurmej4j3n1jn8bbj1a2.htm&docsetVersion=14.3&locale=en](https://documentation.sas.com/?docsetId=emref&docsetTarget=n061bzurmej4j3n1jn8bbj1a2.htm&docsetVersion=14.3&locale=en)

Como vemos, al igual que CRISP-DM, se trata de un proceso iterativo y con frecuencia hay que volver a fases anteriores. Por ejemplo, si en la última fase al evaluar el modelo vemos que es interesante añadir nuevas variables en nuestros datos, volvemos a la fase inicial.

- **SAMPLE (Muestreo).** Extracción de una muestra representativa. Es la primera fase de la metodología, se realiza la extracción de un conjunto de datos que constituyan una buena representación de la población a estudiar. Esto simplifica el trabajo, dado que trabajamos sobre un volumen de datos más reducido. Como hemos visto en anteriores módulos, el desarrollo de tecnologías Big Data permite en ocasiones trabajar sobre poblaciones completas de alto volumen de datos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **EXPLORE (Exploración).** Exploración de los datos. Se realiza una inspección sobre los datos para conocer bien sus características: la distribución de los mismos, posibles relaciones, tipos de datos, detectar datos anómalos, etc. La exploración se puede realizar a través de herramientas visuales, o empleando diferentes técnicas estadísticas como las vistas en el apartado anterior.
- ▶ **MODIFY (Modificación).** Modificación de los datos. La modificación de los datos consiste en seleccionar y transformar las variables existentes o crear nuevas variables. En ocasiones será una mera preparación del dato y otras veces transformaciones más complejas. Es un punto al que se suele volver desde los posteriores al ser la metodología dinámica e iterativo.
- ▶ **MODEL (Modelado).** Modelización de los datos. En esta fase, una vez preparados los datos, se utilizan algoritmos o modelos matemáticos que ayuden a modelizar el comportamiento de los datos y sus relaciones.
- ▶ **ASSESS (Valoración).** Evaluación de los datos obtenidos. Después de la creación y ejecución de los modelos se realiza una evaluación de los mismos. Una buena práctica para identificar si los resultados con el modelo creado son los esperados, es aplicar este modelo a una porción de datos diferente a la que se utilizó para entrenar el modelo. Si el modelo funciona correctamente para esta muestra y para la muestra utilizada para la generación del modelo, hay una buena probabilidad de tener un modelo válido.

Metodología CRISP-DM

La metodología **CRISP-DM** (Cross Industry Standard Process for Data Mining) es algo más completa que la anterior ya que involucra más temas relacionados directamente con el negocio. Esta metodología busca una ejecución por iteraciones en las que las diferentes fases están relacionadas e integra las actividades de gestión de proyecto y puesta en producción de los modelos generados.

Tema 2. Configuración de cuadros de mando en entornos computacionales

CRISP–DM, creada por el grupo de empresas SPSS, NCR y Daimler Chrysler en el año 2000, es actualmente la guía de referencia más utilizada en el desarrollo de proyectos de Analítica de datos.

Estructura el proceso en **seis fases**: Comprensión del negocio, Comprensión de los datos, Preparación de los datos, Modelado, Evaluación e Implantación [5]. La sucesión de fases no es necesariamente rígida. Cada fase es descompuesta en varias tareas generales de segundo nivel. Las tareas generales se proyectan a tareas específicas, pero en ningún momento se propone como realizarlas. Es decir, CRISP-DM establece un conjunto de tareas y actividades para cada fase del proyecto, pero no especifica cómo llevarlas a cabo.

A continuación, vemos un diagrama general con las tareas de primer nivel:




Figura17. Diagrama general de la metodología CRISP-DM.

Fase 1. Conocimiento del negocio. Las tareas que incluye esta primera fase son:

- **Determinar los objetivos del negocio:** cuál es el problema que se desea resolver, por qué la necesidad de utilizar analítica de datos y definir los criterios de éxito (de forma cualitativa o cuantitativa)

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **Evaluación de la situación:** se debe calificar el estado de la situación antes de iniciar el proceso de DM/ML, considerando aspectos tales como: ¿cuál es el conocimiento previo disponible acerca del problema?, ¿se cuenta con la cantidad de datos requerida para resolver el problema?, ¿cuál es la relación coste beneficio de la aplicación de DM/ML?, etc. Se definen los requisitos del problema, tanto en términos de negocio como en términos de Data Mining o Machine Learning.
- ▶ **Determinación de los objetivos de DM/ML:** tiene como objetivo representar los objetivos del negocio en términos de las metas del proyecto de DM/ML, como por ejemplo, si el objetivo del negocio es el desarrollo de una campaña publicitaria para incrementar la asignación de créditos hipotecarios, la meta de DM/ML será por ejemplo, determinar el perfil de los clientes respecto de su capacidad de endeudamiento.
- ▶ **Producción de un plan del proyecto.** Finalmente, esta última tarea de la primera fase de CRISP-DM, tiene como meta desarrollar un plan para el proyecto, que describa los pasos a seguir y las técnicas a emplear en cada paso.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En la ilustración vemos estas tareas y sus tareas secundarias:




Figura 18. Fase 1: Conocimiento del negocio.

Esta fase permite:

- ▶ La familiarización con el dominio del problema y la obtención de conocimiento a priori disminuye el espacio de soluciones posibles lo que redundará en una mayor eficiencia en el resto del proceso.
- ▶ En problemas de analítica de datos se suele trabajar con datos de diferentes departamentos de una entidad por lo que es conveniente agrupar y unificar la información. Esto nos puede conducir a concentrar la información en un DWH a partir de:
 - Información interna: distintas BBDD diseñadas para trabajo transaccional y de otro tipo (hojas de cálculo, informes, ...)
 - Estudios publicados (demografía, catálogos, páginas, ...)
 - Otras bases de datos (compradas, industrias/empresas afines, ...) o información en

Tema 2. Configuración de cuadros de mando en entornos computacionales

Datalakes

De forma práctica, es fundamental concluir con una pregunta de negocio bien definida a la que vamos a dar respuesta:

- ▶ ¿Puedo calcular la probabilidad de baja de los clientes de mi cartera?
- ▶ ¿Qué tipo de clientes tiene mayor probabilidad de caer en impago?
- ▶ ¿Existe un patrón en las operaciones fraudulentas?, ¿puedo obtenerlo?
- ▶ ¿Puedo identificar los e-mails recibidos que son SPAM?

Una vez bien definidas las preguntas, podemos marcar unos objetivos concretos. Por ejemplo, establezco como objetivo generar un modelo que prediga cuando un cliente se va a dar de baja y doy por bueno un nivel de aciertos del 80%.

Fase 2. Comprensión de los datos. Esta fase arranca con una colección inicial de datos. El analista procede a familiarizarse con los datos, identificar la calidad de estos, descubrir ideas iniciales en los datos o detectar subconjuntos para formar hipótesis sobre información a analizar.

Tema 2. Configuración de cuadros de mando en entornos computacionales

La calidad del análisis no depende sólo del algoritmo sino de la calidad de los datos. En esta fase, interesa disponer de un DWH aunque a veces se trabaja en las BBDD. Incluye cuatro pasos:

- ▶ **Recolección de datos iniciales.** La primera tarea en esta segunda fase del proceso de CRISP-DM, es la recolección de los datos iniciales y su adecuación para el futuro procesamiento. Objetivo: elaborar informes con una lista de los datos adquiridos, su localización, las técnicas utilizadas en su recolección y los problemas y soluciones inherentes a este proceso.
- ▶ **Descripción de los datos.** Después de adquiridos los datos iniciales, estos deben ser descritos. Este proceso involucra establecer volúmenes de datos (número de registros y campos por registro), su identificación, el significado de cada campo y la descripción del formato inicial.
- ▶ **Exploración de datos.** se procede a su exploración, cuyo fin es encontrar una estructura general para los datos. Esto involucra la aplicación de pruebas estadísticas básicas, que revelen propiedades en los datos recién adquiridos, se crean tablas de frecuencia y se construyen gráficos de distribución. La salida de esta tarea es un informe de exploración de los datos.
- ▶ **Verificación de la calidad de los datos.** se efectúan verificaciones sobre los datos, para determinar la consistencia de los valores individuales de los campos, la cantidad y distribución de los valores nulos, y para encontrar valores fuera de rango, los cuales pueden constituirse en ruido para el proceso. La idea en este punto es asegurar la completitud y corrección de los datos /

Tema 2. Configuración de cuadros de mando en entornos computacionales

En la ilustración vemos estas tareas y sus tareas secundarias:




Figura 19. Fase 2: Comprensión de los datos.

Fase 3. Preparación de los datos. Cubre todas las actividades para construir el conjunto final de los datos que serán utilizados en la(s) herramienta(s) de modelado. Las tareas incluyen la selección de tablas, registros y atributos, así como la transformación y limpieza de los datos para las herramientas de modelado.

Los componentes de esta fase son:

- ▶ **Estructuración de los datos.** incluye las operaciones de preparación de los datos tales como la generación de nuevos atributos a partir de atributos ya existentes, integración de nuevos registros o transformación de valores para atributos existentes.
- ▶ **Integración de los datos.** involucra la creación de nuevas estructuras, a partir de los datos seleccionados, por ejemplo, generación de nuevos campos a partir de otros existentes, creación de nuevos registros, fusión de tablas campos o nuevas tablas donde se resumen características de múltiples registros o de otros campos en nuevas tablas de resumen.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Formateo de los datos.** realización de transformaciones sintácticas de los datos sin modificar su significado, esto, con la idea de permitir o facilitar el empleo de alguna técnica de análisis (DM/ML) en particular, como por ejemplo la reordenación de los campos y/o registros de la tabla o el ajuste de los valores de los campos a las limitaciones de las herramientas de modelación (eliminar comas, tabuladores, caracteres especiales, máximos y mínimos para las cadenas de caracteres, etc.).




Figura 20. Fase 3: Preparación de los datos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Las técnicas utilizadas para asegurar la calidad de los datos y que estén en la forma adecuada son: limpieza, transformación y reducción de la dimensionalidad. Por ejemplo:

► Técnica de Limpieza o data cleaning:

- Datos perdidos (missing values)
- Datos anómalos (outliers)

► Técnica de Transformación

- Construcción de atributos (no tienen mucho poder predictivo por sí solos o cuando los patrones dependen de variaciones lineales de las variables globales)
- Discretización: Pasar atributos continuos (o discretos con muchos valores) a casos discretos manejables o a categóricos

► Técnica de Reducción de la dimensionalidad

- Reducción de casos / filas: Las técnicas utilizadas van desde la compresión al muestreo de los datos, pasando por la elección de representantes (clustering)
- Selección de variables (feature selection / proyección): Seleccionar el conjunto de atributos adecuado para la tarea específica a realizar (técnicas: estadísticas, basadas en búsqueda combinadas con métodos empíricos, ...)-

Fase 4. Modelado de los datos. El objetivo del modelo es la aplicación de algoritmos y modelos matemáticos para obtener nuestro objetivo de análisis. Los componentes de esta fase son:

- **Selección de la técnica de modelado.** Esta tarea consiste en la selección de la técnica de análisis (DM/ML) más apropiada al tipo de problema a resolver. Por ejemplo, si el problema es de clasificación, se podrá elegir de entre árboles de decisión...

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **Generación del plan de prueba. procedimiento destinado a probar la calidad y validez del mismo.** Por ejemplo, en una tarea supervisada típicamente se separan los datos en dos conjuntos, uno de entrenamiento y otro de prueba, para luego construir el modelo basado en el conjunto de entrenamiento y medir la calidad del modelo generado con el conjunto de prueba
- ▶ **Construcción del Modelo.** Se ejecuta la técnica elegida sobre los datos previamente preparados (1 o más modelos). Se realiza la selección de los mejores parámetros de cada técnica de modelado es un proceso iterativo, basado en los resultados generados para interpretarlos y justificar su rendimiento.
- ▶ **Evaluación del modelo.** Se interpretan los modelos de acuerdo con el conocimiento preexistente del dominio y los criterios de éxito preestablecidos.

Podemos ver las subtareas en la siguiente ilustración:




Figura 21. Fase 4: Modelado de los datos

Tema 2. Configuración de cuadros de mando en entornos computacionales

De forma práctica tendremos que tomar las siguientes decisiones:

- ▶ ¿Qué tipo de conocimiento buscamos?
 - Predictivo
 - Descriptivo
- ▶ ¿Qué técnica es la más adecuada?
 - Clasificación / Regresión
 - Agrupamiento (clustering)
 - Asociaciones, ...
- ▶ ¿Qué tipo de modelo?
 - Por ej.: Clasificación: reglas, redes neuronales, árboles de decisión,...
- ▶ ¿Es necesaria la incertidumbre en el modelo resultante? Certeza, probabilidad, lógica difusa, etc.
- ▶ ¿Qué algoritmo es el más adecuado? Por ej.: en clustering: duro, jerarquizado, k-means, iterativo, EM, ...
- ▶ Diseñar el proceso de evaluación (como muestra la ilustración):
 - Creación del conjunto de datos de entrenamiento y validación (ejemplo 70% y 30%),
 - Revisar proporciones de clases (ejemplo: caso clases desbalanceadas).

Tema 2. Configuración de cuadros de mando en entornos computacionales




Figura 22. Diseño del proceso de evaluación. Fuente:

https://commons.wikimedia.org/wiki/File:Supervised_machine_learning_in_a_nutshell.svg

Fase 5. Evaluación. El objetivo es evaluar los modelos para comprobar si cumplen los criterios de éxito establecidos previamente. Se compone de las siguientes tareas principales:

- ▶ **Evaluación de los resultados.** Evaluación del modelo en relación a los objetivos del negocio y busca determinar si hay alguna razón de negocio para la cual, el modelo sea deficiente, o si es aconsejable probar el modelo, en un problema real si el tiempo y restricciones lo permiten. Además de los resultados directamente relacionados con el objetivo del proyecto, ¿es aconsejable evaluar el modelo en relación a otros objetivos distintos a los originales?, esto podría revelar información adicional.
- ▶ **Proceso de revisión.** El proceso de revisión se refiere a calificar al proceso entero de DM/ML, a objeto de identificar elementos que pudieran ser mejorados
- ▶ **Determinación de futuras fases.** Si se ha determinado que las fases hasta este momento han generado resultados satisfactorios, podría pasarse a la fase siguiente, en caso contrario podría decidirse por otra iteración desde la fase de preparación de datos o de modelación

Tema 2. Configuración de cuadros de mando en entornos computacionales

De forma gráfica, las subtareas son:




Figura 23. Fase 5: Evaluación.

En esta fase podemos concluir que:

- ▶ Estafase puede producir varias hipótesis de modelos.
- ▶ Es necesario establecer qué modelos son los más válidos.
- ▶ Criterios: los patrones descubiertos deben ser:
 - precisos,
 - comprensibles, e
 - interesantes (útiles, novedosos)
- ▶ La interpretación de los mejores modelos (visualización, simplicidad, posibilidad de integración, ventajas colaterales, ...) ayuda a la selección del modelo(s) final(es).

Tema 2. Configuración de cuadros de mando en entornos computacionales

Fase 6. Despliegue. Esta fase se compone de las siguientes tareas principales:

► **Plan de implementación.**

- Para implementar el resultado analítico (DM/ML) en nuestra empresa, en esta tarea recogemos los resultados de la evaluación y desarrollamos una estrategia para su implementación.
- Si hemos identificado un procedimiento general para crear el modelo, lo documentaremos para su posterior implementación.

► **Monitorización y Mantenimiento.**

- Si los modelos resultantes del proceso de DM/ML los implementamos en el dominio del problema, como parte de la rutina diaria es aconsejable preparar estrategias de monitorización y mantenimiento para ser aplicadas sobre los modelos.
- La retroalimentación generada por la monitorización y mantenimiento pueden indicar si el modelo lo estamos utilizando apropiadamente.

► **Informe Final.**

- Es la conclusión del proyecto de analítica de datos (DM/ML) realizado.
- Dependiendo del plan de implementación, este informe puede ser sólo un resumen de los puntos importantes del proyecto y la experiencia lograda o puede ser una presentación final que incluya y explique los resultados logrados con el proyecto.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- **Revisión del proyecto:** En este punto se evalúa qué fue lo correcto y qué lo incorrecto, qué es lo que se hizo bien y qué es lo que se requiere mejorar

En la ilustración podemos ver las subtareas asociadas a las anteriores tareas principales:




Figura 24. Fase 6: Despliegue

Una vez construido y validado el modelo puede utilizarse:

- para recomendar acciones.
- para aplicar el modelo a diferentes conjuntos de datos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En cualquier caso, es necesario:

- ▶ Difusión: Elaboración de informes para su distribución.
- ▶ Utilización del nuevo conocimiento de forma independiente.
- ▶ Incorporación a sistemas ya existentes, lo que permite comprobar con el conocimiento ya utilizado para evitar inconsistencias y posibles conflictos.

La monitorización del sistema en acción dará lugar a nuevos casos que realimentarán el ciclo del KDD. Las conclusiones iniciales pueden variar, invalidando el modelo adquirido

Tema 2. Configuración de cuadros de mando en entornos computacionales

2.3. Métodos y algoritmos de minería de datos

Ideas Clave

Para estudiar este tema lee las Ideas Clave que se presentan a continuación y revisa los contenidos adicionales para mejorar la comprensión y aumentar los conocimientos sobre las materias tratadas.

En este tema vamos a revisar los algoritmos principales de Minería de datos o Data Mining. El primer punto a trabajar es el saber diferenciar la minería de datos de otras técnicas ya estudiadas dentro de la analítica avanzada como es el caso del aprendizaje automático visto en el módulo correspondiente.

Podríamos decir que la principal diferencia **radica en el objetivo que tiene** cada una de las técnicas o disciplinas. Mientras que la **minería de datos** descubre patrones que nos eran desconocidos previamente, el aprendizaje automático se usa para reproducir patrones conocidos y generar predicciones basadas en esos patrones.

El segundo punto será el de revisar las técnicas utilizadas en la minería de datos y que son compartidas con el aprendizaje automático. Eso sí, al cambiar el objetivo, también cambian los problemas a resolver así como la forma de afrontar su resolución.

Los apartados de los que consta este tema son:

- ▶ Técnicas de minería de datos.
- ▶ Algunas herramientas y productos en el mercado.

Minería de datos como disciplina independiente

La minería de datos lleva muchos años siendo una herramienta fundamental en muchas empresas para alcanzar objetivos de mejorar, entre otras cosas, en el conocimiento del cliente, estudiar impacto de sus productos o desarrollo de nuevas

Tema 2. Configuración de cuadros de mando en entornos computacionales

ideas. Pero es con el inicio de la tecnología big data cuando ha podido llevar estas técnicas hasta la resolución de problemas mucho más complejos e inabarcables hace apenas 20 años.

El aprendizaje automático puede observar los patrones y aprender de ellos para adaptar el comportamiento de incidencias en el futuro, mientras que la minería de datos se suele utilizar como una fuente de información para el aprendizaje de máquinas. Aunque los científicos de datos pueden configurar la minería de datos para buscar automáticamente tipos específicos de datos y parámetros, **no aprenden y aplican el conocimiento por sí mismos sin la interacción humana**. La minería de datos tampoco puede ver de forma automática y con la misma profundidad las relaciones existentes entre los datos dentro de conjuntos de datos que se analizan.



La minería de datos junto al aprendizaje automático está arraigada en la ciencia de datos e información, y aunque a menudo se entrecruzan o se confunden entre sí, tienen algunas distinciones clave entre los dos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En la minería de datos, estamos buscando datos ocultos, pero sin tener idea o una idea imprecisa de qué tipo de datos estamos buscando exactamente y para qué planeamos usarlos una vez que los encuentre. Cuando descubrimos información interesante, el conocimiento de negocio es fundamental para pensar en cómo hacer uso de ella para impulsar nuestra toma de decisiones de negocio.

Veámoslo en la práctica:

Un científico de datos de una fábrica de productos comienza a realizar un trabajo de minería con los datos que obtiene de los registros de envíos de sus productos a clientes; no existe un objetivo predeterminado sino posibles patrones nuevos. A medida que comienza a extraer los datos, descubre un patrón: hay más solicitud de envíos internacionales los viernes en comparación con todos los demás días. Al verlo detenidamente, acuerdan con la empresa de logística una reducción de las tarifas internacionales en fines de semana y además promueven una campaña de reducción de precios. Las compras aumentan y los clientes están contentos con una bajada de tarifas de envío lo que aumenta ventas e incluso margen de venta.

En general, los pasos a considerar en la minería de datos suelen ser los siguientes:

Tema 2. Configuración de cuadros de mando en entornos computacionales



Figura 25. Pasos generales en la minería de datos

- ▶ **Integración de datos:** en el primer paso, los datos se integran y recopilan de varias fuentes.
- ▶ **Selección de datos:** como anteriormente es posible que no recopilemos todos los datos simultáneamente, en este paso seleccionamos solo los datos que quedan y que consideramos son útiles para la minería de datos.
- ▶ **Limpieza de datos:** la información que hemos recopilado no está limpia lo que quiere decir que no puede utilizarse directamente en algoritmos ya que tiene errores, datos extraños o inconsistentes, valores faltantes y otros defectos. Por lo tanto, debemos implementar varias estrategias para solucionar todos estos problemas.
- ▶ **Transformación de datos:** los datos, incluso después de la limpieza, no están preparados para la minería, por lo que debemos transformarlos en estructuras adecuadas para la búsqueda que vamos a hacer. Los métodos utilizados para lograr esto son agregación, normalización, suavizado, etc.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ **Minería de datos:** una vez que los datos se han transformado, estamos listos para implementar métodos y algoritmos de minería de datos para extraer información, conocimiento y patrones útiles de los conjuntos de datos. Por ejemplo, las reglas de asociación de agrupamiento es una técnica muy utilizada en minería de datos y que da resultados muy interesantes.
- ▶ **Evaluación de patrones:** la evaluación de patrones contiene visualización, eliminación de patrones aleatorios o carentes de información útil, transformación, etc. de esos patrones que generamos.
- ▶ **Decisión:** es el último paso en la minería de datos. Ayuda a los usuarios a hacer uso de los datos iniciales adquiridos para tomar mejores decisiones en nuestra empresa.

Veamos los 2 grandes campos de trabajo de la minería de datos y sus diferencias antes de pasar a trabajar con técnicas específicas aplicadas.

Extracción de los datos

Ya hemos comentado que la minería de datos y el aprendizaje automático comparten técnicas y metodologías, pero difieren en los objetivos. Al hacer **minería de datos**, un científico de datos utiliza datos extraídos de la información existente para buscar patrones ocultos que puedan ayudar a mejorar nuestros procesos de toma de decisiones.

Por otro lado, el **aprendizaje automático** sí que puede aprender de los datos existentes y genere el conocimiento necesario para que una máquina mejore con el tiempo.

Por ejemplo, la extracción de datos se utiliza normalmente en el aprendizaje automático para ver las conexiones entre las relaciones. Podemos ver cómo Uber lo utiliza para el cálculo de las mejores rutas o en los tiempos de entrega de comidas para UberEATS.

Tema 2. Configuración de cuadros de mando en entornos computacionales

En el caso de la minería de datos se utiliza para extraer **insights** de negocio. Pero ¿qué significa *insights*? Consiste en buscar claves internas que pasan desapercibidas a menos que analistas expertos puedan encontrarlas. Es ahí donde entra la capacidad de las técnicas y algoritmos para realizar esa extracción inteligente en primer lugar, y en ayudar a definir estrategias de negocio en segundo lugar.

Si lo aplicamos a la investigación financiera, los inversores pueden utilizar la extracción de datos y el web scrapping para analizar el estado financiero de una startup y tomar la decisión de ofrecerles financiación. Una empresa también puede usar la minería de datos para ayudar a recopilar datos sobre las tendencias de ventas que den con la clave de conocimiento: desde mercadotecnia hasta necesidades de inventario, o el aseguramiento de nuevos clientes potenciales. Y qué decir del ámbito público...

Más ejemplos de extracción los encontramos en el análisis de perfiles de redes sociales, sitios web y cualquier entorno digital con el objetivo de enfocar correctamente una campaña de marketing. Con esta cantidad de información, podemos incluso predecir tendencias futuras que nos ayudarán como empresa a prepararnos en las tendencias de gusto de clientes a corto o medio plazo.

Además de estas técnicas comunes entre la minería de datos y el aprendizaje automático, éste también puede crear correlaciones automáticas y realizar un aprendizaje para mejorar algoritmos o crearlos nuevos. Estos algoritmos y análisis están destinados a mejorar de forma continua, por lo que el resultado mejora en precisión con el tiempo (y la cantidad de datos).

Reconocimiento de patrones

El proceso anterior de extracción y recopilación de datos incluye una parte del problema. La otra gran parte es darle sentido a todo y aplicarlo.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Como hemos visto hasta ahora en el máster es necesario un software y unas herramientas específicas para poder analizar e interpretar las enormes cantidades de información que actualmente se recopilan.

A la hora de buscar patrones reconocibles sobre los que actuar podemos hacer uso de estas mismas herramientas o bien de otras más u otras más específicas para estas tareas. Esta búsqueda puede ser compleja, sutil e incluso aleatoria en ocasiones. Tanto la preparación del dato como esta labor 'científica e investigadora' suelen llevar a altos costes de tiempo y dinero.

Un gran ejemplo de empresa que se ha orientado al dato con gran éxito es Walmart. Esta empresa de Retail buscaba almacenar la mayor cantidad de datos para configurar sus predicciones de ventas o determinar qué tipos de productos son realmente apreciados por sus clientes. Para ello datos en los puntos de venta de sus más de 3.000 tiendas y los integra en sus DWH y Datalakes. Todos sus proveedores pueden ver esta información y utilizarla para identificar patrones de compra, de forma que puedan generar sus propias predicciones de inventario y procesos personalizados para el futuro.

Principales métodos y algoritmos de minería de datos

En la lección anterior ya revisamos algunas de las metodologías de minería de datos (válidas para el aprendizaje automático en particular y la ciencia de datos en general) más conocidas para el análisis en Big Data, como SEMMA y CRISP-DM. Dando un paso más allá nos centraremos en las principales técnicas de minería de datos utilizadas en el mundo del Big Data.

La minería de datos también trabajará en la generación de un modelo con el mejor algoritmo (y su optimización) mediante los procesos vistos hasta ahora. Al igual que con aprendizaje automático, puede tomar diversas formas, incluyendo:

- Un conjunto de clústeres que describe cómo se relacionan los casos de un dataset.

Tema 2. Configuración de cuadros de mando en entornos computacionales

- ▶ Un árbol de decisión que predice un resultado y que describe cómo varían éstos con distintos criterios.
- ▶ Un modelo matemático que predice las ventas.
- ▶ Un conjunto de reglas que describen cómo se agrupan los productos en una transacción (reglas), y las probabilidades de que dichos productos se adquieran juntos.

Extracción de reglas de asociación

Podríamos llamarlo también minería de datos frecuentes. La extracción de reglas de asociación usada como técnica de minería de datos busca inferir silogismos, tipo si.../entonces..., partiendo de conjuntos de registros.

De este modo podemos conocer mejor una muestra de datos dada, discriminar atributos y establecer cuál o qué combinación de ellos puede ser el origen de un resultado recurrente (una consecuencia). Es decir, trabaja la extracción de asociaciones y correlaciones interesantes entre los diferentes elementos de la muestra, identificando patrones.

Es el clásico ejemplo del 'Análisis de la cesta de la compra' que permite deducir implicaciones entre productos en las transacciones de compra de un supermercado. A la hora de representar los patrones se pueden utilizar las denominadas reglas de asociación.

La regla de asociación trabaja, fundamentalmente, con los parámetros **soporte y confianza** para conocer la 'relación' de los elementos asociados.

Tema 2. Configuración de cuadros de mando en entornos computacionales

De un grupo de compras, verificamos las transacciones en las que se compraron leche y cereales juntos y lo identificamos como:

- ▶ **Soporte:** proporción de veces que aparecen los objetos A en las transacciones sobre el total.
- ▶ **Confianza:** proporción de ocurrencias del conjunto de objetos B dado que se ha dado el conjunto de objetos A.

Es un trabajo del científico de datos establecer los criterios para decidir si una regla de asociación $A \rightarrow B$ es **interesante**. Esto lo hace mediante un nivel o umbral mínimo para considerar una relación como patrón a trabajar.

Por ejemplo, unos umbrales de soporte del 5% y de confianza del 75% en la relación: leche cereales significa que en el 5% de las compras había leche y en el 75% de ellas además se compraron cereales.

Los pasos para implementar el análisis de asociación:

- ▶ Encontrar conjuntos de elementos frecuentes. Un conjunto de elementos que contiene k elementos es un conjunto de elementos k. La frecuencia de un conjunto de elementos es el número de transacciones que contienen el conjunto de elementos.
- ▶ Generación de reglas de asociación sólidas a partir de conjuntos de elementos frecuentes. Por reglas de asociación estrictas, queremos decir que se cumple el umbral mínimo de soporte y confianza.

Dentro de los métodos de análisis de relación (o métodos frecuentes) de minería de conjuntos de datos, hay diferentes aproximaciones como: el **algoritmo a priori**, el **enfoque de crecimiento de patrones** y la minería utilizando el **formato de datos vertical**.

Tema 2. Configuración de cuadros de mando en entornos computacionales

El **algoritmo a priori** fue propuesto por Agarwal and Srikant in 1994 y supuso en cierta forma un cambio importante en la forma en la que las empresas comenzaron a aplicar estas técnicas de exploración de datos. Los pasos son:

- ▶ Dado un umbral de soporte, el algoritmo a priori elimina los objetos que no superan el umbral de soporte, descartando por tanto todos los posibles conjuntos que contienen a los elementos poco frecuentes.
- ▶ A continuación, estudia qué combinaciones de 2, 3, 4... elementos forman conjuntos de objetos que superen ese umbral.
- ▶ Una vez que sólo tenemos conjuntos de objetos que superan el umbral de soporte, se estudian las posibles reglas de asociación que parten de esos conjuntos de objetos que son suficientemente frecuentes.

Con él podemos conseguir valorar la similitud:

- ▶ en un sitio web, con el fin de proporcionar servicios variados o publicidad dirigida.
- ▶ artículos para vender a esos usuarios, con el fin de proporcionar películas o productos recomendados (recomendadores).
- ▶ genes humanos, con el fin de encontrar personas que comparten los mismos antepasados

Otra técnica, extensión de estas, es el **análisis de correlación** que añade un parámetro adicional como es la correlación entre ambos productos- Se mide mediante lift y chi-square (elevación).

Tema 2. Configuración de cuadros de mando en entornos computacionales

Regresión

La regresión como técnica de minería de datos toma como punto de partida una serie histórica para, a partir de ella, predecir qué sucederá a continuación. En el caso de minería de datos la aplicación de este método permite localizar regularidades dentro de los datos que permiten trazar una línea de evolución extrapolable al futuro.

Este tipo de análisis es supervisado e identifica qué conjuntos de elementos entre las diferentes relaciones están relacionados o son independientes entre sí. Cuando se proporciona una entrada, el algoritmo de regresión comparará la entrada y el valor esperado, y el error se calcula para obtener un resultado preciso. Por ejemplo, se aplicaría en la comparación de los esfuerzos de marketing y desarrollo de productos.

Como ya hemos visto en el módulo anterior, la clasificación es una regresión aplicada a valores discretos por lo que aplicaría a la localización de determinadas clases que tenemos previsto analizar.

Árboles de decisión

Recordemos que los **árboles de decisión** son diagramas lógicos que plantean, ante una determinada situación, las opciones de intervención posibles, agregando sus implicaciones, costes, ventajas y desventajas.

Se basan en la aplicación de un **algoritmo clasificador** que, a partir de un nodo, desarrolla ramas (decisiones) y determina el potencial resultado de cada una de ellas.

Su importancia radica en la capacidad de explicación de las conclusiones o relaciones que obtenemos al hacer la minería de datos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Clustering o segmentación

El clustering o agrupamiento en minería de datos tiene como objetivo la segmentación de elementos que presentan alguna característica definitoria en común. Es un tipo de aprendizaje no supervisado ya que no se conoce la información de la etiqueta.

El conjunto de datos se desglosa en grupos o grupos de objetos se denomina clúster. La agrupación se realiza mediante algoritmos que atienden a condiciones de cercanía o similitud para hacer su trabajo.

Los métodos de agrupación identifican datos que son similares o diferentes entre sí, y se realiza un análisis de las características.

El análisis de clústeres se puede utilizar como un paso previo para aplicar otros algoritmos como caracterización, selección de subconjuntos de atributos, etc. El análisis de clústeres también se puede utilizar para la detección de valores atípicos, como compras elevadas en transacciones con tarjeta de crédito (análisis de anomalías).

Esta técnica de data mining está muy extendida en el mundo del marketing para el envío de correos y promociones personalizadas a los usuarios que integran una base de datos.

Entornos como el reconocimiento de imágenes, búsqueda web y seguridad, están consiguiendo resultados muy significativos.

Tema 2. Configuración de cuadros de mando en entornos computacionales

Modelado estadístico

El **modelado estadístico** pretende **dibujar el mapa de relaciones entre variables explicativas y dependientes**. En base a ello trabaja un planteamiento de fijar parámetros y muestra cómo cambia ese mapa a medida que lo hacen aquellos.

Para ello hace uso de una ecuación matemática que intenta reproducir la realidad de la manera más fiel posible, incorporando, incluso, la influencia del azar y el posible margen de error en el cálculo.

Redes bayesianas

Las redes bayesianas son representaciones gráficas de relaciones, en este caso, con dependencia probabilística entre distintas variables.

Ayuda en casos de diagnóstico de patologías o enfermedades, pero también en cálculos del riesgo en el sector financiero y asegurador.

Redes neuronales profundas (Deep learning)

Las redes neuronales se engloban dentro de las técnicas predictivas de minería de datos y, como todo modelo de aprendizaje automático, requiere un entrenamiento con amplios conjuntos de datos para proporcionar una alta fiabilidad de sus respuestas.

Ejemplo práctico: Reglas de asociación

A continuación, veremos un ejemplo de aplicación de la técnica de la regla de asociación. Como comentábamos anteriormente, se trata de una técnica específica para la búsqueda de relaciones o asociaciones.

Tema 2. Configuración de cuadros de mando en entornos computacionales

El análisis de afinidad permite ver la similitud entre muestras y es muy utilizado en recomendadores. Las recomendaciones de productos automatizadas a través de la minería de datos son una de las fuerzas impulsoras detrás de la revolución del comercio electrónico.

Veremos un ejemplo en Python. En él reproduciremos un servicio básico de recomendación de productos. Premisa: cuando históricamente dos artículos se compran juntos, es más probable que se compren juntos en el futuro.

Si una persona compra el producto X, es probable que compre el producto Y

Este tipo de pensamiento está detrás de muchos servicios de recomendación de productos, tanto en negocios en línea como fuera de línea.

Aunque podríamos utilizar varios productos y ver si se compra un tercero, trabajaremos con una relación simple para simplificar el código.

Utilizaremos 2 cuadernos jupyter con el código: uno generará la matriz de resultados (el dataset de entrada con los tickets o transacciones) y otro con el desarrollo.

```
# Aquí presentamos los nombres de las características como referencia
features = ["pan", "leche", "queso", "manzanas", "peras"]
```

Si vemos las 5 primeras líneas y consideramos que un 1 quiere decir que se compró ese producto y un 0 que no, podemos leer:

```
[ ] 1 print(X[:5])

[[0. 0. 1. 1. 1.]
 [1. 1. 0. 1. 0.]
 [1. 0. 1. 1. 0.]
 [0. 0. 1. 1. 1.]
 [0. 1. 0. 0. 1.]]
```

Tema 2. Configuración de cuadros de mando en entornos computacionales

El primer cliente compró los últimos 3 productos: queso, manzanas y peras. Y así sucesivamente.

Ahora veamos la regla de nuestra premisa: personas que compran manzanas.

```
1 # Aquí presentamos los nombres de las características como referencia
2 features = ["pan", "leche", "queso", "manzanas", "peras"]

1 # Primero, cuantas filas contiene nuestra premisa: esa persona que compra manzanas
2 num_apple_purchases = 0
3 for sample in X:
4     if sample[3] == 1: # Esta persona sí ha comprado manzanas
5         num_apple_purchases += 1
6     print("{0} personas compraron manzanas".format(num_apple_purchases))

36 personas compraron manzanas
```

Y verificamos la relación con compra de peras también:

```
1 # ¿Cuántos casos de una persona que compró manzanas incluyen a personas que compraron peras también?
2 # Guardamos ambos casos en los que la regla es válida e inválida.
3 rule_valid = 0
4 rule_invalid = 0
5 for sample in X:
6     if sample[3] == 1: # Esta persona sí ha comprado manzanas
7         if sample[4] == 1:
8             # Esta persona compró manzanas y peras
9             rule_valid += 1
10        else:
11            # Esta persona compró manzanas, pero no peras
12            rule_invalid += 1
13    print("{0} casos descubiertos que validan la regla".format(rule_valid))
14    print("{0} casos descubiertos que no validan la regla".format(rule_invalid))

21 casos descubiertos que validan la regla
15 casos descubiertos que no validan la regla
```

A partir de aquí, introducimos los parámetros de **Soporte y Confianza** que nos permitirán cuantificar los umbrales a disponer:

```
[12] 1 # Ahora ya tenemos toda la información necesaria para calcular Soporte(Support) y Confianza (Confidence)
2 support = rule_valid # El Soporte es el número de veces que se descubre nuestra regla.
3 confidence = rule_valid / num_apple_purchases
4 print("El soporte es {0} y la confianza es de {1:.3f}".format(support, confidence))
5 # Confianza se puede ver como un porcentaje si hacemos uso de esto:
6 print("Como porcentaje, el valor de la confianza es del {0:.1f}%".format(100 * confidence))

El soporte es 21 y la confianza es de 0.583.
Como porcentaje, el valor de la confianza es del 58.3%.
```

Tema 2. Configuración de cuadros de mando en entornos computacionales

Definamos ahora todas las posibles reglas para después medir:

```
[14] 1 from collections import defaultdict
      2 # Calculemos ahora todas las posibles reglas
      3 valid_rules = defaultdict(int)
      4 invalid_rules = defaultdict(int)
      5 num_occurrences = defaultdict(int)
      6
      7 for sample in X:
      8     for premise in range(n_features):
      9         if sample[premise] == 0: continue
          # Guardamos que la premisa se compró pero en otra transacción
          num_occurrences[premise] += 1
          for conclusion in range(n_features):
          if premise == conclusion: # Da un cierto sentido a afirmar que si X -> X.
              continue
          if sample[conclusion] == 1:
          # Esta persona también compró el producto conclusión ('conclusion')
          valid_rules[(premise, conclusion)] += 1
          else:
          # Esta persona compró la premisa pero no la conclusión
          invalid_rules[(premise, conclusion)] += 1
      21 support = valid_rules
      22 confidence = defaultdict(float)
      23 for premise, conclusion in valid_rules.keys():
      24     confidence[(premise, conclusion)] = valid_rules[(premise, conclusion)] / num_occurrences[premise]
```

Que dará como resultado un conjunto de métricas a valorar:

```
1 for premise, conclusion in confidence:
2     premise_name = features[premise]
3     conclusion_name = features[conclusion]
4     print("Regla: Si una persona compra {0} también comprará {1}".format(premise_name, conclusion_name))
5     print(" - Confianza: {0:.1f}%".format(100 * confidence[(premise, conclusion)]))
6     print(" - Soporte: {0}".format(support[(premise, conclusion)]))
7     print("")
```

Regla: Si una persona compra queso también comprará manzanas

- Confianza: 61.0%

- Soporte: 25

Regla: Si una persona compra queso también comprará peras

- Confianza: 65.9%

- Soporte: 27

Regla: Si una persona compra manzanas también comprará queso

- Confianza: 69.4%

- Soporte: 25

Tema 2. Configuración de cuadros de mando en entornos computacionales

Regla: Si una persona compra manzanas también comprará peras

- Confianza: 58.3%

- Soporte: 21

Regla: Si una persona compra peras también comprará queso

- Confianza: 45.8%

- Soporte: 27

Regla: Si una persona compra peras también comprará manzanas

- Confianza: 35.6%

- Soporte: 21

Regla: Si una persona compra pan también comprará leche

- Confianza: 51.9%

- Soporte: 14

Regla: Si una persona compra pan también comprará manzanas

- Confianza: 18.5%

- Soporte: 5

Regla: Si una persona compra leche también comprará pan

- Confianza: 30.4%

- Soporte: 14

Regla: Si una persona compra leche también comprará manzanas

- Confianza: 19.6%

Tema 2. Configuración de cuadros de mando en entornos computacionales

- Soporte: 9

Regla: Si una persona compra manzanas también comprará pan

- Confianza: 13.9%

- Soporte: 5

Regla: Si una persona compra manzanas también comprará leche

- Confianza: 25.0%

- Soporte: 9

Regla: Si una persona compra pan también comprará queso

- Confianza: 14.8%

- Soporte: 4

Regla: Si una persona compra queso también comprará pan

- Confianza: 9.8%

- Soporte: 4

Regla: Si una persona compra leche también comprará peras

- Confianza: 41.3%

- Soporte: 19

Regla: Si una persona compra peras también comprará leche

- Confianza: 32.2%

- Soporte: 19

Regla: Si una persona compra pan también comprará peras

Tema 2. Configuración de cuadros de mando en entornos computacionales

- Confianza: 63.0%

- Soporte: 17

Regla: Si una persona compra peras también comprará pan

- Confianza: 28.8%

- Soporte: 17

Regla: Si una persona compra leche también comprará queso

- Confianza: 15.2%

- Soporte: 7

Regla: Si una persona compra queso también comprará leche

- Confianza: 17.1%

- Soporte: 7

Para generalizar el código, podemos organizar según los parámetros una ordenación de las mejores reglas:

```
1 def print_rule(premise, conclusion, support, confidence, features):  
2     premise_name = features[premise]  
3     conclusion_name = features[conclusion]  
4     print("Regla: Si una persona compra {} también comprará {}".format(premise_name, conclusion_name))  
5     print(" - Confianza: {:.3f}".format(confidence[(premise, conclusion)]))  
6     print(" - Soporte: {}".format(support[(premise, conclusion)]))  
7     print("")
```

Y dará como resultado:

Tema 2. Configuración de cuadros de mando en entornos computacionales

```
[19] 1 premise = 1
      2 conclusion = 3
      3 print_rule(premise, conclusion, support, confidence, features)

[20] 1 # Ordenando por soporte
      2 from pprint import pprint
      3 pprint(list(support.items()))

[21] 1 from operator import itemgetter
      2 sorted_support = sorted(support.items(), key=itemgetter(1), reverse=True)

[22] 1 for index in range(5):
      2     print("Regla #{0}".format(index + 1))
      3     (premise, conclusion) = sorted_support[index][0]
      4     print_rule(premise, conclusion, support, confidence, features)
```

Regla #1

Regla: Si una persona compra queso también comprarán peras

- Confidence: 0.659

- Support: 27

Regla #2

Regla: Si una persona compra peras también comprarán queso

- Confidence: 0.458

- Support: 27

Regla #3

Regla: Si una persona compra queso también comprarán manzanas

- Confidence: 0.610

- Support: 25

Regla #4

Regla: Si una persona compra manzanas también comprarán queso

Tema 2. Configuración de cuadros de mando en entornos computacionales

- Confidence: 0.694

- Support: 25

Regla #5

Regla: Si una persona compra manzanas también comprarán peras

- Confidence: 0.583

- Support: 21

```
[23] 1 # Ordenando por confianza
      2 sorted_confidence = sorted(confidence.items(), key=itemgetter(1), reverse=True)

✓ [25] 1 for index in range(5):
      2     print("Regla #{0}".format(index + 1))
      3     (premise, conclusion) = sorted_confidence[index][0]
      4     print_rule(premise, conclusion, support, confidence, features)
```

Regla #1

Regla: Si una persona compra manzanas también comprarán queso

- Confidence: 0.694

- Support: 25

Regla #2

Regla: Si una persona compra queso también comprarán peras

- Confidence: 0.659

- Support: 27

Regla #3

Regla: Si una persona compra pan también comprarán peras

- Confidence: 0.630

Tema 2. Configuración de cuadros de mando en entornos computacionales

- Support: 17

Regla #4

Regla: Si una persona compra queso también comprarán manzanas

- Confidence: 0.610

- Support: 25

Regla #5

Regla: Si una persona compra manzanas también comprarán peras

- Confidence: 0.583

- Support: 21

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Objetivos

En esta unidad se van a conocer los principales sistemas para gestionar y almacenar grandes volúmenes de datos viendo los diferentes mecanismos de almacenamiento y las herramientas que nos ayudan a facilitar la búsqueda de respuesta.

Desde un punto de vista teórico se van a ver todas las formas de almacenamiento de grandes volúmenes de datos, así como entender en qué momento es recomendable utilizar cada uno de ellos dependiendo por un lado del tipo de información que se almacene y de lo que se vaya a hacer con la información por otro.

Se verán algunas herramientas como aquellas destinadas al almacenamiento de ficheros de manera distribuida como HDFS o Hive para consultar su información. Otras herramientas como bases de datos no relacionales o NoSQL que juegan un papel importantísimo a la hora de almacenar grandes volúmenes de información y por último veremos Kafka sistema de almacenamiento temporal que se puede usar cuando necesitamos procesar información en tiempo real o Elasticsearch muy usada cuando lo que buscamos es desarrollar un motor de búsqueda estilo Google.

También se verán algunas herramientas que ayudan a importar la información a estos sistemas de almacenamiento para que esa labor sea más sencilla. Aquí las herramientas que se verán serán Sqoop y Flume.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

3.1. Sistemas de gestión almacenamiento. HDFS

Sistemas Big Data

El crecimiento de la información producida en el mundo por fuentes de todo tipo, tanto físicas como electrónicas, es exponencial de un tiempo a esta parte. Aunque las estimaciones acerca del volumen divergen, la siguiente gráfica muestra de manera orientativa este fenómeno.




Figura 1. Estimación crecimiento de datos. Fuente: Reinsel et al., 2018.

Fíjate como va a crecer de manera exponencial el volumen de información almacenada la información en los próximos años y que si en los últimos años ha crecido no tiene nada que ver con lo que va a crecer en los próximos años. El volumen de información que se va a tener que almacenar se va a multiplicar prácticamente por tres.

La primera empresa que fue consciente del aumento de los datos que se estaban generando en Internet fue Google, ya que su buscador debe ser capaz de indexar las webs nuevas para que puedan ser encontradas. En los albores del siglo XX, Sanjay

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Ghemawat, Howard Gobioff y Shun-Tak Leung (2003) publicaron un artículo que se hizo mundialmente famoso, en el cual explicaban el sistema de archivos distribuido Google File System (GFS) que habían desarrollado. Los autores presentaron por primera vez la idea de utilizar ordenadores convencionales conectados entre sí (formando un clúster) para poder almacenar archivos que ocupaban más que un solo disco duro.

A esto se le denomina **commodity hardware**: máquinas no especialmente potentes, similares a las que tienen los usuarios domésticos, pueden conectarse entre sí para trabajar conjuntamente como una sola, a fin de resolver tareas de mayor envergadura. GFS fue la base del sistema de archivos distribuido HDFS.

Prácticamente todas las herramientas que funcionan hoy en día en Big Data lo hacen basadas en un sistema distribuido.

La arquitectura Big Data tiene como principal objetivo el análisis y procesamiento de grandes cantidades de datos que no pueden realizarse de la manera convencional, pues se superan las capacidades de los sistemas estándar para su almacenamiento, gestión y tratamiento.

La arquitectura Big Data consiste, entonces, en el diseño de sistemas y modelos para el tratamiento de grandes volúmenes de datos de diferentes tipos y orígenes con el fin de transformarlos en información que permita la mejor toma de decisiones.

La arquitectura de Big Data es la base para el análisis de Big Data. Es el sistema general que se utiliza para administrar grandes cantidades de datos para que puedan analizarse con fines comerciales, dirigir el análisis de datos y proporcionar un entorno en el que las herramientas de análisis de big data pueden extraer información comercial vital de datos que de otro modo serían ambiguos. El marco de la arquitectura de big data sirve como modelo de referencia para las infraestructuras y soluciones de big data, definiendo lógicamente cómo funcionarán las soluciones de

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

big data, los componentes que se utilizarán, cómo fluirá la información y los detalles de seguridad.

Los componentes de la arquitectura de la analítica de big data suelen constar de cuatro capas lógicas y realizan cuatro procesos principales.

Capas de arquitectura de Big Data

Una vez se adquiere la información de las fuentes de datos hay distintas capas que realizan diferentes acciones sobre los datos (Figura 1):

- ▶ **Capa de gestión y almacenamiento:** recibe datos de la fuente y almacena los datos de acuerdo con su formato.
- ▶ **Capa de procesamiento:** un entorno de big data puede gestionar tanto el procesamiento por lotes como el procesamiento en tiempo real de fuentes de Big data, como almacenes de datos, sistemas de gestión de bases de datos relacionales, aplicaciones SaaS y dispositivos de IoT. Convierte los datos en un formato comprensible para la herramienta de análisis de datos o de visualización.
- ▶ **Capa de análisis:** las herramientas de análisis extraen inteligencia empresarial de la capa de almacenamiento de big data.
- ▶ **Capa de consumo:** recibe los resultados de la capa de análisis de big data y los presenta a la capa de salida pertinente, también conocida como capa de inteligencia empresarial o de visualización.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 2. Representación arquitectura Big Data. Fuente: elaboración propia.

Definir una correcta arquitectura Big Data es un trabajo complejo debido a la cantidad de herramientas existentes y especializadas en funcionalidades concretas y que se irán detallando a lo largo del módulo. Además, se unen varios factores a tener en cuenta para elegir estas herramientas y que hacen que no existan dos proyectos Big Data iguales ya que para unas circunstancias puede ser mejor usar unas herramientas u otras dependiendo de la necesidades y requisitos del proyecto.

De manera transversal a todo lo visto hay dos puntos importantes dentro de una arquitectura Big Data como son la **capa de seguridad** de **seguimiento del flujo de datos**.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Sistemas distribuidos

Para entender que es un sistema distribuido lo mejor es empezar entendiéndolo a través de un ejemplo. Imagina que hay un aula con diez equipos y cada uno de ellos tiene un disco duro de 1 TB de capacidad de almacenamiento. Si se pasa un fichero o un grupo de ficheros cuyo tamaño total es de, imagina, 3 TBs, no se podría guardar en ninguno de los equipos, ahora bien, si consigo que todos los equipos trabajen como si fuera uno solo uniendo todos sus recursos, como en total habría 10 TBs de almacenamiento entre todos si fuera posible guardar ese o esos ficheros. Pues esta es la idea de sistema distribuido.

Una definición de lo que sería un sistema distribuido podría ser:

“Conjunto de computadores cuyos componentes hardware y software, interconectados, se comunican y coordinan sus acciones mediante el paso de mensajes. Comparten un estado, ofreciendo una visión de sistema único.”

Es decir, varios ordenadores interconectados entre ellos que permiten usar sus recursos de manera unificada para conseguir un objetivo o funcionalidad como en el caso anterior poder guardar información que de otra manera solo se hubiera podido almacenar con un disco con más capacidad de almacenamiento y en muchas ocasiones un coste mayor que unir varios discos de pequeña capacidad. Es como montar un super ordenador uniendo las piezas de todos los ordenadores.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 3. Representación de un sistema distribuido. Fuente: Shutterstock, s. f.

Los sistemas distribuidos son un desarrollo importante para las TI y las ciencias de la computación, ya que un número creciente de trabajos relacionados son tan masivos y complejos que sería imposible que una sola computadora los manejara sola. Pero la informática distribuida también ofrece ventajas adicionales sobre los entornos informáticos tradicionales.

Las máquinas que forman parte de un sistema distribuido pueden ser computadoras, servidores físicos, máquinas virtuales, contenedores o cualquier otro nodo que pueda conectarse a la red, tener memoria local y comunicarse mediante el paso de mensajes.

Hay dos formas generales en que funcionan los sistemas distribuidos:

- Cada máquina trabaja hacia un objetivo común y el usuario final ve los resultados como una unidad cohesiva.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- Cada máquina tiene su propio usuario final y el sistema distribuido facilita compartir recursos o servicios de comunicación.

Al conjunto de ordenadores que forman el sistema distribuido se le denomina cluster y a cada una de las máquinas que forman parte de él son los nodos.

De esta forma tenemos por ejemplo para un cluster de cuatro nodos tendríamos:




Figura 4. Representación de un clúster con sus nodos. Fuente: elaboración propia.

Es importante saber que dentro del cluster todas las máquinas tienen que tener visibilidad entre sí, es decir todas se tienen que comunicar con todas para poder mandarse instrucciones, en caso de que alguna de ellas deje de estar visible para el resto ésta no formará parte del cluster.

Características principales de los sistemas distribuidos

Son varias las ventajas que tiene trabajar con un sistema distribuido entre ellas tenemos:

- **Escalabilidad horizontal:** dado que la computación se realiza de forma independiente en cada nodo, es fácil y generalmente económico agregar o quitar nodos al cluster según sea necesario. De esta forma, por ejemplo, si necesitas más

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

espacio en tu cluster es suficiente con añadir más nodos al cluster sin necesidad de detener nada de lo que se está ejecutando.

Los sistemas tradicionales (no distribuido) funcionan con lo que se denomina un escalado vertical, es decir, para poder aumentar la capacidad de almacenamiento por ejemplo se debe adquirir una máquina mucho más potente y luego pasar a esta nueva máquina todo lo que estuviera en la antigua lo que conlleva una parada de servicio para hacerlo y un coste alto de los equipos a adquirir.

- ▶ **Tolerancia a fallos:** la mayoría de los sistemas distribuidos son tolerantes a fallos, ya que pueden estar formados por cientos de nodos que funcionan juntos. El sistema generalmente no experimenta ninguna interrupción si falla una sola máquina. Esto es debido a que la información que almacenan se replica a lo largo de todo el cluster, es decir un mismo bloque de ficheros puede encontrarse en varios nodos al mismo tiempo, así si un nodo que contiene uno de esos bloques cae, el sistema puede seguir funcionando porque el mismo bloque se encontraba en otro nodo.
- ▶ **Rendimiento:** los sistemas distribuidos son extremadamente eficientes porque las cargas de trabajo se pueden dividir y enviar a varias máquinas. No es lo mismo que un único proceso tenga que leer un fichero entero a que ese fichero se divida en diez bloques por ejemplo y diez procesos paralelos vayan leyendo cada uno de los bloques, el tiempo total en leerlo todo será, hipotéticamente, diez veces menos.
- ▶ **Compartición o multiusuario:** El que un recurso compartido intente ser accedido simultáneamente desde varias aplicaciones no tiene efectos sobre la ejecución de la aplicación.
- ▶ **Abstracción:** El usuario que ejecuta un proceso o se refiere a un proceso del cluster no necesita saber dónde se encuentran los recursos, se lanzará un proceso y el

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

usuario no tiene que hacer nada para que se ejecute correctamente todo lo que ocurra por “detrás” se encargará la herramienta que implemente el sistema distribuido y por tanto es totalmente transparente.

- ▶ **Compatibilidad:** Los dispositivos pueden funcionar con diferentes sistemas operativos. Esto no impide que puedan ofrecer siempre los mismos servicios a los usuarios. Por tal razón, todos los dispositivos conectados son compatibles entre sí.
- ▶ Otro tema fundamental es el diseño del software, porque este también es compatible con todos los sistemas y usuarios que se tienen en cada computadora.

Capa de almacenamiento

Toda arquitectura Big Data tiene como uno de los elementos principales la capa de almacenamiento de información.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 5. Representación arquitectura Big Data. Capa de almacenamiento. Fuente: elaboración propia.

Para el almacenamiento desde hace ya décadas se han venido usando las bases de datos relacionales que fueron y son herramientas muy usadas para almacenar nuestros datos, pero éstas se han ido quedando “cortas” en cuanto a las necesidades que han ido apareciendo en los últimos años.

Pero con las nuevas aplicaciones empresariales estratégicas de análisis de Big Data, ya no debes asumir que la persistencia debería ser relacional.

Se necesitan diferentes bases de datos para manejar las diferentes variedades de datos, pero el uso de diferentes bases de datos genera una sobrecarga. Es por eso que hay una introducción al nuevo concepto en el mundo de las bases de datos, es decir, la Persistencia Políglota.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

La persistencia políglota es la idea de utilizar múltiples bases de datos para impulsar una sola aplicación. La persistencia políglota es la forma de compartir o dividir sus datos en múltiples bases de datos y aprovechar su poder en conjunto. Aprovecha la fuerza de diferentes bases de datos. Aquí se organizan varios tipos de datos de diversas formas. En resumen, significa elegir la herramienta adecuada para el caso de uso adecuado.

Es la misma idea detrás de la programación políglota, que es la idea de que las aplicaciones deben escribirse en una combinación de lenguajes en la ingestión de datos para aprovechar el hecho de que diferentes lenguajes son adecuados para abordar diferentes problemas utilizando el marco de ingestión de datos correcto.

Ahora bien, cuando hablamos de Big Data hay diferentes maneras de almacenar información dependiendo del uso que se vaya a hacer de ella, si es solo almacenamiento, si se quieren realizar consultas o si bien lo que queremos es desarrollar un motor de búsqueda.

Caja de almacenamiento




Figura 6. Sistemas de almacenamiento. Fuente: elaboración propia.

Dentro de cada una de ellas tenemos las herramientas más representativas y que se irán viendo más en detalle en las siguientes unidades.

- Para los **sistemas de ficheros distribuidos** la herramienta por excelencia es **HDFS** (Hadoop Distributed File System) la cual nos va a permitir almacenar volúmenes grandes de datos en un sistema de ficheros distribuido.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- **HDFS (Hadoop Distributed File System):** sistema de archivos distribuido inspirado en el GFS de Google, que permite distribuir los datos entre distintos nodos de un clúster, gestionando la distribución y la redundancia de forma transparente para el desarrollador que vaya a hacer uso de esos datos.
- ▶ En cuanto las bases de datos NoSQL hay varios tipos diferentes que se adaptan perfectamente a la información semiestructurada y a múltiples funcionalidades que se quieran aplicar a la información que se almacena. En este punto las bases de datos NoSQL más conocidas son **MongoDB, Cassandra, Redis, HBase, Redis, Neo4J** entre otras ...
- **HBase:** base de datos NoSQL de tipo columnar, que permite, entre otras cosas, tener registros (filas) de longitud y número de campos variable.
- ▶ En cuanto a los motores de búsqueda nos van a permitir implementar nuestro propio motor de búsqueda como Google. Por ejemplo, son múltiples las páginas que venden productos que tienen uno de estos motores. Amazon, o El Corte Inglés son algunos ejemplos de empresas que implementan su propio motor de búsqueda. **Elasticsearch** o **Solr** haciendo uso de la librería Lucene son algunos ejemplos de dichas herramientas.
- ▶ Incluso podemos encontrar sistemas de almacenamiento que solo persisten la información de manera temporal (durante horas o días) y que se usan mucho a la hora de procesar información en tiempo real ya que van a servir como una especie de “cola” donde ir almacenando la información que se necesita procesar. En este caso la herramienta más usada es **Kafka**.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

En este punto es bueno aclarar que todas las herramientas mencionadas funcionan de manera distribuida, cumpliendo todas las características vistas, lo único que cada una de ellas lo implementa de una manera diferente.

Sistemas de ficheros distribuidos. HDFS

El artículo publicado por Ghemawat, Gobioff y Leung (2003) acerca de Google File System (GFS) fue el germen del sistema de archivos distribuido **HDFS** (Hadoop Distributed File System), que constituye una parte fundamental del ecosistema Hadoop y el cual se ha seguido utilizando sin apenas cambios desde que se introdujo por primera vez.

Podemos definir HDFS como:

Un sistema de archivos distribuido destinado a almacenar archivos muy grandes, pensado para clústeres de ordenadores convencionales.

Si desgranamos esta definición, tenemos que:

- ▶ **1. Sistema de archivos distribuido:** los archivos se almacenan en una red de máquina, lo cual implica que:
 - Son máquinas *commodity* (*hardware* convencional, que puede fallar). Esto difiere de los sistemas tradicionales, donde se adquiría un gran ordenador o *mainframe*, mucho más potente de lo que un usuario doméstico poseía en casa, pero con la restricción de que, al ser una sola máquina, el fallo o la falta de capacidad obligaba a reemplazar el *mainframe* por otro más grande.
 - Es escalable horizontalmente: si se requiere más capacidad, basta con añadir más

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

nodos, en lugar de reemplazar una máquina por otra más grande.

- Necesita incorporar mecanismos *software* de recuperación frente a fallo de un nodo, algo que veremos en la siguiente sección.

- ▶ **2. Pensado para almacenar archivos muy grandes** : permite guardar archivos mayores que la capacidad del disco de una máquina individual. Es decir, un solo archivo puede ocupar cientos de GB, varios TB e incluso PB, a pesar de que cada disco duro de un nodo tenga una capacidad limitada de 500 GB solamente, por ejemplo.
- ▶ **3. Archivos con patrón de acceso *write-once, read-many***: archivos que se crean y después se accede a ellos para ser leídos en numerosas ocasiones. No son archivos cuyo contenido necesitemos reemplazar con frecuencia ni que sean borrados habitualmente. Además, a diferencia de una base de datos, no es importante el tiempo de acceso a partes concretas del archivo (por ejemplo, el fragmento exacto del archivo que contiene el registro con los datos de una persona en concreto), sino que se suele utilizar y procesar el archivo completo en las aplicaciones (modo *batch*, no interactivo). Por este motivo:
 - ▶ No soporta modificación de archivos existentes, sino solo lectura, escritura y borrado.
 - ▶ No funciona bien para:
 - Aplicaciones que requieran baja latencia a fin de acceder a registros individuales dentro de un archivo.
 - Muchos archivos pequeños (generan demasiados metadatos).
 - Archivos que se modifiquen con frecuencia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

HDFS es, en realidad, un *software* escrito en lenguaje Java, que se instala encima del sistema de archivos de cada nodo del clúster. El *software* HDFS se encarga de proporcionarnos una abstracción que nos da la ilusión de estar usando un sistema de archivos, pero, por debajo, continúa usando el sistema de archivos nativo del sistema operativo (por ejemplo, en el caso de máquinas Linux, que son las más habituales para instalar HDFS, estará utilizando por debajo el conocido sistema de archivos ext4). La peculiaridad es que nos permite almacenar archivos de manera distribuida, pero manejarlos como si fuese un único sistema de archivos.

Arquitectura de HDFS

Lo primero que hay que entender es que la información que se va a almacenar es información tan grande que poder guardarla en un único dispositivo sería imposible o altamente costoso. Lo que se hace para guardar la información es partirla en bloques y repartirlos a lo largo del cluster. Esos bloques de información al estar repartidos por múltiples nodos son muy susceptibles de que pueda perderse en caso de que a alguno de los nodos le pase algo, es por ello que los bloques se replican, es decir que la misma información del bloque esté en varios nodos a la vez, de esa forma, aunque le pase algo al nodo que aloja determinados bloques como éstos están duplicados en otros nodos la información no se pierde.

¿Cómo gestiona todo esto HDFS? Hay una serie de servicios que van a estar ejecutándose en los distintos nodos del cluster que son los encargados de ir haciendo todo este trabajo, totalmente transparente para el usuario. Todos estos servicios se gestionan a través de una arquitectura denominada Maestro-Esclavo, donde uno de los servicios ejecutados en un nodo será el que coordina a todos los demás.

Para poder almacenar la información de manera distribuida estos son los elementos y servicios que entran en juego:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Bloques de HDFS

En un dispositivo físico como un disco duro, un bloque físico (o sector) de disco es la cantidad de información que se puede leer o escribir en una sola operación de disco. Habitualmente son 512 bytes. En un sistema de archivos convencional, como, por ejemplo, ext4 de Linux, o NTFS y FAT32 de Windows, un bloque del sistema de archivos es el mínimo conjunto de sectores que se pueden reservar para leer o escribir un archivo. Suele ser configurable (Linux ext4 permite 1 KB, 2 KB, etc.). Generalmente es de 4 KB, y siempre debe contener un número de sectores físicos que sea potencia de 2.

En sistemas de archivos convencionales (p. ej., ext4 de Linux, o NTFS y FAT32 de Windows), los archivos menores que el tamaño de bloque del sistema de archivos siguen ocupando un bloque completo, es decir, se desperdicia una pequeña cantidad de espacio. HDFS tiene su propio tamaño de bloque, que es configurable (por defecto, es de **128 MB**), pero los archivos de menos de un bloque de HDFS no desperdician espacio, a pesar de que siempre usan su propio bloque de datos (es decir, nunca se comparte un bloque de HDFS entre varios archivos).

El tamaño de bloque de HDFS tiene varias implicaciones:

- ▶ Un archivo se parte en bloques, que pueden almacenarse en máquinas diferentes. Así se puede almacenar un archivo mayor que el disco de una sola máquina, ya que se almacena troceado.
- ▶ Cada bloque requiere metadatos (que se almacenan en el *namenode*) para mantenerlo localizado y saber de qué archivo forma parte. Si los bloques son muy pequeños, se generan demasiados metadatos, lo cual llena muy rápido el *namenode* y hace más difíciles las búsquedas. Si son muy grandes, limitan el paralelismo de *frameworks* que operan a nivel de bloque (como Spark), en los que varias máquinas

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

procesan a la vez bloques diferentes de un mismo archivo.

- ▶ Los bloques de datos suelen estar replicados para ofrecer alta disponibilidad y máximo paralelismo: cada bloque está en k máquinas, donde k es el factor de replicación. HDFS fija por defecto un factor de replicación de 3, aunque este valor es configurable individualmente

Namenode y Datanodes

Cuando se instala HDFS en un clúster, cada nodo puede utilizarse como *datanode* o como *namenode*. El *namenode* (servicio maestro) mantiene la estructura de directorios existentes y los metadatos asociados a cada archivo. El nodo donde se ejecuta este servicio no guarda ningún bloque de información únicamente la metainformación del bloque, por ejemplo, uno de los datos que almacena es donde se encuentra cada bloque de un fichero que se almacena.

Por su parte, los *datanodes* almacenan bloques de datos y los devuelven a petición del *namenode* o del programa cliente que está accediendo a HDFS para leer datos.




Figura 7. Arquitectura HDFS. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Factor de replicación

Toda la información de los bloques ya se ha mencionado que se replica en otros nodos para evitar pérdida de datos en caso de que algún nodo falle. En HDFS el factor de replicación por defecto es 3. En el ejemplo de arquitectura de la Figura 5, ese factor de replicación se habría modificado a 2.




Figura 8. Arquitectura HDFS. Fallo de nodo, El bloque en ese nodo se replica de nuevo. Fuente: elaboración propia.

Para saber si un nodo sigue “vivo” el *namenode* recibe periódicamente de los *datanodes* un *heartbeat* (por defecto, cada tres segundos, aunque es configurable en la propiedad `dfs.heartbeat.interval`) y un listado de todos los bloques presentes en cada *datanode* (por defecto, cada seis horas, configurable en `dfs.blockreport.*`). De esta forma se asegura que los nodos “esclavos” siguen en funcionamiento, y en caso de que alguno de ellos no envíe el *heartbeat* el *namenode* asume que ese nodo se ha perdido y que la información de los bloques que estaban en ese nodo se tendrá que volver a replicar para mantener el factor de replicación (ver Figura 8)

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Punto único de fallo

El *namenode* es punto único de fallo (SPOF), lo que significa que, sin él, no es posible utilizar HDFS. La razón es que el *namenode* posee la estructura de directorios del sistema de archivos y conoce qué bloques forman cada archivo y dónde se almacenan físicamente. Por ese motivo, se han ideado diferentes mecanismos, tanto de respaldo del *namenode* como de alta disponibilidad, que detallamos ahora. Más adelante explicamos cómo escalar el *namenode* cuando, en el sistema de archivos, ha crecido el número y la complejidad de estos.

Respaldo de datos del namenode

Se trata de una copia preventiva frente a fallos del *namenode*. Existen dos maneras complementarias de llevarla a cabo:

- ▶ **Copia** de los **archivos persistentes** de los metadatos a otros nodos o a un sistema de ficheros externos como NFS (Network File System (sistema de archivos de red)).
- ▶ **Secondary Namenode:** en otro nodo que no es realmente un *namenode*, un proceso va fusionando los cambios que indica el *log* de edición respecto a la imagen del *namenode*, para tener una fotografía actualizada del estado de los ficheros en el clúster. En caso de fallo del *namenode*, se transfieren a esa máquina los posibles metadatos adicionales que estuviesen replicados en NFS y se empieza a utilizar esa máquina como el *namenode* activo. Esto es un proceso manual que requiere unos treinta minutos, durante los cuales no podemos utilizar HDFS. Al ser tan largo el intervalo de pérdida de servicio, no se considera un mecanismo de alta disponibilidad.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Alta disponibilidad del namenode

Se utilizan un par de *namenodes*, uno de ellos denominado activo y el otro en *stand by*. Ambos comparten un *log* de edición en un sistema de almacenamiento externo y que posee también alta disponibilidad. El *log* va siendo modificado por el *namenode* activo, pero el *namenode* en *stand by* lo va leyendo y va aplicando esos cambios en sus propios metadatos, para estar siempre actualizado respecto al *namenode* activo. Los *datanodes* reportan la información a ambos para monitorizar el estado. En caso de fallo del *namenode* activo, el que se encontraba en *stand by* pasa inmediatamente a activo. Como señalábamos, estará actualizado, puesto que todas las operaciones realizadas por las aplicaciones cliente (las que generan peticiones de lectura o escritura en HDFS) son recibidas siempre por ambos *namenodes*. En la práctica, este proceso apenas lleva un minuto hasta que se restablece el servicio normal gracias al nuevo *namenode*.

Escalando el namenode: namenodes federados

Este mecanismo se utiliza cuando el *namenode* se encuentra saturado y cerca de llenarse. No es un mecanismo de protección contra fallos como tal, aunque también cumple esa función. Consiste en que varios *namenodes* que funcionan a la vez se encargan de directorios distintos del sistema de archivos, sin solapamiento.

Por ejemplo: los metadatos relativos a todo el árbol de directorios que cuelga de */user* se pueden almacenar en un *namenode*, mientras que todo el árbol que cuelga de */share* lo puede hacer en otro. De esta manera, el posible fallo de un *namenode* no afecta en nada a los archivos o directorios que no cuelgan de esa jerarquía. Los *datanodes* sí pueden almacenar indistintamente bloques de archivos de varios *namespaces* (es decir, de varios subárboles).

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

3.2. Sistemas de gestión de almacenamiento de datos

Bases de datos NoSQL

Bases de datos NoSQL. HBase

Otro sistema de almacenamiento muy usado en Big Data son las bases de datos no relacionales o **NoSQL**. En este caso utilizadas no solo como sistema de almacenamiento sino también para poder realizar consultas que ayuden a extraer la información.



Figura 9. Bases de datos NoSQL. Fuente: elaboración propia.

El término NoSQL se definió en 2009 con el fin de agrupar todas aquellas bases de datos no relacionales que estaban ganando popularidad en ese momento. El término NoSQL hace alusión a métodos de almacenamiento no necesariamente estructurados, cuyo lenguaje de consulta «no es SQL» o «no solo es SQL», «Not only SQL».

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Historia del paradigma NoSQL

Aunque se habla mucho de NoSQL actualmente, no es una tecnología tan nueva como la gente se piensa. El nombre NoSQL fue utilizado por Carlo Strozzi en 1998 como nombre de la base de datos basada en archivos que estaba desarrollando. Irónicamente, esta base de datos relacional era solo una interfaz SQL, por lo que no forma parte del movimiento NoSQL actual.

El término volvió a surgir en 2009, cuando Eric Evans lo utilizó para referirse al continuo aumento de bases de datos no relacionales. Aunque el nombre naciera en 2009, las bases de datos NoSQL se remontan a la época de las bases de datos de red y jerárquicas y una serie de productos no relacionales que resolvían problemas que nada tienen que ver con los de Amazon, YouTube, Facebook, Twitter, Netflix o Yahoo.

A lo largo de los años, son muchas las bases de datos que han ido surgiendo, pero si algo ha contribuido al desarrollo de los productos NoSQL, ha sido la serie de papers publicados por Google entre 2003 y 2006 sobre cómo construir una infraestructura escalable para el procesamiento paralelo de grandes volúmenes de datos, que originó Hadoop (y luego Hadoop MapReduce de Yahoo). Más tarde, en 2007 Amazon liberó su servicio de base de datos NoSQL, DynamoDB, con un modelo de datos clave-valor de alta disponibilidad.

Es en este punto donde empiezan los problemas para poder gestionar todo ese volumen de información. Inicialmente, lo que se hizo en las empresas para paliar la falta potencia y rendimiento fue utilizar máquinas más potentes, pero se dieron cuenta que a la larga iba a pasar exactamente lo mismo y el coste iba a ser exponencial. Otra alternativa era la creación de mecanismos pensados para un uso específico que con el paso del tiempo han dado lugar a soluciones robustas, potentes y fáciles de escalar apareciendo así las bases de datos NoSQL.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Las bases de datos NoSQL lo que nos van a permitir es almacenar información en aquellas situaciones en las que las bases de datos relacionales generan ciertos problemas debido principalmente a problemas de escalabilidad y rendimiento de las bases de datos relacionales donde se dan cita miles de usuarios concurrentes y con millones de consultas diarias.

Otra peculiaridad que tienen las bases de datos NoSQL es que son sistemas de almacenamiento de información que no cumplen con el esquema entidad–relación tan utilizada en las bases de datos relacionales.

Tampoco utilizan una estructura de datos en forma de tabla donde se van almacenando los datos, sino que para el almacenamiento hacen uso de otros formatos como clave–valor, mapeo de columnas o grafos.

En 2012, la cantidad de bases de datos NoSQL ha llegado a ser superior a 120 y cada año están saliendo más y más, con el fin de ocupar su lugar en el mercado o creándose con la necesidad de suplir unas características específicas.

Características de las bases de datos NoSQL

A la hora de trabajar con todas estas bases de datos podemos encontrar una serie de características comunes:

- ▶ No usan SQL: el lenguaje de manipulación de datos (lenguaje SQL) de las bases de datos relacionales no es usado en las bases de datos NoSQL teniendo cada una de ellas su propio lenguaje el cual puede llegar a ser muy diferente entre cada una de las diferentes bases de datos NoSQL como ya veremos más adelante. Sin embargo, algunas de ellas utilizan lenguajes de consultas muy similares a SQL tales como CQL en Cassandra.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Algunos de los modelos de bases de datos NoSQL nacieron por la necesidad de ejecutarse sobre clústeres (sistemas distribuidos) ya vistos en módulos anteriores, lo que determinó su modelo de datos y las soluciones implementadas para mantener la consistencia de los datos. Las transacciones ACID utilizadas por las bases de datos relacionales para manejar la consistencia de la base de datos son incompatibles con un entorno de clúster.
- ▶ Operan sin esquema, es decir no es necesario definir previamente la estructura de los datos. Esto permite añadir libremente campos a los registros de la base de datos. Esta característica es particularmente útil cuando se trata con campos de datos personalizados y no uniformes.
- ▶ En general se trata de proyectos de código abierto
- ▶ Posibilidad de gestionar y procesar grandes cantidades de datos rápidamente y eficientemente. En el caso de querer utilizar una base de datos relacional sería necesario disponer de una máquina con grandes prestaciones y mucho más costosa.

La aparición de las bases de datos NoSQL abre la posibilidad de utilizar soluciones personalizadas a las diferentes circunstancias y problemáticas.

Así en vez de usar por defecto siempre una solución basada en una base de datos relacional, primero se puede analizar la naturaleza de los datos y cómo se quieren manipular. A partir del análisis realizado, se decidirá cuál es el tipo de base de datos o combinación de bases de datos más adecuado para realizar la persistencia de los datos.

Ventajas y desventajas de las bases de datos NoSQL

Esta forma de almacenar la información ofrece ciertas ventajas sobre los modelos relacionales. Entre las ventajas más significativas podemos destacar:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Uso de Commodity Hardware, es decir no es necesario equipos muy potentes para poder trabajar, la capacidad de procesamiento necesario para estas bases de datos es mucho menor que las de los sistemas basado en SQL.
- ▶ Escalabilidad horizontal: Para mejorar el rendimiento o aumentar el volumen de información que se quiere almacenar simplemente se consigue añadiendo más nodos al cluster, es decir añadiendo más máquinas sin unos recursos muy altos para hacer que el clúster cada vez sea más potente.
- ▶ El volumen de información almacenado es mucho mayor: como se ha comentado anteriormente al tener más nodos en el cluster la capacidad de almacenamiento aumenta y la gestión de la información almacenada en muchos casos se realiza mediante tablas Hash. En este punto veremos cómo las distintas bases de datos NoSQL utilizan técnicas de sharding para repartir la información a lo largo del cluster

Si no conoces bien que es una tabla Hash te recomiendo que veas el siguiente video de BettaTech (2018) donde se explica con detalle qué son.

<https://www.youtube.com/watch?v=LluB6jU-SwY>

Por el contrario, tiene una serie de desventajas que según la necesidad hacen de su utilización más o menos conveniente:

- ▶ Aunque esté cambiando esta premisa, no ofrecen tanto soporte y nombre como lo hacen bases de datos como Oracle, IBM o Microsoft. Generalmente un vendedor de código abierto no tiene el alcance global, servicios de soporte y la credibilidad de Oracle o IBM.
- ▶ No están lo suficientemente maduras para algunas empresas.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Limitaciones de inteligencia de negocios. Por el momento, las bases de datos NoSQL no tienen buena aceptación con las herramientas de BI, lo que origina que una consulta ad hoc y su análisis implica conocimientos avanzados de programación. Sin embargo, esta tendencia está cambiando, por ejemplo, Quest Software ha creado Toad para bases de datos en la nube, que proporciona capacidades de consulta ad hoc para algunas bases de datos NoSQL.
- ▶ La falta de experiencia. Debido a que NoSQL es una tecnología novedosa, no hay una gran cantidad de desarrolladores y administradores que la dominen. Esto hace difícil a las empresas encontrar personas con los conocimientos técnicos apropiados.
- ▶ Problemas de compatibilidad. A diferencia de las bases de datos relacionales, que comparten ciertos estándares, las bases de datos NoSQL tienen pocas normas en común. Cada base de datos NoSQL tiene su propia API, las interfaces de consultas son únicas y tienen peculiaridades. Esta falta de normas hace difícil el cambio de unos proveedores a otros.

Diferencias entre bases de datos relacionales vs NoSQL

Las bases de datos relacionales han constituido el modelo predominante de base de datos durante las últimas décadas. La razón de este éxito se ha debido a que proporcionaban un modelo estándar. Es decir, los mecanismos nucleares son los mismos y las diferencias se refieren a temas particulares de implementación y funcionamiento en cada producto de base de datos relacional concreto. Pero esencialmente el funcionamiento es el mismo.

Además del almacenamiento de los datos, las bases de datos relacionales ofrecen otras ventajas tales como:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **Gestión de la concurrencia**, permiten gestionar los accesos concurrentes a los datos garantizando la consistencia de los mismos mediante el uso de un mecanismo denominado transacciones ACID (Atómicas, consistentes, aisladas y durables).
- ▶ Permite la integración de varias aplicaciones.
- ▶ Basadas en un modelo formal, se basan en un modelo abstracto formal denominado modelo relacional.
- ▶ Utilizan un lenguaje estándar de manipulación de datos, **SQL**.

Han sido dos los puntos principales que hicieron que estas bases de datos no se pudieran usar con un volumen de datos masivo.

- ▶ **El problema de la impedancia**: Diferencia entre el modelo relacional y las estructuras de datos de los lenguajes de programación. Los valores en una tupla relacional tienen que ser atómicos tales como enteros, booleanos, reales... (no pueden descomponerse en otros valores más simples ni tener una estructura más compleja). Esta limitación no se da en los lenguajes de programación, donde existen estructuras de datos más complejas que las relaciones (no solo existen valores atómicos, sino que los datos pueden organizarse en estructuras compuestas tales como listas, colas...). Por tanto, el problema de la impedancia se refiere a la existencia de dos representaciones diferentes de los mismos datos que requieren una traducción.
- ▶ **El problema de la distribución de datos**: Desde el punto de vista de las bases de datos relacionales existe un problema para implementar soluciones basadas en escalado horizontal dado que no están diseñadas para ejecutarse sobre un clúster.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Aunque sería factible que una base de datos relacional se ejecutara en máquinas diferentes para diferentes conjuntos de datos, sin embargo, la aplicación que usara esta base de datos debería controlar dónde se encuentran los conjuntos de datos de forma que supiera a dónde realizar las consultas de datos según el tipo de datos consultado y posteriormente traer aquellos datos que estuvieran únicamente relacionados lo que lo convierte en un proceso pesado y de poco rendimiento.

Estos problemas a la hora de manejar cantidades grandes de datos hicieron que fuera necesario crear otro tipo de bases de datos y es donde surgen las bases de datos NoSQL.

- ▶ Las bases de datos NoSQL son un conjunto de bases de datos que no se ajustan al modelo de base de datos relacional y se caracterizan por **no tener esquema, por no utilizar SQL ni permitir joins, por no garantizar la propiedad ACID, por escalar horizontalmente, por hacer uso amplio de la memoria principal del ordenador, por resolver el problema de los altos volúmenes de información** y la inmensa cantidad de consultas y transacciones diarias; en resumen, no son relacionales.
- ▶ Una de las características de NoSQL, como ya se ha dicho antes, es la flexibilidad que proporciona para el uso de modelos de datos, la cual permite tener registros con modelos diferentes. Se puede disponer de registro en el que el atributo «color» aparezca o exista y de registros similares que no contengan dicho atributo, y en otros casos que el atributo sea un array o una cadena de caracteres, sin que ocasione ningún tipo de error en base de datos.
- ▶ El gran problema que tiene esta flexibilidad es la capacidad de introducir errores tanto de desarrollo como de insertado, por lo que el programador tiene una alta responsabilidad al lidiar con los datos, ya que de no hacerlo correctamente dará lugar a alteraciones del modelo que generen errores en la aplicación.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Como punto a favor de esta y otras características, mejoran mucho el rendimiento, principal característica de las arquitecturas NoSQL, pero esto no significa que los datos no respondan a un modelo fijo si así se quiere.

Tipos de bases de datos NoSQL. Concepto agregado

Dependiendo de la forma en la que almacenen la información, nos podemos encontrar varios tipos distintos de bases de datos NoSQL. Es complicado realizar una categorización de las bases de datos NoSQL, sin embargo, de acuerdo con el modelo de datos se puede distinguir dos tipos principales, las **orientadas a agregados** y las **orientadas a grafos**.

Bases de datos orientadas a agregados

Lo primero que hay que entender de estas bases de datos es el concepto de **agregado**. En el modelo orientado hacia agregados la información se estructura en base a conjuntos de datos relacionados que son tratados como una unidad que se denomina agregado. En este sentido, un agregado constituye **la unidad de manipulación mínima de la base de datos**, es decir los agregados se actualizan mediante operaciones atómicas.

El uso de agregados facilita que las bases de datos se ejecuten en clústeres dado que el agregado se utiliza como unidad para distribuir y replicar los datos entre las máquinas de un clúster.

Además, el agregado resuelve en parte el problema de la impedancia, dado que un agregado se parece más a las estructuras de datos utilizadas en los lenguajes de programación.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Para entender bien que sería un agregado, podemos partir de la información almacenada en una base de datos relacional, para generar un agregado tendríamos que coger toda la información perteneciente a una entidad y guardarla en un único elemento como por ejemplo u documento JSON.

Véase el siguiente ejemplo, partiendo de las tablas PERSON y CAR generamos un agregado (en este caso en formato JSON) con toda la información perteneciente a una entidad de la base de datos.

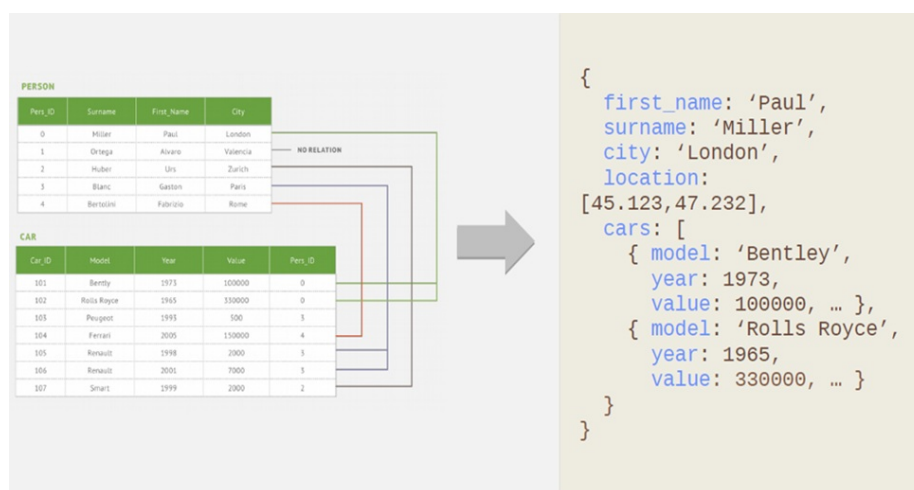


Figura 10. Fuente: elaboración propia.

A partir de ahí la información para una compra quedaría toda recogida en un único agregado representado en este caso en formato JSON. Pues a partir de este concepto encontramos diferentes bases de datos orientadas a agregados:

- **De tipo clave-valor simples.** Como su nombre indica, utilizan una clave para acceder a un valor en específico. Los valores almacenados se manejan como arrays de bytes, es decir, sin ningún esquema específico asignado. Su aplicación es común en sistemas de caché. Uno de los sistemas más conocidos en esta categoría es Memcached, el cual es el sistema de facto para la gestión de caché de datos en aplicaciones web.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **De tipo clave-valor sofisticados.** Estos sistemas son un refinamiento de la categoría anterior con el objetivo de permitir operaciones de lectura y escritura más complejas, así como un modelo de datos ligeramente más elaborado. Ejemplos de sistemas en esta categoría son Cassandra, Dynamo, Voldemort y Riak.
- ▶ **De tipo documental.** Los sistemas dentro de esta categoría permiten almacenar estructuras de datos relativamente complejas. Las implementaciones más conocidas en este grupo son CouchDB y MongoDB, la cual se estudiará con más detalle.
- ▶ **De tipo Columnar.** Como su nombre lo indica, las bases de datos están organizados de columna por columna en lugar de la fila: es decir, todos los casos de un solo elemento de datos (por ejemplo, Nombre de cliente) se almacenan de modo que se puede acceder como una unidad. El objetivo de una base de datos columnar es escribir y leer datos de manera eficiente, desde y hacia el almacenamiento en disco duro, para acelerar el tiempo que se tarda en devolver el resultado de una consulta. Esto los hace especialmente eficaz en las consultas analíticas.

Uno de los principales beneficios de una base de datos columnar es que los datos pueden ser altamente comprimidos. La compresión permite que las operaciones columnares como MIN, MAX, SUM, COUNT y AVG se realicen muy rápidamente.

Ejemplos de sistemas en esta categoría son Cassandra o HBase la cual se verá en detalle un poco más adelante debido a que además basa su sistema de almacenamiento en HDFS

Otra ventaja es que debido a que un sistema de gestión de base de datos columnar es auto indexable, utiliza menos espacio en disco que un sistema de gestión de base de datos relacional que contenga los mismos datos.

- ▶ Basadas en series temporales u objetos, mucho menos utilizadas que las anteriores, pero de las que también veremos algunos ejemplos y cuándo se pueden utilizar.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Bases de datos NoSQL orientadas a grafos

Las bases de datos que entran en esta categoría son las que almacenan la información en estructuras de grafos, cuyos nodos representan la información y las aristas, sus relaciones. Las bases de datos de grafos brindan la facilidad de consultar su información aplicando teoría de grafos.

Dicha teoría comprende un gran número de algoritmos conocidos, que optimizan el recorrido de todos los elementos del grafo (la base de datos), ofreciendo así una navegación mucho más eficiente que las bases de datos relacionales. Algunas implementaciones conocidas son InfoGrid, Virtuoso y Neo4j.

Existe otro tipo de bases de datos denominadas multimodelos, las cuales combinan características de los cuatro tipos antes descritos. Esta unión de características les permite ofrecer una variedad de funcionalidades muy útiles de cara a la explotación de la información.

El hecho de que soporten varios modelos amplía la forma de interactuar con los datos, independientemente del modelo de datos que se esté utilizando. Esto último brinda a los desarrolladores flexibilidad a la hora de construir sus aplicaciones dentro de la compañía, sin preocuparse de las características del dato.

Dentro de este tipo de bases de datos se encuentra Redis. Redis es una base de datos NoSQL multimodelo que permite búsquedas, mensajería, transmisión, grafos y otras capacidades más allá de las que ofrece un simple almacén de datos.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

HBase

Hbase es una base de datos que forma parte del ecosistema de Apache Hadoop.

En su propio portal (<https://hbase.apache.org/>) se define como “una base de datos distribuida, escalable y para almacenamiento de Big Data”.

Además, es importante saber que no es una base de datos relacional, es decir, se podría englobar dentro de las bases de datos “No SQL”. HBase está pensada para almacenar grandes cantidades de datos. Está diseñada para almacenar los datos de forma distribuida, y para proporcionar una gran escalabilidad horizontal. (Es decir, que aumente de forma lineal el rendimiento y la capacidad de almacenamiento con respecto al número de nodos del clúster).

Ésta gran escalabilidad, unida al uso de **Commodity Hardware**, hace que sea posible tener un cluster de un tamaño medio-grande, con un coste por Terabyte bajo, sin los costes prohibitivos del hardware high-end de otras soluciones big data propietarias.

Hbase es un sistema de administración de bases de datos **orientado a columnas que se ejecuta sobre HDFS** (Sistema de archivos distribuido Hadoop).

Tradicionalmente, cuando una base de datos necesitaba más capacidad de procesamiento o de almacenamiento, se escalaba verticalmente. Esto significa que se añadía más memoria o procesador a la máquina, o directamente se migraba la base de datos a un servidor más potente.

La escalabilidad horizontal, en cambio es algo que está en el diseño, no solo de HBase, sino de prácticamente todas las tecnologías del ecosistema Hadoop.

HBase es una implementación de las ideas que Google publicó en su paper sobre BigTable. La idea es ser capaces de almacenar tablas enormes de datos (miles de millones de filas y millones de columnas). Está diseñada para proporcionar escrituras

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

y lecturas aleatorias muy rápidas. Es decir, conociendo la “key” de una fila, es muy rápido obtener columnas de esa fila, aunque la tabla tenga un tamaño de varios Terabytes.

Por tanto, HBase logra un **alto rendimiento** y **baja latencia** al proporcionar un acceso de lectura/escritura más rápido en grandes conjuntos de datos. Por lo tanto, HBase es la elección para las aplicaciones que requieren un acceso rápido y aleatorio a una gran cantidad de datos.

Proporciona **compresión**, **operaciones en memoria** y **filtros Bloom** (estructura de datos que indica si un valor está presente en un conjunto o no) para cumplir con el requisito de lectura-escritura rápida y aleatoria.

Veamos ahora un poco más en detalle las características de HBASE:

- **Open Source:** Como la gran mayoría de las tecnologías dominantes actualmente en el entorno de BigData, HBase es OpenSource. Al igual que Hadoop, pertenece a la Apache Software Foundation. El hecho de que sea opensource, facilita mucho tener un contacto de primera mano con esta tecnología para hacer demos ó pruebas de concepto sin necesidad de pasar por un proceso de compra.

Pero no siempre Open Source significa “gratis”, ya que, en muchas ocasiones, las empresas (especialmente las grandes) están más que dispuestas a pagar dinero a otras empresas que les den soporte de software open source. Es decir, no se pagan licencias de software, pero sí servicios y soporte asociados a los mismos.

- **Distribuida:** HBase utiliza normalmente HDFS como capa de almacenamiento de datos. De forma similar a HDFS y YARN, HBase tiene un nodo máster, que realiza las tareas de coordinación del clúster HBASE y varios nodos workers, que se llaman regionserver. HBase distribuye el contenido de una tabla en “regiones”. Cada región contiene un subconjunto de los datos de la tabla. Cuando una tabla abarca

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

varias regiones, éstas estarán almacenadas en diferentes servidores del clúster, con lo que se consigue que la carga se balancee entre los diferentes workers (regionservers).

- ▶ **Versionable:** Como veremos posteriormente en el modelo de datos, una celda (la intersección de una fila y una columna en una tabla HBase) está versionada, es decir, podemos tener almacenadas varias versiones de la misma celda.
- ▶ **No Relacional / No-SQL:** A raíz de las necesidades en cuanto a capacidad, tipos de datos a almacenar/procesar, y diferentes modelos de acceso a los datos, de algunas empresas de Internet como Google, FaceBook, Twitter, etc. surgieron tecnologías de bases de datos que no seguían el modelo relacional, y por lo tanto no usan SQL para las consultas de datos.

Esto no significa que las bases de datos relacionales “tradicionales” como MySQL, Oracle y Postgresql no sigan siendo de gran utilidad, sino que, para ciertas cargas de trabajo, y ciertos volúmenes de información, se hacen necesarias tecnologías con un diseño diferente. HBase es un ejemplo de estas tecnologías NoSQL.

- ▶ **Orientada a Columnas:** Esto significa que HBase almacena los datos en el file-system organizados por columnas. Esto implica que será mucho más eficiente acceder ó hacer cálculos sobre los valores de unas pocas columnas (aunque el cálculo se compute sobre muchísimas filas). En cambio, en una base de datos orientada a columnas, no es eficiente querer obtener todas las columnas de un registro.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Caso de uso:

Imaginemos que tenemos una cantidad masiva de datos sobre los usuarios de nuestra aplicación (cientos de millones), y para una nueva funcionalidad, requerimos poder acceder de forma muy rápida a los datos de usuarios concretos.

Supongamos que los datos son del tipo:

	Persona 1	Persona 2	Persona 3
Alias	Mperez	Rafaomg	
Nombre	Maria	Rafael	
Primer apellido	Perez	Andrade	
Teléfono particular	34-655145698	34-638597	
Email particular	mperez@google.com	rafaandrade@asesoria.com	
Teléfono trabajo	34-915489878		
Email trabajo	mperez@myst.com		

Figura 11. Fuente: elaboración propia.

Una forma de intentar resolver este problema sería siguiendo un esquema relacional, es decir, como lo haríamos si la tecnología fuera, por ejemplo, MySQL.

Siguiendo este modelo, podríamos definir 3 tablas:

- ▶ Una, con la información básica de personas: Identificador (alias), nombre, apellido.
- ▶ Otra tabla, relacionada con la anterior, con los datos personales adicionales, por ejemplo, email, teléfono, dirección, etc.
- ▶ Una tercera tabla, también relacionada con la tabla “personas”, con los datos profesionales

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Personas	Alias	Nombre	PrimerApellido
	Mperez	Maria	Pérez
	Rafaomg	Rafael	Andrade

Datos personales	Alias	Telefono	Email
	Mperez	34-655145698	mperez@google.com
	Rafaomg	34-638597	

Datos profesionales	Alias	Telefono	Email
	Mperez	34915489878	mperez@myst.com
	Rafaomg		rafaandrade@asesoria.com

Figura 12. Fuente: elaboración propia.

Si ahora quisiéramos obtener, por ejemplo, los diferentes números de teléfono de un usuario concreto, tendríamos que unir (join) datos de estas tres tablas. En nuestro caso, si las tablas son de cientos de millones de filas, estos joins pueden ser muy costosos, y probablemente no cumpliríamos el requisito de que el acceso a estos datos debe ser prácticamente instantáneo.

Vamos a plantear ahora, cómo resolveríamos este problema con una tecnología como HBase. En vez de separar los datos del usuario en diferentes tablas, y posteriormente hacer joins para resolver queries, lo que haríamos sería definir un modelo de datos con una sola tabla que contenga todos los datos de cada usuario.

Cada fila de esta tabla contendría toda la información sobre el usuario, y estaría identificada únicamente por una KEY, en este caso, nuestro “alias”.

Con este modelo, y con una tecnología como HBase, podríamos acceder muy rápidamente a los números de teléfono de un usuario concreto, sin importar que en

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

nuestra base de datos haya cientos de millones de usuarios almacenados

Este sería un ejemplo en el que usar algo como HBase es mucho más conveniente que usar por ejemplo MySQL. Pero recuerda que habrá otros problemas o patrones de acceso donde una base de datos relacional sea más apropiada.

Personas	Personales			Profesionales	
	Alias	Nombre	PrimerApellido	Telefono	Email
	Mperez	Maria	Perez	34-655145698	mperez@google.com
	Rafaomg	Rafael	Andrade	34-638597	

Figura 13. Fuente: elaboración propia.

Modelo de Datos en Hbase

Los datos son almacenados en tablas.

- ▶ Las tablas están formadas por filas y columnas.
- ▶ La intersección de fila y columna, se denomina celda, y puede tener versiones (normalmente, identificadas por un timestamp).
- ▶ El contenido de una celda puede ser cualquier conjunto de bytes (HBase no limita el tipo de datos a almacenar).
- ▶ Cada fila está identificada por una clave única.
- ▶ Las columnas están agrupadas en familias. Es decir, para acceder a los datos almacenados en una celda, tendríamos que conocer:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 14. Fuente: elaboración propia.

Las filas son ordenadas por la clave(Key) en orden léxico. Es decir, si la clave es 1,2,15,28. El orden que vendrá será 1,15,2,28.

► FAMILIAS DE COLUMNAS

Este concepto, después de entender la clave, es fundamental para tener un rendimiento óptimo, ya que HBase almacena los datos organizados por familias de columnas.

Siguiendo con el ejemplo anterior, imaginemos que tenemos datos de personas, unos personales y otros profesionales. Dependiendo del tipo de query más frecuente, nos puede interesar organizar estas columnas en una sola familia o en dos.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Por ejemplo, podríamos definir las siguientes 2 familias de columnas:

Familia de datos personales					
Personas	Alias	Nombre	PrimerApellido	Telefono	Email
	Mperez	Maria	Perez	34-655145698	mperez@google.com
	Rafaomg	Rafael	Andrade	34-638597	

Familia de datos profesionales			
Personas	Alias	Telefono	Email
	Mperez	34-915489878	mperez@myst.com
	Rafaomg		rafaandrade@asesoria.com

Figura 15. Fuente: elaboración propia.

Este modelo se adaptaría bien si en la mayoría de las consultas que hacemos, solo buscamos datos de contacto profesional o personal (pero no ambos).

Si, por el contrario, la mayoría de las consultas acceden a ambos tipos de datos, sería más eficiente dejarlo todo en una misma familia, ya que, a la hora de leer los datos de disco, estarían almacenados “juntos” y evitaríamos hacer 2 lecturas.

OPERACIONES CRUD Y TIMESTAMP

CRUD es el acrónimo en inglés de Crear, Leer, Actualizar y Borrar (Create, Read, Update, Delete).

La operativa habitual del CRUD en Bases de Datos Relacionales es:

- ▶ Create: Se crea un nuevo dato y se escribe en el disco.
- ▶ Read: Se lee el dato del disco
- ▶ Update: se busca el dato a actualizar, y luego se sobrescribe con el nuevo valor.

Tema 3. Gestión y almacenamiento de datos. Búsqueda de respuestas en grandes conjuntos de datos

- **Delete:** Se busca el dato a borrar y luego se efectúa el borrado de este.

Efectivamente, en su configuración más habitual, HBase almacena los datos en HDFS. Si recuerdas lo que has aprendido del diseño de HDFS, recordarás que HDFS es, por diseño, “append-only”, ya que esto le permite poder tratar con ficheros de tamaño muy grande de forma eficiente. El modelo “append-only” es similar a la escritura de un log, en el que siempre se están añadiendo datos al final. Esto es mucho más eficiente que estar buscando líneas en cualquier posición del fichero para modificarlas o borrarlas, pero plantea algunos desafíos, sobre todo cuando es la base para una tecnología de Base de Datos.

Desde el punto de vista del usuario de HBase, se pueden hacer Updates y Deletes con HBase. Pero ya sabemos que HBase está basado en HDFS, por lo tanto ¿cómo puede proporcionar esta funcionalidad?

Ya hemos visto que en HBase, cada celda puede tener múltiples versiones. Pues bien, HBase simula las operaciones de borrado y actualización asociando al valor de cada celda un timestamp, siendo el último de ellos, el más reciente, el valor válido:

- **Operación de Modificación:** Si mperez cambia su número de teléfono, lo que hace Hbase es agregar ese dato como una nueva fila asociada a la clave. Siendo válida la más reciente.

Personas	Alias	Nombre	PrimerApellido	Telefono
	Mperez	Maria	Perez	34-655145698@t1
				34-638189587@t2

Figura 16. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- **Operación de borrado:** Si mperez borra su número de teléfono, el proceso sería marcar ese dato como borrado y asociado a su timestamp.

Personas	Alias	Nombre	PrimerApellido	Telefono
	mperez	Maria	Perez	34-655145698@t1
				34-638189587@t2
				borrado@t3

Figura 17. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

3.3. Importación: Flume, Sqoop, Apache NiFi

Ingesta de datos

La ingestión de datos es el proceso de transmisión de cantidades masivas de datos en nuestro sistema, desde varias fuentes externas diferentes, para ejecutar análisis y otras operaciones requeridas por la empresa. Los datos se ingieren para comprender y dar sentido a una cantidad tan enorme de datos para hacer crecer el negocio.




Figura 18. Representación arquitectura Big Data. Ingesta de datos. Fuente: elaboración propia.

La ingestión de datos se puede realizar en tiempo real o en lotes (batch) a intervalos regulares. Depende enteramente de los requisitos del proyecto.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Algunos ejemplos de tipos de ingesta:

- ▶ La ingestión de datos en tiempo real se prefiere típicamente en sistemas que leen datos médicos como un latido del corazón, sensores de IoT de presión arterial donde el tiempo es de vital importancia.
- ▶ En sistemas que manejan datos financieros como eventos del mercado de valores. Estos son algunos casos en los que el tiempo, la vida y el dinero están estrechamente relacionados.
- ▶ Al contrario, en sistemas que leen tendencias a lo largo del tiempo. Por ejemplo, al estimar la popularidad del deporte durante un período de tiempo, seguramente podemos ingerir datos en lotes.
- ▶ También hay otros usos de la ingestión de datos, como el de la monitorización de la eficiencia de un servicio, para obtener la señal de que todo está bien de los dispositivos de IoT utilizados por millones de clientes.

La ingestión de datos es la parte inicial y la más difícil de toda la arquitectura de procesamiento de datos. Los parámetros clave que deben tenerse en cuenta al diseñar una solución de ingestión de datos son:

- ▶ **Velocidad, tamaño y formato de los datos:** los datos fluyen a través de varias fuentes diferentes al sistema a diferentes velocidades y tamaños. Flujos de datos de redes sociales, dispositivos IoT, máquinas y demás. Y cada flujo de datos que fluye tiene una semántica diferente. Una corriente puede estar estructurada, no estructurada o semiestructurada.
- ▶ **La frecuencia de transmisión de datos:** los datos se pueden transmitir de forma continua en tiempo real o en lotes regulares. Necesitaríamos datos meteorológicos para transmitirlos continuamente. Por otro lado, para estudiar las tendencias, los datos de las redes sociales se pueden transmitir a intervalos regulares.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

¿Cuáles son algunas de las herramientas de ingestión de datos más populares?

A continuación, se muestra una lista de algunas de las herramientas de ingesta de datos más populares disponibles en el mercado.

- ▶ **Apache NiFi:** Apache NiFi es una herramienta escrita en Java y desarrollada por la NSA (Agencia de Seguridad Nacional de EEUU). Automatiza el flujo de datos entre sistemas de software.
- ▶ **Apache Flume:** Apache Flume está diseñado para manejar cantidades masivas de datos de logs.
- ▶ **Apache Sqoop:** herramienta de línea de comandos desarrollada para transferir grandes volúmenes de datos de bases de datos relacionales a HDFS.
- ▶ **Elastic Logstash:** Logstash es una canalización de procesamiento de datos que ingiere datos de múltiples fuentes simultáneamente.
- ▶ **Kafka Connect:** es una herramienta para la transmisión de datos escalable y confiable entre Apache Kafka y otros sistemas de datos.

Apache SQOOP

Apache Sqoop es una herramienta diseñada para transferir datos de manera eficiente entre fuentes de datos estructuradas, semiestructuradas y no estructuradas. Las bases de datos relacionales son ejemplos de fuentes de datos estructuradas con un esquema bien definido para los datos que almacenan. Cassandra, Hbase son ejemplos de fuentes de datos semiestructuradas y HDFS es un ejemplo de fuente de datos no estructurados que Sqoop puede admitir.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

El procesamiento analítico con Hadoop requiere la carga de grandes cantidades de datos de diversas fuentes en clústeres de Hadoop. Este proceso de carga masiva de datos en Hadoop, desde fuentes heterogéneas y luego procesarlos, conlleva un cierto conjunto de desafíos. Mantener y garantizar la coherencia de los datos y garantizar la utilización eficiente de los recursos son algunos factores para considerar antes de seleccionar el enfoque correcto para la carga de datos.

Básicamente lo que se persigue es pasar información que tenemos en tablas en una base de datos relacional a un fichero o ficheros en HDFS sin necesidad de programar nada. Todo esto viene por la necesidad que muchas empresas tuvieron de poder hacer por ejemplos back-ups de su información en HDFS. Sin Sqoop se necesitaría:

- ▶ Un equipo con conocimientos técnicos y que sea capaz de mantener y garantizar la coherencia de los datos y garantizar la utilización eficiente de los recursos.
- ▶ Tiempo de desarrollo para **extraer** la información de las tablas de la base de datos **generar** un fichero con dicha información y **guardarlo** en HDFS.

Por lo que puedes ver es un proceso que siempre es igual por lo que se decidió crear esta herramienta para que pueda automatizar dicho proceso y pueda ser usada por cualquier entidad que necesite ejecutar esos pasos de una manera sencilla. Todo esto se puede conseguir con Sqoop ejecutando un script muy simple y que puede hacer todo ese trabajo en cuestión de minutos, sin necesidad de tener muchos conocimientos y asegurándonos de la integridad de los datos.

La integración de Sqoop con otra herramienta del ecosistema Hadoop como es Apache Oozie (programador de flujo de trabajo para Hadoop) permite programar y automatizar las tareas de importación y exportación. La arquitectura Sqoop es una arquitectura basada en conectores que puede admitir complementos, lo que proporciona conectividad a nuevas fuentes externas.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Arquitectura

Todos los sistemas de gestión de bases de datos existentes están diseñados teniendo en cuenta el estándar SQL. Sin embargo, cada DBMS (sistema de administración de bases de datos) difiere con respecto al dialecto hasta cierto punto. Por lo tanto, esta diferencia plantea desafíos cuando se trata de transferencias de datos a través de los sistemas. Los conectores Sqoop son componentes que ayudan a superar estos desafíos.

La transferencia de datos entre Sqoop Hadoop y el sistema de almacenamiento externo es posible con la ayuda de los conectores de Sqoop.

Sqoop tiene conectores para trabajar con una variedad de bases de datos relacionales populares, incluidas MySQL, PostgreSQL, Oracle, SQL Server y DB2. Cada uno de estos conectores sabe cómo interactuar con su DBMS asociado. También hay un conector JDBC genérico para conectarse a cualquier base de datos que admita el protocolo JDBC de Java. Además, Sqoop Big Data proporciona conectores MySQL y PostgreSQL optimizados que utilizan API específicas de la base de datos para realizar transferencias masivas de manera eficiente.




Figura 19. Sqoop como intermediario entre una base de datos y HDFS. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Ejecución de Sqoop

La ejecución de Sqoop se realiza a través de una serie de herramientas basadas en script las cuales a través de una serie de parámetros conseguimos realizar las acciones que se necesiten. Para pasar datos de un sistema de almacenamiento a HDFS se usará la herramienta *import* mientras que si lo que se quiere es extraer la información de HDFS para guardarla por ejemplo en una base de datos relacional se usará la herramienta *export*.

Herramienta de importación

Importa una tabla individual de un RDBMS a HDFS. Cada fila de una tabla se representa como un registro independiente en HDFS. Los registros se pueden almacenar como archivos de texto (un registro por línea).

La sintaxis para invocarla es la siguiente:

```
$ sqoop import (generic-args) (import-args)
```

```
$ sqoop-import (generic-args) (import-args)
```

Si bien los argumentos genéricos de Hadoop deben preceder a los argumentos de importación, puedes escribir los argumentos de importación en cualquier orden entre sí.

Puedes ver un listado completo de los argumentos en el siguiente [link](#).

Ejemplo donde se realiza una conexión a una base de datos utilizando usuario y contraseña para obtener los datos de una tabla y guardarlos en el directorio */user/ubuntu/tableName* de HDFS:

```
$sqoop import \  
--connect jdbc:mysql://localhost:3306/db1
```

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

```
--username root --password secret
--table tableName
--target-dir /user/ubuntu/tableName
```

Ejemplo de Carga de datos de MySQL a HDFS (restringiendo datos con COLUMNS):

```
$ sqoop import \
--connect jdbc:mysql://localhost/mibbdd \
--username=root -P \
--table=mitabla \
--driver=com.mysql.jdbc.Driver \
--target-dir=/ej_2_columns \
--columns nombre,edad
```

Ejemplo de Carga de datos de MySQL a HDFS (restringiendo datos con WHERE):

```
$ sqoop import \
--connect jdbc:mysql://localhost/mibbdd \
--username=root -P \
--table=mitabla \
--driver=com.mysql.jdbc.Driver \
--target-dir=/ej_edad_mas_40 \
--where "edad > 40"
```

Herramienta de exportación

- La herramienta de exportación exporta un conjunto de archivos de HDFS a un RDBMS. La tabla de destino ya debe existir en la base de datos. Los archivos de entrada se leen y analizan en un conjunto de registros de acuerdo con los delimitadores especificados por el usuario.

La operación predeterminada es transformarlos en un conjunto de instrucciones INSERT que inyectan los registros en la base de datos. En el "modo de actualización", Sqoop generará declaraciones UPDATE que reemplazan los registros

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

existentes en la base de datos, y en el "modo de llamada", Sqoop realizará una llamada a procedimiento almacenado para cada registro.

```
$ sqoop export (generic-args) (export-args)
$ sqoop-export (generic-args) (export-args)
```

Puedes ver los argumentos completos de export en el siguiente [link](#)

```
sqoop export \ --connect
jdbc:mysql://localhost/mibbdd \
--username=root -P \
--table=mitabla2 \
--export-dir=/mitabla_hdfs - m 1
```

Apache Flume

Apache Flume es un servicio distribuido que mueve de forma fiable y eficiente grandes cantidades de datos, especialmente logs. Ideal para aplicaciones de analíticas en línea en entornos Hadoop.

Flume tiene una arquitectura sencilla y flexible basada en flujos de datos en streaming, que permite construir flujos de múltiples por donde viajan los eventos a través de diferentes agentes hasta que alcanzan el destino final.

Inicialmente ideado para garantizar que los logs de múltiples sistemas fuesen almacenándose en el HDFS a medida que se van generando (*streaming*), proporciona un mecanismo para la recolección, agregación y transporte de flujo de grandes cantidades de datos como ficheros de log, eventos syslog... etc. desde varias fuentes a un data store centralizado.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Características de Flume

Las principales características de Flume son:

- ▶ Ingesta de datos de múltiples fuentes en un almacén centralizado (HDFS, HBase)
- ▶ Proporciona un mecanismo para obtener datos de múltiples servidores de forma inmediata en Hadoop
- ▶ Flume no solo se usa para la ingesta de ficheros de logs, también para importar los grandes volúmenes de datos generados por las redes sociales y sitios de comercio electrónico.




Figura 20. Obtención de diferentes tipos de información por parte de Flume. Fuente: elaboración propia.

- ▶ Flume soporta escalabilidad horizontal
- ▶ Especializado en datos de logs.
- ▶ Permite la recolección y agregación de logs de forma sencilla.
- ▶ Pensado para eventos simples, no para eventos complejos.
- ▶ Robusto y tolerante a fallos, con mecanismos de fiabilidad configurables y de conmutación por error y recuperación.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Transferencia de datos a Hadoop

Generalmente, la mayoría de los datos que tienen que ser analizados se producen por varias fuentes de datos como aplicaciones, redes sociales, servidores en cloud...

El método tradicional de transferir datos al HDFS es usar el **comando put**.

```
$ bin/hdfs dfs -put /path/localsrc /path/destHDFS
```

Las limitaciones del uso del comando put son:

- ▶ Solo podemos transferir un fichero cada vez mientras que la generación de datos es mucho mayor que la transferencia al HDFS por lo que el análisis de datos se hace sobre datos “antiguos” perdiendo precisión.
- ▶ Para la ejecución del comando put los datos necesitan estar “empaquetados, fijados” para no enviar datos “a medias” y esto es muy difícil debido a su continua generación.

Añadido a las limitaciones del comando put, hay que tener en cuenta que en HDFS el fichero de entrada tiene tamaño 0 hasta que se cierra la transferencia. Por ejemplo, si una fuente está escribiendo datos en HDFS y la red se interrumpe en medio de la operación de escritura (sin cerrar el archivo) los datos escritos se perderán.

Por todo esto necesitamos una solución que permita la transferencia continua de datos (*streaming*) a HDFS de forma fiable como por ejemplo Apache Flume.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Arquitectura Apache Flume

Los conceptos claves en la arquitectura de Flume son los siguientes:

- ▶ **Evento:** representa la unidad de datos en flume, cuenta de una carga de bytes y una cabecera opcional.
- ▶ **Flujo de datos:** describe el movimiento de eventos del origen al destino, cabe destacar que un evento puede pasar por agentes que de manera encadenada antes de llegar a su destino.
- ▶ **Cliente:** implementación de interfaz que opera en el punto de origen de los eventos y los entrega a los agentes. Los clientes suelen operar en el espacio de proceso de la aplicación de la que están consumiendo datos. Flume Log4j Appender es un ejemplo de cliente.
- ▶ Un proceso independiente que se encarga de recibir, guardar y enviar eventos, está compuesto por:
 - **Source:** implementación de una interfaz que puede consumir eventos que le son enviados con un mecanismo específico y ponerlos en el canal. Avro es un ejemplo de interfaz.
 - **Canal:** almacén transitorio de eventos. Los eventos se entregan al canal a través de las fuentes que operan en el agente. Un evento permanece en un canal permanece en el canal hasta que un receptor lo quite para su posterior transporte. JDBC es un ejemplo de canal que utiliza una base de datos incrustada respaldada por el sistema de archivos para conservar los eventos hasta que sean eliminados por un receptor.
 - **Sink:** implementación de una interfaz que permite consumir eventos de un canal y transmitirlos al siguiente agente o a al destino final. Flume HDFS es un ejemplo de

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Básicamente un agente es un proceso desarrollado en java que configura y define el Source, el Canal y el Sink para un evento.




Figura 21. Agentes de Flume. Fuente: elaboración propia.

Apache NiFi

¿Qué es Apache Nifi?

Es una aplicación con interfaz de usuario basada en web que permite automatizar el flujo de datos entre sistemas. Fue desarrollado por la NSA durante más de ocho años, hasta que en noviembre de 2014 fue donado a Apache Foundation.

Aunque el término flujo de datos se usa en una variedad de contextos, aquí lo usa para referirse al flujo de información automatizado y administrado entre los sistemas. Esta problemática ha existido desde que las empresas tienen más de un sistema y

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

algunos de los sistemas creaban datos y otros sistemas consumían datos. NiFi ha sido diseñado para abordar estos desafíos de los flujos de datos.

Podemos decir que:

“Apache NiFi es una plataforma para el enrutamiento, transformación y entrega de datos entre multitud de sistemas, vía grafos que se construyen desde un entorno web”

Dicho de forma simple, carga datos de una fuente, los pasa por un flujo de procesos para su tratamiento, y los vuelca en otra fuente.

Apache NiFi es una herramienta ETL que se encarga de cargar datos de diferentes fuentes, los pasa por un flujo de procesos para su tratamiento, y los vuelca en otra fuente.

A modos resumen, estos serían los puntos clave de Apache Nifi:

- ▶ Aplicación con interfaz de usuario basada en web.
- ▶ Automatizar el flujo de datos entre sistemas.
- ▶ Sistema basado en flujos.
- ▶ Potente y Fácil de usar.
- ▶ Sistema fiable de procesamiento de datos.
- ▶ Permite distribuir datos.
- ▶ Soporta potentes y escalables gráficos dirigidos al enrutamiento de datos.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Conceptos básicos

- ▶ **Flowfile:** Representa cada objeto que se mueve a través del sistema por los diferentes processors. NiFi realiza un seguimiento de cada uno de ellos con un mapeo de sus pares de clave/valor y su contenido asociado.
- ▶ **Processor:** Son los que realmente realizan el trabajo. Son los diferentes componentes por los que van pasando los flowfiles, que se visualizan en forma de cajitas dentro de la zona de trabajo en la interfaz gráfica. Por ejemplo, son los que realizan la combinación de datos, transformación o mediación entre sistemas.
- ▶ **Connection:** son los encargados de unir los diferentes Processors. Actúan como colas y permite que diferentes procesos interactúen a diferentes velocidades.
- ▶ **Flow Controller:** Mantiene el conocimiento de cómo los procesos conectan y gestionan los subprocessos y actúa como intermediario facilitando el intercambio de FlowFiles entre procesadores.
- ▶ **Process Group:** Conjunto de procesos y sus conexiones. Se puede crear nuevos componentes con uno o varios process groups. Pueden recibir datos a través de puertos de entrada y enviar datos a través de puertos de salida.




Figura 22. Procesadores en NiFi. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 23. Grupo de procesadores en NiFi. Fuente: elaboración propia.

Processors

Cada una de las *cajas* que forman parte del flujo, los procesadores, aportan una funcionalidad concreta al flujo. NiFi viene precargado con una larga lista de operaciones sobre los datos, en forma de procesadores:

- ▶ **Transformación:** ReplaceText, ConvertJSONToAvro,...
- ▶ **Routing:** RouteOnAttribute, RouteOnContent, ControlRate,...
- ▶ **Bases de datos:** ExecuteSQL, ConvertJSONToSQL, PutSQL...
- ▶ **Extracción de atributos:** EvaluateJsonPath, ExtractText, UpdateAttribute...
- ▶ **Interacción con el sistema:** ExecuteProcess ...
- ▶ **Ingestión de datos:** GetFile, GetFTP, GetHTTP, GetHDFS, ListenUDP, GetKafka...
- ▶ **Envío de datos:** PutFile, PutFTP, PutKafka, PutEmail...

Tema 3. Gestión y almacenamiento de datos. Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **División y agregación:** SplitText, SplitJson, SplitXml, MergeContent...

- ▶ **HTTP:** GetHTTP, ListenHTTP, PostHTTP...

- ▶ **AWS:** FetchS3Object, PutS3Object, PutSNS, GetSQS

Para casos específicos en los que el tratamiento del dato requiera algo *ad hoc*, NiFi proporciona un mecanismo para integrar un proceso definido en una simple clase java, como un procesador más dentro del diseño del flujo.

Arquitectura

NiFi se ejecuta dentro de una Máquina Virtual de Java dentro de un sistema operativo. Los componentes principales se reflejan en la imagen.




Figura 24. Arquitectura NiFi. Fuente: Fernandez, O., 2024.

- ▶ **Web Server:** aloja la API de control.

- ▶ **Flow Controller:** es el cerebro de la aplicación tal como se detalló anteriormente.

- ▶ **Extensions:** hay varias extensiones que se pueden añadir, que se ejecutan dentro de la JVM.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **FlowFile Repository:** Es el proceso donde Nifi lleva un control del estado de los distintos flujos
- ▶ **Content Repository:** Donde se alojan los bytes de los flujos de datos activos. Se almacenan en forma de bloques de datos y puede alojarse en diferentes particiones físicas para reducir su volumen
- ▶ **Provenance Repository:** Repositorio donde se alojan todos los eventos de datos. También pueden alojarse en distintas particiones, y contienen un índice para facilitar la búsqueda

Interfaz de usuario

La aplicación web de Apache NiFi es uno de sus puntos fuertes. No sólo permite diseñar y configurar de forma visual el flujo por el que viajarán los datos, sino que, desde esa misma vista, se pueden tanto operar sobre el proceso (arranque y parada) como monitorizar el estado, viendo los posibles errores que se hayan producido.

Este flujo puede modificarse durante su ejecución, simplemente, deteniendo el proceso en un punto, y realizando los cambios. Los datos se encolan en el paso anterior, hasta que se reanude la ejecución.

Tema 3. Gestión y almacenamiento de datos. Búsqueda de respuestas en grandes conjuntos de datos




Figura 25. Elementos de la web de NiFi. Fuente: elaboración propia.

Se puede:

- ▶ Construir un flujo arrastrando los processors.
- ▶ Iniciar, detener y configurar los componentes en tiempo real.




Figura 26. Elementos de la web de NiFi. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Ver errores en los mensajes.
- ▶ Ver estadísticas y estado del flujo de datos.
- ▶ Crear plantillas para conexiones comunes.

Características

Algunas de sus características entrando más al detalle son:

- ▶ Sistema potente y fiable para procesar y distribuir datos. Los datos se procesan en varios servidores antes de enviarlos al usuario o a un sistema de almacenamiento.
- ▶ Interfaz de usuario basada en web para la creación, seguimiento (diagramación visual) y control de los flujos de datos.
- ▶ Muy configurable a la hora de modificar el flujo de datos en tiempo de ejecución y dar prioridad a los datos de forma dinámica.
- ▶ Permite concurrencia, descomposición en diferentes componentes, pruebas y reutilización.
- ▶ Seguimiento de datos Origen a través de todo el sistema (clúster de servidores).
- ▶ Fácilmente extensible a través del desarrollo de componentes personalizados (JAVA).
- ▶ Escalable con nuevos procesadores, puede ser protegido por contraseña, y soporta conexiones seguras vía SSL, SSH y HTTPS.

Los problemas que se pueden evitar con NiFi son:

- ▶ Fallo de los sistemas.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Cuello de botella de consumo en el flujo.
- ▶ Diferentes tamaños de datos y velocidades de sistemas.
- ▶ Seguridad en el flujo de datos entre sistemas.

Algunos ejemplos de casos de uso que resuelve NiFi son:

- ▶ Captura de la información de los sensores remotos.
- ▶ Flujos de datos entre sistemas.
- ▶ Flujos de datos dentro de los propios sistemas.
- ▶ Ingestión de grandes volúmenes de datos.
- ▶ Procesamiento de datos (enriquecimiento, la filtración, la desinfección).

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

3.4. Sistemas de almacenamiento publicador/subscriptor y motores de búsqueda

Sistemas de almacenamiento basados en patrón publicador/subscriptor.
Apache Kafka

Introducción patrón publicador/subscriptor

Todas las aplicaciones crean datos, ya sean mensajes de log, métricas, actividad de los usuarios, notificaciones, entre otros muchos. Estos informan de diferentes aspectos de la aplicación y ayudan a tomar decisiones y a llevar a cabo ciertas acciones, muchas veces relacionadas con otras partes de la aplicación distintas de aquellas donde fueron generados los datos en sí. Por tanto, a fin de aprovechar estos datos generados para beneficiar y optimizar otros procesos, generalmente es necesario que lleguen a aquellos sistemas que los puedan analizar y usar convenientemente. Por ejemplo, Amazon usa información generada durante la navegación web por su plataforma de compra (en qué productos ha hecho clic el usuario, cuáles ha acabado comprando, etc.) para ofrecer recomendaciones a ese usuario durante su navegación. Es decir, utiliza la información recolectada durante la navegación del usuario para generar en tiempo real recomendaciones ajustadas que lo inviten a comprar más productos. De este modo, mejora el funcionamiento de la plataforma de compra (desde un punto de vista de negocio).

Sin embargo, para que esto sea posible, la información de navegación almacenada debe llegar hasta los sistemas que se encargan del procesado necesario para generar las recomendaciones. Y se requiere que este transporte de información se lleve a cabo a la escala que demanda el volumen de usuarios que navega a la vez en la web de Amazon. Este ejemplo pone de manifiesto la necesidad de ampliar las tecnologías *big data* clásicas de almacenamiento y cómputo con otras capaces de mover datos de unos sistemas a otros para su óptimo aprovechamiento.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Entre los diferentes patrones que existen para este fin, la mensajería basada en el patrón publicación/suscripción (en inglés, *publish/suscribe* o *pub/sub*) es una de las más utilizadas actualmente en diferentes plataformas. Este patrón de transporte de datos se caracteriza por tener emisores (publicadores de información o *publishers*) de datos (mensajes) que no están dirigidos a ningún receptor en concreto (contrasta, por ejemplo, con el servicio de correo electrónico, donde el emisor envía un mensaje a un receptor o conjunto de receptores específicos). En lugar de ello, el emisor clasifica el mensaje que envía bajo cierta clase (*topic*) y los receptores interesados (suscriptores o *suscribers*) se suscriben a la clase de mensajes que les interesan para poder recibir todos los mensajes asociados a dicha clase.

¿De dónde surge la necesidad de este tipo de sistemas? Generalmente, las aplicaciones constan de diferentes subsistemas que necesitan comunicarse entre sí. En su forma más sencilla, esta comunicación se hace mediante una cola de mensajes o un canal de comunicación entre procesos. Por ejemplo, en una gran aplicación web de compras, podemos tener varios servidores *frontend* que muestran la página web y permiten la interacción de un gran volumen de usuarios con la plataforma de compra. Dichos servidores *frontend* pueden enviar diferentes métricas de la aplicación (en qué productos hace clic cada uno de los diferentes usuarios, cuánto tiempo permanecen viendo cada producto, qué producto incluyen en o eliminan de su lista de deseos, etc.) a un servidor encargado de procesar todos estos datos para generar métricas semanales, mensuales, por producto, etc., tal y como muestra la figura siguiente.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 27. Sistema sencillo: varios servidores *frontend* (web) envían información sobre navegación de los usuarios al servidor de métricas. Fuente: elaboración propia.

Esta solución sería suficiente si no hubiera que conectar más que dos sistemas: el servidor *frontend* con el de procesamiento de métricas. Pero el problema aparece cuando se requiere conectar varios servidores (no solo el *frontend*, sino también el servidor de chat, otro con datos de las valoraciones de los productos, el que gestiona la cesta de la compra, etc.) con un sistema de métricas más complejo, que tiene un servidor de procesamiento y generación de métricas, otro de monitorización activa de métricas para generar notificaciones y alarmas, otro de visualización de métricas, otro de almacenamiento, etc. De repente, la información relacionada con métricas de la aplicación procedente de diferentes sistemas (productores de la información) necesita ser comunicada a otros tantos sistemas diferentes (consumidores de la información), que utilizan esa misma información, pero de diferentes formas (procesamiento, visualización, almacenamiento...). Como vemos en la figura 2, la complejidad aumenta considerablemente, ya que hay que tener en cuenta que cada flecha, que representa el envío de información de cada grupo de productores a cada consumidor, significa una implementación concreta de dicha conexión con protocolos y formatos de mensaje específicos (y, en ocasiones, distintos).

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 28. Sistema más complejo: muchos productores de mensajes de métricas envían su información a diferentes consumidores. Fuente: elaboración propia.

Para evitar este incremento exponencial de conexiones, ¿por qué no crear un único sistema donde publicar toda la información relacionada con las métricas, de manera que cualquier otro sistema pueda consultarla en dicho punto central? Así se reduce significativamente la complejidad. Como se observa en la figura siguiente, disminuye el número de conexiones y todas ellas se realizan con un elemento central; por tanto, son iguales.




Figura 29. Uso de un bus de mensajes que centraliza la información producida y consumida. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Ahora bien, ¿qué ocurre si este mismo problema se extiende no solo a la información de métricas, sino también a los logs de los diferentes sistemas y a cualquier otro tipo de información interesante para la aplicación? Acabaría teniendo un sistema de publicación/consulta para las métricas, otro exactamente igual para los logs, y así sucesivamente, de forma que estaríamos replicando el mismo sistema para diferentes tipos de información. Esto supone un gasto de recursos de mantenimiento de distintos sistemas que, según se puede concluir si se analizan de cerca, hacen el mismo trabajo (independientemente del tipo de información contenida en los mensajes, el sistema de transporte es el mismo) y que es probable que haya que replicar en un futuro con nuevos tipos de información.

De aquí nace la idea de utilizar un único sistema de transporte de información centralizado (denominado a veces bus o canal de datos), que permita a diferentes sistemas publicar diversos tipos de información que posteriormente pueda ser consultada por otros tantos sistemas distintos, y que se pueda escalar según aumenten las necesidades de la aplicación (es decir, según se incremente el volumen de información producida y consumida). Esto es lo que se denomina patrón publicación/suscripción (pub/sub), el cual se muestra de forma esquemática en la figura siguiente.




Figura 30. Sistema de mensajería publicación/suscripción. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

En este sentido Apache Kafka utiliza dicho patrón para crear la base de lo que se denomina una plataforma de transmisión distribuida. Kafka se utiliza para crear canalizaciones de datos en tiempo real y aplicaciones de transmisión. Es escalable horizontalmente, tolerante a fallos, muy rápido y se ejecuta en producción en miles de empresas.

Introducción a Apache Kafka

Apache Kafka es un sistema de mensajería que sigue el patrón publicación/suscripción (*pub/sub*) descrito en la sección previa. Proporciona un único bus (canal) de datos común, donde varias aplicaciones puedan escribir mensajes y el cual garantice que otras aplicaciones puedan recibirlos leyendo del bus, según los tipos de mensajes que les sean relevantes. Esto se formaliza en la siguiente definición:

Kafka es un bus de datos (también llamado cola de mensajes) distribuido y replicado, basado en el paradigma publicación/suscripción.

Existen varios conceptos en esta descripción que merecen ser examinados con mayor detalle:

- ▶ **Bus.** Un bus de datos es un canal donde las aplicaciones escriben (publican) mensajes, como si fuese un cable de datos de capacidad inmensa. Se llama también cola porque los mensajes se van insertando en un cierto orden y las aplicaciones los van consumiendo (leyendo) según esa misma disposición.
- ▶ **Mensaje.** Se llama también cola de mensajes porque la unidad de información es el mensaje, que sería el equivalente a un registro (fila) de una base de datos. Un mensaje es simplemente un *array* de bytes, sin significado para Kafka. Cada mensaje tiene asociado una clave, que es otro *array* de bytes sin significado. La

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

clave se utiliza para indicar que el mensaje debe escribirse en una partición concreta del *topic* al que va destinado. Por eficiencia, los mensajes se escriben en Kafka en lotes (*batches*), para no generar demasiada sobrecarga en la red. Cuanto mayores son los lotes, más mensajes se pueden gestionar por unidad de tiempo, pero más tarda un mensaje en propagarse al resto de máquinas y aplicaciones consumidoras.

- ▶ **Distribuido y replicado.** Los mensajes se reciben y escriben en el disco local de las máquinas interconectadas; forman así un clúster de Kafka, que opera como un único bus de datos. Además, los mensajes enviados son replicados automáticamente en varias máquinas. Esto aporta robustez frente a fallos o caídas de máquinas, y también un aumento de rendimiento y escalabilidad cuando existan muchas aplicaciones escribiendo y leyendo del bus a la vez.
- ▶ **Publicación/suscripción.** Las aplicaciones que desean recibir mensajes de manera continua se suscriben a un *topic* concreto del bus, de manera que solo les llegarán los mensajes que hayan sido publicados (es decir, escritos por alguna aplicación) en ese *topic*, y ningún otro.
- ▶ **Topics y particiones.** Un *topic* sería el equivalente a una tabla de una base de datos o a un directorio de un sistema de archivos, e indica una agrupación de los mensajes tal que todos están estructurados del mismo modo y pueden interpretarse igual. Una aplicación que escriba o lea del bus debe determinar en qué *topic* desea hacerlo. Es como tener una especie de categorización de los mensajes que se están enviando de esta forma al estar los mensajes que se envían categorizados los subscriptores podrán decidir a que categoría se quieren conectar para obtener los mensajes.

Dentro de cada *topic*, se definen particiones, que indican cómo se distribuyen físicamente los datos y que serían equivalentes a los bloques físicos en los que HDFS divide un archivo. Los mensajes se insertan y se leen por orden de llegada,

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

dentro de una misma partición, pero no existe un orden entre particiones distintas de un *topic*.

El particionamiento permite la escalabilidad y la replicación de los datos, de un modo similar a como lo hacen los bloques de HDFS. Así, si aumenta la frecuencia de escrituras en uno o varios *topics*, podemos añadir más máquinas (brókeres) al clúster de Kafka y más particiones al *topic* para aprovecharlas. Al igual que ocurre en HDFS, es posible indicar la organización física (en armarios o *racks*) de las máquinas del clúster de Kafka para decidir cómo ubicar físicamente las réplicas de cada partición de un *topic*.




Figura 31. Un *topic* llamado con tres particiones. Fuente: elaboración propia.

Casos de uso típicos de Kafka

Algunos de los casos de uso más comunes con Kafka son siguientes:

- **Tracking de actividad en una web**: fue el propósito original de Kafka en LinkedIn. El frontal web envía mensajes a Kafka con la interacción del usuario con la web (clics, modificación de contenido del perfil, etc.). Estos son consumidos por varios sistemas, que monitorizan la información y luego elaboran informes, entrenan modelos de *machine learning* o personalizan la página o los resultados en tiempo real, durante la propia navegación.
- **Mensajería**: varias aplicaciones envían mensajes que después otra aplicación reúne y formatea para mandar por email informes o resúmenes más completos, o información de alertas en tiempo real vía SMS.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **Métricas y logs:** múltiples aplicaciones pueden enviar a Kafka desde diversos puntos el mismo tipo de mensajes de *logs*, que luego son utilizados para elaborar informes o análisis en modo *batch*, o para monitorización y creación de alertas en tiempo real, con base en casuísticas más complejas que afectan a varios sistemas.
- ▶ **Historial de cambios de bases de datos:** para replicar los cambios de una base de datos en otros lugares o para mezclar los cambios desde varias bases de datos distintas.
- ▶ **Procesamiento en tiempo real de flujos de datos:** es el caso más típico. Se opera con datos según van llegando para realizar o actualizar agregaciones. Está incluido en los casos anteriores. Con frecuencia, se utilizan *frameworks* de procesamiento distribuido como Spark, Flink, etc.




Figura 32. Kafka como bus de datos único, con múltiples productores y consumidores. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Conceptos fundamentales

Kafka nació en 2010 como *software* interno de LinkedIn, para resolver un problema que no podían solventar con el *software* existente: un sistema de mensajería con múltiples consumidores al mismo tiempo, en tiempo real, por donde circularsen datos de diverso tipo, y con alta disponibilidad, rendimiento y fácil escalabilidad. Se donó en 2011 a la Apache Software Foundation y se convirtió en proyecto top en 2012.

En 2014, varios exempleados de LinkedIn fundaron Confluent, empresa que soporta el desarrollo actualmente y que incluye productos relacionados como Kafka Stream y Kafka Connect. Hoy lo utilizan intensivamente todas las grandes compañías: PayPal, Walmart, LinkedIn, Cisco, Netflix, Spotify, Uber, eBay, Amazon, etc.

Vamos a ver algunos detalles y conceptos relacionados con el funcionamiento de Apache Kafka.

Bróker

Máquina o nodo donde se ejecuta el servicio de Apache Kafka.

Clúster de Kafka

Mientras que utilizar un clúster de Kafka con un único bróker puede ser suficiente para pruebas de concepto y desarrollos locales, existen numerosos beneficios asociados a tener múltiples brókeres configurados como un clúster. El principal es la capacidad de escalar la carga entre los brókeres que conforman el clúster, así como el uso de replicación de información para evitar pérdidas de datos por fallos potenciales de alguno de los brókeres o durante sus tareas de mantenimiento.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

En versiones anteriores a la 2.8 Apache Kafka utilizaba otra herramienta del ecosistema Hadoop, llamada Zookeeper, para almacenar metadatos sobre el clúster de Kafka (y, en versiones más antiguas aún, también sobre los consumidores). En concreto, Zookeeper posee una lista de los brókeres que son parte de un clúster Kafka en todo momento. Cada bróker tiene un identificador único, con el que se registra en Zookeeper al iniciarse. De esta forma, Zookeeper notifica a un nuevo bróker que intenta unirse al clúster si trata de hacerlo con un ID que ya está registrado.

El primer bróker que se registra en Zookeeper como parte del clúster de Kafka es designado como bróker controlador del clúster (*controller*). Este se encarga de seleccionar las particiones líderes (concepto que se expondrá más adelante) tan pronto detecta brókeres que se unen o se caen del clúster. Si este bróker controlador pierde la conexión con el clúster, el resto de nodos tratarán de ser controladores. Zookeeper mediará en la pugna por ser controlador y asignará este papel al bróker que primero haga la petición.




Figura 33. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Es normal ver aún proyectos que trabajan con versiones a la 2.8, ahora mismo ya no usa Zookeeper y es el propio Kafka quien gestiona cuales son los brókeres controladores.

Topics en Kafka y número de particiones

Los *topics* se crean desde la consola (no se gestionan ni desde los productores ni desde los consumidores) y existen varias opciones de configuración para ello. Una de ellas es el número de particiones, que se puede especificar durante la creación del *topic* o confiar en el parámetro *num.partitions* en la configuración del servidor (por defecto, configurada en 1). **Es importante tener en cuenta que el número de particiones de un *topic* únicamente se puede incrementar, nunca disminuir**, por lo que hay planificar de antemano cuántas particiones son óptimas y qué configuración existe en el servidor en caso de que queramos un número de particiones menor que el preestablecido.

El comando para crear un topic con 3 particiones y factor de replicación de 1:

```
kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic topic_name --create --partitions 3 --replication-factor 1
```

El comando para ver información del topic:

```
kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic topic_name --describe
```

Y para listar los topics que hay creados en Kafka puedes usar el comando:

```
kafka-topics.sh --zookeeper 127.0.0.1:2181 --list
```

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Teniendo en cuenta que **el número de particiones va a ser en parte responsable del balanceo de la carga de mensajes en el clúster**, la pregunta que puede surgir en este punto es: ¿qué número de particiones es óptimo al crear un *topic*? En muchos casos, se indica un número de particiones igual o múltiplo del número de brókeres en el clúster para distribuir la carga de forma homogénea. Si se quiere hilar más fino y se tiene información más específica de los requisitos y capacidades del sistema, otros factores que tener en cuenta son la capacidad de envío/recepción de los productores/consumidores frente a la capacidad que se espera del *topic*. Por ejemplo, si se desea alcanzar una tasa de lectura de 1GB/s en un *topic* concreto y cada consumidor tiene un máximo de procesado de 50MB/s, entonces se necesitarán, al menos, 20 particiones para dicho *topic*, de forma que pueda haber hasta 20 consumidores leyendo del *topic* a la vez ($20 \text{ consumidores} \times 50\text{MB/s} = 1\text{GB/s}$).

Otro aspecto que debe configurarse es la **política de retención**, es decir, determinar cuándo eliminar mensajes de un *topic*. Existen dos variantes de esta configuración: por tiempo o por tamaño. La estrategia más habitual es configurar cuánto tiempo se va a mantener cada mensaje grabado en disco y disponible para su consumo. Este parámetro se puede configurar en diferentes escalas (horas, minutos y hasta milisegundos), aunque 168 horas (una semana) es el valor por defecto. La estrategia alternativa es configurar el número total de bytes de mensajes que se mantendrán en disco; en este caso, se configura por partición (no por *topic*). Si se especifican ambos criterios (tiempo y tamaño de partición), los mensajes se eliminarán según se vayan cumpliendo cualquiera de las dos condiciones.

Replicación de particiones, líder de partición y sincronización de réplicas

Como se comentaba previamente, tener un clúster de Kafka con varios brókeres proporciona la oportunidad de replicar particiones, una de las principales características de este sistema. La replicación es crítica porque garantiza la

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

disponibilidad y durabilidad de los mensajes publicados, aun cuando alguno de los brókeres falle.

Los mensajes de Kafka están organizados en *topics*. Cada *topic* está a su vez dividido en diferentes particiones, cada una de las cuales está replicada en varios brókeres, lo que proporciona redundancia frente a fallos. La cantidad de réplicas o factor de replicación (concepto análogo a HDFS) es configurable mediante un parámetro, fijado en 3 por defecto. Existen dos tipos de réplicas de una partición:

- ▶ **La réplica líder.** Cada partición tiene una única réplica designada como líder. Todos los mensajes publicados y consumidos en una partición se harán en la réplica líder. Es decir, el bróker que contenga la réplica líder de una partición será el encargado de recibir todos los mensajes publicados en dicha partición, así como de enviar todos los mensajes que los consumidores lean de dicha partición (figura 7).
- ▶ **Las réplicas *followers*.** Todas las réplicas de una partición que no son líderes se denominan *followers*. Los brókeres que contienen una réplica *follower* de una partición no escriben mensajes procedentes de productores en la réplica ni sirven mensajes a consumidores de dicha partición. Su única función respecto a la partición de la que contienen la réplica *follower* es replicar los mensajes que se escriben en la réplica líder (procedentes de peticiones de productores) y mantenerse actualizados. En caso de que el bróker con la réplica líder falle, el bróker controlador elegirá un nuevo bróker como líder de la partición de entre los *followers*.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos




Figura 34. Topic con dos particiones replicadas. Cada bróker es líder de una partición. Fuente: Narkhede, Shapira y Palino, 2017.

Para mantenerse sincronizados, los brókeres con réplicas *followers* solicitan regularmente al bróker con la réplica líder los últimos mensajes que este haya recibido. Esas peticiones son un indicativo de cómo de retrasados van en la sincronización. Los retrasos pueden estar causados por la congestión de la red, por caídas ocasionales del bróker, etc. El líder es responsable de saber qué réplicas *followers* están sincronizadas (*in-sync*) y cuáles no. Aquellas que no han pedido los últimos mensajes a la réplica líder desde hace más de 10 segundos se consideran réplicas no sincronizadas (*out-of-sync*) y dejan de ser valoradas como potenciales sucesores de la partición líder en caso de que esta falle.

Por otro lado, es importante también decidir cómo repartir las réplicas entre los brókeres. En general, se persiguen tres objetivos:

- Repartir las réplicas de forma homogénea (por ejemplo, si hay 40 réplicas en total entre todos los *topics* y hay 5 brókeres, cada bróker tendrá 8 réplicas).

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Asegurar que, para cada partición, cada una de sus réplicas está en un broker distinto.
- ▶ Si los brókeres saben en qué *rack* están instalados, asignar réplicas de cada partición en *racks* distintos, siempre y cuando sea posible.

Procesamiento de las peticiones de escritura

En general, la función de un bróker es procesar peticiones enviadas desde productores, suscriptores, brókeres con réplicas *followers* de sus réplicas líder o desde el bróker controlador. Siempre son los clientes (productores, consumidores, o brókeres) los que inician las conexiones y envían las peticiones, y el bróker las procesa y responde a todas ellas. Concretamente, el bróker procesa y responde todas las peticiones recibidas de un mismo cliente en el mismo orden en que las ha recibido, de forma que se garantiza el funcionamiento de Kafka como una cola de mensajes.

Las dos peticiones más habituales son las peticiones de escritura o producción de mensajes (*produce request*) y las peticiones de consumición o lectura de mensajes (*fetch requests*), ambas enviadas al bróker con la réplica líder. Si un bróker con réplica *follower* recibe peticiones para dicha réplica, el cliente que ha realizado la petición recibirá un error. Dado que el responsable de saber a qué bróker enviar la petición es el cliente, existe una petición adicional, la petición de metadatos, que sirve para obtener información de quién es el bróker con la réplica líder de la partición requerida. Cuando un cliente realiza estas peticiones de metadatos, guarda la información recibida en caché para reducir el número de peticiones enviadas.

En cada productor, se configura, de manera independiente, el número de réplicas de una partición que han de recibir un mensaje para considerarlo como escrito con éxito. Que un mensaje haya sido escrito con éxito significa que puede ser leído por los

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

consumidores. Hasta que un mensaje no llega a este estado, no puede ser leído por ningún consumidor, como veremos más adelante. El número de réplicas que tienen que recibir el mensaje para considerarlo escrito con éxito se configura en el parámetro *nacks* y puede tomar uno de tres valores:

- ▶ *nacks=0*, ni siquiera esperamos a que el líder de la partición lo haya escrito.
- ▶ *nacks=1*, basta con que el líder confirme que lo ha recibido y escrito.
- ▶ *nacks=all*, tienen que recibirlo todas las réplicas que estén sincronizadas.

El bróker que recibe un mensaje para una de sus particiones líder lo escribe inmediatamente en disco. Si el valor de *nacks* que venía en la petición es 0 o 1, el bróker devuelve un mensaje de respuesta al productor como que se ha escrito con éxito. Si no, el líder, además, escribe el mensaje provisionalmente en un *buffer* llamado purgatorio de mensajes, hasta que recibe las peticiones de las réplicas que desean mantenerse actualizadas, les envía este mensaje y estas confirman su escritura. Es decir, el mensaje escrito en la réplica líder permanece en el purgatorio hasta que el bróker con dicha réplica líder ha recibido confirmación de que el mensaje ha sido escrito en todas las réplicas *followers*. Solo en ese momento el líder devolverá la respuesta de éxito al productor que solicitó la escritura.

Procesamiento de las peticiones de lectura

Cuando un consumidor desea leer mensajes de un *topic*, envía una petición al bróker que posee la réplica líder de esa partición. Como comentábamos antes, para saber qué bróker tiene la réplica líder de la partición en la que desea escribir, enviará una petición de metadatos si no tiene dicha información en caché. El mensaje de petición de lectura de mensajes contiene varios datos:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ El *topic*, la partición y el *offset* del mensaje a partir del cual desea consumir (por ejemplo, «envíame los mensajes, empezando en el *offset* 25 de la partición 1 del *topic* “vuelos”»),
- ▶ El tamaño máximo del bloque de mensajes que desea que le sean devueltos. Esto garantiza que el bróker no enviará más datos de los que el cliente es capaz de almacenar en memoria.
- ▶ Opcionalmente, el tamaño mínimo de datos que desea recibir. En este caso, el bróker no le envía ningún mensaje hasta no tener acumulado, al menos, ese mínimo. Este parámetro suele ir acompañado de otro que indica un tiempo máximo de espera, transcurrido el cual el bróker devolverá los mensajes que tenga, aunque no alcancen el tamaño mínimo indicado. Esto permite reducir procesado y uso de la red cuando los *topics* no manejan una gran cantidad de mensajes.

Si el *offset* especificado existe (no se ha borrado aún del disco), el bróker con la réplica líder de la partición envía directamente desde disco los mensajes solicitados. A pesar de necesitar lecturas y escrituras de disco, el acceso es rápido gracias a la estructura del fichero y a la existencia de índices. Además, Kafka utiliza un mecanismo denominado *zero-copy*, es decir, envía datos directamente desde disco, sin pasar por un *buffer* en memoria principal. Esto contrasta con el funcionamiento de otros sistemas que utilizan cachés locales antes de enviar datos a los clientes, y permite obtener un mejor rendimiento.

Es importante tener en cuenta que un bróker (líder de una partición) solo devolverá mensajes que hayan sido escritos en todas las réplicas sincronizadas (*in-sync-replicas*). Si no, los mensajes no serán visibles, porque todavía no existirán oficialmente en Kafka y no podrán ser consumidos. Este comportamiento evita riesgos de tener comportamientos inconsistentes. Por ejemplo, si solo el bróker con la réplica líder tiene un mensaje que aún no ha sido enviado a ninguna otra réplica

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

follower, podría ocurrir que un cliente leyera dicho mensaje y, acto seguido, el *broker* líder fallara; así, cuando otro cliente fuera a leer el mensaje, este no estaría disponible, con lo que se crearía una situación de inconsistencia en relación con la información leída por los diferentes clientes. Al permitir la lectura de mensajes solo cuando están escritos tanto en la réplica líder como en todas las réplicas sincronizadas, se evitan este tipo de situaciones.

Cabe destacar que todos los mensajes enviados por un productor tienen que estar disponibles en todas las réplicas *in-sync* antes de poder ser leídos, independientemente del valor de *nacks* que tenga configurado el productor. Es decir, si un productor tiene configurado *nacks*=1, solo significa que Kafka le indicará que su mensaje ha sido escrito en la réplica líder, pero no está garantizado que este pueda ser leído por los consumidores todavía, no hasta que no esté escrito también en todas las réplicas sincronizadas.




Figura 35. Los consumidores solo ven mensajes que existan en todas las réplicas sincronizadas. Fuente: Narkhede, Shapira y Palino, 2017.

Implementación de productores Kafka

Hasta ahora, hemos visto cómo funciona Kafka desde el punto de vista de un observador externo que inspecciona el funcionamiento global del sistema.

Sin embargo, para que este funcione, se necesita tener cierto código en las aplicaciones productoras que permita escribir datos en Kafka, y cierto código en las

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

aplicaciones consumidoras para la lectura de estos. A fin de implementar este código, Apache Kafka ofrece una serie de scripts en su instalación y un API para diferentes lenguajes como Java o Python que proporcionan la funcionalidad requerida por los productores (escritura de mensajes en *topics*) y consumidores (lectura de mensajes de *topics*).




Figura 36. Productor de Kafka emitiendo información a un *topic* con tres particiones. Fuente: elaboración propia.

Centrándonos en el punto de vista del productor vamos a verlo como crearlos y empezar a emitir información de con los propios scripts de Kafka.

Para crear un productor desde línea de comandos se haría de la siguiente manera:

```
kafka-console-producer.sh --broker-list 127.0.0.1:9092 --topic topic_name
```

Y a partir de ese momento toda la información que se escriba se mandará al topic. Esta no es la forma habitual de trabajar, se suele hacer usando las APIs de los distintos lenguajes de programación, pero para entender el funcionamiento es bastante útil.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Implementación de consumidores Kafka

Como hemos visto, un consumidor es una aplicación que, mediante el empleo de la API proporcionada por Kafka, es capaz de leer mensajes de un *topic* concreto que es de su interés.

Dichos mensajes están organizados en particiones, las cuales se encuentran físicamente distribuidas entre los brókeres.



Figura 37. Un único consumidor leyendo información de un *topic* con tres particiones. Fuente: elaboración propia.

Antes de entrar en los detalles de implementación de los consumidores igual que hicimos en la sección previa con los productores, es necesario revisar un concepto clave en Kafka: los grupos de consumidores. Una vez tengamos claro qué son, por qué son tan importantes y cómo funcionan, pasaremos a ver algunos detalles de implementación con la API Java de Kafka.

Para leer a través de la línea de comandos la información de un *topic* puedes ejecutar la siguiente instrucción:

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

```
kafka-topics.sh --zookeeper 127.0.0.1:2181 --topic topic_name --create --partitions 3 --replication-factor 1
```

Esto leerá solo la información que llegue a partir de ese momento, si quieres leer la información que hay desde el principio ejecuta:

```
kafka-console-consumer.sh --bootstrap-server 127.0.0.1:9092 --topic topic_name --from-beginning
```

Grupos de consumidores

Es habitual que un consumidor lea mensajes de Kafka, realice algún tipo de procesado con ellos y los almacene o envíe a un nuevo *topic* de Kafka. Tanto el procesado como el almacenamiento son procesos no excesivamente rápidos, que pueden suponer un problema si el ritmo de publicación de mensajes es muy alto y el consumidor no puede seguirlo. Recordemos que Kafka nació en un entorno, LinkedIn, donde el tráfico de mensajes creados era muy alto y, consecuentemente, se requería que los consumidores pudieran procesar ese gran volumen de datos publicados rápidamente a un ritmo adecuado.

En casos como este, resulta necesario un mecanismo para escalar el consumo de mensajes de un *topic*. Para ello, podemos crear varios procesos consumidores que lean del mismo *topic* de forma paralela, lo que permite aumentar el ritmo de consumo de mensajes. Con esta idea en mente nace el concepto *grupo de consumidores*. Generalmente, un proceso consumidor forma parte de un grupo de consumidores concreto. Las particiones existentes en el *topic* al que está suscrito el grupo de consumidores son asignadas por Kafka a sus distintos miembros. Por ejemplo, si tenemos tres particiones en un *topic* y existe un grupo con un único consumidor, este será el encargado de leer de todas las particiones; sin embargo, si el grupo está

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

compuesto por dos consumidores, cada uno de ellos tendrá acceso a dos de las particiones y otro a una mientras que si tenemos tres consumidores cada uno de ellos leerá la información de una partición (figura 34).




Figura 38. Asignación de particiones de un *topic* a los consumidores de un grupo. Fuente: elaboración propia.

Nótese que, en este caso, no tendría sentido tener más de tres consumidores en el grupo, porque un cuarto consumidor quedaría ocioso al estar ya asignadas todas las particiones a algún consumidor.

Para crear por consola consumidores dentro de un grupo puedes ejecutar el siguiente comando tantas veces como consumidores quieras meter en un grupo lo importante es que todos tengan el mismo id de group en este caso grupo1.

```
kafka-console-consumer.sh --bootstrap-server 127.0.0.1:9092 --topic  
topic_name --group grupo1
```

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Motores de Búsqueda. Elasticsearch

Un motor de búsqueda es una potente herramienta que permite indexar un gran volumen de datos para posteriormente hacer consultas sobre ellos.

Los motores de búsqueda permiten hacer búsquedas aproximadas, facetas y resaltado de contenido sobre la información indexada.

Un caso de uso clásico es hacer consultas de texto completo. Al estar los datos indexados los resultados se obtienen de forma muy rápida. Un claro ejemplo de esto es el buscador de Google o de páginas o aplicaciones con muchos productos como Amazon, El Corte Inglés o Spotify entre otros.

Conceptos básicos

Los motores de búsqueda almacenan la información en formato documento Json

```
{
  "_id": "53636f6d",
  "_index": "indexertrigger-2014.12.09",
  "_score": 1,
  "_source": {
    "@version": "1",
    "@timestamp": "2014-12-09T16:07:34.043Z",
    "type": "trigger",
    "host": "VD8022",
    "datasource": "Scom",
    "metricname": "% Processor Time",
    "metricinstant": "1415606400000"
  }
}
```

Los documentos están divididos en **campos**:

```
{
  "_id": "53636f6d",
```


Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

```
"_index": "indexertrigger-2014.12.09",
"_score": 1,
"_source": {
  "@version": "1",
  "@timestamp": "2014-12-09T16:07:34.043Z",
  "type": "trigger",
  "host": "VD8022",
  "datasource": "Scom",
  "metricname": "% Processor Time",
  "metricinstant": "1415606400000"
}
```

Los campos de un documento tienen tipos que los describen:

```
{
  "_id": "53636f6d",           #String
  "_index": "indexertrigger-2014.12.09",   #String
  "_score": 1,                 #Integer
  "_source": {                 #Objeto
    "@version": "1",
    "@timestamp": "2014-12-09T16:07:34.043Z",
    "type": "trigger",
    "host": "VD8022",
    "datasource": "Scom",
    "metricname": "% Processor Time",
    "metricinstant": "1415606400000"
  }
}
```

Y, respetando las normas de los tipos, los campos almacenan valores:

```
{
  "_id": "53636f6d",
  "_index": "indexertrigger-2014.12.09",
  "_score": 1,
  "_source": {
    "@version": "1",
    "@timestamp": "2014-12-09T16:07:34.043Z",
    "type": "trigger",
    "host": "VD8022",
```

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

```
"datasource": "Scom",
"metricname": "% Processor Time",
"metricinstant": "1415606400000"
}
}
```

Algunos campos, son especiales... y permiten guardar metadatos del motor de búsqueda:

```
{
  "_id": "53636f6d",
  "_index": "indexertrigger-2014.12.09",
  "_score": 1,
  "_source": {
    "@version": "1",
    "@timestamp": "2014-12-09T16:07:34.043Z",
    "type": "trigger",
    "host": "VD8022",
    "datasource": "Scom",
    "metricname": "% Processor Time",
    "metricinstant": "1415606400000"
  }
}
```

Índice

Podemos pensar que un índice en un motor de indexación es similar a una representación virtual de índices tradicionales de biblioteca. De igual manera que un índice de una biblioteca almacena de forma ordenada los datos de los libros que contiene la librería, un índice de un motor de indexación contiene la información ordenada de los datos que el motor ha indexado.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Un índice es un mecanismo de organización de datos, que permite al usuario particionar los datos de una determinada manera. Es una estructura de datos que almacena información. La Información que ha sido recopilada, analizada y procesada por el motor de indexación.

La forma más sencilla de pensar en un índice es compararlo con una base de datos relacional. Se podría decir a muy alto nivel que un índice es como una base de datos.

- ▶ Bases de datos => Tablas => Columnas / Filas
- ▶ Índices => Tipos => Documentos con propiedades

Si bien es cierto que los índices/tipos son mucho más flexibles que las abstracciones de tabla/base de datos a las que estamos acostumbrados en las RDBM. Pueden considerarse mecanismos convenientes de organización de datos, con beneficios de rendimiento adicionales según la forma en que configure sus datos.

¿Cómo es la estructura de datos de un índice?

Los índices de los motores de indexación hacen uso de una estructura de datos llamada **índice invertido**. Esta estructura de datos es lo opuesto a cómo una base de datos relacional almacena la información:

- ▶ La base de datos relacional almacena los datos en una fila e indexa los valores de los campos para poder hacer un acceso basado en búsqueda ordenada. Encontrar una fila supone buscar en su índice un valor y retornar únicamente la fila encontrada.
- ▶ La estructura de índice invertida almacena un índice con todos los valores posibles indexados. Para cada valor indexado, la estructura almacena una entrada por cada documento donde ese valor fue encontrado. Así, al buscar un valor en concreto, se busca de forma ordenada en el índice, pero una vez encontrado, la estructura de datos retorna todos los documentos donde ese valor aparece.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Los índices, además, almacenan metadatos con información adicional sobre:

- ▶ Frecuencia de aparición de términos: permite que documentos con mayor frecuencia del mismo término gocen de mayor relevancia en nuestras búsquedas.
- ▶ Ubicación en el documento: el índice guarda la posición donde aparece el término en el documento. Facilita que, cuando se visualice el resultado en modo página web, el texto buscado pueda resaltarse en otro color de forma sencilla.
- ▶ Significados similares: pudiendo buscar Madrid, por ejemplo, y retornar valores como 'Comunidad de Madrid', 'Municipio de Madrid', etc.

Tanto la estructura de índice invertida como los metadatos que la enriquecen, son factores que permiten mejorar la calidad de la búsqueda hasta límites insospechables, encontrando documentos que, aunque no coincidan directamente, sí tienen una relación semántica con la búsqueda.




Figura 39. Fuente: elaboración propia.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

El proceso de indexación de información reúne una serie de etapas:

- ▶ **Tokenización:** proceso por el cual el motor de búsqueda es capaz de encontrar límites entre palabras. Corta el texto en diferentes 'tokens' y analiza cada token por separado a la hora de indexar el documento. Una vez indexado, el 'token' está disponible en el índice para su consulta directa posterior.
- Hay muchos tokenizadores, por espacios en blanco, por guiones, Camel Case o incluso especificar con expresiones regulares

{“title”:“Torrente, el brazo tonto de la ley”}

Torrente
el
brazo
tonto
de
la
ley

Figura 35. Fuente: elaboración propia.

- ▶ **Análisis de texto:** cuando indexamos información, es necesario que el texto se procese de acuerdo con nuestros requisitos antes de dividir el mismo en términos que se almacenen en el índice invertido. Es decir, es un proceso por el cual el motor de indexación es capaz de analizar 'token' a 'token' e inferir conocimiento sobre ellos: es una dirección de correos, es un número, es una dirección geográfica. El análisis de texto permite agregar metadatos al índice y hacer así que la búsqueda sobre los 'tokens' indexados sea más eficiente.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Por ejemplo:

- ▶ Analizador de español y de sinónimos (deja raíz más sinónimos)
- ▶ Eliminar stop words.
- ▶ **Stemming**: mediante la deducción de palabras relacionadas o derivadas. El motor de búsqueda enriquece el índice con información de 'tokens' parecidos o derivados de otros 'tokens'. Enriqueciendo así la búsqueda y haciéndola capaz de encontrar términos 'que se parecen a...'

Torrente	→	torrent, arroyo, riachuelo
el		el
brazo		braz, extremidad
tonto		tont, bob, mem, neci
de		de
la		la
ley		ley, norma, precepto

Figura 40. Fuente: elaboración propia.

¿Que nos aportan los motores de indexación y búsqueda?

Facilitan que el proceso de búsqueda sea más rápido mediante una adecuada estructura de datos.

Búsquedas más eficientes basadas en *relevance scoring*, con mayor acierto en las respuestas.

- ▶ ¿Cuántas coincidencias tengo en un mismo documento?

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Para dos coincidencias, ¿cuál debo mostrar primero?
- ▶ Las respuestas pueden ser priorizadas basadas en su contenido

Llevar a cabo búsquedas distribuidas:

- ▶ Consultas balanceadas sobre un grupo de fuentes de datos externas
- ▶ Resultados son fusionados y presentados en un formato conciso
- ▶ El usuario recibe una respuesta única, sin duplicados y ordenada.

El agrupamiento de texto:

- ▶ Agrupa cientos de resultados de búsqueda en temas calculados on-the-fly.
- ▶ Permite la navegación por el contenido y por temas y no por metadatos.
- ▶ Metadatos son mostrados a modo de facetas.

El filtrado por facetas:

- ▶ Facilitando la exploración de las búsquedas mediante el filtrado de la información.
- ▶ El filtrado de la información está basado en el contenido mostrado en la búsqueda.

Motores SQL transaccionales vs. Motores de indexación y búsqueda

El motor de indexación es superior en sus tareas que el motor de base de datos tradicional.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Esto no significa que los motores de base de datos sean peores, son mucho más eficientes para las tareas que fueron diseñados que los motores de indexación: almacenamiento de datos transaccionales.

Una arquitectura de gestión de datos perfecta sería:

- ▶ Un sistema de SQL gestionando datos transaccionales de una aplicación.
- ▶ Un crawler de SQL leyendo la información de los datos transaccionales muy frecuentemente.
- ▶ Y alimentando a un motor de indexación con dicha información.

Con este sistema, los usuarios que deseen ejecutar consultas complejas como la propuesta en nuestro problema original lanzarían la pregunta contra el motor de búsqueda, evitando así el problema de rendimiento que pudiéramos encontrar en el motor transaccional. Una vez encontrados los documentos que quisiera ver en detalle, sería el motor de SQL quien le diera los valores finales almacenados.

Es muy normal ver escenarios donde un motor relacional se encarga de los datos transaccionales mientras un motor de indexación, sobre esos mismos datos, se encarga de las búsquedas complejas.

Motores de búsqueda en el mercado

Principales motores de búsqueda open source:

- ▶ Apache Lucene
- ▶ Apache Solr
- ▶ Elasticsearch

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Sphinx

Principales motores de búsqueda empresariales:

- ▶ Google Search Appliance
- ▶ EMC Corp.
- ▶ HP (acquired Autonomy Corporation which in turn acquired Verity K2 and Ultraseek)
- ▶ Microsoft (includes Microsoft Search Server, Fast Search & Transfer)
- ▶ Open Text Corporation
- ▶ Oracle Corporation (includes Secure Enterprise Search and Endeca Technologies Inc.)
- ▶ Recommind
- ▶ SAP

Apache LuceneCore

Apache Lucene es un motor de búsqueda de texto de alto rendimiento escrito completamente en Java.

Tecnología adecuada para casi cualquier aplicación que requiera la búsqueda de texto, especialmente multiplataforma.

Incluye búsqueda rango, múltiples tipos de consulta, búsqueda por campos, búsqueda de artículos múltiples, flexibles, etc.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Implementa Near Realtime Search – hace que los datos actualizados estén disponibles milisegundos después de haber sido insertados.

- ▶ Se puede utilizar directamente como motor de búsqueda en tiempo real.
- ▶ En la mayor parte de los casos es más que suficiente.
- ▶ La mayoría de proyectos no tratan con millones de datos diariamente ni miles de consultas por segundo, por lo que el sharding, la escalabilidad, la tolerancia a fallos, o la escalabilidad, quedan relegados a un segundo lugar.

Si nuestro proyecto no entra dentro de ese pequeño porcentaje que necesita realmente tomarse muy en serio la escalabilidad, entonces simplemente configurar Lucene es una alternativa.

Apache Solr

Creado en 2004 por un desarrollador CNET llamado Yonik Seeley. Solr es la (2.^a) plataforma más popular para búsqueda empresarial de código abierto rápido.

Permite entre otras cosas:

- ▶ Búsqueda de texto completo
- ▶ Hit highlighting
- ▶ Búsqueda a través de facetas
- ▶ Indexación en tiempo real
- ▶ Agrupación dinámica
- ▶ Integración de bases de datos

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Add-ins para la manipulación de documentos (Word, PDF, etc.)
- ▶ Búsqueda geoespacial
- ▶ Fiable, escalable y tolerante a fallos,
- ▶ Capaz de distribuir la carga de indexación, replicación y la consulta

SphinX

Servidor de búsqueda de texto completo de código abierto.

Diseñado desde cero - no está basado en Lucene

Enfocado en performance, calidad de búsqueda y simplicidad de integración.

Está escrito en C ++ y es multiplataforma - Linux (RedHat, Ubuntu, etc), Windows, MacOS, Solaris, FreeBSD, y otros muchos sistemas.

Sphinx da soporte para indexar datos desde múltiples fuentes:

- ▶ Bases de datos SQL estándar
- ▶ Almacenamiento NoSQL
- ▶ Sistemas de archivos
- ▶ Etc.

Indexa en tiempo real.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Elasticsearch

Elasticsearch es un motor de búsqueda e indexación en tiempo real. Se desarrolló en Java y, originalmente, fue lanzado como código abierto bajo licencia Apache. Utiliza la librería de Apache Lucene e intenta que todas sus funciones estén disponibles a través de la API REST lo que le otorga una gran sencillez de uso.

Se puede utilizar para buscar todo tipo de documentos, maneja documentos en formato JSON sin esquema. Cualquier campo puede ser indexado en tiempo real y se puede buscar por el contenido de cualquier campo en tiempo real. Además, es capaz de llevar a cabo cálculos analíticos en tiempo real.

Es un sistema escalable y distribuido:

- ▶ Los índices se pueden dividir en fragmentos o shards
- ▶ Y cada fragmento puede vivir en diferentes servidores
- ▶ Idóneo para manejar PB (Petabytes) de información estructurada o no estructurada.
- ▶ Altamente escalable a cientos de máquinas, soporta ejecución en múltiples servidores

La familia de *Elasticsearch* contempla también un sistema de recolección de datos y análisis de registros llamado *Logstash* una plataforma de análisis y visualización llamada *Kibana* y un sistema de obtención de información denominado *Beat*. Los cuatro están diseñados para ser utilizados como una solución integrada, conocida como **Elastic Stack**.

Según el ranking de [motores de búsqueda de DB-Engines](#), Elasticsearch es el motor de búsqueda más popular.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

□ Include secondary database models

21 systems in ranking, October 2021

Rank			DBMS	Database Model	Score		
Oct 2021	Sep 2021	Oct 2020			Oct 2021	Sep 2021	Oct 2020
1.	1.	1.	Elasticsearch	Search engine, Multi-model ⓘ	158.25	-1.98	+4.41
2.	2.	2.	Splunk	Search engine	90.61	-0.99	+1.21
3.	3.	3.	Solr	Search engine, Multi-model ⓘ	51.17	+1.36	-1.31
4.	4.	4.	MarkLogic ⚡	Multi-model ⓘ	9.43	-0.16	-2.30
5.	5.	7.	Sphinx	Search engine	7.61	-0.03	+1.27
6.	6.	5.	Algolia	Search engine	7.61	+0.30	+0.31
7.	7.	6.	Microsoft Azure Search	Search engine	6.99	+0.14	+0.30
8.	9.	10.	Virtuoso ⚡	Multi-model ⓘ	4.69	+0.27	+2.12

Figura 41. Fuente: elaboración propia.

Características de Elasticsearch

Es un sistema muy fácil de configurar

- ▶ Requiere un esfuerzo mínimo para ponerlo en marcha: es un simple proceso java.
- ▶ Es capaz de autoconfigurarse sin necesidad de terceros.
- ▶ Es capaz de auto sanarse sin intervención manual alguna.

Proporciona un conjunto amplio de interfaces REST que permiten manejar el motor:

- ▶ **Document API** – permite ejecutar operaciones CRUD sobre documentos.
- ▶ **Index API** – permite ejecutar operaciones de gestión de índices.
- ▶ **Search API** – permite ejecutar operaciones de búsqueda sobre documentos.
- ▶ **Cluster API** – permite ejecutar operaciones de gestión del cluster.

Está orientado a documentos y permite flexibilidad en el esquema

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Es capaz de inferir el esquema inicial de un documento
- ▶ Reconoce nuevos campos cuando son agregados
- ▶ No permite modificar un campo ni su tipo una vez han sido creados

Permite la gestión de múltiples índices en paralelo y en tiempo real

- ▶ Los índices se dividen en shards, que se distribuyen entre los servidores y se replican para obtener alta disponibilidad.
- ▶ Los índices pueden ser consultados de forma aislada o en grupo (cross-index search).
- ▶ Admite el uso de caracteres comodín en las consultas.

En el apartado de ACID (Atomicity, Consistency, Isolation, and Durability)

- ▶ Elasticsearch no soporta transacciones ACID
- ▶ Aunque sí tiene consistencia a nivel de documento
- ▶ Permite una pequeña gestión de conflictos haciendo uso de un número de versión de documento
- ▶ Es muy buena práctica delegar el sistema transaccional en una base de datos tradicional e indexar en Elasticsearch

Dispone de varios [clientes](#) escritos en múltiples lenguajes: Java, Groovy, .NET, PHP, Perl, Python...

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Es un sistema de alto rendimiento:

- ▶ Alta velocidad en sus operaciones de indexación y búsqueda en Real-Time.
- ▶ Facilita procesos en lote para operaciones sobre múltiples documentos.
- ▶ Trabaja en memoria con sistemas de cacheo con estrategia "write behind" para atender a las búsquedas.

Sistema distribuido que permite arrancar pequeño y escalar horizontalmente cuando sea necesario:

- ▶ Agregar nuevos nodos es un proceso sencillo y automático que no requiere intervención manual.
- ▶ El proceso de replicación de datos se hace de forma automática y transparente al usuario.
- ▶ El sharding ocurre también de forma transparente.
- ▶ En caso de fallos catastróficos de servidores, el motor reorganiza de forma automática los datos en el cluster.
- ▶ Permite llevar a cabo la distribución y balanceo de la carga cuando se ejecutan consultas.

Presenta una arquitectura multitenant, siguiendo el principio de Shared-Nothing

- ▶ Los servidores no comparten nada entre ellos.
- ▶ Si un servidor falla, el resto puede actuar de forma eficiente sin pérdida de datos ni servicio.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Con todo ello, Elasticsearch es un sistema altamente disponible.

Arquitectura de datos. Documentos en Elasticsearch

Elasticsearch almacena toda su información en documentos con formato JSON. Un documento equivaldría a una fila de datos de una tabla de una base de datos relacional.

Los documentos tienen las siguientes características:

- ▶ Un documento se almacena en un único índice bajo una única clave.
- ▶ Un mismo documento puede tener una o más versiones.
- ▶ Los valores de un documento se guardan asociándose a un atributo.
- ▶ Los atributos tienen asociados un tipo que formaliza el valor.
- ▶ Los tipos facilitan las operaciones sobre los valores y se definen en el *Mapping*.

Índices en Elasticsearch

El índice es el lugar donde ES almacena los datos de forma lógica. Equivale a la base de datos en el sistema relacional.

Es una estructura preparada para:

- ▶ Almacenar la información del proceso de indexación.
- ▶ Llevar a cabo búsquedas eficientes de datos.

Indexar un documento es almacenarlo en un índice para que pueda recuperarse y consultarse.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

De forma predeterminada, todos los campos de un documento están indexados (tienen un índice invertido) y, por lo tanto, se pueden buscar. Por otro lado, los índices no tienen conocimiento de datos que existan en otros índices

La unidad mínima de almacenamiento de un índice es el documento.

Mapping

Mapear un documento es definir cómo un documento, y los campos que contiene, se almacenan e indexan. Por lo tanto, define como un documento ha de ser almacenado en Elasticsearch:

- ▶ Cuáles son los campos, sus tipos y sus propiedades
- ▶ Qué campos de cadena deben tratarse como campos de texto completo
- ▶ Qué campos contienen números, fechas o geolocalizaciones
- ▶ Que valores deben ser indexados para poder ser buscados
- ▶ El formato de los valores de fecha.
- ▶ Reglas personalizadas para controlar el mapeo de campos agregados dinámicamente
- Cómo es analizada la información mediante analizadores durante el proceso de indexación
- Cómo es tokenizada la información mediante tokenizadores durante el proceso de indexación

Sería el equivalente al schema de una base de datos relacional. Elasticsearch creará un mapping por defecto para un tipo o campo nuevo si no se le ha indicado nada antes de guardar un documento en el índice.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Existen dos tipos de Mappings en ES:

- ▶ Mapping dinámico: no definimos el mapping que tiene un índice y delegamos en Elasticsearch el cual a través de la información almacenada establece con sus criterios los tipos.
- ▶ Mapping explícito: definimos todos los campos, atributos, analizadores y tokenizadores que tiene el índice.

Arquitectura de servidor

Elasticsearch puede trabajar como un sistema solitario o con múltiples servidores o nodos colaborando entre sí en un clúster. Puede escalar de dos formas diferentes:

- ▶ Verticalmente: donde aumentamos las capacidades de la máquina en sí (más RAM, más CPU, etc.)
- ▶ Horizontalmente: donde agregamos más máquinas al cluster para que colaboren en las tareas.

Elasticsearch escala mejor Horizontalmente, verticalmente tiene ciertos límites a los que podemos llegar como por ejemplo máximo 30GB de RAM, en cambio horizontalmente puede manejar PBs (Petabytes) de datos sin problemas.

Elasticsearch tiene naturaleza distribuida:

- ▶ Sabe cómo manejar más nodos de forma automática.
- ▶ Sabe cómo recuperarse de errores de forma automática.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Elasticsearch puede llegar a escalar a cientos o miles de servidores

- ▶ Diseñado para estar siempre disponible.
- ▶ Diseñado para escalar cuando sea necesario.

Cada vez que inicia una instancia de Elasticsearch, está iniciando un nodo. Un nodo es una instancia única de un servicio de ElasticSearch en una máquina.

Se ejecuta en una JVM propia, respetando los [principios de Shared-Nothing](#)

Todos los nodos conocen todos los demás nodos del clúster y pueden reenviar las solicitudes de los clientes al nodo apropiado.

Tipos de Nodos

Elasticsearch proporciona diferentes tipos de nodos útiles para dividir responsabilidades entre ellos. En clústeres grandes, se dividen las tareas para los nodos que haya configurados con tareas específicas que van a realizar asignando más memoria o más CPU según para que se les asigne.

Encontramos los siguientes tipos de nodos:

- ▶ Maestro
- ▶ Datos
- ▶ Cliente o Coordinación
- ▶ Ingesta
- ▶ Tribe

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Si bien los más importantes son los tres primeros

Maestro:

- ▶ Encargado de **gestionar el estado del cluster** y hacer tareas ligeras como crear o borrar índices, llevar el control de los nodos que forman el clúster o decidir en que shard debe guardarse un documento.
- ▶ Los nodos se marcan como posibles maestros, pero para ello tiene que ser promocionado, solo hay uno, pero hay varios que pueden serlo en caso de que este caiga
- ▶ Si no hay un maestro el clúster no funciona.
- ▶ Por defecto todos los nodos están configurados para ser maestros.

Datos:

- ▶ Capacidad de almacenar shards y réplicas. Almacenan los documentos
- ▶ Todos también por defecto son nodos de datos. Se mantiene esta configuración cuando el cluster es pequeño.
- ▶ Son los más importantes y de los que más hay.
- ▶ Los nodos de datos manejan operaciones relacionadas con datos como CRUD, búsqueda y agregaciones.
- ▶ Estas operaciones requieren E/S, memoria y CPU.
- ▶ Es importante monitorizar estos recursos y agregar más nodos de datos si están sobrecargados.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Ingesta:

- ▶ Labores similares a Logstash (preprocesamiento) también por defecto todos son nodos de Ingesta.
- ▶ Recomendable en clústeres grandes tener nodos exclusivos de ingesta para aprovechar capacidad de procesamiento (consumen mucha CPU) y así no interfiere con otros procesos

Coordinación:

- ▶ Se les deshabilita la opción de ser maestros, de almacenar datos y hacer labores de ingesta.
- ▶ Únicamente recibe peticiones de aplicaciones externas y funcionarían a modo de **balanceador** para enviar las peticiones a las zonas adecuadas.
- ▶ Actúan como balanceadores liberan a los nodos de datos.
- ▶ Encargados de gestionar la interfaz REST hacia el exterior.
- ▶ Son los que enrutan las consultas al nodo de datos adecuado.

Tribe:

- ▶ Lanzar búsquedas a diferentes clústeres

Únicamente puede existir un nodo maestro en el cluster y es el responsable de cualquier cambio que se haga en el cluster, coordina la anexión de nuevos nodos y es el encargado también de coordinar la reestructuración de los datos cuando hay una caída de un nodo.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

No participan en procesos de indexación, únicamente gestionan el cluster. Siempre sabe cuál es el estado de los otros nodos del cluster.




Figura 42. Fuente: elaboración propia.

Réplicas

En un entorno de red se pueden esperar problemas en cualquier momento, por tanto, es recomendable tener un mecanismo de conmutación por error en caso de que un nodo falle por alguna razón. Elasticsearch permite hacer copias de los shards de su índice en lo que se denomina réplicas.

- ▶ Cada índice se puede dividir en varios fragmentos (shards) y a su vez cada fragmento se puede replicar en cero (es decir, sin réplicas) o más veces.
- ▶ Una vez replicado, cada índice tendrá shards primarios (los originales) y shards replicados (las copias)
- ▶ El número de fragmentos y réplicas se puede definir por índice en el momento en que se crea el índice.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

La replicación es importante por dos razones principales:

- ▶ Proporciona alta disponibilidad (HA) en caso de fallo: es importante que un fragmento de réplica nunca se asigne en el mismo nodo que el fragmento original del que se copió.
- ▶ Permite mejorar el rendimiento de búsqueda: ya que las búsquedas se pueden ejecutar en todas las réplicas en paralelo.

De forma predeterminada, a cada índice en ES se le asignan 5 fragmentos primarios y 1 réplica: con dos nodos en su grupo, un índice tendrá 5 fragmentos primarios y otros 5 fragmentos de réplica para un total de 10 fragmentos por índice.




Figura 43. Fuente: elaboración propia.

API Rest

A través de las APIs podremos hacer peticiones tipo REST a través de los métodos soportados por el protocolo HTTP (put, post, get, delete) y ES nos devolverá un JSON con el resultado.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Hay varios tipos de APIs dependiendo a lo que queramos acceder:

- ▶ Document API
- ▶ Index API
- ▶ Cluster API
- ▶ Search API
- ▶ Catálogo.

Document API

- ▶ Este API se utiliza para manejar documentos en ES. Permite llevar a cabo todo tipo de operaciones de altas, bajas y modificaciones de documentos en un índice.
- ▶ Hay dos tipos de interfaces dentro del Document API:
 - Single-document API
 - Multi-document API

Single document API

Permite la gestión de documentos de uno en uno. Un único documento gestionado en cada interacción HTTP.

- ▶ Index API
- ▶ Get API
- ▶ Delete API

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ Update API
- ▶ Update by Query API (nueva... y muy necesitada)

Multi-document API

- ▶ Permite la gestión de múltiples documentos en un único post.
- ▶ Este tipo de interfaces es la adecuada cuando queremos trabajar con grandes volúmenes de datos
 - Multi Get API
 - Bulk API
 - Bulk UDP API
 - Delete By Query API

Index API

- ▶ Este API de Elasticsearch permite a los usuarios administrar índices, asignaciones y plantillas.
- ▶ Usado para:
 - Gestión de índices: creación, consulta, borrado, exists y apertura/cierre
 - Gestión de mapping: crear, obtener, obtener campos o borrado
 - Altas bajas y modificaciones de álias de índices
 - Configuración de índices: actualización, consulta, análisis, warmers...

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- Gestión de réplicas
- Monitorización de índices: status, estadísticas, segments, recuperación de índices
- Gestión de caché: limpieza, refresco, flush, optimización, actualización

Search API

- ▶ Como su nombre lo indica, estas llamadas a la API se pueden utilizar para consultar datos indexados para obtener información específica.
- ▶ Las API de búsqueda se pueden aplicar globalmente, en todos los índices y tipos disponibles, o más específicamente dentro de un índice.
- ▶ Las respuestas contendrán coincidencias con la consulta específica.

Cluster API

- ▶ Estas son llamadas a la API específicas del clúster que le permiten administrar y monitorear
- ▶ su clúster de Elasticsearch. La mayoría de las API le permiten definir a qué nodo de
- ▶ Elasticsearch llamar utilizando el ID de nodo interno, su nombre o su dirección.

Catalog API

- ▶ Permite retornar los datos en un formato más fácil de usar en lugar de la respuesta JSON normal.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

¿Cómo funciona el protocolo REST?

Representational State Transfer es una arquitectura para diseñar sistemas distribuidos.

No es un estándar sino un conjunto de restricciones que definen los principios de REST

- ▶ Los recursos exponen las URI de estructura de directorios fácilmente comprensibles.
- ▶ Las representaciones transfieren JSON o XML para representar objetos de datos y atributos.
- ▶ Los mensajes utilizan métodos HTTP explícitamente (por ejemplo, GET, POST, PUT y DELETE).
- ▶ Las interacciones no almacenan contexto de cliente. El cliente mantiene el estado de la sesión.

REST no está estrictamente relacionado con HTTP, pero está asociado con él.

¿Cómo funciona el protocolo REST?

Los métodos HTTP son usados para asignar las operaciones CRUD a las solicitudes HTTP (hay más):

- ▶ **GET**: usado para recuperar la información
- ▶ **POST**: usado para crear una nueva entidad, pero también se puede usar para actualizar una entidad.
- ▶ **PUT**: puede crear una nueva entidad o reemplazar una existente.
- ▶ **DELETE**: solicita que se elimine un recurso. Pueden ser solicitudes asíncronas

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

Cuando la llamada retorna al cliente, lo hará con uno de estos códigos de errores (hay más):

- ▶ **1XX** - informational
- ▶ **2XX** - success
- ▶ **4XX** - client error
- ▶ **5XX** - server error

Es importante tener en cuenta que existe una amplia variedad de herramientas para generar llamadas/respuestas HTTP:

- ▶ **Navegador web**: es una forma sencilla y limitada de ejecutar llamadas REST. Un navegador web, cuando abre una URL, está haciendo una llamada HTTP con verbo GET. Podemos ejecutar los GETs sencillos contra Elasticsearch desde cualquier navegador pero este método acabará limitado por únicamente poder ejecutar llamadas GET
- ▶ **Curl**: desde la línea de comando podemos lanzar llamadas HTTP a interfaces REST con curl de una manera sencilla. Permite hacer scripting cuando tenemos que ejecutar múltiples llamadas de forma automática.
- ▶ **Developer Tools de Kibana para Elasticsearch**: la herramienta de Kibana tiene un entorno de desarrollo donde podemos ejecutar llamadas HTTP de forma amigable.

Todas las herramientas funcionan bajo el mismo principio:

- ▶ **URL**: donde se encuentra el recurso REST al que queremos llamar
- ▶ **Verbo HTTP**: que expresa la acción que queremos ejecutar

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

- ▶ **Carga o Payload:** un documento JSON que contiene la información de la consulta

Las respuestas que Elasticsearch retornará ante nuestras llamadas REST serán documentos en formato JSON sin formatear. Esta información suele ser complicada de leer y de interpretar por su falta de formato.

Toda interfaz REST de Elasticsearch proporciona tres mecanismos comunes para hacer nuestra vida más sencilla cuando lancemos queries contra el motor de indexación:

- ▶ Resultados 'Pretty' – ?pretty=true
- ▶ Human readable – ?human=true
- ▶ Fechas e incrementos – y(ear), m(onth), w(eek), d(ay), h(our), m(inute), s(econd)
 - +1h – agrega 1h a la fecha mostrada
 - -1d – elimina 1 día a la fecha mostrada
 - /d – redondea la fecha al día más próximo
- ▶ La mejor manera de aprender a manejar estas interfaces REST es mediante su uso.
- ▶ Existen dos formatos: cURL y Sense.

cURL

- ▶ Para hacer uso de las consultas de cURL necesitaremos un Shell de Linux. Podemos ejecutar los comandos desde el Shell de MS-DOS pero se hace complicado a la hora de formatear la entrada con caracteres no admitidos.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

¿Cómo funciona cURL?

```
$ curl -XPUT "http://localhost:9200/tutorial/helloworld/1" -d {"ejemplo":10}
```

- curl: el nombre del ejecutable
- -XPUT: el verbo HTTP que queremos ejecutar (XPUT, XGET, XPOST, XDELETE)
- http://ip-del-servidor:puerto-http/nombreIndice/nombreTipo
- -d: el contenido de datos que queremos enviar al servidor en formato JSON

Figura 44. Fuente: elaboración propia.

Sense

- El formato Sense es más sencillo, pero únicamente puede ser utilizado desde Kibana en su sección de desarrollo.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

3.5. Referencias bibliográficas

Apache Software Foundation (2021). *Apache Kafka. Documentation*.

<https://kafka.apache.org/documentation/>

Be A Better Dev. (2020). *SQL vs NoSQL Explained* [Vídeo]. Youtube.

<https://www.youtube.com/watch?v=ruz-vK8lesE>

BettaTech. (2018). *¿Qué son las TABLAS de HASH? | Estructuras de Datos en Ingeniería Informática* [Vídeo]. YouTube.

<https://www.youtube.com/watch?v=LluB6jU-SwY>

Chansler, R., Kuang, H., Radia, S., Shvachko, K. y Srinivas, S. (S. f.). The Hadoop distributed file system. En A. Brown y G. Wilson (eds.), *The architecture of open source applications. Elegance, evolution, and a few fearless hacks*. Aosa Book.

<http://www.aosabook.org/en/hdfs.html>

Databricks. (2021). *Hadoop*. Databricks. <https://databricks.com/glossary/hadoop>

Distributed Systems Course. (2019). *L16: The CAP Theorem* [Vídeo]. YouTube.

<https://www.youtube.com/watch?v=k-Yaq8AHIFA>

Elastic. (S. f.). *Elastic Documentation*. Disponible en: <https://www.elastic.co/docs>

Fernandez, O. (2024). *Apache NiFi: Introducción* [Imagen]. Aprender Big Data.

<https://aprenderbigdata.com/introduccion-apache-nifi/>

Hadoop Apache. (2020). *HDFS Users Guide*. The Apache Software Foundation.

<http://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsUserGuide.html>

Jacob Avila Camacho. (2020). *1 Bases de Datos NoSQL* [Vídeo]. YouTube.

Tema 3. Gestión y almacenamiento de datos.

Búsqueda de respuestas en grandes conjuntos de datos

<https://www.youtube.com/watch?v=caS51djbuk4>

Microsoft. (S. f.). *Formación práctica sobre bbdd NoSQL y almacenamiento en la nube* [Página Web]. <https://docs.microsoft.com/es-es/learn/modules/cmu-case-study-nosql-databases/>

Narkhede, N., Shapira, G. y Palino, T. (2021). *Kafka: the definitive guide*. O'Reilly. <https://www.confluent.io/resources/kafka-the-definitive-guide/>

Official Elastic Community. (2021). *Primeros pasos con Elasticsearch - Jan 27th Elastic meetup* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=uTg7w0prP6A>

Reinsel, D., Gantz, J., y Rydning, J. (2018). *The Digitization of the World. From Edge to Core* [Imagen]. IDC.

Tiwari, S. (2011). *Professional NoSQL* (pp. 3-20, 97-135, 217-232). John Wiley & Sons.

White, T. (2015). *Hadoop: the definitive guide* (4ta edición). O'Reilly.

Tema 4. Aplicación de herramientas para la visualización de datos

Objetivos

En esta unidad se van a empezar conociendo cuales son los tipos de datos más comunes a la hora de representar información de manera visual centrándonos en los semiestructurados y las diferencias con los estructurados. Luego veremos el papel que representa la inteligencia artificial en el análisis de datos para ver posteriormente en qué consiste un clúster y cómo podemos monitorizar su estado.

Para continuar y como punto más importante veremos las herramientas de visualización más importantes que se usan actualmente dentro de las empresa para representar y analizar los datos, centrándonos en las dos más importantes como PowerBI y Tableau para finalizar viendo cual es la tendencia de la visualización dentro de las empresas.

Tema 4. Aplicación de herramientas para la visualización de datos

4.1. Datos no estructurados: fuentes, tipología

Datos, información y conocimiento

¿Es lo mismo, datos, información o conocimiento? La tendencia inicial es a responder afirmativamente a este interrogante, pero la respuesta correcta es NO.



Figura 1. Preguntas sobre datos e información. Fuente: elaboración propia.

Si empezamos a indagar un poco sobre ellas, las tres tienen significado diferente:

- ▶ **Los datos** son elementos sin procesar, sacados de la realidad que a su vez genera nuevos elementos y que por sí solos no generan nuevo conocimiento. Ejemplos de datos: el precio de un producto, la edad, el nombre de una persona, etc.
- ▶ **La información** es el principio del conocimiento. Son datos con un significado o función especial o el resultado de combinar diferentes datos, es decir, son datos con contexto.
- ▶ **El conocimiento** es la información analizada que hace nuevos aportes a un área específica.

Tema 4. Aplicación de herramientas para la visualización de datos



Figura 2. Cómo se integran los datos y la información. Fuente: Weller, K., 2010.

Los datos son la principal fuente de información para el análisis de grandes volúmenes, por lo que es fundamental que las empresas realicen una selección lo más adecuada y cuidadosamente posible. La categorización de los datos es importante para cualquier proyecto, en especial cuando se trabaja con grandes volúmenes (*big data*). La principal categorización de los datos se basa en su estructura en la que nos encontramos principalmente dos posibilidades:

Los datos son la principal fuente de información para el análisis de grandes volúmenes, por lo que es fundamental que las empresas realicen una selección lo más adecuada y cuidadosamente posible. La categorización de los datos es importante para cualquier proyecto, en especial cuando se trabaja con grandes volúmenes (*big data*). La principal categorización de los datos se basa en su estructura en la que nos encontramos principalmente dos posibilidades:

- ▶ **Estructurados:** estos datos son aquellos que se tienen una estructura definida y que no cambia independientemente de cuál sea su origen. Es decir, son aquellos datos que poseen un modelo (o estructura) definido. Entre estos tipos de datos podemos encontrar registros de bases de datos, que son el ejemplo más típico, datos de sensores o los que se obtienen a partir del API de Twitter.
- ▶ **No estructurados:** estos datos son aquellos datos que no disponen de una estructura bien definida. Es decir, son aquellos que no poseen un modelo (o estructura) definido o que no están ordenados de alguna manera. Entre estos tipos de datos podemos encontrar fotografías, vídeos o documentos de texto (Word, PDF, etc.).

Tema 4. Aplicación de herramientas para la visualización de datos



Figura 3. Introducción a la categorización de datos. Fuente: elaboración propia.

¿Cómo se generan los datos?

En cuanto a cómo se han generado los datos, nos podemos encontrar con los siguientes tipos de datos:

- ▶ **Creados:** son aquellos generados por la propia empresa a través de los sistemas de información.
- ▶ **Compilados:** son aquellos que se utilizan de otras grandes bases de datos, como censos electorales, información obtenida de las administraciones públicas en salud, vivienda, impuestos, etc.
- ▶ **Experimentales:** son los generados por simulaciones o pruebas para determinar la validez de los sistemas.

En la figura a continuación se muestran algunas fuentes de información que hoy en día se han ampliado gracias a las nuevas tecnologías de la información.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 4. Fuente de datos. Fuente: elaboración propia.

- ▶ **Web (Internet) y medios sociales:** son aquellos que tienen origen en la red. Según los expertos, es la fuente más grande del *big data* y una de las más utilizadas en la actualidad. Se genera información en los clics de los vínculos y elementos, así como en las búsquedas que se hacen, las publicaciones en las redes sociales (Twitter, Facebook, LinkedIn...) y el contenido web como páginas, enlaces o imágenes.
- ▶ **Tabletas y móviles (*smartphone*):** son dispositivos móviles que permiten acceder a información desde cualquier parte gracias a su tamaño, las aplicaciones y su acceso a Internet. Entre todas las fuentes de datos utilizables, el teléfono inteligente o tableta es el que más potencial tiene.

Tema 4. Aplicación de herramientas para la visualización de datos

Gracias a estos dispositivos, compañías como Google y Apple pueden saber dónde se encuentra una persona en cada momento y, de esta manera, poder conocer los gustos de comida, vestuario y diversión, entre otros.

- **Bases de datos y sistemas de información:** una base de datos es un almacén en el que se puede organizar datos, para evitar la redundancia y mejorar el acceso a estos. Diferentes programas y usuarios deben poder utilizar los datos guardados. De allí el término base «sistema de información».

Origen y calidad de los datos

Datos, información y conocimiento

En situaciones informales es común usar indiscriminadamente los términos dato, información y conocimiento. En ámbitos profesionales y académicos, es conveniente distinguir estos conceptos para evitar malinterpretaciones durante las distintas fases de la analítica de datos.

Existen varias aproximaciones para la distinción de estos términos. En el contexto de esta asignatura se utilizará la definición descrita por Davenport y Prusak (2000).

Un dato puede definirse como un hecho concreto y discreto acerca de un evento. La característica de ser discreto significa que, semánticamente, es la unidad mínima que puede comunicarse o almacenarse. Por sí solos, los datos no brindan detalles significantes del entorno del que fueron obtenidos. Ejemplos de datos pueden ser:

- 2010.
- 443.
- DE.

Tema 4. Aplicación de herramientas para la visualización de datos

La información puede distinguirse simplemente como un mensaje formado por la composición de varios datos. Esto significa que, a diferencia del dato, la información sí posee un significado para un receptor u observador. Por ejemplo, utilizando los datos anteriores se podría obtener la siguiente información:

- ▶ El año de establecimiento de la empresa ACME fue el 2010.
- ▶ La altura del edificio Empire State es de 443 metros.
- ▶ DE es el código ISO que identifica al idioma alemán.

Los datos deben ser transformados para añadirles valor y convertirlos en información. Estas transformaciones incluyen métodos como:

- ▶ **Contextualización:** conocer el propósito del dato obtenido.
- ▶ **Categorización:** conocer la unidad de medida y los componentes del dato.
- ▶ **Cálculo:** realizar una operación matemática sobre el dato.
- ▶ **Corrección:** eliminar errores del dato.
- ▶ **Agregación:** resumir o minimizar un dato de forma más concisa.

El conocimiento implica una combinación de experiencias, información contextual y relevancia sobre cierta información. Así como la información se genera a partir de datos, el conocimiento surge de la agregación de información. Ejemplos de métodos que generan esta transformación son:

- ▶ **Comparación:** relación entre información obtenida en distintas experiencias.
- ▶ **Repercusión:** implicación de la información en decisiones y acciones.
- ▶ **Conexión:** relación entre distintos tipos de información.

Tema 4. Aplicación de herramientas para la visualización de datos

- **Conversación:** opinión de otras personas sobre la información.

La jerarquía del conocimiento suele representarse gráficamente por una pirámide, siendo los datos la base y el conocimiento la cima.



Figura 5. Jerarquía del conocimiento. Fuente: elaboración propia.

Distinguir estos conceptos básicos proporciona un nivel de abstracción útil para la separación de características en el proceso de análisis. El hecho de que un dato sea inválido o erróneo debe distinguirse fácilmente de que la información que se obtiene de dicho conjunto de datos sea adecuada o no al problema que se intenta resolver.

Por ejemplo, es importante conocer si la malinterpretación de un análisis de datos se debe a un error en la fuente de datos, a un problema al combinar los datos en el proceso de análisis o a una confusión por parte del usuario final, debido a experiencias en otros contextos.

Tema 4. Aplicación de herramientas para la visualización de datos

Evaluación de la calidad

Las métricas o dimensiones utilizadas para describir la calidad de un conjunto de datos pueden agruparse con base en los actores que interactúan con los datos. **Los diseñadores y administradores** de almacenes de datos tratan con métricas que afectan el diseño o esquema de los datos obtenidos y no con los datos directamente. Entre estas métricas se podría mencionar la completitud de los datos obtenidos y el minimalismo del conjunto de datos, el cual se interpreta como la eliminación de redundancias en el diseño del almacén de datos.

Los **desarrolladores de software** tratan con métricas específicas de la producción de productos informáticos. Si bien en esta categoría entran métricas que no están relacionadas con los datos directamente, es importante tener en cuenta que estas métricas afectan al proceso de almacenaje, acceso y manipulación de los datos.

El último actor que interactúa con los datos es el **usuario final**, es decir, quien utilizará los datos presentados para crear una conclusión y tomar una decisión acorde. Las métricas relevantes para este actor pueden ser el nivel de disponibilidad de los datos y el nivel de interpretación requerido para entender los datos presentados.

A partir de estas perspectivas, presentan un conjunto de dimensiones para evaluar las propiedades de un conjunto de datos:

- ▶ La **completitud o cobertura** describe el porcentaje de datos disponibles respecto a la población total que representa dichos datos. Por ejemplo, un conjunto de datos con información de 90 de 100 tratamientos médicos realizados en un hospital presenta una cobertura de 90 %. Esto también se aplica a subconjuntos de los datos obtenidos, por ejemplo, el 5 % de los tratamientos médicos no incluyen la fecha de finalización del tratamiento, lo cual disminuiría la cobertura debido a esta característica.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ La **credibilidad** representa la fiabilidad que se le brinda al organismo que proporciona el conjunto de datos. Esta métrica puede reflejarse en el conjunto de datos por aquellas características que presenten un valor por defecto. Por ejemplo, si se habla de postres, es fácil ver que, si incluye valores por defecto como tarta, helado, fruta, etc., el dato es fiable, pero nunca lo será si se habla de pincho moruno.
- ▶ La **precisión** indica el porcentaje de datos correctos respecto al total disponible. También se representa por medio de un porcentaje.
- ▶ La **consistencia** describe el nivel con el que los datos son coherentes entre ellos. Un ejemplo de la aplicación de esta métrica se da en datos geográficos: se puede concluir que si una misma entidad tiene asociada una ciudad y un país que no tienen relación, existe un problema de consistencia.
- ▶ La **interpretabilidad** define el grado en el que los datos pueden ser entendidos correctamente por una persona. Entre los atributos que definen la interpretabilidad de un conjunto de datos se puede mencionar la documentación de elementos importantes y si el formato en el que se proporcionan los datos es entendible.

A continuación, se proporciona un conjunto de datos de fuente desconocida representadas en la siguiente tabla:

Datos de ejemplo					
Marca	Modelo	Precio	Motor	Consumo	Fecha
Audi	La Ferrari	15 000 €	963 CV diésel	alto	2014
Lamborghini	Murciélago	300 000 €	580 CV 7500 rpm		2011
BMW	M6	158 000€	560 CV 4935 rpm	13,6/7,6/9,9	2012
Porsche	911 turbo	127 000 €	420 CV 7500 rpm	11 litros	2017

Figura 6. Datos de ejemplos. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Si analizamos estos datos con respecto a los indicadores de calidad antes mencionados:

- ▶ **Compleitud:** 75 % respecto a los datos de consumo, o el mismo porcentaje con respecto a las revoluciones por minuto del motor del coche.
- ▶ **Credibilidad:** al tratarse de una fuente desconocida, la credibilidad es baja debido a que no se puede comprobar la fuente. Además, por defecto, se sabe que Ferrari solo hace motores de gasolina y que, por defecto, no existen motores diésel de ese caballaje.
- ▶ **Precisión:** es claro ver que los datos no son precisos, ya que el precio de un súper deportivo no puede ser de 15 000€ y las revoluciones de algunos coches son demasiado redondas. Además, un consumo «alto» no es una cifra de consumo.
- ▶ **Consistencia:** la consistencia de los datos es baja porque a poco que se entienda algo de coches, el modelo de Ferrari nunca puede pertenecer a la marca Audi, sino a Ferrari.
- ▶ **Interpretabilidad:** podría mejorarse, puesto que hay muchos datos que no incluyen unidades o que ofrecen un conjunto de números que si no se está familiarizado con el entorno no se conocerá su significado, como ocurre con los 3 valores de consumo.

Fuentes de información

Los métodos para la captura de información se pueden clasificar con base en las características del elemento que genera el conjunto de datos. Las cinco categorías más utilizadas en la actualidad son:

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ La **captura manual** de datos es la categoría más tradicional y también una de las más frecuentes en el contexto de investigación en ámbitos sociales y naturales. Entre los métodos que encajan en esta categoría se encuentra el uso de encuestas y las mediciones a través de observaciones.

Si bien esta es la única categoría que no tiene una dependencia directa de las tecnologías de información, para su utilización es necesario que la información se digitalice, ya sea en el momento de la captura o en un procesamiento posterior.

- ▶ El **procesado de documentos estructurados** consiste en la obtención directa de datos disponibles en documentos, cuyo fin inicial no es ser consultados como fuente de datos. Uno de los métodos más comunes en esta categoría es el procesamiento de páginas HTML en un sitio web, conocido como web scraping.

Otro ejemplo es el análisis de logs o ficheros que contienen un listado secuencial de los eventos ocurridos dentro de un sistema y son creados con el objetivo de tener una bitácora y no para ser accedido por otras aplicaciones.

- ▶ La **salida de aplicaciones** es una de las categorías más triviales. Los métodos de este tipo involucran el acceso a almacenes de datos tradicionales, tales como bases de datos relacionales, ficheros con valores separados por comas (CSV), etc.
- ▶ Los **datos obtenidos a través de sensores**. En este conjunto se pueden mencionar ejemplos como sensores meteorológicos, sensores de ambiente (ruido o luz), sensores corporales (ritmo cardíaco o conductividad de la piel) y sensores de dispositivos móviles (acelerómetro o giroscopio).

Tema 4. Aplicación de herramientas para la visualización de datos

Actualmente existe un gran interés en el uso de sensores para la captura de datos en el contexto personal; este movimiento es conocido como quantified self.

- El **acceso a datos públicos**, ya sea mediante la descarga de conjuntos de datos o a través de interfaces de programación de aplicaciones (API, por sus siglas en inglés). Por un lado, muchas de las entidades públicas (como gobiernos centrales y locales) publican catálogos de datos para que sean analizados y se desarrollen nuevas aplicaciones a partir de ellos.

La publicación de estos datos de carácter público suele realizarse en un portal dedicado, por ejemplo <http://datos.gob.es> en España, <http://data.gov.uk> en Reino Unido y <http://data.gov> en Estados Unidos.

Por otro lado, algunas empresas brindan acceso a datos de forma pública, siendo uno de los fines el formar parte de una plataforma de desarrollo, como, por ejemplo, los servicios de redes sociales (Facebook o Twitter) que suelen brindar un API tanto para obtener información sobre un usuario en particular, como para alterar dicha información.

¿Qué son los datos no estructurados?

Los datos no estructurados son **información que no está organizada de acuerdo con un modelo o esquema** de datos preestablecido y, por lo tanto, no se puede almacenar en una base de datos relacional tradicional o RDBMS.

Los datos no estructurados suelen ser textuales, como respuestas de encuestas abiertas y conversaciones en redes sociales, pero también pueden ser no textuales, como imágenes, videos y audio. Muchos documentos comerciales no están estructurados, al igual que los mensajes de correo electrónico, videos, fotos, páginas web y archivos de audio.

Tema 4. Aplicación de herramientas para la visualización de datos

La información no estructurada está creciendo rápidamente debido al mayor uso de aplicaciones y servicios digitales. Algunas estimaciones dicen que el 80-90% de los datos de la empresa no están estructurados y continúan creciendo a un ritmo alarmante por año.

Si bien los datos estructurados son importantes, los datos no estructurados son aún más valiosos para las empresas si se analizan correctamente. Puede proporcionar una gran cantidad de información que las estadísticas y los números simplemente no pueden explicar.

Aunque contienen cifras, estadísticas y hechos, los datos no estructurados suelen tener mucho texto o estar configurados de una manera que es difícil de analizar. Las publicaciones en las redes sociales, por ejemplo, pueden contener opiniones, temas que se están discutiendo y recomendaciones de funciones. Pero esta información es difícil de procesar a granel. En primer lugar, se deben extraer y categorizar fragmentos específicos de información y luego analizarlos para obtener información útil.

Los almacenes de datos no estructurados contienen una gran cantidad de información que se puede utilizar para guiar las decisiones comerciales. Sin embargo, históricamente los datos no estructurados han sido muy difíciles de analizar. Con la ayuda de la inteligencia artificial y el aprendizaje automático, están surgiendo nuevas herramientas de software que pueden buscar en grandes cantidades para descubrir inteligencia comercial beneficiosa y procesable.

Diferencias entre datos estructurados y no estructurados

Las estimaciones dicen que solo el 20% de los datos están estructurados, mientras que los datos no estructurados representan el 80-90% de los datos.

Tema 4. Aplicación de herramientas para la visualización de datos

Ambos tipos de datos se recopilan, procesan y analizan de diferentes maneras, pero con el mismo objetivo de extraer información para tomar decisiones basadas en datos.

Entonces, ¿cuáles son exactamente las diferencias entre datos estructurados y no estructurados? Los datos estructurados están organizados y encajan ordenadamente en hojas de cálculo y bases de datos relacionales. Los datos no estructurados, por otro lado, no tienen una construcción o sistematización predefinida. Viene en forma de texto, audio, imágenes, videos y puede ser difícil de analizar.

Datos estructurados	Datos no estructurados
Los datos estructurados son cuantitativos y, a menudo, se muestran como números, fechas, valores y cadenas.	Los datos no estructurados son datos cualitativos e incluyen texto, video, audio, imágenes y más.
Los datos estructurados se almacenan en filas y columnas.	Los datos no estructurados se almacenan como archivos de audio, texto y video, o bases de datos NoSQL.
Aproximadamente el 20% de los datos comerciales.	Aproximadamente el 80-90% de los datos comerciales (¡y creciendo!).
Se encuentra en encuestas cerradas, como puntajes NPS y CSAT, y análisis web.	Se encuentra en consultas de atención al cliente, reseñas en línea, mensajes de correo electrónico, preguntas abiertas y más.
Almacenado en almacenes de datos.	Almacenado en aplicaciones, bases de datos NoSQL (no relacionales), lagos de datos y almacenes de datos.
Revela patrones y tendencias que le muestran lo que está sucediendo.	Revela patrones y tendencias que explican por qué algo está sucediendo.
Requiere menos espacio de almacenamiento.	Necesita más espacio de almacenamiento.
Fácil de analizar con herramientas como Excel.	Difícil de analizar sin herramientas de IA.

Figura 7. Fuente: elaboración propia.

Entre estos dos tipos de datos se encuentran los datos semiestructurados, que tienen un marco organizativo flexible. Por ejemplo, el correo electrónico es un ejemplo de datos semiestructurados porque está parcialmente organizado en

Tema 4. Aplicación de herramientas para la visualización de datos

carpetas, pero el texto del cuerpo dentro de los correos electrónicos no está estructurado.

Aunque contienen cifras, estadísticas y hechos, los **datos no estructurados** suelen tener mucho texto o estar configurados de una manera que es difícil de analizar.

Las publicaciones en las redes sociales, por ejemplo, pueden contener opiniones, temas que se están discutiendo y recomendaciones de funciones. Pero esta información es difícil de procesar a granel. En primer lugar, se deben extraer y categorizar fragmentos específicos de información y luego analizarlos para obtener información útil.

Los **datos estructurados**, por otro lado, suelen ser numéricos y fáciles de analizar. Está organizado en un formato estructurado predefinido, como Excel y Google Sheets, donde los datos se agregan a columnas y filas estandarizadas relacionadas con parámetros preestablecidos. El marco de los modelos de datos estructurados está diseñado para facilitar la entrada, búsqueda, comparación y extracción de datos.

También hay **datos semiestructurados**, que también son datos con mucho texto, pero están vagamente organizados en categorías o "metaetiquetas". Esta información se puede dividir fácilmente en sus grupos individuales, pero los datos dentro de estos grupos no están estructurados.

El correo electrónico es un buen ejemplo de esto: puede buscar su correo electrónico por Bandeja de entrada, Enviados y Borradores, pero el texto del correo electrónico dentro de cada categoría no tiene una estructura preestablecida.

Tema 4. Aplicación de herramientas para la visualización de datos

¿Qué son los datos estructurados?

Los datos estructurados son cuantitativos, altamente organizados y fáciles de analizar utilizando software de análisis de datos. Está formateado en sistemas que tienen un diseño regular, encajando en filas, columnas y tablas establecidas.

El lenguaje de consulta estructurado (SQL) es el lenguaje estándar que se utiliza para comunicarse con una base de datos y es particularmente útil cuando se manejan datos estructurados. Utilizado para buscar, agregar, actualizar y eliminar datos, entre otros usos, SQL facilita la organización de datos estructurados.

Piensa en la base de datos de un hotel, donde puedes buscar huéspedes por nombre, número de teléfono, número de habitación, etc. O códigos de barras utilizados para organizar y clasificar productos a nivel de producción, distribución y punto de venta.

Los datos estructurados generalmente están contenidos en bases de datos relacionales (RDBMS). La información dentro de las bases de datos puede ser ingresada por humanos o máquinas y se puede buscar fácilmente mediante consultas o algoritmos ingresados manualmente.

Los programas altamente metódicos como Excel también se utilizan para almacenar y organizar datos estructurados y se pueden conectar fácilmente a otras herramientas analíticas para un análisis más detallado.

Los datos estructurados son excelentes para la organización básica y los cálculos cuantitativos, pero deben ajustarse a parámetros preestablecidos rígidos. Ejemplos de datos estructurados son puntos de datos que se pueden buscar fácilmente dentro de su estructura establecida y se pueden comparar con otras bases de datos. Puede buscar por dirección de cliente para descubrir qué productos son los más populares en una determinada ubicación o averiguar qué productos piden varios clientes varias veces.

Tema 4. Aplicación de herramientas para la visualización de datos

Sin embargo, los datos estructurados tienen sus **desventajas**:

- ▶ No es excelente para obtener información realmente granular: los "cómo" y los "por qué" del análisis de datos.
- ▶ No es flexible: los datos estructurados generalmente se almacenan en almacenes de datos, que tienen esquemas rígidos. Si desea realizar incluso pequeños cambios en el "modelo" del esquema, deberá reorganizar grandes cantidades de datos, lo que implica grandes costos y tiempo.

¿Qué son los datos semiestructurados?

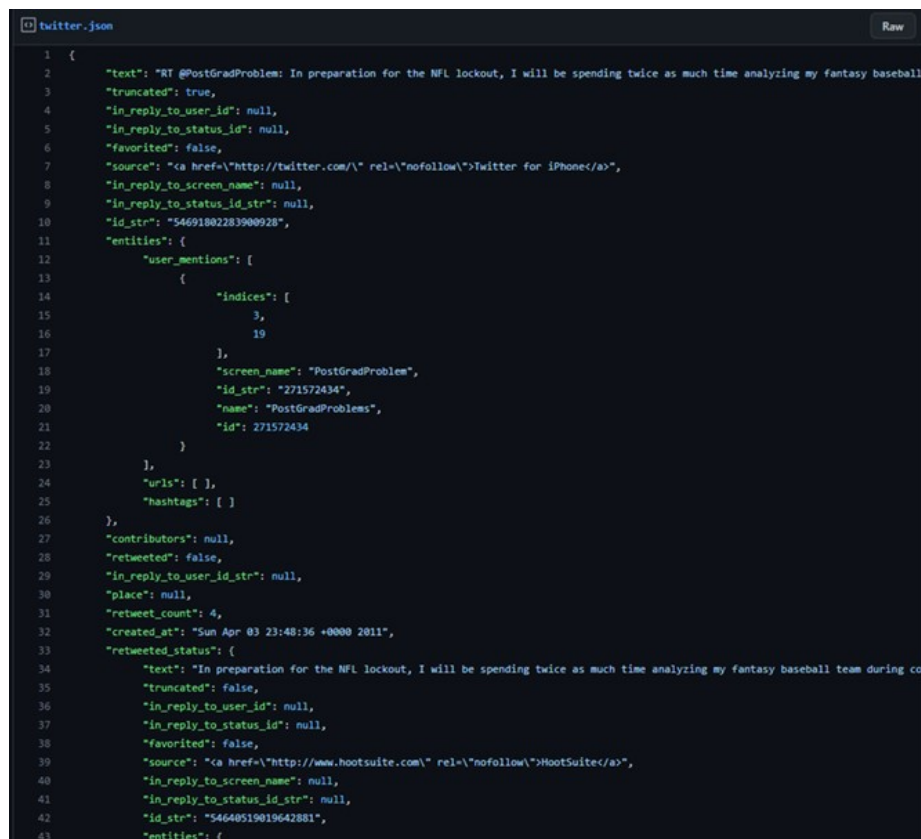
También hay datos semiestructurados, que contienen principalmente texto no estructurado, pero se clasifican vagamente con "metaetiquetas". Un ejemplo de esto sería el correo electrónico, que puede buscar por Bandeja de entrada, Enviados, Borradores, etc. O las redes sociales que pueden categorizarse como Amigos, Mensajes, Publicaciones públicas, Publicaciones privadas, etc.

Los datos semiestructurados se pueden dividir fácilmente en sus categorías predefinidas, pero la información dentro de estas categorías, en sí misma, no está estructurada.

Al analizar correos electrónicos, la clasificación de intenciones puede ser útil para leer automáticamente los correos electrónicos comerciales con la intención de que un cliente le diga si está respondiendo a una consulta con un interés genuino o no.

Algunos tipos de ficheros que almacenan información semiestructurada son JSON y XML. Aquí puedes ver un ejemplo de una parte de un fichero JSON de un Tweet:

Tema 4. Aplicación de herramientas para la visualización de datos



```
1 {
2   "text": "RT @PostGradProblem: In preparation for the NFL lockout, I will be spending twice as much time analyzing my fantasy baseball
3   "truncated": true,
4   "in_reply_to_user_id": null,
5   "in_reply_to_status_id": null,
6   "favorited": false,
7   "source": "<a href='\"http://twitter.com/\"' rel='\"nofollow\"'>Twitter for iPhone</a>",
8   "in_reply_to_screen_name": null,
9   "in_reply_to_status_id_str": null,
10  "id_str": "54691802283900928",
11  "entities": {
12    "user_mentions": [
13      {
14        "indices": [
15          3,
16          19
17        ],
18        "screen_name": "PostGradProblem",
19        "id_str": "271572434",
20        "name": "PostGradProblems",
21        "id": 271572434
22      }
23    ],
24    "urls": [ ],
25    "hashtags": [ ]
26  },
27  "contributors": null,
28  "retweeted": false,
29  "in_reply_to_user_id_str": null,
30  "place": null,
31  "retweet_count": 4,
32  "created_at": "Sun Apr 03 23:48:36 +0000 2011",
33  "retweeted_status": {
34    "text": "In preparation for the NFL lockout, I will be spending twice as much time analyzing my fantasy baseball team during cu
35    "truncated": false,
36    "in_reply_to_user_id": null,
37    "in_reply_to_status_id": null,
38    "favorited": false,
39    "source": "<a href='\"http://www.hootsuite.com/\"' rel='\"nofollow\"'>HootSuite</a>",
40    "in_reply_to_screen_name": null,
41    "in_reply_to_status_id_str": null,
42    "id_str": "54648519819642881",
43    "entities": {
```

Figura 8. Fuente: elaboración propia.

¿Cómo estructurar datos no estructurados?

Mientras que los datos estructurados encajan perfectamente en las hojas de cálculo y las bases de datos relacionales, los datos no estructurados pueden presentar varios problemas al intentar clasificarlos porque los formatos y las ubicaciones pueden variar ampliamente. Sin embargo, con la ayuda del software de análisis de texto, los datos no estructurados pueden formatearse automáticamente y analizarse adecuadamente.

El software de análisis de texto utiliza algoritmos de aprendizaje automático y técnicas de **procesamiento de lenguaje natural (NLP)** para "leer" texto no estructurado, luego categorizarlo y analizarlo como lo haría un ser humano, pero en una fracción del tiempo y con total precisión.

Tema 4. Aplicación de herramientas para la visualización de datos

A menudo, el software de análisis de texto realizará una variedad de tareas de NLP en datos no estructurados para obtener información más precisa.

- ▶ **Clasificación de temas** para leer automáticamente los tickets de atención al cliente por tema, urgencia y más, y enrutarlos directamente al empleado adecuado.
- ▶ **Análisis de sentimiento** para leer la polaridad de la opinión (positiva, negativa, neutral y más allá). Una vez entrenados adecuadamente, los modelos de análisis de sentimientos pueden decirle los sentimientos reales de sus clientes.
- ▶ **Extracción de entidades** para comprender automáticamente los datos de texto y extraer nombres, direcciones, números de teléfono y otra información específica.
- ▶ **Extracción de palabras clave** para leer automáticamente los comentarios de los clientes y extraer las palabras más utilizadas e importantes. Se puede realizar de forma constante y en tiempo real para estar siempre pendiente de tu marca.

¿Para qué se utilizan los datos no estructurados?

Se pueden realizar **búsquedas de contenido simple** en datos textuales no estructurados. Las herramientas de análisis tradicionales están optimizadas para datos relacionales altamente estructurados, por lo que son de poca utilidad para fuentes no estructuradas como medios enriquecidos, interacciones con clientes y datos de redes sociales.

Big Data y los datos no estructurados a menudo van de la mano. Se estima que el 90% de estos conjuntos de datos extremadamente grandes no están estructurados.

Recientemente se han puesto a disposición nuevas herramientas para analizar estas y otras fuentes no estructuradas. Impulsadas por inteligencia artificial y aprendizaje automático, estas plataformas funcionan a una velocidad casi en tiempo real y se educan a sí mismas en función de los patrones y los conocimientos que descubren.

Tema 4. Aplicación de herramientas para la visualización de datos

Estos sistemas se están empleando contra grandes conjuntos de datos no estructurados para habilitar aplicaciones nunca antes posibles.

Tipos y ejemplos de datos desestructurados

Los ejemplos de datos no estructurados incluyen documentos legales, audio, chats, videos, imágenes, texto en una página web, ficheros (xml y json) y mucho más.

Ejemplos de datos no estructurados son:

- ▶ Documentos empresariales
- ▶ Correos electrónicos
- ▶ Medios de comunicación social
- ▶ Comentarios de los clientes
- ▶ Páginas web
- ▶ Respuestas de encuestas abiertas
- ▶ Imágenes, audio y video

Documentos empresariales

Los informes comerciales escritos, los documentos legales y las presentaciones a menudo se imprimen en papel, en PDF o incluso se escriben a mano, y algunos pueden contener hojas de cálculo, imágenes o archivos XML.

Aunque los archivos de texto pueden organizarse en un formato común, los datos no están estructurados de manera que puedan analizarse sin tecnología avanzada de inteligencia artificial.

Tema 4. Aplicación de herramientas para la visualización de datos

Estos documentos contienen enormes cantidades de datos no estructurados que a menudo no se explotan, ya que se considera que su análisis requiere demasiado tiempo. Afortunadamente, mediante el uso de técnicas de análisis de texto, las empresas ahora pueden recopilar información valiosa de estos documentos sobre clientes, empleados y utilizarlos para la investigación competitiva.

Correos electrónicos

Enviamos decenas de correos electrónicos a diario, lo que se traduce en enormes cantidades de datos no estructurados. Aunque los correos electrónicos están semiestructurados por categorías, como en este ejemplo a continuación, los datos dentro de cada correo electrónico no están estructurados.

El software de análisis de texto puede escanear miles de correos electrónicos en segundos para extraer información del cliente, organizar por categoría y enrutar al departamento adecuado, rastrear la calidad del servicio al cliente y más.

Incluso es posible averiguar qué tipo de lenguaje funciona mejor para la comunicación con el cliente y analizar fácilmente para descubrir los principales puntos débiles del cliente en solo unos minutos. Por ejemplo, puedes descubrir temas particulares que se mencionan con mayor frecuencia de manera negativa.

Medios de comunicación social

Los datos de las redes sociales son similares a los correos electrónicos, ya que algunos de ellos están organizados. Los hashtags, por ejemplo, ayudan a los usuarios a buscar temas que les interesen. Pero los mensajes que contienen estos hashtags no están estructurados.

Tema 4. Aplicación de herramientas para la visualización de datos

Una búsqueda de hashtag en Twitter como ejemplo de datos semiestructurados. Los datos de las redes sociales crecen en masa por segundos hasta convertirse en un archivo enorme, nebuloso y en tiempo real de ideas, opiniones y estadísticas. Cuando los usuarios de las redes sociales mencionan marcas y productos, pueden convertirse en datos útiles que se pueden extraer para obtener opiniones.

Incluso es posible seguir las tendencias dentro de su campo en tiempo real y con regularidad. Una vez que establezca los parámetros y entrene los modelos de análisis de texto para su negocio, puede obtener docenas de información útil de las redes sociales. Y todo se hace automáticamente con el aprendizaje automático.

Comentarios de los clientes

Los comentarios de los clientes pueden presentarse de muchas formas: reseñas en línea, encuestas, llamadas telefónicas y publicaciones no solicitadas en las redes sociales. Cuando es posible recopilar y analizar toda esta información en conjunto, puede obtener una visión totalmente equilibrada de los pensamientos de sus clientes.

Al realizar un análisis de los comentarios de los usuarios o clientes, puedes tener datos concretos sobre lo que piensa el cliente y una visión general de lo que hace.

Páginas web

Internet crea datos no estructurados a una velocidad vertiginosa. Las páginas web pueden incluir texto, imágenes, audio, video, todo tipo de contenido. Y aunque la estructura de las páginas web está escrita en código HTML, esto en realidad no explica el contenido de las páginas.

Tema 4. Aplicación de herramientas para la visualización de datos

Puede ser útil extraer y organizar estos datos para encontrar información sobre clientes, competidores y el sentimiento general del público. Además, dado que las páginas web cambian constantemente, el software de aprendizaje automático le permite rastrearlas constantemente y compararlas a lo largo del tiempo.

Respuestas de encuesta abiertas

Si bien algunas encuestas están diseñadas para analizarse fácilmente con preguntas de opción múltiple, generalmente se pueden obtener más conocimientos de los cuestionarios abiertos. Debido a que los encuestados responden con sus propias palabras, el texto o las grabaciones producidas deben desglosarse en datos utilizables antes de que puedan analizarse adecuadamente.

Realizar análisis de encuestas en respuestas abiertas ofrece más matices e incluso puede incluir nuevas ideas y recomendaciones de los clientes.

Una vez recopiladas las respuestas no estructuradas, se pueden organizar y analizar con herramientas de inteligencia empresarial que clasifican, analizan y visualizan datos.

Imágenes, audio y video

Aunque los archivos multimedia pueden estar etiquetados con títulos o temas y guardados en bases de datos como MP3, JPG, PNG, GIF, etc., aún no están estructurados porque no sabemos qué representa la imagen, el audio o el video.

Tema 4. Aplicación de herramientas para la visualización de datos

Sin embargo, la tecnología de voz a texto como [Gong](#) se puede utilizar para convertir archivos de audio en texto, que luego se puede analizar mediante un software de procesamiento de lenguaje natural. Y el análisis de imágenes y videos ha hecho grandes avances con tratamientos faciales y subjetivos.

Importancia de los datos no estructurados

Como ya hemos visto la mayoría de los datos creados hoy en día no están estructurados (documentos, redes sociales, correos electrónicos) y, a menudo, son un recurso sin explotar. Cuando se administran de la manera correcta, los datos no estructurados pueden brindar innumerables conocimientos que lo ayudan a tomar decisiones informadas basadas en datos.

La tecnología de aprendizaje automático le permite administrar y analizar automáticamente datos no estructurados de forma rápida y precisa. Gracias a los avances tecnológicos, como el procesamiento del lenguaje natural (NLP), las máquinas ahora pueden leer texto como lo haría un ser humano. Eso significa que puede eliminar las tareas repetitivas, como etiquetar y enrutar manualmente los boletos, o filtrar las publicaciones en las redes sociales.

En cambio, la tecnología de IA puede aprender automáticamente cómo extraer palabras clave, nombres, números de teléfono y ubicaciones, comprender opiniones e intenciones y reconocer temas que son importantes para su negocio. Una vez se hayan organizado todos sus datos no estructurados, obtendrá información granular que le ayudará a tomar decisiones comerciales informadas.

Cómo analizar datos no estructurados

En el pasado, el análisis que se podía realizar en datos no estructurados era relativamente insignificante y se almacenaba en sistemas de gestión de documentos

Tema 4. Aplicación de herramientas para la visualización de datos

que realizaban un seguimiento de los historiales de versiones, los metadatos y la indexación. Pero el análisis de datos de documentos individuales era esencialmente manual.

Ahora hay una serie de herramientas de análisis de datos con algoritmos muy avanzados que están diseñados específicamente para desglosar datos no estructurados (generalmente texto) y almacenar los resultados. Las herramientas de análisis de datos no estructurados combinan algoritmos de aprendizaje automático y procesamiento de lenguaje natural para crear programas de software de aprendizaje profundo que se pueden entrenar para industrias y necesidades específicas.

Vamos a ver cómo administrar adecuadamente los datos no estructurados, para que estén listos para que los analice:

- ▶ 1. Elige el objetivo final: Asegúrate de definir un conjunto claro de objetivos medibles. ¿Qué información deseas obtener de tus datos?
- ▶ 2. Recopilar datos relevantes: Los datos están en todas partes, pero tal vez solo desee centrarse en los datos de un canal, como las redes sociales, las reseñas en línea o las encuestas. Según tu objetivo final, puedes recopilar datos en tiempo real, ver datos históricos o solicitar datos (encuestas).
- ▶ 3. Limpieza de datos: Para que los datos no estructurados sean más fáciles de analizar, primero se deberá preprocesar o limpiar los datos. El preprocesamiento de datos implica reducir el “ruido”, eliminar información irrelevante (por ejemplo, palabras vacías) y dividir los datos en piezas de contenido más manejables.
- ▶ 4. Implementar tecnología: Necesitaras algo más que herramientas de análisis de datos no estructurados para aprovechar al máximo los datos. La arquitectura de almacenamiento de datos y recuperación de información, como **las bases de datos NoSQL**, por ejemplo, son esenciales para ayudar a administrar un flujo de datos, mientras que las herramientas de visualización de datos, como Tableau y Google

Tema 4. Aplicación de herramientas para la visualización de datos

Data Studio, ayudan a resumir los datos no estructurados.

Almacenamiento de los datos no estructurados. NoSQL

En la gran mayoría de las ocasiones los datos no estructurados se van a almacenar en las bases de datos NoSQL ya que la arquitectura que tienen estas bases de datos es perfecta para su correcto almacenamiento.

Existen diferentes tipos de bases de datos según como almacenen la información:

- ▶ **Almacenes de clave-valor simples.** Como su nombre indica, utilizan una clave para acceder a un valor en específico. Los valores almacenados se manejan como *arrays* de *bytes*, es decir, sin ningún esquema específico asignado. Su aplicación es común en sistemas de caché. Uno de los sistemas más conocidos en esta categoría es **memcached**, el cual es el sistema de facto para la gestión de caché de datos en aplicaciones web.
- ▶ **Almacenes de clave-valor sofisticados.** Estos sistemas son un refinamiento de la categoría anterior con el objetivo de permitir operaciones de lectura y escritura más complejas, así como un modelo de datos ligeramente más elaborado. Ejemplos de sistemas en esta categoría son **Cassandra**, **Dynamo**, **Voldemort** y **Riak**.
- ▶ **Almacenes de documentos.** Los sistemas dentro de esta categoría permiten almacenar estructuras de datos relativamente complejas. Las implementaciones más conocidas en este grupo son **CouchDB** y **MongoDB**, la cual se estudiará con más detalle.
- ▶ **Almacenes de grafos.** Las bases de datos que entran en esta categoría son las que almacenan la información en estructuras de grafos, cuyos nodos representan la información y las aristas, sus relaciones. Las bases de datos de grafos brindan la facilidad de consultar su información aplicando teoría de grafos.

Tema 4. Aplicación de herramientas para la visualización de datos

Dicha teoría comprende un gran número de algoritmos conocidos, que optimizan el recorrido de todos los elementos del grafo (la base de datos), ofreciendo así una navegación mucho más eficiente que las bases de datos relacionales. Algunas implementaciones conocidas son InfoGrid, Virtuoso y **Neo4j**.

Existe otro tipo de bases de datos llamadas **multimodelos**, las cuales combinan características de los cuatro tipos antes descritos. Esta unión de características les permite ofrecer una variedad de funcionalidades muy útiles de cara a la explotación de la información.

El hecho de que soporten varios modelos amplía la forma de interactuar con los datos, independientemente del modelo de datos que se esté utilizando. Esto último brinda a los desarrolladores flexibilidad a la hora de construir sus aplicaciones dentro de la compañía, sin preocuparse de las características del dato.

Dentro de este tipo de bases de datos se encuentra Redis. **Redis** es una base de datos NoSQL multimodelo que permite búsquedas, mensajería, transmisión, grafos y otras capacidades más allá de las que ofrece un simple almacén de datos.

Beneficios de las herramientas de análisis de datos no estructurados

Las herramientas de análisis de datos no estructurados están diseñadas específicamente para **recopilar y analizar información no estructurada**. Con herramientas de análisis de datos no estructurados, equipadas con aprendizaje automático y capacidades de procesamiento de lenguaje natural, puede escanear automáticamente correos electrónicos o tickets de servicio al cliente y obtener información valiosa.

El análisis manual de datos no estructurados requiere mucho tiempo y los humanos se aburren fácilmente, lo que puede sesgar los resultados. El uso de herramientas de

Tema 4. Aplicación de herramientas para la visualización de datos

análisis de datos es 1200 veces más rápido que una persona, consistentemente preciso, completamente escalable y funciona constantemente, en tiempo real.

El software de análisis de texto puede monitorear correos electrónicos, chats en vivo, publicaciones en redes sociales en tiempo real.

Las herramientas de análisis de datos no estructurados, como las nubes de palabras, también pueden leer rápidamente el texto para crear una vista fácil de entender de las palabras y frases de uso común dentro de su conjunto de datos.

La siguiente es una nube de palabras:



Figura 9. Nube de palabras. Fuente: Ssalonso, 2011.

Las nubes de palabras son visualizaciones de las palabras más utilizadas en un texto: cuanto más grandes son las palabras, más frecuentemente se utilizan. Pueden ser geniales para encontrar las palabras más importantes en las que centrarse y compararlas con la competencia. Sin embargo, necesitaras herramientas de análisis de datos no estructurados más avanzadas para obtener información más granular.

Tema 4. Aplicación de herramientas para la visualización de datos

4.2. Inteligencia artificial en el análisis de datos

Los orígenes de la IA

Para un concepto y una tecnología tan revolucionarios y aparentemente desconcertantes como la IA, puede ser una valiosa experiencia básica retroceder unos pasos para comprender cómo llegamos a las capacidades actuales.

La evolución de la IA

En esencia, la IA ocurre cuando las máquinas usan entradas para crear una salida deseada o lograr un objetivo deseado. Entre los principales ejemplos encontramos:

- ▶ Alexa de Amazon entiende tu voz y tu intención cuando le pides que reproduzca un género musical de una década específica.
- ▶ Algoritmos que analizan flujos de datos de máquinas para predecir cuándo un componente de la máquina está a punto de fallar. (O, en el campo de la medicina, máquinas que analizan datos de humanos para predecir problemas médicos graves).
- ▶ El sistema de seguridad de un automóvil escanea el entorno que lo rodea para saber cuándo reducir la velocidad, cambiar de carril o dejar de retroceder.

Tema 4. Aplicación de herramientas para la visualización de datos

La idea de máquinas que imitan la inteligencia humana ha existido durante cientos de años, incluso en la mitología griega antigua. El campo de la investigación de la IA se fundó oficialmente cuando Dartmouth College realizó un taller sobre el tema en 1956. Casi al mismo tiempo, los científicos informáticos desarrollaron programas para competir con los humanos en damas y ajedrez. Había un gran optimismo sobre el futuro de las computadoras pensantes, y los gobiernos invirtieron miles de millones de dólares en investigación sobre IA. Sin embargo, la potencia informática y la escala necesarias no existían en ese momento para convertir tales visiones en realidad.

En los últimos años, sin embargo, los académicos y los ingenieros han logrado un progreso significativo tanto en el poder computacional como en las plataformas de procesamiento de datos escalables masivamente. En esta década y en la anterior, los fundadores han creado miles de empresas para ofrecer soluciones impulsadas por IA, y organizaciones grandes y establecidas han hecho de la IA un componente integral de productos nuevos y existentes. Ahora, la IA es tan omnipresente en nuestra vida diaria que rara vez la notamos.

La evolución de BI

BI, tal como la conocemos, también es relativamente joven. Las organizaciones comenzaron a implementar sistemas de soporte de decisiones, el precursor de BI, en la década de 1960, y estos sistemas se convirtieron en un área de investigación seria en la década de 1970, con académicos y proveedores que invirtieron considerablemente en las interacciones y la interfaz entre los sistemas y los usuarios.

Paralelamente, muchos defensores de los sistemas de bases de datos relacionales propusieron que estas bases de datos deberían ser la plataforma para los sistemas de soporte de decisiones. De hecho, algunos expertos han rastreado el uso común del término "BI" hasta mediados de la década de 1980, cuando Procter & Gamble

Tema 4. Aplicación de herramientas para la visualización de datos

contrató a Metaphor Computer Systems para construir e integrar una interfaz de usuario con una base de datos.

BI seguiría estando estrechamente vinculada al almacenamiento de datos y las bases de datos relacionales en las décadas siguientes, aunque pasarían muchos años antes de que los investigadores y los proveedores de tecnología conectaran la IA y la BI.

Análisis impulsado por IA

Hoy en día, la IA se está convirtiendo en un impulsor clave de la analítica. BI permanece fuera del alcance técnico de la persona de negocios promedio y los volúmenes de datos se han disparado. En 1979, la mayoría de los líderes empresariales nunca podrían imaginar acumular un terabyte completo de datos. Hoy en día, muchas personas almacenan terabytes en sus hogares y en la nube. Y seguimos creando más datos todo el tiempo con cosas tan comunes como nuestros teléfonos, así como con dispositivos conectados como hogares inteligentes, automóviles, aviones y trenes, Internet de las cosas (IoT), por nombrar solo algunos datos. fuentes.

En una encuesta reciente de análisis de McKinsey, casi la mitad de todos los encuestados dijo que "los datos y el análisis han cambiado significativa o fundamentalmente las prácticas comerciales en sus funciones de ventas y marketing, y más de un tercio dice lo mismo sobre I+D".

Tema 4. Aplicación de herramientas para la visualización de datos

El desafío para el BI tradicional, en el que los expertos en datos resumen y agregan datos de un almacén de datos y luego los cargan en un servidor de BI para exploración e informes, es que no puede soportar la agilidad y los conocimientos más profundos que requieren las empresas, ni la cantidad de información. Aun así, las organizaciones reconocen la necesidad de basarse en datos para mantenerse al día con los competidores existentes y defenderse de los nuevos nativos digitales.

Aquí es donde la IA presenta una oportunidad importante. Gracias en parte a las explosiones paralelas de datos, los recursos informáticos asequibles y los algoritmos avanzados, la IA ahora puede recopilar la cantidad de entradas necesarias para tomar decisiones razonables y entregar los resultados de los análisis de manera oportuna para que sean valiosos.

El análisis impulsado por IA puede ayudar a los usuarios a revelar información en segundos de múltiples maneras. Un ejemplo es el uso del **procesamiento del lenguaje natural** (NLP). Las soluciones analíticas modernas admiten NLP para permitirle usar el lenguaje cotidiano para hacer preguntas sobre los datos.

Los **análisis automatizados** son otro ejemplo de análisis de aumento de IA para acelerar el tiempo de conocimiento. En este caso, un usuario puede simplemente apuntar su solución de análisis a un conjunto de datos, un campo o incluso un punto de datos específico y pedirle a AI que identifique los factores clave y las anomalías dentro de esos datos. Gracias a la potencia informática moderna y las técnicas de programación, la IA puede ejecutar miles de análisis en miles de millones de filas en segundos. A través de la generación de lenguaje natural, el sistema puede presentar al usuario los conocimientos impulsados por la IA de manera intuitiva, incluidos los resultados de las preguntas que el usuario podría no haber pensado en hacer. Con los comentarios de los usuarios y el aprendizaje automático, la IA puede volverse más inteligente sobre qué información es más útil.

Tema 4. Aplicación de herramientas para la visualización de datos

Esta noción de análisis aumentado, que aplica técnicas de inteligencia artificial como el aprendizaje automático y la generación de lenguaje natural al análisis, presenta una disrupción tal en el mercado de datos y análisis que los líderes de opinión de la industria están alentando su adopción. La oportunidad es tan importante que la firma de analistas Gartner, Inc. dice que los análisis aumentados son "cruciales para tomar decisiones imparciales, una conciencia contextual imparcial y actuar sobre la base de los conocimientos".

Adoptando tecnologías de IA

Al igual que con muchas tecnologías nuevas, los usuarios y beneficiarios potenciales de la IA primero deben considerar si adoptarla y, si eligen hacerlo, dónde y cómo aplicarla. Afortunadamente, las tecnologías que permiten la IA son comunes y bien comprendidas, y la lista de posibles aplicaciones es amplia.

IA desmitificada

Para que la IA, y sus ramificaciones, el aprendizaje automático y el aprendizaje profundo, respalden los casos de uso del mundo real, se requieren arquitecturas tecnológicas escalables masivamente. Eso es porque la IA es más "artificial" que "inteligente". La IA requiere grandes cantidades de datos para capacitarse y aprender, de modo que pueda ofrecer resultados precisos (y relevantes).

Por ejemplo, considera una búsqueda meteorológica en Google. Cuando se buscaba "clima" y algún código postal o ciudad hace siete años, Google devolvía enlaces a varias páginas con el clima actual y los pronósticos para esa localidad.

Tema 4. Aplicación de herramientas para la visualización de datos

Avance rápido hasta el día de hoy. Tan pronto como escriba "clima" en su barra de búsqueda, Google le devolverá las condiciones actuales en función de su dirección IP. Si completa la búsqueda con un código postal, Google devuelve múltiples detalles sobre las condiciones climáticas actuales y pronosticadas y, según sus patrones de búsqueda, también puede incluir enlaces a elementos relevantes como correos electrónicos en su bandeja de entrada de Gmail que hacen referencia a esa ubicación, cosas que hacer allí, y otros datos interesantes.

Todo esto es el resultado del aprendizaje de la IA de Google durante varios años y miles de millones de búsquedas en lo que los usuarios están interesados cuando buscan "tiempo". Almacenar y procesar toda esta información requiere una escala masiva.

IA: uniendo bases de datos y tecnologías de análisis

Fundamentalmente, la IA requiere tecnologías de base de datos y análisis que operen a un volumen y una velocidad masivos. AI requiere un almacenamiento significativo para contener todos los datos que sus modelos requieren para la capacitación y el aprendizaje. Y la IA necesita tecnología de análisis para hacer algo útil con todos esos datos, ya sea que el resultado final sea identificar a una persona por su rostro o predecir qué productos serán los más vendidos el próximo mes. Todo esto debe combinarse con una potencia de procesamiento masiva para obtener resultados de manera oportuna.

Esencialmente, los datos son el petróleo crudo de nuestra economía digital. Se puede obtener un gran valor con los datos, pero se requieren recursos muy significativos para convertir volúmenes masivos de datos sucios en información brillante. Los datos en su forma cruda a menudo son inútiles. Al igual que el refinamiento de petróleo, el refinamiento de datos es difícil y costoso. Como parte de

Tema 4. Aplicación de herramientas para la visualización de datos

la población que puede beneficiarse de la información de los datos, aquellos que saben cómo procesar y analizar datos son relativamente pocos. Y, como el petróleo crudo, hay millones de consumidores esperando para usar los productos de datos completos.

La IA nunca podría integrarse con BI más allá de los casos de uso más simples, ya que BI no se creó para escalar. BI tradicional se basa en cubos y agregados de datos cargados en un único servidor de BI. En el momento en que alguien, o algo, como IA, necesita aprender más al profundizar en un detalle que es más granular o está fuera del alcance del cubo, el proceso se rompe.

Esto no quiere decir que el análisis impulsado por IA requiera todos los componentes y características de las bases de datos tradicionales. Pero, como mínimo, requiere una integración más estrecha entre almacenamiento, cómputo y análisis, junto con una capa de visualización o alguna otra técnica de publicación para que la inteligencia se entregue en el momento oportuno para que sea de valor.

En una nota relacionada, en nuestro mundo siempre conectado, ahora esperamos que la información esté siempre disponible para nosotros sin importar dónde nos ubiquemos o lo que estemos haciendo. Por lo tanto, la capa de servicio para la información y los resultados impulsados por IA debe ser a escala planetaria. Esto no era posible antes de la adopción generalizada de tecnologías en la nube. Amazon Web Services (AWS), que posee la mayor parte del mercado de computación y almacenamiento basado en la nube, tiene solo una docena de años. Por lo tanto, el análisis impulsado por IA es un avance tecnológico relativamente joven, aunque ya probado.

Tema 4. Aplicación de herramientas para la visualización de datos

El papel de la memoria

El mercado en evolución para el procesamiento y el almacenamiento en memoria también ha desempeñado un papel importante en los avances recientes en el análisis impulsado por IA. La segunda generación de herramientas de BI se inventó antes de la popularización de la informática de 64 bits y solo podía escalar hasta unos pocos gigabytes de memoria de acceso aleatorio (RAM). A medida que el costo de la memoria RAM ha disminuido, a las empresas les resulta más factible almacenar y procesar volúmenes de datos cada vez más grandes en la memoria en lugar de unidades de disco menos costosas, pero significativamente más lentas.

De hecho, los desarrolladores de análisis basados en memoria e impulsados por IA miden sus optimizaciones de código en nanosegundos, una mil millonésima de segundo. Se dice que "la latencia de nanosegundos está a la vanguardia de la computación en tiempo real" y "el valor del tiempo nunca ha sido tan alto y, por lo tanto, la velocidad nunca ha sido más crítica para las aplicaciones comerciales".

Avances recientes en IA

El análisis impulsado por IA es un concepto relativamente nuevo, pero no es la única área en la que la IA ha logrado avances en los últimos años. Muchas organizaciones han adoptado activamente varias formas de aprendizaje automático, el subconjunto de IA mencionado anteriormente en el que las máquinas se vuelven progresivamente más inteligentes o mejores para realizar tareas específicas. Esencialmente, el aprendizaje automático es el uso de algoritmos para el análisis estadístico de los datos de entrada para predecir los resultados. El aprendizaje automático a menudo se divide en tres categorías: supervisado, no supervisado y de refuerzo. Tomemos un momento para ver cada uno de estos:

Tema 4. Aplicación de herramientas para la visualización de datos

Aprendizaje automático supervisado

Un científico o analista de datos proporciona tanto las entradas como la salida deseada, incluida la retroalimentación sobre los resultados para ayudar a los modelos a "aprender" para que puedan hacer mejores predicciones. El experto itera y la máquina modifica los modelos hasta que finalmente no hay o hay muy pocos resultados incorrectos.

Un ejemplo claro lo tenemos en los sitios web de redes sociales en los que los usuarios identifican personas en imágenes. Cuando un usuario carga una nueva foto, el sitio puede hacer una sugerencia muy precisa de quién debe etiquetarse en la foto.

Aprendizaje automático no supervisado

Las computadoras se basan en un aprendizaje profundo similar a las redes neuronales (en lugar de la retroalimentación de un experto en datos) para hacer sus predicciones. Al observar cantidades extremadamente grandes de puntos de datos, las máquinas pueden identificar tendencias y correlaciones entre variables por sí mismas y luego usar este entrenamiento para reconocer nuevos puntos de datos o hacer predicciones.

Los especialistas en marketing utilizan algoritmos de aprendizaje automático no supervisados, como la agrupación en clústeres, para identificar grupos similares de clientes o posibles clientes para campañas de marketing dirigidas.

Aprendizaje automático de refuerzo

Las máquinas toman acciones en un entorno para maximizar una "recompensa". Esto generalmente se hace a través de un proceso de decisión de Markov cuando no

Tema 4. Aplicación de herramientas para la visualización de datos

hay un modelo matemático exacto del entorno y los expertos no están involucrados en proporcionar las entradas o la retroalimentación sobre las salidas. El objetivo es maximizar la recompensa en función del conocimiento existente y, al mismo tiempo, adquirir nuevos conocimientos.

Un ejemplo popular es el de un jugador con una fila de máquinas tragamonedas para elegir. Las aplicaciones comunes incluyen la optimización de la cartera financiera, el enrutamiento de redes y los ensayos clínicos. El aprendizaje automático de refuerzo se aplica a menudo en videojuegos y robótica.

Muchas empresas han invertido mucho en el aprendizaje profundo, un subconjunto del aprendizaje automático, que en sí mismo es un subconjunto de la IA. El aprendizaje profundo y las redes neuronales artificiales permiten el reconocimiento de imágenes, el reconocimiento de voz, la PNL y otros avances recientes. Ya hemos llegado a dar por sentado esto en nuestra vida personal en la era de Internet y los grandes datos, pero tales características no son comunes en el software de análisis.

Algoritmos comunes de IA utilizados en análisis

Si bien el análisis impulsado por IA aún es demasiado incipiente para describir los algoritmos que lo sustentan como "populares", hay algoritmos que se utilizan cada vez más en el panorama de la IA para el análisis. Examinemos algunos de estos aquí:

Regresión lineal

La regresión lineal (Figura 1) modela la respuesta de una variable dependiente a una independiente o un conjunto de variables independientes. El modelo es una ecuación con el dependiente en un lado y un peso para cada variable en el otro lado. La

Tema 4. Aplicación de herramientas para la visualización de datos

ecuación se puede utilizar para generar información sobre el comportamiento o la rentabilidad del cliente.




Figura 10. Ejemplo de regresión lineal. Fuente: elaboración propia.

Regresión logística

La regresión logística (Figura 2) es similar a la regresión lineal en que construye un modelo lineal para una variable independiente y una dependiente. Sin embargo, en una regresión logística, el dependiente es binario: 0 o 1, verdadero o falso, sí o no. Se puede utilizar para segmentación y procesamiento de imágenes o predicciones categóricas.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 11. Ejemplo de regresión logística. Fuente: elaboración propia.

Árboles de decisión

Los árboles de decisión son modelos similares a árboles de decisiones y consecuencias o resultados, a menudo con la probabilidad de esos resultados modelados como ponderaciones. Son populares en logística, gestión de proyectos, atención médica y finanzas. La Figura 3 muestra un ejemplo.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 12. Ejemplo de árbol de decisión. Fuente: elaboración propia.

Clasificación Naive de Bayes

La Clasificación Naive Bayes es una técnica de aprendizaje automático, que se muestra en la figura siguiente, que supone que las características o predictores son independientes entre sí para calcular la probabilidad de que un elemento se clasifique en varias categorías. Es muy popular en el análisis de texto para casos de uso como el reconocimiento de spam y el etiquetado de categorías de noticias.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 13. Resultado de un modelo de clasificación de Naive Bayes. Fuente: elaboración propia.

Algoritmos de clasificación

Este tipo de algoritmos intentan agrupar elementos que son más similares entre sí. K-means, representado en la figura siguiente, es probablemente el algoritmo de agrupamiento más popular.

Para comenzar, selecciona el número de clases o grupos que desea crear y los centros de esos grupos. A medida que el modelo entrena, cambiará el centro de los grupos hasta que finalmente encuentre el centro con la distancia más corta entre los miembros de su grupo y la distancia más alejada de los miembros del otro grupo. Este es un método muy rápido porque hay pocos cálculos: solo está calculando la distancia entre los puntos de datos y el centro. Los algoritmos de agrupamiento se utilizan en la segmentación de clientes, bioinformática, imágenes médicas, análisis de redes sociales y búsqueda web.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 14. Resultados de un modelo de clasificación. Fuente: elaboración propia.

Análisis de componentes principales (PCA)

PCA se usa más comúnmente para la reducción de dimensiones. En este caso, PCA mide la variación en cada variable (o columna en una tabla). Si hay poca variación, descarta la variable, como se ilustra en la Figura 6, lo que facilita la visualización del conjunto de datos. PCA se utiliza en finanzas, neurociencia y farmacología.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 15. Resultados de un modelo de clasificación. Fuente: Naveen, 2022.

Avances en procesamiento

Aunque algunos de los algoritmos descritos en la sección anterior requieren relativamente pocos cálculos, requerirán volúmenes masivos de datos para entrenar de manera efectiva. Como se comentó anteriormente, la falta capacidad de cómputo y de datos, históricamente han sido impedimentos para el desarrollo de la IA. Se necesitan grandes volúmenes de datos para que los modelos aprendan, y se necesitan grandes recursos informáticos para realizar rápidamente cualquier cálculo complejo.

Afortunadamente, los desarrolladores han logrado avances significativos en el procesamiento durante las últimas décadas, y el costo de aprovechar estos avances ha disminuido considerablemente. Las unidades de procesamiento gráfico (GPU) y la RAM ahora son lo suficientemente asequibles como para que las empresas puedan incorporarlas en sistemas de misión crítica. Las empresas ahora almacenan terabytes de sus datos empresariales en RAM para un acceso y análisis rápidos. Y

Tema 4. Aplicación de herramientas para la visualización de datos

gracias al procesamiento masivo en paralelo, el software puede combinar de manera inteligente los recursos de muchas máquinas para multiplicar la potencia de procesamiento.

Esto ha llevado a nuevos marcos de programación como el aprendizaje profundo. En el aprendizaje profundo, las computadoras aprenden cómo se representan las características en lugar de depender de algoritmos específicos de tareas. El aprendizaje profundo ha adquirido prominencia en el reconocimiento de voz, NLP, bioinformática y otros campos. Esto puede ser supervisado o no supervisado.

Las redes neuronales profundas, quizás el subcampo más popular del aprendizaje profundo, examinan las entradas y determinan las salidas. "Profundo" significa que una red neuronal tiene múltiples capas ocultas entre la entrada y la salida, que las redes neuronales profundas utilizan para aprender las características de los datos para aplicar ponderaciones (la probabilidad de cada salida) a varios factores para crear una jerarquía de características. Esto requiere grandes cantidades de datos y grandes cantidades de poder de cómputo. A través del entrenamiento, eventualmente la máquina establecerá el peso apropiado para cada función y podrá clasificar correctamente las nuevas entradas sin ayuda humana.

Tema 4. Aplicación de herramientas para la visualización de datos

Implementando IA

Con la tecnología disponible, ¿cómo se empieza a utilizar la IA?

Una consideración debe ser el deseo de personalización y flexibilidad frente a la facilidad de desarrollo o uso. Por ejemplo, TensorFlow es una biblioteca de software de código abierto y gratuita popular por su biblioteca de aprendizaje automático. Pero para aquellos que buscan una ruta rápida para comenzar o probar un concepto, Keras es una biblioteca de redes neuronales de alto nivel que actúa como un envoltorio para TensorFlow, así como para Microsoft Cognitive Toolkit y Theano para permitir una experimentación rápida.

Además, debes considerar cómo la IA y el aprendizaje automático se alinean con su estrategia de nube. Varios marcos están más estrechamente relacionados con las populares nubes públicas:

- ▶ Google Cloud Platform (GCP) proporciona una estrecha integración con su motor de aprendizaje automático en la nube para que "los desarrolladores y científicos de datos construyan y lleven a la producción modelos superiores de aprendizaje automático".
- ▶ AWS proporciona servicios preentrenados, marcos para crear, entrenar e implementar aprendizaje automático y marcos de código abierto para crear modelos personalizados.
- ▶ Microsoft Azure ofrece un entorno de creación de arrastrar y soltar para aplicaciones de aprendizaje automático.
- ▶ IBM Cloud incluye servicios de Watson para NLP, reconocimiento visual y aprendizaje automático.

Tema 4. Aplicación de herramientas para la visualización de datos

Además, los proveedores de tecnología de soluciones que aprovechan la IA pueden optar por implementar funciones o incluso productos completos en una o dos nubes en lugar de en todas las nubes públicas, en función de una variedad de factores estratégicos y de mercado.

Para muchas de las tecnologías de código abierto, existen proveedores cuyo objetivo principal es desarrollar, implementar y dar servicio a las tecnologías de IA centrales y sus ecosistemas. Databricks, por ejemplo, fue fundado por los creadores de Apache Spark y proporciona una plataforma de análisis impulsada por Spark para equipos de ciencia de datos.

¿Por qué IA para análisis de datos?

Debe quedar claro que la próxima evolución de la analítica estará impulsada por la IA. En la era de los grandes datos, los informes y paneles estáticos ya no son suficientes para brindarnos todos los conocimientos que necesitamos para maximizar el valor de nuestros datos y mantenernos por delante de la competencia. La IA es necesaria para analizar los tesoros de datos que las empresas, los clientes y las fuerzas del mercado crean constantemente, para presentar los conocimientos que son importantes para nuestro negocio de una manera intuitiva.

Tal vez sea útil considerar todos los beneficios que brinda la IA para el análisis a través de dos lentes: eficiencia y efectividad.

Hemos cubierto muchas de las formas en que la IA hace que el análisis sea más eficiente. Existe una escasez de expertos en datos, lo que ha contribuido al surgimiento de los ciudadanos científicos de datos. Al permite que los no expertos se beneficien de procesos analíticos complejos sin saber cómo programar cada componente detallado del flujo de trabajo.

Tema 4. Aplicación de herramientas para la visualización de datos

Debido a que el análisis impulsado por IA puede aprender lo que es importante para nosotros, puede acelerar nuestra velocidad hacia los conocimientos. En lugar de rebanar, dividir y profundizar durante horas, los usuarios pueden simplemente pedirle al sistema que realice análisis y presente los conocimientos más relevantes.

Con la automatización, incluso podemos programar dichos análisis. Por ejemplo, considera una tabla de una base de datos que se actualiza casi en tiempo real. Puedes programar un análisis impulsado por IA para que se ejecute todos los días o incluso cada hora, y el sistema podría alertarlo si detecta cambios o patrones relevantes en los nuevos datos.

En última instancia, todas estas características impulsadas por IA hacen que el análisis y la BI sean más fáciles de usar. Los no expertos pueden usar la IA para realizar análisis que alguna vez fueron competencia de un puñado de especialistas capacitados. Los expertos pueden concentrarse en tareas de mayor valor en lugar de lidiar con la acumulación de solicitudes que se acumulan en los escenarios de BI tradicionales.

Además, la IA aumenta la eficacia de los análisis al revelar información relevante sin interacción humana. El análisis impulsado por IA aumenta la alfabetización analítica y mejora las habilidades de los usuarios.

Como ya se comentó, los volúmenes masivos de datos disponibles en nuestro mundo de big data hacen que las soluciones de BI tradicionales sean útiles para preguntas conocidas y simples, pero ineficaces para la IA y revelan patrones ocultos. Las soluciones de análisis impulsadas por IA pueden resaltar el contexto para que los usuarios brinden una imagen completa. Sin IA, los volúmenes de datos dificultan el descubrimiento de información importante que, de otro modo, permanecería enterrada en los datos. Con IA, las soluciones de análisis pueden descubrir de manera inteligente relaciones entre registros y sugerir nuevas áreas para explorar.

Tema 4. Aplicación de herramientas para la visualización de datos

Aplicaciones comunes de IA en análisis

Aunque es difícil exagerar el potencial de la IA para remodelar el análisis, hay varias aplicaciones para las que la IA ya ha desarrollado una sólida posición:

Analítica predictiva

El análisis predictivo usa datos sobre lo que sucedió para predecir lo que probablemente sucederá a continuación. La IA es poderosa aquí porque puede examinar cantidades masivas de datos históricos y probar muchas predicciones posibles al mismo tiempo para encontrar la mejor respuesta.

Esto es importante en **marketing**; por ejemplo, en casos de uso, como determinar qué oferta hacer a continuación, cómo fijar el precio y qué tan significativo es el descuento. Además, el análisis predictivo impulsado por IA puede ayudarnos a predecir la rotación para que, a su vez, podamos reducirla.

Uno de los casos de uso más populares para el **IoT industrial** es el mantenimiento predictivo, un tipo específico de análisis predictivo. Aquí, los sistemas recopilan flujos o lotes regulares de datos de las máquinas y buscan patrones para predecir cuándo pueden fallar los equipos o componentes.

Generación de información automatizada

La generación de información es una aplicación clave de la IA en el análisis. En lugar de depender de que un usuario haga las preguntas correctas, las soluciones de análisis impulsadas por IA pueden atravesar conjuntos de datos masivos con solo hacer clic en un botón, o a través de un programador, y encontrar información

Tema 4. Aplicación de herramientas para la visualización de datos

interesante por sí mismos. Con los comentarios de los usuarios, el aprendizaje automático puede ayudar a determinar qué conocimientos son realmente interesantes y cuáles son solo ruido para usuarios individuales y grupos.

Búsqueda natural

La búsqueda natural se basa en NLP, un campo en AI. Históricamente, un analista que estaba familiarizado con sus datos escribía SQL para extraer los datos necesarios de su almacén de datos y los cargaba en su servidor de BI. Luego, iniciarían sesión en su interfaz de BI y arrastrarían métricas y dimensiones a un espacio de trabajo, seleccionarían una visualización para representar gráficamente los datos, luego modificarían y filtrarían según fuera necesario hasta llegar a un medio para responder a su pregunta.

Con la búsqueda natural, las soluciones de análisis pueden interpretar de manera inteligente las consultas del lenguaje humano, como "ingresos por región por trimestre del año pasado". Podemos entrenar a la PNL para que sea aún más natural y conversacional para que entienda, por ejemplo, que "los artículos más populares" significan "los productos más vendidos".

Análisis autónomo

Los análisis autónomos aprovechan la IA para proporcionar a los usuarios resultados más valiosos sin requerir más entradas. Por ejemplo, ver cómo un usuario final puede simplemente "observar" un análisis en el que esté interesado, y el sistema realizará ese análisis regularmente a medida que ingresen nuevos datos al sistema, para monitorear anomalías y nuevas tendencias.

Tema 4. Aplicación de herramientas para la visualización de datos

Al igual que otros avances en IA, los análisis autónomos requieren una escala masiva para tomar instantáneas de datos con regularidad para realizar un seguimiento activo de las métricas críticas para el negocio. Primero, el análisis impulsado por IA crea una vista de serie temporal de estas métricas. Luego busca regularmente cambios significativos. Cuando el sistema detecta algo valioso, alerta al usuario. El usuario puede simplemente indicar las áreas comerciales que desea monitorizar y, a partir de ahí, el sistema y la IA toman el control.

Manejo y preparación de datos

La mayor parte del ciclo de vida de análisis implica preparar datos para análisis. Hay muchas tareas que pueden estar involucradas y, a menudo, requieren un analista experto o un científico de datos. Sin embargo, el aprendizaje automático y el aprendizaje profundo pueden ayudar a los sistemas a aprender a manejar algunas de estas tareas de forma independiente, liberando el tiempo de los usuarios finales para que se concentren en el análisis, la información y la acción.

Estas son algunas de las áreas en las que la IA se está convirtiendo en el núcleo de la tecnología de análisis.

Análisis impulsado por IA en la práctica

Varias industrias han adoptado rápidamente soluciones de análisis que integran IA directamente en los sistemas. Los minoristas, los proveedores de servicios financieros, los fabricantes y las empresas de tecnología están aprovechando estas nuevas tecnologías.

Tema 4. Aplicación de herramientas para la visualización de datos

Venta minorista

En el comercio minorista, los equipos de comercialización han sido algunos de los que más han adoptado el análisis impulsado por IA.

Con BI tradicional, los analistas de negocios de una tienda de ropa masculina tenían su exploración restringida a los datos contenidos en cubos y agregados. No podían explorar áreas temáticas como el inventario y las ventas, lo que limitaba sus conocimientos, y los informes estáticos y enlatados que usaban no podían seguir el ritmo de las condiciones dinámicas de los clientes y las tiendas.

Con una solución de análisis impulsada por IA, apuntan el sistema a un conjunto de datos específico, ID de producto o ID de tienda, y el sistema profundizará para identificar los artículos mejor y peor vendidos en cualquier momento para que en la tienda se puedan optimizar sus accesorios. para mejorar el margen bruto. Esto condujo a un aumento del 5 %, lo que resultó en un aumento de los ingresos anuales de \$10 millones.

Servicios financieros

Los proveedores de servicios financieros se enfrentan a una competencia increíblemente dura además de regulaciones muy complejas. Uno de los enfoques de las regulaciones de los servicios financieros es la transparencia. Independientemente de cuán inteligente sea o se vuelva la IA, debe ser auditable para resistir el escrutinio regulatorio.

Afortunadamente, algunos proveedores de tecnología que incorporan capacidades de inteligencia artificial en sus soluciones de análisis han tenido esto en cuenta. Cuando los usuarios aprovechan tales capacidades de IA, pueden ver exactamente qué tipos de análisis se ejecutaron en qué conjuntos de datos y puntos específicos.

Tema 4. Aplicación de herramientas para la visualización de datos

En una de las empresas de gestión de inversiones más grandes del mundo, los equipos de ventas y marketing miden y predicen las transacciones operativas asociadas con fondos mutuos vendidos por proveedores, por lo que necesita visibilidad en una variedad de datos, incluidos los datos de evaluación de riesgos, rendimiento, activos y clientes.

La solución de BI tradicional de la empresa, aunque posicionada como autoservicio, era demasiado complicada para los usuarios comerciales, que esperaban días para que el equipo de BI cumpliera con cada solicitud de informe. El equipo de TI tuvo que pasar horas preparando, combinando y uniendo datos para el análisis.

Con análisis impulsados por IA, el equipo de TI configura fácilmente todas sus fuentes de datos en un solo lugar, y cualquiera puede usar IA para análisis ad hoc en segundos en todos los datos de la empresa. La empresa ha reducido el tiempo de comprensión en un 50 %. Los equipos de ventas y marketing ahora tienen información instantánea, lo que les permite crear campañas de marketing dirigidas y aumentar las ventas.

Manufactura y alta tecnología

Aunque al principio pueden parecer una pareja poco probable, las empresas de fabricación y las empresas de alta tecnología están adoptando soluciones de BI con capacidades de IA para mejorar sus análisis de adquisiciones.

Una empresa utilizó BI tradicional para sus necesidades de informes, y esto fue suficiente para sus megamarcas globales que tenían una gran cantidad de recursos de soporte operativo y de adquisiciones. Sin embargo, los equipos que respaldan a sus marcas más pequeñas carecían de una manera fácil de acceder a la información relacionada con las adquisiciones. Con análisis impulsados por IA, todos los equipos tienen acceso de autoservicio a información sobre los datos de adquisiciones. Usan

Tema 4. Aplicación de herramientas para la visualización de datos

IA para responder una variedad de preguntas sobre órdenes de compra, como qué regiones tienen las órdenes de compra más abiertas para cada marca; qué marcas tienen el mayor volumen total de órdenes de compra; y qué órdenes de compra aún no se han cumplido.

El sistema de compras de otra empresa tenía una interfaz de informes personalizada que dejaba al equipo de compras dependiente de los usuarios avanzados: los usuarios comerciales no podían crear informes por sí mismos y el sistema se ralentizaba a medida que crecían los volúmenes de datos. Al mismo tiempo, el equipo de adquisiciones necesitaba abordar el aumento de la complejidad y el riesgo. A medida que crecía la cantidad y distribución de proveedores, el equipo de adquisiciones necesitaba gestionar el riesgo de toda la cadena de suministro en caso de eventos inesperados. También necesitaba tener preparada una vista flexible de 360 grados del proveedor, en caso de oportunidades con poca antelación para optimizar el rendimiento de las adquisiciones.

Con análisis impulsados por IA, el equipo de adquisiciones obtiene información sobre todos sus datos sin agregar recursos. El sistema escala a miles de millones de filas de datos y miles de usuarios.

Tema 4. Aplicación de herramientas para la visualización de datos

4.3. Clúster de máquinas información distribuida y redundante

Clúster de máquinas. Sistemas distribuidos

Ya se vio anteriormente cómo surgió la necesidad de los sistemas distribuidos cuando Google necesitó poder indexar todas las páginas web, pero que es realmente un sistema distribuido y que podemos hacer cuando tenemos un sistema distribuido es lo que se va a explicar a continuación.

Para entender que es un sistema distribuido lo mejor es empezar entendiéndolo a través de un ejemplo. Imagina que hay un aula con diez equipos y cada uno de ellos tiene un disco duro de 1 TB de capacidad de almacenamiento. Si se pasa un fichero o un grupo de ficheros cuyo tamaño total es de, imagina, 3 TBs, no se podría guardar en ninguno de los equipos, ahora bien, si consigo que todos los equipos trabajen como si fuera uno solo uniendo todos sus recursos, como en total habría 10 TBs de almacenamiento entre todos si sería posible guardar ese o esos ficheros. Pues esta es la idea de sistema distribuido.

Una definición de lo que sería un sistema distribuido podría ser:

“Conjunto de computadores cuyos componentes hardware y software, interconectados, se comunican y coordinan sus acciones mediante el paso de mensajes. Comparten un estado, ofreciendo una visión de sistema único.”

Es decir, varios ordenadores interconectados entre ellos que permiten usar sus recursos de manera unificada para conseguir un objetivo o funcionalidad como en el caso anterior poder guardar información que de otra manera solo se hubiera podido almacenar con un disco con más capacidad de almacenamiento y en muchas

Tema 4. Aplicación de herramientas para la visualización de datos

ocasiones un coste mayor que unir varios discos de pequeña capacidad. Es como montar un super ordenador uniendo las piezas de todos los ordenadores.




Figura 16. Representación sistema distribuido. Fuente: Shutterstock, s. f.

Los sistemas distribuidos son un desarrollo importante para las TI y las ciencias de la computación, ya que un número creciente de trabajos relacionados son tan masivos y complejos que sería imposible que una sola computadora los manejara sola. Pero la informática distribuida también ofrece ventajas adicionales sobre los entornos informáticos tradicionales.

Las máquinas que forman parte de un sistema distribuido pueden ser computadoras, servidores físicos, máquinas virtuales, contenedores o cualquier otro nodo que pueda conectarse a la red, tener memoria local y comunicarse mediante el paso de mensajes.

Tema 4. Aplicación de herramientas para la visualización de datos

Hay dos formas generales en que funcionan los sistemas distribuidos:

- ▶ Cada máquina trabaja hacia un objetivo común y el usuario final ve los resultados como una unidad cohesiva.
- ▶ Cada máquina tiene su propio usuario final y el sistema distribuido facilita compartir recursos o servicios de comunicación.

Al conjunto de ordenadores que forman el sistema distribuido se le denomina cluster y a cada uno de las máquinas que forman parte de él son los nodos.

De esta forma tenemos por ejemplo para un cluster de cuatro nodos tendríamos:




Figura 17. Representación de un clúster con sus nodos. Fuente: elaboración propia.

Es importante saber que dentro del cluster todas las máquinas tienen que tener visibilidad entre sí, es decir todas se tienen que comunicar con todas para poder mandarse instrucciones, en caso de que alguna de ellas deje de estar visible para el resto ésta no formará parte del cluster.

Características principales de los sistemas distribuidos

Son varias las ventajas que tiene trabajar con un sistema distribuido entre ellas tenemos:

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ **Escalabilidad horizontal:** dado que la computación se realiza de forma independiente en cada nodo, es fácil y generalmente económico agregar o quitar nodos al cluster según sea necesario. De esta forma, por ejemplo, si necesitas más espacio en tu cluster es suficiente con añadir más nodos al cluster sin necesidad de detener nada de lo que se está ejecutando.

Los sistemas tradicionales (no distribuido) funcionan con lo que se denomina un escalado vertical, es decir, para poder aumentar la capacidad de almacenamiento por ejemplo se debe adquirir una máquina mucho más potente y luego pasar a esta nueva máquina todo lo que estuviera en la antigua lo que conlleva una parada de servicio para hacerlo y un coste alto de los equipos a adquirir.

- ▶ **Fiabilidad:** la mayoría de los sistemas distribuidos son tolerantes a fallos, ya que pueden estar formados por cientos de nodos que funcionan juntos. El sistema generalmente no experimenta ninguna interrupción si falla una sola máquina. Esto es debido a que la información que almacenan se replica a lo largo de todo el cluster, es decir un mismo bloque de ficheros puede encontrarse en varios nodos al mismo tiempo, así si un nodo que contiene uno de esos bloques cae, el sistema puede seguir funcionando porque el mismo bloque se encontraba en otro nodo.
- ▶ **Rendimiento:** los sistemas distribuidos son extremadamente eficientes porque las cargas de trabajo se pueden dividir y enviar a varias máquinas. No es lo mismo que un único proceso tenga que leer un fichero entero a que ese fichero se divida en diez bloques por ejemplo y diez procesos paralelos vayan leyendo cada uno de los bloques, el tiempo total en leerlo todo será, hipotéticamente, diez veces menos.
- ▶ **Compartición o multiusuario:** El que un recurso compartido intente ser accedido simultáneamente desde varias aplicaciones no tiene efectos sobre la ejecución de la aplicación.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ **Abstracción:** El usuario que ejecuta un proceso o se refiere a un proceso del cluster no necesita saber dónde se encuentran los recursos, se lanzará un proceso y el usuario no tiene que hacer nada para que se ejecute correctamente todo lo que ocurra por “detrás” se encargará la herramienta que implemente el sistema distribuido y por tanto es totalmente transparente.
- ▶ **Compatibilidad:** Los dispositivos pueden funcionar con diferentes sistemas operativos. Esto no impide que puedan ofrecer siempre los mismos servicios a los usuarios. Por tal razón, todos los dispositivos conectados son compatibles entre sí.

Otro tema fundamental es el diseño del software, porque este también es compatible con todos los sistemas y usuarios que se tienen en cada computadora.

Tipos de arquitecturas distribuidas

En computación distribuida podemos diferenciar dos tipos de arquitecturas basándonos en la centralidad de la red como criterio de clasificación: las centralizadas y las descentralizadas. Esta clasificación va a influir en el modelo de toma de decisiones del clúster. Aunque cada herramienta tiene su propia arquitectura con sus peculiaridades, vamos a utilizar esta diferenciación para clasificarlas.

Dos de los modelos de arquitectura más comunes en el Big Data son la arquitectura maestro-esclavo y la arquitectura p2p.

- ▶ **Arquitectura maestro-esclavo:** Se trata de un modelo de arquitectura distribuida centralizado, en el que contamos con una organización jerárquica entre las máquinas, diferenciando dos clases de nodos en la red: maestros y esclavos. Llamamos nodo maestro o master a las máquinas que coordinan el trabajo de otras máquinas; y esclavos, trabajadores o ejecutores a las máquinas que realizan el trabajo que el nodo maestro les asigna. El nodo master sirve como centro de comunicación entre los nodos trabajadores y el sistema que solicita el resultado, ya

Tema 4. Aplicación de herramientas para la visualización de datos

sea un usuario u otro proceso. Si bien este nombre por connotaciones esclavistas está últimamente cambiando su nombre en múltiples sistemas, "Slaves" o esclavo está siendo cambiado por "workers" o "helpers" (trabajadores o ayudantes), y "master process" fue cambiado por "parent process" (proceso padre).

- **Arquitectura entre pares:** Comúnmente llamadas P2P o peer-to-peer por su traducción al inglés. Este es un modelo de arquitectura descentralizado en el que no existen diferencias entre los nodos de la red, se tratan como iguales. No existen nodos con funciones especiales, y por tanto ningún nodo es imprescindible para el funcionamiento de la red. Por esta razón se denomina arquitectura entre iguales o entre pares. Al ser un modelo descentralizado no tiene los inconvenientes de punto de contacto único y de punto de fallo único. Esta arquitectura se caracteriza por su escalabilidad, tolerancia a fallos y alta disponibilidad, ya que todos los nodos pueden realizar cualquier función. Sin embargo, esta configuración requiere de un sistema de toma de decisiones más complejo al no tener una jerarquía.

Características principales de los sistemas distribuidos

Son varias las ventajas que tiene trabajar con un sistema distribuido entre ellas tenemos:

- **Escalabilidad horizontal:** dado que la computación se realiza de forma independiente en cada nodo, es fácil y generalmente económico agregar o quitar nodos al cluster según sea necesario. De esta forma, por ejemplo, si necesitas más espacio en tu cluster es suficiente con añadir más nodos al cluster sin necesidad de detener nada de lo que se está ejecutando.

Los sistemas tradicionales (no distribuido) funcionan con lo que se denomina un **escalado vertical**, es decir, para poder aumentar la capacidad de almacenamiento

Tema 4. Aplicación de herramientas para la visualización de datos

por ejemplo se debe adquirir una máquina mucho más potente y luego pasar a esta nueva máquina todo lo que estuviera en la antigua lo que conlleva una parada de servicio para hacerlo y un coste alto de los equipos a adquirir.

- ▶ **Tolerancia a fallos:** la mayoría de los sistemas distribuidos son tolerantes a fallos, ya que pueden estar formados por cientos de nodos que funcionan juntos. El sistema generalmente no experimenta ninguna interrupción si falla una sola máquina. Esto es debido a que la información que almacenan se replica a lo largo de todo el cluster, es decir un mismo bloque de ficheros puede encontrarse en varios nodos al mismo tiempo, así si un nodo que contiene uno de esos bloques cae, el sistema puede seguir funcionando porque el mismo bloque se encontraba en otro nodo.
- ▶ **Rendimiento:** los sistemas distribuidos son extremadamente eficientes porque las cargas de trabajo se pueden dividir y enviar a varias máquinas. No es lo mismo que un único proceso tenga que leer un fichero entero a que ese fichero se divida en diez bloques por ejemplo y diez procesos paralelos vayan leyendo cada uno de los bloques, el tiempo total en leerlo todo será, hipotéticamente, diez veces menos.
- ▶ **Compartición o multiusuario:** El que un recurso compartido intente ser accedido simultáneamente desde varias aplicaciones no tiene efectos sobre la ejecución de la aplicación.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ **Abstracción:** El usuario que ejecuta un proceso o se refiere a un proceso del cluster no necesita saber dónde se encuentran los recursos, se lanzará un proceso y el usuario no tiene que hacer nada para que se ejecute correctamente todo lo que ocurra por “detrás” se encargará la herramienta que implemente el sistema distribuido y por tanto es totalmente transparente.
- ▶ **Compatibilidad:** Los dispositivos pueden funcionar con diferentes sistemas operativos. Esto no impide que puedan ofrecer siempre los mismos servicios a los usuarios. Por tal razón, todos los dispositivos conectados son compatibles entre sí.
- ▶ Otro tema fundamental es el diseño del software, porque este también es compatible con todos los sistemas y usuarios que se tienen en cada computadora.

Cómo gestionar y monitorizar un cluster

Cuando estamos antes un cluster tenemos múltiples servicios que se están ejecutando en los nodos de dicho cluster, por tanto, son muchos los elementos a tener en cuenta para ver que todo funciona correctamente. Todas las herramientas suelen traer un mecanismo de monitorización bien a través de gráficos en una página web o gestionando sus logs. Pero cuando el número de herramientas a controlar y monitorizar es elevado se vuelve muy complicada tal gestión. Además, todo esto implica la intervención de varios agentes: analistas de requisitos que evalúan los requisitos de rendimiento, arquitectos de sistemas que evalúan las configuraciones de hardware, ingenieros de sistemas que instalan y configuran el ecosistema de Hadoop.

Monitorizar por ejemplo las métricas de Hadoop es vital para asegurarse de que todo se mantengan en funcionamiento. Si bien se puede monitorizar las métricas de Hadoop a través de JMX o una API HTTP, no ofrece la experiencia de monitorización completa que ofrecen muchas herramientas de monitorización.

Tema 4. Aplicación de herramientas para la visualización de datos

Estas herramientas ofrecen funciones como paneles personalizados y alertas que le brindan una perspectiva más holística de lo que está sucediendo. Al recopilar todos sus datos de rendimiento de Hadoop y colocarlos en un solo lugar, podrá monitorear el rendimiento de sus sistemas de manera mucho más efectiva.

Por eso existen una serie de herramientas a su vez que ayudan a gestionar y monitorizar todas las herramientas big data de una manera única y sencilla. Son las denominadas distribuciones de las que existen varias en el mercado

Existen diferentes herramientas o distribuciones que nos permiten administrar nuestro clúster de manera sencilla.

Hay muchas herramientas en el mercado, pero las más conocidas como Cloudera, EMC, Hortonworks, IBM Big Blue, Intel Distribution o MapR vamos a ver los detalles más significativos de cada una de ellas y otras independientes como Datadog, LogicMonitor y Dynatrace si bien estas ya no son gratuitas.

Como más adelante verás las distribuciones vamos a centrarnos en algunas de las otras como por ejemplo Datadog.

Datadog

[Datadog](#) es una herramienta de monitorización en la nube que puede monitorizar servicios y aplicaciones. Con Datadog puedes monitorizar el estado y el rendimiento de un cluster.

Hay un dashboard que muestra información sobre los servicios.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 18. Representación de un clúster con sus nodos. Fuente: elaboración propia.

Características clave:

- ▶ Tablero de monitorización de cluster
- ▶ Integraciones para HDFS, MapReduce, YARN y ZooKeeper
- ▶ Alertas
- ▶ Acceso completo a la API

El sistema de alertas facilita el seguimiento de los cambios de rendimiento cuando se producen al proporcionar notificaciones automáticas. Por ejemplo, Datadog puede notificar si fallan los trabajos de Hadoop. El sistema de alertas utiliza el aprendizaje automático, que tiene la capacidad de identificar comportamientos anómalos.

Datadog además brinda acceso completo a la API para que se puedan crear nuevas integraciones. Puedes usar el acceso a la API para completar tareas como consultar Datadog en la línea de comandos o crear paneles con formato JSON.

Tema 4. Aplicación de herramientas para la visualización de datos

Ventajas:

- ▶ Ofrece plantillas y dashboards preconstruidos para la monitorización de un cluster y la aplicación de la seguridad.
- ▶ Tableros personalizables fáciles de usar
- ▶ Admite el descubrimiento automático que crea mapas de topología de red sobre la marcha
- ▶ Los cambios realizados en la red se reflejan casi en tiempo real

Contras:

- ▶ La herramienta tiene un coste y la versión de prueba dura solo 14 días.

Tema 4. Aplicación de herramientas para la visualización de datos

4.4. Herramientas de visualización de datos

Introducción

Los datos y sus relaciones no son siempre algo fácil de entender. Mientras que algunas personas pueden mirar una hoja de cálculo y encontrar instintivamente la información que necesitan y sus relaciones dentro de una maraña de cifras, otras necesitamos un poco de ayuda, y ahí es donde la visualización de datos puede ser la solución.

La visualización puede ayudarnos a tratar con información más compleja.

No se trata de representar un conjunto de datos de forma amigable y con un diseño elaborado, sino también de hacerlo simplificando la complejidad y destacando aquella información que realmente es relevante, distinguiéndola del resto de los datos.

Una de las mejores formas de transmitir un mensaje es utilizar una visualización para llamar la atención rápidamente sobre los mensajes clave. Y al presentar los datos visualmente, también es posible descubrir patrones y elementos sorprendentes que no serían aparentes con la sola observación de los datos.

Hoy en día, existe una gran variedad de herramientas y recursos que nos permiten hacerlo. Así que para empezar a ayudarte hemos reunido algunas de las herramientas de visualización de datos más destacadas disponibles en la web.

Hay distintos tipos de herramientas que puedes usar para generar gráficos dependiendo de que es lo que se pretenda conseguir o bien de tus conocimientos de programación. Hay muchas herramientas que sin conocimientos de programación permiten realizar multitud de gráficos eso si basados en lo que las herramientas te

Tema 4. Aplicación de herramientas para la visualización de datos

proporcionan y donde la capacidad de personalización o crear efectos nuevos es complicada por no decir imposible. Si tienes conocimientos de programación las herramientas que requieren de dichos conocimientos pueden ser un poco más complejas que las anteriores, pero a cambio puedes conseguir efectos en las visualizaciones que no podrías realizar con las otras herramientas.

Herramientas y librerías para usuario desarrollador

Para utilizar estas herramientas se requieren conocimientos de programación. Esta característica puede suponer una barrera de entrada, pero precisamente este inconveniente es también su mayor ventaja, ya que también les otorga enormes capacidades para personalizar gráficos y prácticamente infinitas posibilidades de desarrollo.

Google Chart

Es la librería de visualizaciones utilizada por Google Spreadsheets, siendo la API de gráficos de Google. Se trata de una potente y sencilla librería, con una gran variedad de gráficos disponibles. <https://developers.google.com/chart>

Tema 4. Aplicación de herramientas para la visualización de datos

D3.js

Es una librería de JavaScript que utiliza HTML, CSS y JavaScript para mostrar algunos diagramas y gráficos sorprendentes de una variedad de fuentes de datos. Esta librería, más que la mayoría, es capaz de algunas visualizaciones muy avanzadas con complejos conjuntos de datos. D3 tiene una poderosa capacidad para gestionar gráficos vectoriales en formato SVG (*Scalable Vector Graphics*).

<https://d3js.org/>

Librerías de Python

- ▶ Matplotlib (<https://matplotlib.org/>): librería de Python especializada en la creación de gráficos en dos dimensiones.
- ▶ Seaborn (<https://seaborn.pydata.org/>): librería para Python que permite generar fácilmente elegantes gráficos. Seaborn está basada en matplotlib y proporciona una interfaz de alto nivel que es realmente sencilla de aprender. Dada su gran popularidad se encuentra instalada por defecto en la distribución Anaconda.
- ▶ Bokeh (<https://bokeh.org/>): Bokeh es una biblioteca de Python para crear visualizaciones de datos interactivas en un navegador web. Ofrece una presentación de datos rápida y legible por humanos de una manera visualmente agradable.

Tema 4. Aplicación de herramientas para la visualización de datos

Herramientas y librerías para usuario no desarrollador

La facilidad de uso es la característica principal de este grupo de herramientas. Si algo las caracteriza es que es el propio usuario final quien tiene la capacidad para extraer y manejar los datos, crear informes o compartir los datos sin necesidad de pasar por un equipo de desarrollo, reduciendo de esta forma el tiempo que transcurre entre la necesidad y la respuesta. Evidentemente, la autonomía de los usuarios para la visualización de los datos con estas herramientas es máxima.

Según la consultora de mercado Gartner, en la actualidad, las principales plataformas modernas de analítica e inteligencia de negocio (Analytics and business intelligence, ABI) **ya no se diferencian por sus capacidades en la visualización de datos**. En su lugar, su diferenciación reside, por un lado, en cómo se integran con el resto de las aplicaciones corporativas de analítica e informes y, por otro, en sus capacidades aumentadas que les permiten acelerar las fases de preparación de los datos y generación de conocimiento para el negocio.

De forma resumida, Gartner evalúa todas las plataformas ABI con base en las siguientes 15 capacidades:

- ▶ **Seguridad:** capacidades que permiten la seguridad de la plataforma, la administración de los usuarios, la auditoría del acceso a la plataforma y la autenticación.
- ▶ **Capacidad de gestión:** capacidades para rastrear el uso, gestionar cómo se comparte la información y por quién, realizar análisis de impacto y trabajar con aplicaciones de terceros.
- ▶ **Cloud:** la capacidad de apoyar la construcción, despliegue y gestión de análisis y aplicaciones analíticas en la nube.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ **Conectividad de la fuente de datos:** capacidades que permiten a los usuarios conectarse e ingerir datos, estructurados y no estructurados, contenidos en varios tipos de plataformas de almacenamiento.
- ▶ **Preparación de datos:** soporte para la combinación de datos de diferentes fuentes, por medio de arrastrar y soltar, y realizable por los usuarios de negocio, así como la propia creación de modelos analíticos.
- ▶ **Complejidad del modelo:** soporte para modelos de datos complejos, incluyendo la capacidad de manejar múltiples tablas e interoperar con otras plataformas analíticas.
- ▶ **Catálogo:** la capacidad de generar y agregar automáticamente un catálogo que permita la búsqueda de los objetos creados y utilizados por la plataforma.
- ▶ **Insights automatizados:** un atributo fundamental de la analítica aumentada es la capacidad de aplicar técnicas de *machine learning* e inteligencia artificial para generar automáticamente conocimientos para los usuarios finales (por ejemplo, identificando los atributos más importantes de un conjunto de datos).
- ▶ **Análisis avanzado:** capacidades analíticas avanzadas a las que los usuarios pueden acceder fácilmente, ya sea porque estén contenidas en la propia plataforma ABI, o bien porque puedan utilizarse mediante la importación e integración de modelos desarrollados externamente.
- ▶ **Visualización de datos:** soporte para cuadros de mando interactivos y la exploración de datos mediante la manipulación de imágenes gráficas. Se incluye una serie de opciones de visualización que van más allá de las de los gráficos circulares, de barras y de líneas, como son los mapas de calor y de árboles, mapas geográficos, gráficos de dispersión y otros visuales de propósito especial.
- ▶ **Consulta de lenguaje natural:** permite a los usuarios consultar los datos utilizando búsquedas basadas en lenguaje natural.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ **Narración de datos:** capacidad de combinar la visualización interactiva de datos con técnicas narrativas a fin de empaquetar y ofrecer conocimientos de forma convincente y fácil de entender para su presentación a los responsables de negocio.
- ▶ **Análisis integrado:** las capacidades incluyen un SDK con API y soporte para estándares abiertos con el fin de integrar el contenido analítico en un proceso de negocio, una aplicación o un portal.
- ▶ **Generación de lenguaje natural** (*Natural Language Generation*): la creación automática de descripciones lingüísticamente ricas de los conocimientos encontrados en los datos.
- ▶ **Presentación de informes:** la capacidad de crear y distribuir a los usuarios informes de forma programada.

Tomando como referencia estos criterios de evaluación, Gartner elabora anualmente el informe denominado *Magic Quadrant for Analytics and Business Intelligence Platforms*, donde posiciona a las diferentes plataformas y herramientas del mercado.

Tema 4. Aplicación de herramientas para la visualización de datos

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



Figura 19. Cuadrante mágico de Gartner sobre plataformas de analítica e inteligencia de negocio. Fuente: Fortinet, s.f.

En la asignatura abordaremos aquellas herramientas consideradas líderes del mercado según Gartner: Microsoft (PowerBI), Tableau, Qlik...

Tema 4. Aplicación de herramientas para la visualización de datos

Tableau

Repleto de gráficos, tablas y mapas, [Tableau Public](#) es una popular herramienta de visualización de datos. Los usuarios pueden arrastrar y soltar fácilmente los datos en el sistema y ver cómo se actualizan en tiempo real.

PowerBI

[PowerBI](#) es la propuesta de Microsoft que nos permite conectar diferentes orígenes de datos, transformarlos, limpiarlos, relacionarlos y visualizarlos de forma eficiente y sencilla.

Qlik

[Qlik](#) es una herramienta que se centra en ofrecer al usuario final la posibilidad de extraer y manipular directamente los datos, creando informes sencillos y todo esto sin la necesidad de pasar por un equipo de desarrollo. Es decir, maximiza la facilidad de uso para usuarios no desarrolladores.

Carto

[Carto](#) es realmente una herramienta que hay que conocer. La facilidad con la que puedes combinar datos tabulares con mapas es insuperable. Por ejemplo, puedes alimentar un archivo CSV de cadenas de direcciones y lo convertirá en latitudes y longitudes, además, las trazará en un mapa.

Iremos profundizando en cada una de estas herramientas en los siguientes puntos para conocer sus características principales y cómo funcionan.

Tema 4. Aplicación de herramientas para la visualización de datos

PowerBI

Introducción

Power BI puede integrar datos de múltiples y relacionarlos para obtener información relevante y así, poder tomar decisiones desde cualquier dispositivo. Aprenderemos con los fundamentos de cómo utilizar Power BI, sus principales funciones y cómo desarrollar proyectos de visualización con esta herramienta de Microsoft.

Microsoft Power BI está situado como uno de los productos líderes de *Business Intelligence*, según el «cuadrante mágico de Gartner», junto a Tableau y Qlik. Con esta herramienta podrás transformar millones de datos, relacionar múltiples fuentes, realizar cálculos complejos e interactuar fluidamente con visualizaciones. Su interfaz y diseño es muy amigable e intuitivo y cualquier persona puede utilizarla sin conocimientos técnicos avanzados.

Tema 4. Aplicación de herramientas para la visualización de datos



Figura 20. Cuadrante mágico de Gartner sobre plataformas de analítica e inteligencia de negocio. Fuente: Qlik, 2024.

Durante años, después de su lanzamiento en 2013, Power BI fue un producto «seguidor» que solo tenía que ser «lo suficientemente bueno», dado su política de precios bajos. Sin embargo, en la actualidad ha superado a la mayoría de sus competidores en términos de funcionalidad.

Puedes acceder a la página oficial de Power Bi desde el siguiente enlace:<https://powerbi.microsoft.com/es-es/>

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 21. Microsoft Power BI. Fuente: Microsoft, s.f.

Instalación de Power BI

Power BI está disponible como una opción SaaS, que se ejecuta en la nube de Azure o como una opción local a través de su Servidor de informes Power BI. También se puede utilizar Power BI Desktop como una herramienta de análisis personal gratuita e independiente.

Accede a Power BI Desktop desde el siguiente enlace:

<https://powerbi.microsoft.com/es-es/desktop/>

El proceso de instalación es prácticamente automático y solo nos pedirá un *e-mail* para registrar la herramienta.

Tema 4. Aplicación de herramientas para la visualización de datos

Paso 1. Descarga



Figura 22. Descarga Microsoft Power BI. Fuente: elaboración propia.

Si estás en Windows es posible que te aparezca la siguiente ventana.




Figura 23. Descarga Microsoft Power BI. Fuente: elaboración propia.

Al pulsar en «Abrir Microsoft Store» aparece lo siguiente:

Tema 4. Aplicación de herramientas para la visualización de datos



Figura 24. Descarga Microsoft Power BI. Fuente: elaboración propia.

Ya solo es necesario que pulses sobre obtener para que empiece la descarga:



Figura 25. Descarga Microsoft Power BI. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Paso 2. Instalación

Una vez finalizada la descarga empieza automáticamente la instalación.



Figura 26. Descarga Microsoft Power BI. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Paso 3. Abrir

Una vez completada la instalación ya solo es necesario abrir la aplicación:




Figura 27. Abrir Microsoft Power BI. Fuente: elaboración propia.

Al pulsar en abrir aparece la siguiente interfaz.




Figura 28. Interfaz bienvenida Microsoft Power BI. Fuente: elaboración propia.

Te puede preguntar por tu dirección de correo, pero no es obligatorio introducirlo.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 29. Correo opcional Microsoft Power BI. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Interfaz gráfica de PowerBI

Una vez instalado podemos ver la interfaz gráfica:




Figura 30. Página de bienvenida de Power BI. Fuente: elaboración propia.

Respecto a la **interfaz de Power BI**, esta presenta un aspecto muy similar a todos los productos de Microsoft Office.

Dispone de una **barra de herramientas superior** donde podemos encontrar opciones de menú generales como Archivo, que permite las operaciones habituales de Abrir, Guardar, Importar/Exportar informes, Exportar la visualización a PDF, entre otras muchas opciones.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 31. Barra de herramientas superior Microsoft Power BI. Fuente: elaboración propia.

El resto de opciones del menú, tales como Inicio, Insertar y Modelado, incorporan elementos específicos que nos permitirán crear nuestras visualizaciones, aunque en su mayor parte se pueden emplear a través de las opciones de los menús laterales.

Existe un **menú lateral izquierdo**, a través del cual podremos acceder a diferentes vistas de los informes, pasando de la visualización de las gráficas a la visualización de los datos.




Figura 32. Menú lateral izquierdo Microsoft Power BI. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

En la **parte inferior de la pantalla**, existe la opción de agregar nuevas solapas a la visualización, como si fueran pestañas de una hoja Excel.

En el **menú lateral derecho** están dispuestas las opciones de Filtros, Visualizaciones y Campos. Estas opciones nos permiten crear y aplicar diferentes filtros a los datos y, en consecuencia, influir en los criterios de visualización. También podremos escoger con un solo clic el tipo de gráfica que queremos incorporar a nuestro proyecto y seleccionar los campos que queremos incluir en él.




Figura 33. Menú lateral izquierdo Microsoft Power BI. Fuente: elaboración propia.

Iremos profundizando en estas opciones a largo de los diferentes casos de uso que vamos a desarrollar.

Tema 4. Aplicación de herramientas para la visualización de datos

Funciones de Power BI

Todo proyecto de análisis y visualización de datos con Power BI puede estructurarse en los siguientes apartados funcionales:

- ▶ **Obtención de datos:** cargar datos desde diferentes fuentes de datos como archivos de texto planos, hojas Excel, entornos relacionales como SQL Server o servicios en línea como Facebook o Google Analytics. La capacidad de Power BI para integrarse con diferentes fuentes de datos es muy amplia.
- ▶ **Preparación de datos:** limpiar y tratar los datos de una manera estructurada y, para ello, podremos emplear el gestor de datos integrado en Power BI denominado Query Manager.
- ▶ **Modelado de datos:** relacionar datos procedentes de diferentes fuentes y realizar cálculos que nos permitan descubrir información relevante, ajustando nuestros datos y dándoles una estructura que nos facilite su posterior visualización.
- ▶ **Visualización de datos:** dotar a los usuarios de gráficos, tablas y representaciones que les permitan analizar los datos para tomar decisiones.
- ▶ **Reporte de datos:** crear cuadros de mandos o *dashboards* que mejoren la comunicación de los informes tanto desde un punto de vista visual como de usabilidad, creando vistas, aplicando filtros, etc.

Tableau

Introducción y objetivos

Tableau es una herramienta de visualización de datos muy potente y visual. Estas dos características, junto sus posibilidades para el análisis integral de los datos, hacen que Tableau ocupe un lugar destacado en el cuadrante mágico de Gartner, junto a Power BI y Qlik.

Tema 4. Aplicación de herramientas para la visualización de datos

Accede a la página web oficial de Tableau a través del siguiente enlace:

<https://tableau.com/es-es/>



Figura 34. Tableau. Fuente: elaboración propia.

Tableau Software es una compañía estadounidense de *software* con sede en Seattle. La compañía fue fundada en el Departamento de Ciencias de la Computación de la Universidad de Stanford entre 1997 y 2002. El profesor Pat Hanrahan y su estudiante de doctorado, Chris Stolte, quien se había especializado en técnicas de visualización para explorar y analizar bases de datos relacionales y cubos de datos, condujeron sus investigaciones hacia el uso de visualizaciones basadas en tablas para explorar bases de datos relacionales multidimensionales.

Tema 4. Aplicación de herramientas para la visualización de datos

Juntos crearon un lenguaje de consulta estructurado para bases de datos con un lenguaje descriptivo para renderizar gráficos e inventaron un lenguaje de visualización de base de datos llamado VizQL (Visual Query Language).

VizQL formó el núcleo del sistema Polaris, una interfaz para explorar grandes bases de datos multidimensionales. En 2003, después de que Stolte reclutó a su exsocio comercial y amigo, Christian Chabot, para que tomara el papel de CEO, Tableau se separó de Stanford con una aplicación de *software* homónima. El producto consulta bases de datos relacionales, cubos, base de datos en la nube y hojas de cálculo y luego genera una serie de tipos de gráficos que pueden combinarse en paneles y compartirse a través de una red informática o Internet.

No es necesario que tener conocimientos de programación de ningún tipo, todo lo que se necesita son datos para crear con Tableau informes que sean visualmente atractivos y que cuente una historia que impresione. Con la función de arrastrar y soltar, se pueden crear fácilmente historias o informes utilizando solo el ratón y un poco de imaginación.

En 2019 Salesforce firmó un acuerdo definitivo para la adquisición de Tableau.

Instalación e interfaz de Tableau

Tableau está disponible en diferentes versiones de uso:

Tableau Online

Es la opción SaaS que se ejecuta en la nube hospedada por el propio Tableau. Permite el trabajo colaborativo desde cualquier lugar, no necesita ningún tipo de configuración ni costes de *hardware*. Es una solución simple completamente hospedada en la nube.

Tema 4. Aplicación de herramientas para la visualización de datos

Tableau Server

Permite a las empresas un control completo sobre el *software* de Tableau, pero también implementado en entornos como Amazon Web Services, Google Cloud Platform o Microsoft Azure. Es decir, si se quiere no tener que administrar servidores corporativos, pero a la vez se necesita máximo control sobre el *software* de Tableau y los datos empleados, así como aprovecharse de la escalabilidad de las soluciones de nube pública.

Tableau Server también tiene su entorno *inhouse* por si se desea desplegar las capacidades corporativas de este *software* en las instalaciones físicas de la empresa.

Tableau Desktop

Es la solución instalable en los equipos de oficina. Permite garantizar la información confidencial dentro de su propio *firewall* corporativo o equipo autónomo. Es la versión que emplearemos para el desarrollo de los casos en la asignatura.

Tecnología avanzada en memoria: el motor de datos

La mayor parte del *software* de análisis de datos ofrece muchas características sofisticadas, pero casi todas fallan cuando se trata de operar con grandes cantidades de datos, aquí es donde la tecnología avanzada en memoria de Tableau es fundamental para todos aquellos que necesitan obtener informes de cada vez mayores cantidades de datos.

El motor de datos de Tableau es una revolucionaria **base de datos analítica** en memoria, diseñada para superar las limitaciones de las bases de datos y de los silos de datos existentes. Es capaz de ejecutarse en computadoras de prestaciones

Tema 4. Aplicación de herramientas para la visualización de datos

normales, porque aprovecha la jerarquía de memoria completa del disco a la caché L1. Cambia la curva entre los grandes datos y el análisis rápido, el análisis *ad hoc* de datos masivos tiene lugar en segundos y no se requiere un modelo de datos fijo.

Usando Tableau Online

Hay que tener en cuenta que Tableau no es gratuito, lo vamos a poder usar por un tiempo determinado a modo de prueba, normalmente 15 días por eso en este caso para no tener que hacer instalaciones vamos a probar el producto de manera online. Vamos a ver los pasos para empezar a usarlo.

Paso 1. ve al siguiente [link](#) y pulsa sobre “Probar gratis”



Figura 35. Tableau online. Fuente: elaboración propia.

Aparece una página para registrarte. Usa un email que uses para activar la cuenta, el resto de campos pueden ser inventados.

Tema 4. Aplicación de herramientas para la visualización de datos

The diagram illustrates the Tableau registration process in three steps:

- Registration Form:** A form titled "Try it free (or sign in to Tableau Online)" with fields for First Name, Last Name, Business E-mail, Organization (pre-filled with "MiOrganization"), Company Size (dropdown: "1 - 20 employees"), Department (dropdown: "Analytics"), Job Role (dropdown: "Analyst"), Country/Region (dropdown: "Spain"), and Phone (pre-filled with "+34 612 34 56 78"). It includes a checkbox for marketing communications, a privacy statement, and a "REQUEST FREE TRIAL" button.
- Confirmation:** A box stating "Acto seguido recibirás un correo para activarlo" (Immediately after you will receive an email to activate it).
- Activation Screen:** A screen with the Tableau logo, an illustration of a laptop with a bar chart, the text "Your site is waiting for you.", and an "Activate My Site" button.

Figura 36. Registro Tableau. Fuente: elaboración propia.

Una vez pulsas en la activación te aparece la siguiente ventana (es un proceso un poco repetitivo lo sé, pero ya queda poco).

Tema 4. Aplicación de herramientas para la visualización de datos

Almost there...

Enter Your Name

First

Last

Email

[change email](#)

Choose a Password

Password

Passwords must be a minimum of 8 characters, have at least one uppercase letter, one lowercase letter, one number, and one special character.

Confirm

Name Your Site

Pick Your Site Location

We recommend selecting the region closest to your site users or data.

☒ I've read and agree to the [Tableau Online Subscription Agreement](#), the [Data Processing Addendum \(DPA\)](#) and the [Terms of Service](#). For the avoidance of doubt, agreeing to the DPA via checking this box shall be deemed Customer's signature on the DPA, and without limitation, shall constitute agreement and acceptance of the Standard Contractual Clauses incorporated in the DPA, including their appendices.

[Activate My Site](#)

[Need Help?](#)

Figura 37. Registro Tableau. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Y por fin aparecen los datos para iniciar la sesión:



Figura 38. Registro email Tableau. Fuente: elaboración propia.

Una vez te conectas por primera vez aparece la siguiente pantalla:




Figura 39. Tableau página bienvenida. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Y ya podemos empezar a trabajar con Tableau. A continuación, iremos familiarizándonos con la interfaz.

Interfaz Tableau

Respecto a la interfaz de Tableau, esta presenta funcionalmente los mismos elementos que otros productos y herramientas de visualización.




Figura 40. Tableau periodo de prueba. Fuente: elaboración propia.

Esto es lo que vemos al entrar, si te fijas en la parte superior tienes el tiempo que te resta para poder usarlo de manera gratuita.

Creamos un nuevo Proyecto

Vamos a empezar trabajando con Tableau para ello lo primero que tenemos que hacer es crearnos un proyecto.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 41. Creando nuevo proyecto. Fuente: elaboración propia.

Ponemos un nombre y una descripción y pulsamos en crear.




Figura 42. Creando nuevo proyecto. Fuente: elaboración propia.

Una vez creado ve a administrar proyectos:

Tema 4. Aplicación de herramientas para la visualización de datos



Figura 43. Administrar proyecto. Fuente: elaboración propia.

Y dirígete al proyecto que acabas de crear



Figura 44. Administrar proyecto. Fuente: elaboración propia.

Ya estás dentro del proyecto ya puedes empezar a trabajar con datos:



Figura 45. Administrar proyecto. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Creamos un nuevo libro de trabajo donde empezaremos a cargar los ficheros de datos.




Figura 46. Creación nuevo libro. Fuente: elaboración propia.




Figura 47. Nuevo libro. Fuente: elaboración propia.

Dispone de una **barra de herramientas superior** donde podemos encontrar opciones de menú generales como Archivo, que permite las operaciones habituales.

Existe un **menú lateral izquierdo**, a través del cual podremos acceder a los campos y datos de nuestro *dataset*. En terminología Tableau:

- Los datos descriptivos se llaman dimensiones.

Tema 4. Aplicación de herramientas para la visualización de datos

- Los datos numéricos se denominan medidas.




Figura 48. Menú lateral izquierdo. Fuente: elaboración propia.

Arrastrando al panel tanto las medidas como las dimensiones, podremos empezar a crear nuestras visualizaciones. Cuando se combinan, ayudan a visualizar el rendimiento de los datos dimensionales con respecto a los datos que son medidas.

Tema 4. Aplicación de herramientas para la visualización de datos

Estos conceptos los iremos desarrollando con la práctica.

En la **parte superior de la pantalla**, justo encima del panel de visualización, se sitúan los dos elementos más importantes del interfaz: el espacio de **Columnas** y el espacio de **Filas**. Arrastrando los campos de datos (dimensiones o medidas) a estos estantes, podremos empezar a crear las visualizaciones.




Figura 49. Estantes Columnas y Filas. Fuente: elaboración propia.

En la **parte inferior de la pantalla**, existe la opción de agregar nuevas hojas a la visualización, como si fueran pestañas de una hoja Excel. También incorpora una primera pestaña denominada **Fuente de Datos**, donde podremos visualizar la estructura de datos del *dataset*, ver los valores que contiene y realizar transformaciones de datos como **Crear campos calculados**.

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 50. Estantes Columnas y Filas. Fuente: elaboración propia.

A continuación del menú lateral izquierdo se sitúa un bloque de opciones bajo los epígrafes de Páginas, Filtros y Marcas.




Figura 51. Páginas filtro y marcas. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ El bloque o tarjeta **Páginas** permite dividir una vista en una serie de páginas para que se pueda analizar mejor cómo un campo específico afecta al resto de los datos en una vista. Es útil, por ejemplo, cuando se quiere ver cómo evolucionan los datos con el paso del tiempo, y se pueden visualizar todas las páginas de forma automática como si se tratase de una Historia, o bien seleccionar una página concreta.
- ▶ El bloque de **Filtro** permite definir qué datos excluir e incluir en la visualización. Seleccionando los contenedores de datos concretos, se pueden crear vistas a medida.
- ▶ El bloque de **Marcas** tiene el conjunto de funciones más potentes y simples de utilizar en Tableau. Son intuitivas y con gran flexibilidad, ya que permiten estructurar los datos, visualizarlos, darles forma y añadir dimensiones con solo arrastrar los campos ubicados en el lateral izquierdo a las opciones de **Color**, **Tamaño**, **Etiqueta**, **Detalle** o **Descripción emergente**.

Qlik Sense

Qlik Sense es una plataforma completa orientada al descubrimiento de la información que reside en los datos. Eso significa que no solo estamos ante una herramienta de visualización, sino que incluye capacidades propias de entornos de *Business Intelligence*. Es decir, Qlik nos permite **recopilar, procesar y extraer valor de los datos**.

Se va a ver cómo puedes empezar a trabajar con Qlik Sense:

Accede a la página web oficial de Qlik a través del siguiente enlace: <https://www.qlik.com/es-es/products/qlik-sense>

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 52. Qlik Sense. Fuente: elaboración propia.

Empezaremos desde cero con el objetivo de crear visualizaciones de forma sencilla e intuitiva. Comenzando por gráficas simples, ajustando tamaños, filtros, etc. Y poco a poco, iremos incorporando más elementos.

Qlik Sense es un entorno visual que nos facilita la creación de gráficos mediante el modo «arrastrar y soltar».

Instalación de Qlik Sense

Qlik Sense tiene diferentes versiones: *business* y *enterprise*:

- ▶ La versión **business** es la versión orientada a pequeñas y medianas empresas y difieren en sus capacidades como, por ejemplo, posibilidades de integración con APIs, número de espacios o áreas para almacenamiento y desarrollo de apps compartidos, límites de espacio en la app y número de recargas de datos.
- ▶ En la versión *business* no viene incluidas algunas funcionalidades avanzadas que sí están disponibles en la versión **enterprise** como Qlik Nprinting (informes para distribuir), Qlik Associative Big Data Index (conexión a *datasets* en la nube) o Qlik

Tema 4. Aplicación de herramientas para la visualización de datos

GeoAnalytics (funciones avanzadas para geoanalítica).

Vamos a usar la versión *business*, que permite la creación de apps y visualizaciones, tanto en su versión *desktop* como *cloud*, de la misma forma que la versión *enterprise*. Dispone de versiones de prueba para poder evaluar y probar todos los ejemplos de la asignatura.

Paso 1. Registrarse

Desde la página anterior pulsa sobre “Probar gratis”




Figura 53. Qlik Sense. Registro. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos



Comenzar gratis

¿Ya tiene una cuenta de Qlik? [Iniciar sesión](#)

Nombre

Apellido(s)

Email profesional

Siguiente

¡Ya casi está!

Empresa

Cargo

Teléfono (opcional)

País

☐ Sí, me gustaría recibir comunicaciones por correo electrónico relacionadas con Qlik, incluyendo información sobre productos y eventos. Entiendo que cualquier información que proporcione será tratada de acuerdo con la [Política de Privacidad de Qlik](#).

Activar mi prueba

Figura 54. Qlik Sense. Registro. Fuente: elaboración propia.

Los datos de la empresa y el cargo te lo puedes inventar. Al darle a Activar mi prueba, recibirás un correo.




Figura 55. Qlik Sense. Registro. Fuente: elaboración propia.

Una vez metes la contraseña aparece la ventana para finalizar el proceso.

Tema 4. Aplicación de herramientas para la visualización de datos

Ya casi hemos terminado

Basándonos en su dirección IP, hemos establecido su región como Europa (Irlanda). Puede seleccionar otra región en el mapa a continuación. Sin embargo, no podrá modificar esta región una vez que haya completado su configuración.




Figura 56. Qlik Sense. Registro. Fuente: elaboración propia.

Como puedes ver es una prueba gratuita de 30 días.




Figura 57. Qlik Sense. Bienvenida. Fuente: elaboración propia.

Vamos a usar la versión online. En todo caso, las capacidades de versiones *desktop* y *cloud*, aunque difieran ligeramente en su interfaz, son excepcionales y la forma de crear visualizaciones es prácticamente la misma.

Tema 4. Aplicación de herramientas para la visualización de datos

Crear Apps

Para crear una nueva app basta con ir a la página de inicio, descartar los paneles informativos que aparecen la primera vez y podremos observar un mensaje inicial diciéndonos que no tenemos aún creado ningún contenido.

Vamos a Catálogo y pulsamos en “Añadir Nuevo” y “Nueva app analítica”




Figura 58. Qlik Sense. Crear app. Fuente: elaboración propia.

Tras darle un nombre a la app, en este caso «Mi primera App», tendremos ya nuestra primera aplicación:

Figura 59. Qlik Sense. Crear app. Fuente: elaboración propia.

Tema 4. Aplicación de herramientas para la visualización de datos

Una vez creada aparece en el catálogo




Figura 60. Entorno de apps en Qlik Sense. Fuente: elaboración propia.

Hacemos clic en la app y abrimos la aplicación donde podremos empezar a añadir datos de archivos locales y de otras fuentes de datos a nuestro *dashboard*.



Figura 61. Entorno de apps en Qlik Sense. Fuente: elaboración propia.

Añadir datos a una app

Lo primero que podemos hacer con una app es indicar qué datos vamos a utilizar para crear la visualización. Existen dos opciones básicas:

- Utilizar un **fichero de datos** que tengamos descargado en nuestro ordenador.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ Utilizar **fuentes de datos externas** mediante la utilización de los múltiples conectores que nos proporciona Qlik.




Figura 62. Conectores de fuentes de datos. Fuente: elaboración propia.

En Internet existen múltiples sitios donde poder encontrar diferentes *datasets*. Una fuente de libre acceso muy interesante es el Banco Mundial.

Accede a la página oficial del Banco Mundial a través del siguiente enlace:

<http://datos.bancomundial.org>

Puedes empezar a cargar datasets y ver cómo usar Qlik Sense.

D3JS

Introducción y objetivos

Hasta ahora hemos visto herramientas para las cuales no hacen falta conocimientos de programación. Vamos a conocer ahora una librería enormemente flexible y que

Tema 4. Aplicación de herramientas para la visualización de datos

nos permitirá diseñar nuestras gráficas hasta el último detalle. Para ello nos basaremos en JavaScript como lenguaje de programación y abordaremos algunos conceptos avanzados que no suelen aparecer en la programación de páginas en HTML.



Figura 63. D3.js Data Driven Documents. Fuente: D3js, s.f.

Esta librería incluso nos permite crear las visualizaciones, aunque no nos consideremos buenos diseñadores. En GitHub podemos encontrar multitud de ejemplos en los que basarnos y que también podremos modificar.

Tema 4. Aplicación de herramientas para la visualización de datos

Accede a la galería de GitHub a través del siguiente enlace:

<https://github.com/d3/d3/wiki/Gallery>

En concreto vamos a ver los **conceptos básicos** de D3.js para que veas como puedes empezar.




Figura 64. Ejemplos visualizaciones D3. Fuente: Mbostock, 2024.

Definición e instalación

Este tema es exclusivamente de introducción, no hay gran complicación tecnológica, pero es necesario para familiarizarnos con D3, por lo que sería interesante ver los recursos que se recomiendan en este tema.

Tema 4. Aplicación de herramientas para la visualización de datos

Antes de nada, empezaremos definiendo qué es D3.js:

D3.js (*Data-Driven Documents*) es una librería JavaScript que utiliza datos digitales para impulsar la creación y control de gráficas dinámicas e interactivas en los navegadores.

Es una herramienta compatible con W3C, haciendo uso de los estándares en gráficos SVG (*Scalable Vector Graphics*), JavaScript, HTML5 y CSS3 (*Cascading Style Sheets*). A diferencia de otras librerías D3, permite un gran control sobre el resultado visual final. De esta definición resaltaremos varios conceptos que son relevantes:

Data driven documents

Este concepto es bastante importante si lo que estamos pensando es en **reutilizar visualizaciones existentes**. Hasta ahora, debíamos adaptar nuestra estructura de datos a las visualizaciones, mientras que aquí hay algo más de libertad.

Podemos adaptar nuestros datos o bien podemos cambiar la forma en la que D3 está leyendo los datos y es lo que se denomina **documentos orientados a datos**. D3 se creó con la intención de tener control absoluto sobre la visualización.

Scalable Vector Graphics (SVG)

No importa dónde mostremos nuestra visualización: pantallas y formatos grandes como un monitor o soportes más pequeños como los de un móvil. **Nuestra visualización se puede adaptar** a diferentes resoluciones.

Tema 4. Aplicación de herramientas para la visualización de datos

Compatible con estándares

Es compatible con estándares como JavaScript, HTML5 y *Cascading Style Sheets* (CSS3), por lo que funciona en diferentes exploradores y diferentes dispositivos. Como complemento a la definición anterior, podríamos decir que, a alto nivel, D3 es una librería que se caracteriza por las siguientes **funcionalidades**:

- ▶ *Loading*: carga información en la memoria de tu explorador.
- ▶ *Binding*: añade información a elementos existentes en tu HTML, vinculando los datos y los objetos HTML.
- ▶ *Transforming*: es capaz de leer datos y dar una respuesta visual basada en los datos. Para ello puede transformar el código HTML.
- ▶ *Transitioning*: basándose en la entrada del usuario, puede reaccionar y dar una respuesta diferente.




Figura 65. Ejemplos visualizaciones D3. Fuente: Tutorials Teacher, s.f.

Tema 4. Aplicación de herramientas para la visualización de datos

Instalación

Para empezar a utilizar D3 no es necesario instalar ningún tipo de *software*. D3 es una librería *open source* por lo que está disponible de forma libre en su propia página web.

Basta con llamar a la librería JavaScript de D3 desde nuestro propio código fuente. Se puede hacer de dos formas distintas:

- ▶ Incluir la librería D3 desde nuestro ordenador: descargamos la última versión disponible en d3js.org a través del fichero `d3.zip`. Lo descomprimos y extraemos la librería, ubicándola en el directorio local que queramos para poder llamarla desde nuestro código en JavaScript.
- ▶ Incluir la librería D3 desde CDN (*Content Delivery Network*): enlazamos a la última versión de la librería con el siguiente código:

```
<script src="https://d3js.org/d3.v7.min.js"></script>
```

Y este código será la base de nuestros ejemplos:

Código base

```
<html>
  <head>
    <script src="https://d3js.org/d3.v7.min.js"></script>
  </head>
  <body>
  </body>
</html>
```

Tema 4. Aplicación de herramientas para la visualización de datos

Elementos básicos de D3.js. Generando elementos HTML

Empezaremos con un ejemplo fácil. Hemos dicho que una de las características de D3 es que es capaz de transformar el código HTML y vincular datos con objetos HTML. ¿Cómo podemos crear un objeto HTML y añadir un texto con D3?

```
<html>
<head>
  <script language="javascript" type="text/javascript"
    src="http://d3js.org/d3.v7.min.js"></script>
  <script type="text/javascript">
    function draw(){
      d3.select("body").append("p").text("Párrafo nuevo");
    }
  </script>
</head>
<body onload="draw()">
</body>
</html>
```

Si copiamos este texto en nuestro editor de código veremos que lo que hace es **generar un nuevo elemento** en nuestro HTML. Añade un párrafo nuevo cuando el HTML está cargado, `onload="draw()"`, que llama a su vez a la función `draw`, que es la que realiza la acción en sí.

La **sintaxis de D3** sigue el concepto de encadenamiento o *chaining*. Se trata de concatenar varias funciones una seguida de otra, también es habitual utilizarla en Java, por ejemplo.

Pero ¿qué es lo que hace D3 con esta sentencia HTML?

- ▶ **Select:** selecciona el elemento `body` de nuestro HTML.
- ▶ **Append:** indica que añadirá algo a este elemento y define qué tipo de elemento HTML.
- ▶ **Text:** Define el texto que añadirá, es decir, el contenido texto.

Tema 4. Aplicación de herramientas para la visualización de datos

De hecho, tendría el mismo efecto que utilizar lo siguiente:

```
var body = d3.select("body");
var p = body.append("p");
p.text("Párrafo nuevo");
```

Trabajando con datos reales y elementos en el HTML

Ahora veremos cómo trabajar con elementos dentro del HTML.

```
<html>
<head>
<script language="javascript" type="text/javascript"
  src="http://d3js.org/d3.v3.min.js"></script>
<script type="text/javascript">
  function draw(){
    d3.select("#target").text("Añadiendo contenido");
  }
</script>
</head>
<body onload="draw()">
  <p id="target"></p>
</body>
</html>
```

Esta estructura es muy parecida a la versión anterior, pero hemos utilizado las etiquetas o elementos habituales en HTML con las que hemos estado trabajado en temas anteriores.

Modificar elementos HTML y atributos

Pero D3 no solo nos permite añadir texto, sino también modificar los elementos HTML y sus atributos.

Tema 4. Aplicación de herramientas para la visualización de datos

Añadir un atributo

Por ejemplo, queremos añadirle un atributo a nuestro elemento p llamado descr y asignarle el valor "primer_descriptor". Seguidamente lo imprimimos por pantalla.

```
function draw(){
  d3.select("#target").text("Contenido: ");
  // Establece atributo "descr" con el valor "primer descriptor" en el
  elemento p
  d3.select("p").attr("descr", "primer_descriptor");
  // Obtiene el atributo "descr" en el elemento p

  d3.select("#target").text(d3.select("p").text()+d3.select("p").attr("descr"));
}
```

Si miramos nuestro contenido, el resultado final en el HTML es algo muy simple: nos muestra el texto "Contenido: primer_descriptor". Y si miramos el código HTML en la consola de nuestro explorador, podemos ver algo parecido a esto:

```
<html>
<head>...</head>
<body onload="draw()">
<p id="target" descr="primer_descriptor">Contenido: primer_descriptor</p>
</body>
</html>
```

Como puedes observar, hemos añadido un atributo a nuestro elemento en el propio código HTML.

Uso de estilos

Otro uso interesante de los elementos HTML a través de D3 es el uso de los estilos y lo podemos hacer a través de la función style.

Tema 4. Aplicación de herramientas para la visualización de datos

Por ejemplo, cambiarle el tamaño de la fuente:

```
d3.select("#target").style("font-size", function(){return "40px";});
```

Ahora mismo, dentro del código de la función solo devuelve 40px, pero podríamos asignarle un valor dinámico dependiendo de alguna otra variable o del valor de un dato, lo que demuestra las enormes posibilidades que ofrece D3 al poder crear dinámicamente objetos HTML.

Modificar varios elementos HTML al mismo tiempo

Ahora aplicaremos estos conceptos en varios elementos HTML al mismo tiempo. Para ello, utilizaremos uno de tantos ejemplos que podemos encontrar en el libro *Data Visualization with D3.js Cookbook* (Zhu, 2013) en el que los ejemplos son de libre acceso y se pueden descargar. El ejemplo es el siguiente:

```
<html>
  <head>
    <link rel="stylesheet" type="text/css" href="styles.css"/>
    <script language="javascript" type="text/javascript"
src="http://d3js.org/d3.v3.min.js"></script>
    <script type="text/javascript">
      function draw(){
        d3.selectAll("div")
          .attr("class", "red box");
      }
    </script>
  </head>
  <body onload="draw()">
    <div></div>
    <div></div>
    <div></div>
  </body>
</html>
```

Tema 4. Aplicación de herramientas para la visualización de datos

La hoja de estilo a utilizar está definida en el archivo `styles.css`. En él, la clase `.red` y la clase `.box` están definidas de la siguiente forma:

```
.box {  
    width: 200px;  
    height: 200px;  
    margin: 40px;  
    float: left;  
    text-align: center;  
    border: #969696 solid thin;  
    padding: 5px;  
}  
  
.red {  
    background-color: #e9967a;  
    color: #f0f8ff;  
}  
  
.blue {  
    background-color: #add8e6;  
    color: #f0f8ff;  
}
```

Aplicando las clases `.red` y `.box` a los diferentes elementos `<div>` se obtiene el siguiente resultado:



Figura 66. Resultado de dibujar 3 cajas. Fuente: elaboración propia.

Si queremos **iterar** sobre cada elemento para hacer algo diferente, lo podemos hacer de la siguiente manera:

Tema 4. Aplicación de herramientas para la visualización de datos

```
d3.selectAll("div")
.attr("class", "red box")
.each(function (d, i) {
d3.select(this).append("h1").text(i);
});
```

Aquí resaltaremos lo que se diferencia de lo anterior:

```
each(function (d, i) {
  d3.select(this).append("h1").text(i);
});
```

La función `each` itera sobre los diferentes elementos, siendo `d` el elemento en sí, es decir, el elemento `div` referenciado dentro de la función como `this`. Y lo que hacemos es añadir un elemento `h1` con el número de la iteración `i`.




Figura 67. Resultado de dibujar 3 cajas. Fuente: elaboración propia.

Subelementos

Podemos trabajar también con **subelementos**. En el siguiente ejemplo, veremos cómo seleccionar un subelemento dentro de otro elemento. Cambiemos nuestro `body` con lo siguiente:

```
<section id="section1">
  <div>
    <p>blue box</p>
  </div>
<section id="section2">
  <div>
```

Tema 4. Aplicación de herramientas para la visualización de datos

```
<p>red box</p>
</div>
```

Y el código de la función `draw` por este:

```
d3.select("#section1 > div")
  .attr("class", "caja azul");
d3.select("#section2")
  .select("div")
  .attr("class", "caja roja");
```

En el código anterior podemos observar dos maneras diferentes de seleccionar un subelemento:

- ▶ `identificador > elemento html`:

```
d3.select("#section1 > div")
```

- ▶ `doble select`:

```
d3.select("#section2")
  .select("div")
```

El código completo queda de la siguiente forma:

```
<html>
  <head>
    <link rel="stylesheet" type="text/css" href="styles.css"/>
    <script language="javascript" type="text/javascript"
      src="http://d3js.org/d3.v3.min.js"></script>
    <script type="text/javascript">
      function draw(){
        d3.select("#section1 > div")
          .attr("class", "blue box");
        d3.select("#section2")
          .select("div")
          .attr("class", "red box");
      }
    </script>
  </head>
```


Tema 4. Aplicación de herramientas para la visualización de datos

```
<body onload="draw()">
<section id="section1">
  <div>
    <p>caja azul</p>
  </div>
<section id="section2">
  <div>
    <p>caja roja</p>
  </div>
</body>
</html>
```

Y el resultado final es el siguiente:




Figura 68. Resultado dibujar 2 cajas de diferente color y con texto. Fuente: elaboración propia.

Dando un paso más, también podríamos reemplazar toda la sección `body` y dejarla completamente limpia `<body></body>`. Para ello incluimos el código D3 siguiente dentro de la función `draw`:

```
<html>
<head>
<link rel="stylesheet" type="text/css" href="styles.css"/>
<script language="javascript" type="text/javascript"
  src="http://d3js.org/d3.v3.min.js"></script>
<script type="text/javascript">
  function draw(){
    var body = d3.select("body");
    body.append("section")
      .attr("id", "section1")
      .append("div")
```

Tema 4. Aplicación de herramientas para la visualización de datos

```
.attr("class", "blue box")
.append("p")
.text("caja azul dinámica");
body.append("section")
.attr("id", "section2")
.append("div")
.attr("class", "red box")
.append("p")
.text("caja roja dinámica");

d3.select("#section1 > div")
  .attr("class", "blue box");
d3.select("#section2")
  .select("div")
  .attr("class", "red box");
}
</script>
</head>
<body onload="draw()">
</body>
</html>
```

¿Cuáles son las principales diferencias?

Primero creamos una variable `body` y le asignamos el resultado de la función `select("body")`. Esto es lo mismo que hemos hecho al principio del tema.

Para crear la primera caja añadimos un elemento `section`. Le añadimos un atributo identificador llamado `section1`. A este elemento `section1`, le añadimos un elemento `div` y le asignamos la clase `blue box`. A este elemento `div` le añadimos un elemento párrafo o `p` y le asignamos el texto `caja azul dinámica`. La caja roja sigue el mismo patrón de creación.

Ventajas de D3.js

Hemos visto a través de los ejemplos que es necesario conocimientos de JavaScript, aunque el esfuerzo necesario tiene su recompensa:

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ D3.js es una biblioteca de JavaScript. Por lo tanto, puede ser usada con cualquier marco JS de su elección como Angular.js, React.js, etc...
- ▶ D3 se centra en los datos, por lo que es la herramienta más apropiada y especializada para la visualización de datos.
- ▶ D3 es de código abierto, te permite trabajar con el código fuente y añadir tus propias características.
- ▶ Funciona con estándares web, por lo que no se necesita ninguna otra tecnología o *plugin* que no sea un navegador para hacer uso de D3.
- ▶ D3 trabaja con estándares web como HTML, CSS y SVG, no se requiere ninguna nueva herramienta de aprendizaje o depuración para trabajar en D3.
- ▶ D3 proporciona un control completo sobre su visualización para personalizarla de la manera que se desee. Esto le da una ventaja sobre otras herramientas populares como Tableau o QlikView para usos específicos.
- ▶ Dado que D3 es ligero y funciona directamente con los estándares web, es extremadamente rápido y funciona bien con grandes conjuntos de datos.

En definitiva, una potente librería que, aunque requiere una curva de aprendizaje en términos de programación general, a cambio aporta una gran flexibilidad y posibilidades casi infinitas.

Tema 4. Aplicación de herramientas para la visualización de datos

4.5. Tendencias en visualización de datos

Introducción

Como ya has venido viendo la visualización de datos es un término que se refiere a cualquier esfuerzo para ayudar a las personas a comprender los datos presentándolos en un formato visual.

Con las técnicas de visualización de datos, los patrones, las tendencias y las correlaciones que normalmente pueden pasar desapercibidos en los datos numéricos, especialmente para el ojo inexperto, pueden exponerse y reconocerse más fácilmente.

La visualización de datos permite a las empresas que puedan detectar rápidamente nuevas oportunidades, identificar problemas antes de que se conviertan en problemas y crear nuevos productos y flujos de ingresos utilizando visualizaciones de datos efectivas. La presentación visual de datos también puede ayudar a informar, educar o persuadir a clientes e inversores.

Además, tiene otros beneficios:

- ▶ **Facilita la toma de decisiones**: la información visual es más accesible para procesar que la información escrita, lo que permite una toma de decisiones más rápida. El uso de un cuadro, un gráfico u otros elementos visuales para resumir datos complejos permite que la audiencia absorba la información rápidamente.
- ▶ **Mejora la productividad**: debido a que la visualización de datos conduce a una comprensión más rápida de la información, puede resultar en reuniones más cortas, reducción del tiempo de resolución de problemas y una mayor productividad general.
- ▶ **Admite la narración de historias**: puede desarrollar un nuevo lenguaje comercial mediante el uso de visualización de datos para contar su historia a otros. Es un medio que le permite crear fácilmente una narración utilizando gráficos y diagramas,

Tema 4. Aplicación de herramientas para la visualización de datos

que luego se pueden usar para descubrir nuevos conocimientos e involucrar a otros mediante el análisis visual.

Los datos se pueden visualizar de formas distintas a simples gráficos y cuadros estadísticos.

Algunos de los más utilizados son:

- ▶ Mapas
- ▶ Gráfico de dispersión
- ▶ Gráfico de burbujas
- ▶ Gráfico de barras
- ▶ Gráfico de líneas y áreas
- ▶ Gráficos radiales y circulares

El campo de la visualización de datos cambia constantemente a medida que las nuevas tecnologías y técnicas amplían los límites del diseño de datos y los nuevos dispositivos exigen a los expertos en visualización de datos.

La visualización de datos es una forma extremadamente poderosa de generar conocimientos y llegar a mejores decisiones basadas en datos. Debido a una combinación de avances tecnológicos y creativos, el futuro de la visualización de datos se parecerá poco a sus encarnaciones anteriores. Atrás quedaron los días de llenar cuidadosamente los cuadrados de papel cuadriculado a mano: la visualización de datos moderna tenderá más hacia modelos fluidos en tiempo real capaces de capturar con precisión la totalidad de los conjuntos de datos matizados.

Tema 4. Aplicación de herramientas para la visualización de datos

Como hemos visto la visualización de datos nos proporciona una comprensión rápida y clara de la información. Estamos presenciando nuevas formas interesantes y atractivas de diseñar y compartir datos complejos con cualquier tipo de audiencia.

Tendencias en visualización

¿Cuáles son las tendencias actuales en la visualización de datos que nos dan una idea de cómo serán las visualizaciones futuras?

Video infografías

Las vídeo infografías son aquellos contenidos que combinan la utilización de texto, de imágenes y otros gráficos y que permiten mostrar información o datos de diferentes temas, productos o servicios en una campaña de [email marketing](#) de una forma mucho más visual y sencilla.

Las infografías animadas o de vídeo ofrecen muchas posibilidades en el mundo de los negocios, ya que ofrecen un abanico muy amplio de opciones de cómo mostrar un servicio mediante iconos, imágenes y datos de una forma muy moderna.

Las estadísticas de retención de datos para video son incluso más impresionantes que las de imágenes estáticas. Los estudios han encontrado que las personas que reciben instrucciones en video retienen mejor los datos que aquellas que solo reciben instrucciones de texto.

Pero hay más en esto: intuitivamente sabemos que el video es más fácil de procesar para nuestro cerebro, y lo preferimos cuando se nos da la opción. Alrededor del 67% de los usuarios prefieren aprender sobre un nuevo producto o servicio a través de videos en lugar de imágenes o texto.

Tema 4. Aplicación de herramientas para la visualización de datos

Solo recuerda que el beneficio de crear un video infográfico para presentar información es hacer que las ideas complejas parezcan más simples. Trata de mantener sus videos cortos y directos para lograr los mejores resultados.

Puedes ver el siguiente video de la BBC (2010) para entender cómo se puede realizar una buena video-infografía de los datos:

<https://www.youtube.com/watch?v=jbkSRLYSojo>

Uno de los puntos más importantes que juegan a favor de cualquier tipo de infografías es que son informaciones relevantes que son transmitidas a través de imágenes para favorecer la comprensión de la información por parte del cliente.

Para cierto tipo de trabajos, las infografías son muy utilizadas. Sobre todo, para resaltar datos numéricos o información que por su naturaleza tiene un mayor nivel de complejidad. Por ejemplo, es habitual el uso de las vídeo infografías en sectores como el científico, el tecnológico y el [industrial](#).

Además, el vídeo es un medio excelente para que la información que se quiere transmitir sea retenida más fácilmente por el usuario. Por ello, las vídeo infografías para email marketing son cada vez más populares. De hecho, pueden ser utilizadas por cualquier tipo de negocio.

Entre los puntos favorables que cuenta una [vídeo infografía](#) están:

- ▶ Se entiende y se retiene mucho mejor cualquier tipo de información.
- ▶ La información es puede ser consumida a través de un formato más entretenido y didáctico.
- ▶ Tiene mayor tasa de visualización que las campañas con solo texto.
- ▶ Llaman la atención de las personas.

Tema 4. Aplicación de herramientas para la visualización de datos

En definitiva, el vídeo es uno de los formatos que mejor captan la atención de las personas.

Visualización de datos en tiempo real

La visualización de datos en tiempo real lleva las imágenes al siguiente nivel al permitir actualizar tablas y gráficos en tiempo real. Tener datos disponibles en tiempo real permite a la audiencia tomar decisiones más informadas basadas en datos actuales en lugar de históricos.

La visualización de datos en tiempo real brinda a todos información valiosa sobre cómo se relacionan varios conjuntos de datos entre sí, lo que permite a las personas identificar y extraer rápidamente patrones y tendencias que de otro modo estarían ocultos en los datos sin procesar, o que son mucho más difíciles de comprender.

El factor clave que hace que la visualización en tiempo real sea preferible a la visualización por lotes o basada en eventos es el requisito de inmediatez en la toma de decisiones, que tiende a basarse en roles.

La visualización en tiempo real puede ser tremendamente útil para las personas que deben tomar decisiones tácticas u operativas sobre la marcha.

Pero antes de analizar los usos específicos de la visualización de datos en tiempo real, consideremos qué tipos de casos de uso se benefician más de la visualización en tiempo real.

Por lo general, se pueden dividir en dos categorías:

- ▶ Aquellas que permiten a las personas o empresas manejar mejor el riesgo, tanto gestionándolo como respondiendo cuando algo sale mal.

Tema 4. Aplicación de herramientas para la visualización de datos

- ▶ Aquellos que les permiten explotar oportunidades que surgen rápidamente antes de que desaparezcan

Estas circunstancias, donde se deben tomar medidas rápidamente, son donde las visualizaciones en tiempo real brillan al proporcionar un contexto adicional para los tomadores de decisiones.

Caso de uso 1: Gestión de crisis

Quizás el mayor valor de la visualización en tiempo real en el manejo de riesgos proviene de informar a los tomadores de decisiones que necesitan responder a eventos emergentes. Si una tormenta está en camino de destruir un centro de datos, una tienda minorista o cualquier parte de la infraestructura o cadena de suministro de una empresa, por ejemplo, la visualización en tiempo real puede ser tremendamente útil.

Los análisis descriptivos entregados periódicamente hacen poco para poder obtener servicios al cliente de inmediato; para cuando el análisis esté disponible, es probable que la situación haya cambiado.

Por el contrario, la visualización en tiempo real de los activos en una variedad de ubicaciones geográficas permite a los responsables de la toma de decisiones asignar los recursos donde más se necesitan, lo que puede marcar la diferencia entre mantener o perder clientes en industrias donde el tiempo de actividad es crítico.

Caso de uso 2: seguridad y prevención del fraude

Además de brindar a las empresas opciones para responder a situaciones de riesgo, las visualizaciones en tiempo real brindan una gran oportunidad para reducir el riesgo

Tema 4. Aplicación de herramientas para la visualización de datos

en las operaciones diarias. La capacidad de centralizar y visualizar la salida de todos los sensores que tiene una empresa (por ejemplo, cámaras de seguridad, alarmas antirrobo, etiquetas RFID en activos valiosos, etc.) permite que una sola persona controle miles de millones de dólares en propiedades distribuidas globalmente desde un lugar.

Esto también facilita la búsqueda de personas que intentan defraudar o robar a una empresa antes de que se salgan con la suya, ya que las visualizaciones en tiempo real pueden alertar a los gerentes y a los responsables de la toma de decisiones sobre comportamientos sospechosos antes de que realmente ocurra el fraude.

Caso de uso 3: Gestión de recursos

Este caso de uso se encuentra entre el riesgo y la oportunidad, y representa una oportunidad única para que las empresas maximicen el valor que obtienen de los recursos existentes.

La visualización en tiempo real puede ayudar a los gerentes a descubrir ineficiencias y corregirlas mucho antes de que el análisis heredado haya señalado una anomalía. Si, por ejemplo, un vehículo de servicio deja de funcionar al mediodía, la visualización en tiempo real permite a los gerentes regionales reaccionar de manera más eficiente y tomar mejores decisiones con toda la información disponible frente a ellos.

Caso de uso 4: Ventas

La visualización de datos en tiempo real abre grandes oportunidades para las empresas que intentan realizar más ventas, tanto en instituciones físicas como en comercio electrónico.

Tema 4. Aplicación de herramientas para la visualización de datos

Los análisis en tiempo real brindan a las empresas la opción de brindar a los clientes sugerencias contextuales; por ejemplo, un supermercado que sugiere una receta que utiliza principalmente ingredientes que ya están en el carrito de un cliente.

Combine esto con una gestión de inventario más eficiente (reposición de artículos calientes más rápidamente cuando se agoten), y la visualización en tiempo real les da a las empresas una gran flexibilidad para llevar más productos a los consumidores.

Caso de uso 5: Decisiones de compra

Para las empresas que dependen en gran medida de la compra de productos básicos para sus operaciones, la capacidad de visualizar las tendencias del mercado en tiempo real proporciona una gran cantidad de valor agregado. Significa que las empresas de servicios públicos pueden comprar petróleo en su punto más barato y las empresas internacionales pueden capitalizar rápidamente los cambios en los mercados de divisas.

La visualización por lotes o basada en eventos podría hacer que las empresas compren horas después de que los precios alcancen su punto más bajo, mientras que el procesamiento en tiempo real alertará a las empresas sobre insumos baratos, lo que resultará en un gran ahorro de costos.

En última instancia, las empresas de una amplia variedad de mercados harían bien en considerar la tecnología de visualización en tiempo real. Quizás no cambie su dirección estratégica, pero las optimizaciones operativas tienen el potencial de ahorrar dinero real.

Tema 4. Aplicación de herramientas para la visualización de datos

Democratización de los datos

Las herramientas de visualización de datos y generación de informes han permitido un mayor acceso a la información y han venido a optimizar el uso de hojas de cálculo que si bien te permiten la utilización de gráficos, no tienen las mismas características que, por ejemplo, un dashboard.

Los datos solían tener la desagradable costumbre de ser difíciles de entender: requerían la atención de los científicos de datos y otros empleados técnicos para desbloquear sus tesoros.

Esto ya no necesita ser el caso. Las plataformas avanzadas de análisis de datos sin código pueden procesar y desbloquear automáticamente los datos. Esto lo hace fácil de mostrar en cualquier modo de visualización ya que lo hace de manera independiente al nivel de conocimiento tecnológico que los usuarios puedan tener.

Esta es la 'democratización' de los datos que, cuando se combina con una elección efectiva del tipo de visualización de datos, puede desbloquear grandes resultados de datos para equipos en todos los niveles dentro de una organización.

La democratización de datos se puede definir por tanto como hacer que la información digital sea accesible para el usuario promedio, sin conocimientos técnicos, de los sistemas de información sin necesidad de que intervenga el departamento de Tecnología de una empresa.

Es la base del análisis de autoservicio, un enfoque que le permite a estos usuarios con pocos conocimientos técnicos recopilar y analizar datos sin tener que buscar la ayuda de un administrador de datos o sistemas o de algún experto.

Los beneficios parecen obvios, entonces ¿por qué esto no había ocurrido antes y qué está permitiendo que ocurra ahora?

Tema 4. Aplicación de herramientas para la visualización de datos

Factores que afectan a la democratización de datos

- ▶ **Datos en silos:** Las empresas han observado cierto éxito al introducir sus datos en [almacenes de datos](#), [lago de datos](#) o sistemas de inteligencia empresarial. Esto soluciona el problema de almacenamiento. Sin embargo, es difícil para una empresa establecer una única fuente de datos de confianza.
- ▶ **Acceso limitado:** Además del problema de no poder encontrar los datos está el problema de no saber si se puede confiar en ellos. Generalmente, los controles de acceso son proporcionados a los administradores. Pero al levantar un muro entre las personas que gestionan los datos, garantizan su calidad y quienes realizan el análisis y los usuarios de la empresa que necesitaban actuar en función de la información, no se permite el libre flujo de información necesario para moverse de manera ágil.
- ▶ **Falta de herramientas:** Muchas empresas no conocen que existen las herramientas de inteligencia empresarial y de análisis de datos que se pueden usar de forma fácil e intuitiva, sin ser un experto.

¿Cómo lograr la democratización de datos?

Estos son algunos factores que debes de considerar para lograr la democratización de datos:

- ▶ **Rastrear las fuentes:** Un catálogo de datos proporciona un inventario catalogado de todos tus activos de datos mientras que le permite colaborar a todos los miembros de tu equipo, desde analistas de datos, consumidores de datos hasta creadores de datos.
- ▶ **Hacer que todo sea accesible:** Liberar el acceso a los datos adoptando un enfoque más relajado para la gestión y gobernanza de los datos significa que todos los miembros de una organización, y no sólo el equipo de TI, pueden encontrar,

Tema 4. Aplicación de herramientas para la visualización de datos

comprender y colaborar fácilmente con los datos que necesitan para tomar decisiones empresariales impactantes.

En conclusión, puedes utilizar el catálogo de datos para buscar en las fuentes de datos y en usar un dashboard para conocer cómo se están utilizando los activos de datos que contienen.

Visualizaciones compatibles con dispositivos móviles

Los dispositivos móviles representaron el 56 % del tráfico de Internet en febrero de 2021. Las visualizaciones de datos optimizadas para dispositivos móviles son cada vez más importantes a medida que más personas consumen información sobre la marcha.

Esa es una gran cuota de mercado. Como tal, es importante comprender que la visualización de datos no es solo para las necesidades de su equipo interno, sino que también se puede usar para reducir la rotación de clientes, mejorar la lealtad e incluso atraer nuevos clientes, todo a través del poder persuasivo de las imágenes.

Ya sea que los clientes existentes o potenciales se estén informando sobre sus servicios en las redes sociales, en su sitio o en un panel de revisión en línea, la visualización de datos optimizada para dispositivos móviles es esencial. El contenido que es incompatible con los dispositivos móviles significa que un cliente podría cambiar a un competidor frustrado. O simplemente podría significar que no ven un gráfico clave por el que ha pagado una buena cantidad de dinero para que se muestre estratégicamente.

Los dispositivos móviles también tienen características únicas que pueden mejorar la experiencia del consumidor. Uno de los más utilizados es el sistema de posicionamiento global (GPS).

Tema 4. Aplicación de herramientas para la visualización de datos




Figura 69. Casos coronavirus. Fuente: elaboración propia.

Un excelente ejemplo de visualización de datos para dispositivos móviles es la herramienta de noticias Coronavirus de Google, que monitorea la pandemia de Covid-19. Gracias a la optimización móvil efectiva, el usuario puede acercarse a cualquier parte del mundo, incluida su ubicación actual, y obtener información detallada sobre la prevalencia de la enfermedad en esa área. Cuanto más grande sea el círculo, más casos habrá, lo que facilita la evaluación de los números de un vistazo.

Tema 4. Aplicación de herramientas para la visualización de datos

Inteligencia artificial y aprendizaje automático

Como ya viste unas lecciones atrás la IA y el aprendizaje automático son la columna vertebral de toda gran visualización de datos y serán cada vez más clave a medida que avanza la tecnología.

Las visualizaciones de datos que no están respaldadas por IA avanzada están condenadas a ser imprecisas e ineficientes a largo plazo. Porque resulta que los humanos son tan malos para clasificar con precisión los datos sin procesar como para procesarlos.

Los comentarios de los clientes se manejan mejor con programas imparciales que pueden clasificar dichos comentarios en tiempo real y de acuerdo con sus especificaciones. Esto elimina la necesidad de enviar a los empleados a realizar incontables horas de agotadoras tabulaciones manuales que seguramente tendrán algún sesgo.

Resumiendo

En los próximos años, las empresas competirán al filo de la navaja en la visualización de datos al enfrentar sus algoritmos de visualización y análisis de datos avanzados entre sí en la búsqueda de la máxima eficiencia. Sin embargo, en el ciberespacio moderno, varias empresas ni siquiera emplean IA todavía.

Con la visualización de datos, las marcas y las empresas pueden aprovechar el verdadero potencial de sus datos y hacerlo de manera rápida y efectiva. A su vez, esto puede conducir a una mejor calidad y velocidad en la toma de decisiones y un aumento medible de la productividad y la eficiencia.

Tema 4. Aplicación de herramientas para la visualización de datos

Los puntos clave a considerar al crear gráficos de datos incluyen:

- ▶ Comparta datos relevantes: verifique siempre sus datos para asegurarse de que sean valiosos, concisos, honestos y precisos. Los lectores deben poder recordar y utilizar sus datos.
- ▶ Elija lo que funcione mejor para usted: hay varios tipos de gráficos, tablas y otras visualizaciones de datos. Elija el formato que mejor se adapte a los objetivos y la información de su empresa. Los gráficos circulares, por ejemplo, ilustran partes de un todo, los gráficos de barras comparan datos cuantitativos, los mapas muestran representaciones geográficas de varios fenómenos y las infografías presentan historias complejas.
- ▶ Hazlo atractivo y comprensible: las imágenes deben parecer informativas y fáciles de entender al tiempo que presentan una narrativa clara para los usuarios. Cualquiera que mire su tabla o gráfico debería poder obtener información práctica y aprender algo nuevo.

Tema 4. Aplicación de herramientas para la visualización de datos

4.6. Referencias bibliográficas

Anuncia, M., Gohel, H. y Vairamuthu, S. (2020). *Data Visualization: Trends and Challenges Toward Multidisciplinary Perception*. Springer.

BBC. (2010). *Hans Rosling's 200 Countries, 200 Years, 4 Minutes - The Joy of Stats - BBC Four* [Vídeo]. YouTube.

Be A Better Dev. (10 de febrero de 2020). *SQL vs NoSQL Explained* [vídeo]. YouTube. <https://www.youtube.com/watch?v=ruz-vK8lesE>

Empresas. (2021). *Inteligencia artificial para el análisis y la gestión de los datos corporativos*. Disponible en: <https://blog.mundo-r.com/es/empresas/inteligencia-artificial-para-el-analisis-y-la-gestion-de-los-datos-corporativos/>

Frey, L. (5 de febrero de 2013). *Pie charts: the bad, the worst and the ugly*. Visuanalyze. http://visuanalyze.wordpress.com/2013/02/05/bad_piecharts/

Fortinet. (S.f.). *Cuadrante Mágico™ de Gartner® de 2024 para Gestión de información y eventos de seguridad (SIEM)* [Imagen]. <https://www.fortinet.com/lat/resources/analyst-reports/gartner-magic-quadrant-siem>

Gibb, R. (2019). *What is a Distributed System?*

Genoino, C. (5 de diciembre de 2012). *How do scientists collect data?* [vídeo]. YouTube. <http://www.youtube.com/watch?v=mPmiW0x3s3k>

Hickey, W. (26 de junio de 2013). *The 27 Worst Charts of All Time*. Business Insider. <http://www.businessinsider.com/the-27-worst-charts-of-all-time-2013-6?op=1>

Joyanes Aguilar, L. (2019). *Inteligencia de negocios y analítica de datos*. Marcombo.

Mbostock. (2024). *d3/d3* [Imagen]. Github. <https://github.com/d3/d3>

Tema 4. Aplicación de herramientas para la visualización de datos

Microsoft. (S.f.). *Power BI Desktop* [Imagen]. <https://www.microsoft.com/es-es/power-platform/products/power-bi/desktop>

Mr. Guch. (18 de marzo de 2012). *Graphing guidelines*. Mrphysics. <http://mrphysics.org/MrGuch/graph.html>

Nussbaumer, C. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley.

Kozlovski, S. (2018). *A Thorough Introduction to Distributed Systems*. Free Code Camp.

Kzryzanowski, P. (2018). *Distributed systems*. Rutgers University. <https://people.cs.rutgers.edu/~pxk/417/exam/old/2018-exam2-review.pdf>

Paganini, C. (2019). *Distributed Systems and Cloud Native Computing*. Disponible en: <https://es.scribd.com/document/514742357/Leccion-1-Sistemas-Distribuidos-2021>

Qlik. (2024). *2024 Gartner® Magic Quadrant™ for Analytics and Business Intelligence Platforms* [Imagen]. <https://www.qlik.com/us/gartner-magic-quadrant-business-intelligence>

Radzik, I. (S.f.). *Real-Time Data Visualization and Data Exploration*. Striim. <https://www.striim.com/blog/real-time-data-visualization-data-exploration/>

Schwabish, J. (2021). *Better Data Visualizations: A Guide for Scholars, Researchers, and Wonks*. Columbia University Press.

Shoup, K. (2019). *Getting your data ready for IA*. O'Reilly Media Inc.

Sitio web de D3js. (S. f.). <https://d3js.org/>

Ssalonso. (2011). *Nube de etiquetas del artículo "Etiqueta (metadato)"* [Imagen]. Wikipedia. <https://upload.wikimedia.org/wikipedia/commons/thumb/d/d6/Nube-etiquetas.png/800px-Nube-etiquetas.png?20110902145407>

Tema 4. Aplicación de herramientas para la visualización de datos

Stanford Dbclass. (26 de diciembre de 2013). *04 01 json intro part1* [vídeo]. YouTube.

<https://www.youtube.com/watch?v=lutlvfe8YHU>

Tutorials Teacher. (S.f.). *What is D3?* [Imagen].

<https://www.tutorialsteacher.com/d3js/what-is-d3js>

Universidad Internacional de Valencia. (2020). *Sistemas distribuidos, características y clasificación*. www.universidadviu.com

Upbe. (S. f.). *Inteligencia Artificial: la importancia de los datos* (7).

<https://www.upbe.ai/blog/inteligencia-artificial-datos/>

Zinsmeister, S., Young A. y Garrett, R. (2019). *AI-Driven Analytics*. O'Reilly Media Inc.


Storytelling with Data: A Data Visualization Guide for Business Professionals

Nussbaumer Knaflic, C. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley. <https://learning.oreilly.com/library/view/storytelling-with-data/9781119002253/>

Storytelling with Data

Nussbaumer Knaflic, C. (2019). *Storytelling with Data*. Wiley.
<https://learning.oreilly.com/library/view/storytelling-with-data/9781119621492/>

¿Qué son los KPI's? Explicación de los indicadores a través del fútbol




Módulo 4.02.01. ¿Qué son los KPI's? Explicación de los indicadores a través del fútbol

Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=ba9cc335-4bc1-40ad-8a59-b13300e74961>

Interesante vídeo que nos muestra, de forma práctica, qué es un KPI y cómo crearlos para aplicarlo a nuestro negocio.

Análisis de KPIS con dashboards: de los datos al conocimiento




Módulo 4.02.02. Análisis de KPIS con dashboards: de los datos al conocimiento

Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=a92401ff-26f1-4707-bd83-b1330138dcf2>

Ampliando el anterior, un vídeo de 50 minutos con la utilización de los KPI en cuadros de mando y la capacidad de análisis que proporciona.

Storytelling: el arte de contar historias




Módulo 4.02.03. Storytelling: el arte de contar historias

Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=689986ea-4ba4-4bec-85d9-b13300e749bc>

El storytelling y ejemplos de comunicación a través de esta técnica



Módulo 4.02.04. El storytelling y ejemplos de comunicación a través de esta técnica

Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=8c6b0e5e-46e1-4cf6-9997-b13300e7498f>

Introducción a SEMMA de SAS®

Introduction to SEMMA. (2017, agosto 30). SAS institute.
<https://documentation.sas.com/doc/en/emref/14.3/n061bzurmej4j3n1jnj8bbj1a2.htm>

Ayuda detallada del fabricante SAS para la utilización de SEMMA dentro de su entorno Enterprise Miner™.

IBM SPSS Modeler Cookbook

McCormick, K., Abbott, D. Brown, M. S. y Mutchler, S. R. (2013). *IBM SPSS Modeler Cookbook*. Packt Publishing.

IBM SPSS Modeler es un entorno de trabajo de minería de datos que le permite explorar datos, identificar relaciones importantes que puede aprovechar y crear modelos predictivos rápidamente, lo que permite a su organización basar sus decisiones en datos duros, no en corazonadas o conjeturas.

A Visual Guide to Crisp-DM Methodology

Leaper, N. A. (s. f.). Visual Guide to Crisp-DM Methodology. *WordPress*.
<https://exde.wordpress.com/2009/03/13/a-visual-guide-to-crisp-dm-methodology/>

Metodología Crisp-DM

Bucheli Guerrero, V. y Sánchez, J. D. (2021). Metodología CRISP-DM. *Scribd*.
<https://es.scribd.com/document/510484205/Metodologia-CRISP-DM>

Metodología Crisp-DM en adictos al trabajo

Álvarez Gil, D. (2021, enero 14). Metodología CRISP-DM. *Adictos al trabajo*.
<https://adictosaltrabajo.com/2021/01/14/metodologia-crisp-dm/>

Python Data Mining Quick Start Guide

Greeneltch, N. (2019). *Python Data Mining Quick Start Guide: A beginner's guide to extracting valuable insights from your data*. Packt Publishing.

Libro práctico para introducirnos en el mundo de la Minería de Datos con ejemplos prácticos muy interesantes

Minería de datos: modelos y algoritmos

Gironés Roig, J., Casas Roma, J., Minguillón Alfonso, J y Caihuelas, Q. (2017).
Minería de datos. Modelos y algoritmos. Editorial OUC.

Data Mining: Practical Machine Learning Tools and Techniques

Witten, I. H., Frank, E., Hall, M. A. y Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann Publishers.

Basic Statistics and Data Mining for Data Science

Salcedo, J. (2017). *Basic Statistics and Data Mining for Data Science*. O'Reilly.
<https://www.oreilly.com/library/view/basic-statistics-and/9781788476782/>

Interesante serie de vídeos de casi 3 horas, con técnicas y estadística asociada a la minería de datos

Minería de datos

Minería de datos. (2020). En *Wikipedia*.
https://es.wikipedia.org/wiki/Miner%C3%ADa_de_datos

Algoritmos de minería de datos

Kfollis, paulinbar, john-par, TimShererWithAquent. (2023, octubre 31). Algoritmos de minería de datos (Analysis Services: Minería de datos). *Microsoft Learn*.
<https://learn.microsoft.com/es-es/analysis-services/data-mining/data-mining-algorithms-analysis-services-data-mining?view=asallproducts-allversions>

D3 for the Impatient: Interactive Graphics for Programmers and Scientists

Janert, P. K. (2013). *D3 for the Impatient: Interactive Graphics for Programmers and Scientists*. O'Reilly.

Este libro está recomendado para quienes entienden lo básico de HTML, CSS y JavaScript y quieran explorar rápidamente la extensa, pero a menudo abrumadora, documentación de referencia sobre D3.js.

Philipp K. Janert, autor de *Data Analysis with Open Source Tools*, proporciona una concisa hoja de ruta para esta librería, incluyendo sus convenciones y conceptos fundamentales. D3.js para los impacientes es conciso y completo.

Mastering Qlik Sense

Mahler, M. y Vitantonio, J. (2018). *Mastering Qlik Sense*. Birmingham. Packt Publishing.

Técnicas avanzadas en análisis de datos para crear soluciones de business intelligence.

Tableau: Create and Learn

Silva, R. F. (2019). *Tableau: Create and Learn*. Amazon.

Este libro con más de 300 ilustraciones recorre los aspectos más relevantes de Tableau, desde su instalación hasta la creación de *dashboards*.

Visual Data Storytelling with Tableau

Ryan, L. (2018). *Tableau: Create and Learn*. Amazon.

Si quieres contar una historia de datos con Tableau, te recomendamos este libro. *Visual Data Storytelling with Tableau* te ayuda a organizar los datos, estructurar el análisis, profundizar en la exploración y crear visualizaciones avanzadas, pero siempre teniendo en mente que el objetivo final es contar una historia basada en datos.

Introducing Microsoft Power BI

Ferrari, A. y Russo, M. (2016). *Introducing Microsoft Power BI*. Microsoft.

Este libro aborda de una forma sencilla cómo usar Power BI. Es una inspiración para mejorar la toma de decisiones basadas en datos, aprovechando las características analíticas y de colaboración de este entorno.

Applied Microsoft Power BI: Bring your data to life!

Lachev, T., Price, E. y Underwood, J. (2016). *Applied Microsoft Power BI: Bring your data to life!* (5.ª ed.). Prologika.

Este libro te ayudará a expresar las capacidades de este entorno de análisis de datos y visualización, descubriendo cómo se integran y transforman los datos e implementando sofisticados modelos de análisis descriptivos y predictivos.