


Visión por Computadora

Francisco Jáñez Martino


Módulo 3

Aprendizaje Automático Aplicado

Introducción



Introducción







1 - Adquirir la imagen


2 - Procesar la imagen

3 - Interpretar la imagen
obteniendo patrones

Aplicaciones



Metodologías



Metodología tradicional

- Filtro de Sobel: Calcula la derivada en direcciones X e Y para encontrar cambios abruptos en la intensidad de píxeles
- Filtro Laplaciano: Usa la segunda derivada para detectar regiones con cambios de intensidad bruscos
- Detector de Canny: Algoritmo avanzado que aplica filtrado Gaussiano, derivadas, umbralización y seguimiento de bordes para obtener contornos precisos

Metodología tradicional

- SIFT (Scale-Invariant Feature Transform): Detecta y describe características robustas a cambios de escala y rotación
- SURF (Speeded-Up Robust Features): Variante optimizada de SIFT, más rápida pero con menor precisión
- ORB (Oriented FAST and Rotated BRIEF): Algoritmo rápido y eficiente que reemplaza a SIFT y SURF en aplicaciones en tiempo real
- Haralick Features: Extrae texturas desde matrices de co-ocurrencia de nivel de grises, útil en análisis de texturas complejas.



Metodología tradicional

- Thresholding: Clasifica píxeles según su intensidad en blanco o negro
- Watershed: Interpreta la imagen como una topografía y segmenta en cuencas
- GrabCut: Algoritmo interactivo que mejora la segmentación usando modelos de fondo y primer plano
- Local Binary Fitting (LBF): Modelo basado en nivel de conjuntos que segmenta imágenes utilizando información de intensidad y bordes

Metodología tradicional


- Viola-Jones: Algoritmo basado en Haar cascades, utilizado para detección de rostros en tiempo real
- HOG (Histogram of Oriented Gradients): Extrae características basadas en gradientes y se combina con SVM para detectar objetos como peatones y vehículos

Metodología tradicional




Haralick


Metodología tradicional





Local Binary Fitting




Redes Neuronales





Redes convolucionales (CNNs)




Redes convolucionales (CNNs)




Visual Geometry Group VGG16



Residual Neural Network (ResNet)




Residual Neural Network (ResNet)



Entrenamiento desde cero (from scratch)

Este tipo de entrenamiento consiste en entrenar un modelo completamente nuevo sin usar conocimientos previos. Se requiere una gran cantidad de datos y poder computacional, pero permite total flexibilidad para adaptarse a una tarea específica




Transfer Learning

El aprendizaje por transferencia es un enfoque donde un modelo previamente entrenado en una gran cantidad de datos se reutiliza para una nueva tarea relacionada. En lugar de entrenar desde cero, se aprovechan las representaciones aprendidas para mejorar la eficiencia y precisión en una nueva tarea con menos datos



Fine tuning

Es una técnica dentro del **Transfer Learning**, donde se toma un modelo preentrenado y se ajustan algunas o todas sus capas con datos específicos de la nueva tarea. Se entrena con una tasa de aprendizaje baja para adaptar mejor el modelo sin perder el conocimiento previo



Ventajas y desventajas

Enfoque	Ventajas	Desventajas
From Scratch (Desde Cero)	♦ Máxima flexibilidad y adaptación a la tarea. ♦ No depende de sesgos de modelos previos.	✗ Requiere muchos datos y poder computacional. ✗ Tiempo de entrenamiento muy alto.
Transfer Learning (Aprendizaje por Transferencia)	♦ Reduce el tiempo de entrenamiento. ♦ Requiere menos datos etiquetados. ♦ Útil cuando la nueva tarea es similar a la del modelo base.	✗ Puede no adaptarse bien si los datos son muy diferentes. ✗ La última capa suele ser la única entrenada, limitando la personalización.
Fine-Tuning (Ajuste Fino)	♦ Permite adaptar el modelo preentrenado a la nueva tarea con precisión. ♦ Aprovecha el conocimiento previo mientras ajusta detalles específicos.	✗ Riesgo de <i>catastrophic forgetting</i> (perder el conocimiento previo si se ajusta mal). ✗ Puede necesitar más datos que el Transfer Learning básico.

UNIVERSIDAD
INTERNACIONAL
DE LA RIOJA

unir

www.unir.net