





En este caso el proyecto está orientado a la aplicación de Machine Learning para el análisis de sentimientos y a la investigación activa del impacto en los políticos y sus partidos de los nuevos fenómenos que aparecen en las redes sociales. Las fases de CRISP-DM se adaptaron a las necesidades que nos planteaba y a sus características especiales:

- Trabajo sobre los datos que llegan en tiempo real, por lo que ciertos análisis se hacen en NRT ('Near Real Time').
- En muchas ocasiones, se exploran todos los datos identificando correlaciones sin ser necesarias hipótesis previas.
- El preprocesamiento es 'ad hoc' y en una dinámica de limpieza conforme es necesario.

El esfuerzo en este tipo de proyectos aumenta en las tareas de minería de datos y de interpretación / evaluación de la información resultante.



1.1 Fase 1: Comprensión del Negocio




Ilustración 1. Fase 1 _Comprensión del Negocio

1.1.1 Establecer las metas a alcanzar

Inicialmente y como planteamiento formal, realizaremos un análisis con post de X-Twitter de ciudadanos anónimos y de distintos ámbitos españoles como son la política y sus representantes, los medios de comunicación y el CIS, en concreto sus encuestas acerca de nuestras preocupaciones como ciudadanos.

Trataremos de buscar relaciones entre todas estas entidades y la sociedad, de forma que nos permita encontrar patrones de interés. El principal será el de buscar qué tipo de sentimiento aparece con determinadas preocupaciones de tipo social y su relación con esas ‘preguntas’ del CIS.

Estas metas nos proporcionarían una primera herramienta para el análisis de tipo económico-social que creemos que puede ser muy interesante para la asesoría política y atractivo para los medios.

1.1.2 Examinar estudios ya existentes

El hecho de disponer como profesora en nuestro máster de uno de los investigadores españoles que más y mejor ha desarrollado el análisis en X-Twitter como es Mariluz Congosto ([@congosto](#)) nos animó a lanzarnos a realizar este trabajo. La amplitud de sus trabajos y la cantidad de herramientas con las que los ha desarrollado dan una visión muy completa de las posibilidades que nos da esta herramienta. En este caso, plantearemos varias reuniones y una línea de trabajo con Mariluz que nos ayudará tanto en esta tarea como en la anterior.

Además de la gran cantidad de trabajos a nivel internacional – y fundamentalmente en inglés-, en esta tarea, buscaremos especialmente grupos de trabajo que pudieran estar realizando desarrollos de análisis de sentimiento y PLN en lengua española. Realizaríamos una tarea de análisis, selección y posterior integración, si aportara valor, en nuestro proyecto.

1.1.3 Plan de proyecto

En el siguiente apartado describiremos nuestro Plan de proyecto. Debido a las diferentes situaciones de los componentes, planteamos una forma de trabajo basada en metodologías ágiles, realizando un seguimiento casi diario, en la medida que fuera posible, por medios electrónicos y videoconferencias.

1.2 Fase 2: Comprensión de los Datos




Ilustración 2. Fase 2_ Comprensión de los datos

1.2.1 Comprender la plataforma X (Twitter)

Uno de los primeros retos a los que nos enfrentamos es el de que apenas conocemos Twitter a nivel técnico (ni tan sólo de usuario experto), con lo que nuestro esfuerzo de comprensión debería empezar desde el punto de vista del usuario. Los pasos que fijamos serán:

1. **Comprensión de la aplicación como usuarios.** Empezaremos a hacer un uso de X-Twitter muy orientado a comprender su usabilidad, características y limitaciones.
2. **Capacidades.** Al ir conociendo la herramienta, buscaremos las posibilidades que proporciona y cómo estas se reflejan en la variedad de mensajes que se pueden generar.
3. **Usabilidad.** Con el objetivo de relacionar el uso con los datos e información que maneja, realizaremos una serie de pruebas que se reflejen entre nuestras distintas cuentas.
4. **API¹.** Estudio detallado del API y de la estructura formal de los tweets.
5. **Relaciones establecidas en API.** Buscaremos establecer un detalle de la relación entre los tweets que generamos, en distintas baterías de pruebas, y su reflejo en el JSON generado por el API.
6. **Accesibilidad al API.** Evaluaremos la disponibilidad del API y qué posibilidades nos proporcionará el acceso gratuito respecto al de pago, descartando este último ya que podríamos construir nuestro proyecto con la recolección de streaming, directo a histórico y scrapping.
7. **Aplicación al entorno político.** En este aspecto, se trabajaría el aspecto de las comunicaciones relacionadas de los tweets que diariamente hablan de determinadas preocupaciones sociales y los que surgen del ámbito político (partidos y sus políticos) y los medios de comunicación. Buscaremos entender cómo se habla en estos “corrillos”.

1.2.2 Selección de herramienta de recolección de Tweets

Uno de los primeros pasos a dar es la selección de herramientas que nos permitan trabajar con la recolección de tweets. Evidentemente deberán cumplir requisitos de integración con el resto de las herramientas que habrían de utilizarse en las siguientes fases del proyecto, pero principalmente debe ser completa, dedicada-especializada, estándar y manejable.

¹ API – Application Programming Interface que permite integrar nuestras aplicaciones a fuentes de datos e información de una forma estándar.

Localizamos herramientas que son de uso académico como T-hoarder² y T-hoarder-kit que resultaron fundamentales para este trabajo a bajo coste. Además, tenían la ventaja de que se habían hecho con ellas trabajos importantes de similares características sobre X-Twitter, y que su instalación y manejo eran muy sencillos.

Para garantizar disponibilidad usaremos Python como herramienta de desarrollo, integrada en los notebooks, que tiene unas capacidades contrastadas en este tipo de problemas y una gran cantidad de librerías disponibles, así como que proporcionará más flexibilidad de manejo que con algún otro producto más cerrado – como son los entornos y frameworks disponibles.

Para la realización del *scraping*, y dado que podremos utilizar Python también; por ejemplo, hay disponible un script de Python muy estable que cumple nuestros requisitos.

1.2.3 Estudiar el estilo de escritura en X-Twitter

Otro de los retos que supone la nueva forma de comunicación en las redes sociales, es conocer, manejar y comprender el estilo de escritura en X-Twitter. En un análisis de sentimientos, es fundamental conocer todas las expresiones, variantes y tendencias que aparecen en tan poco texto.

Además, y dado que el trabajo se hace en tuits con la nueva longitud ampliada de palabras, existe un cambio de formatos y contenidos que deberíamos tener en cuenta.

1.2.4 Recolectar los datos relevantes

Dada la gran cantidad de datos que se propagan en X-Twitter, está claro que deberíamos acotar las capturas a determinados autores. Escucharemos las cuentas de:

- Partidos políticos principales
- Máximo dirigente y portavoz/representante
- Medios de comunicación principales

Con el uso de las siguientes herramientas para los 2 grupos de datos por recopilar (históricos y streaming) y en los autores seleccionados:

- API de X-Twitter. Mediante T-HOARDER-KIT
- Scraping de tweets. Permitiendo la consulta histórica a X-Twitter por usuario.
- Streaming. Con la utilidad T_HOARDER se hizo escucha tanto dirigida (cuentas específicas) como generales.

1.2.5 Comprender y determinar los fenómenos de predicción en Twitter

Una de las tareas más importantes del proyecto será la de buscar fenómenos de predicción en Internet que ayuden a la preparación de nuestros datos, así como al correcto diseño tanto de las pruebas como de los modelos finales.

Esto supondrá una exploración detallada de los datos, sobre todo porque la herramienta los genera en formato .csv, y por tanto, no trabajamos con el formato JSON original de Twitter. Verificaremos, también, la calidad de los datos para evitar la interferencia en la predicción a realizar en la fase posterior correspondiente y que pudieran deberse a errores en la fase previa de comprensión del negocio.

² Puedes ver actualizaciones tanto de T-hoarder como de Gephi con Python que permiten estudios académicos de redes sociales: [Cómo analizar datos de Twitter con t-hoarder, Gephi y Python - YouTube](#)


1.3 Plan de trabajo

En los siguientes apartados incluimos los principales componentes del Plan de Proyecto global. La gestión del proyecto se realizará con metodología ágil, iterando según las tareas descritas en CRISP-DM. Se utilizarán medios electrónicos para el seguimiento diario sobre cada uno de los sprint diseñados.

Los componentes del proyecto llegarán a realizar diferentes tareas por lo que indicamos los perfiles que serían necesarios (algunos podrán cubrirse por una misma persona para tareas que no se solapen).


1.3.1 Perfiles utilizados

Se tendrán en cuenta los siguientes perfiles y organigrama:



1.3.2 Cronograma

A continuación, presentamos el diagrama de Gantt del proyecto completo:



1.3.3 Presupuesto

El presupuesto empleado en el proyecto contempla los siguientes conceptos:

PROYECTO DE ANÁLISIS DE SENTIMIENTOS SOCIALES EN TWITTER	PVP
SERVICIOS PROFESIONALES	59.436,00 €
FASE1. Definición	7.200,00 €
FASE2. Descarga de datos	20.016,00 €
FASE3. Preparación y modelado de datos	20.700,00 €
FASE4. Visualización de resultados y despliegue	11.520,00 €
COSTE INFRAESTRUCTURA	340,00 €
TOTAL PROYECTO	59.776,00 €

[*] Estos datos no incluyen IVA.