


Predicción de calidad del aire

Metodología CRISP-DM

DIAGRAMA GENERAL DE LA METODOLOGÍA CRISP-DM

METODOLOGÍAS PARA LA ANALÍTICA DE GRANDES DATOS



1. Comprensión del Negocio



a. **Objetivos del Negocio**

En los últimos años las sociedades han sido cada vez más conscientes del impacto ambiental que en la ciudades se crea debido al alto grado de contaminación proveniente de combustible fósiles y la indutria, provocando un deterioro del aire que se respira. Esto a su vez provoca que cientos de personas sufran de enfermedades respiratorias, cardiovasculares entre otras. Por otro lado cientos de industrias afectan negativamente al medio ambiente sin ser sancionadas por los gobiernos y perjudicando gravemente a los ciudadanos de las distintas ciudades.

Es por esto que queremos desarrollar una herramienta que ayude tanto a los gobiernos como a las personas, a que generen políticas ambientales y medidas para regular el nivel medio adecuado para poder así aplicar multas aquellas empresas que violen los límites y puedan ser más responsables ambientalmente hablando y también advertir a la ciudadanía del entorno ambiental actual, día a día.




a. Objetivos del Negocio



POR QUÉ UTILIZAMOS DATA MINING

Porque a través de los datos que iremos suministrando al modelo podemos realizar predicciones que ayuden tanto a los gobiernos como a los ciudadanos a tomar las medidas adecuadas que ayuden a salvaguardar la salud pública. Con estas predicciones crearemos conocimiento Este proceso de extracción de conocimiento a partir de los datos, sigue la llamada “Jerarquía del Conocimiento” o “Pirámide DIKW” (data, information, knowledge & wisdom).



a. Objetivos del Negocio

Criterios de éxito:

Cualitativos: la calidad del aire puede ser definida por indicadores o índices preestablecidos que determinan la concentración de contaminantes en el aire ambiente ligada a escalas que califican esa calidad de forma cualitativa un ejemplo de este tipo de índices es el Índice de la Calidad del Aire (ICA).

Cuantitativos: También puede realizarse lo que se conoce como “Metodos Gravimétricos” que son métodos analíticos cuantitativos en los cuales las determinaciones de las sustancias se llevan a cabo por una diferencia de pesos, donde se determina la masa pesando el filtro, a temperatura y humedad relativa controladas, antes y después del muestreo. Otros métodos pueden ser la concentración real del contaminante (ppm, ppb, g/m³, entre otros.) y la respuesta del analizador (lectura en la carta de registro, salida en volts o salida digital).

b. Valorar la situación

Se tomó en cuenta la investigación de trabajos que se han realizado en los últimos años acerca de este mismo tema o temas que traten de resolver problemas parecidos. En los resultados encontrados pudimos darnos cuenta que existen muchos trabajos y empresas que se dedican a realizar estas predicciones para tratar de solventar crisis ambientales en ciertas ciudades.

El análisis documental que se ha realizado, ha servido para averiguar el estado actual de la cuestión que se pretende resolver, esto es la predicción de la calidad del aire.

En la selección de documentos que se ha realizado, se han encontrado numerosas fuentes de datos, conceptos, técnicas, algoritmos, herramientas, etc. Según todos los trabajos revisados, para poder predecir la calidad del aire se necesita de datos, algoritmos y herramientas.



b. Valorar la situación

Las principales herramientas a utilizar son:

Base de datos abiertas. Como ejemplo utilizaremos la de la ciudad de Madrid ya que dispone de datos abiertos y bien detallados. Este acceso al ser abierto no requiere ningún coste.

Trabajaremos con las herramientas de código abierto de Python y R, como herramienta de análisis y de desarrollo de modelo de predicción. Estas herramientas al ser de código abierto tampoco requieren de costes.

Con estos programas procederemos a la utilización de aprendizaje supervisado. Con la finalidad de desarrollar un modelo predictivo.



c. Determinar los objetivos

- Búsqueda de datos abiertos relevantes para la creación del modelo de predicción de la calidad del aire.
- Obtención de datos abiertos relevantes a través de portales web y API's.
- Caracterización de los niveles de contaminación del aire de Madrid en base a datos abiertos.
- Análisis de diferentes algoritmos de aprendizaje automático para la creación de un modelo supervisado para la predicción de la calidad del aire.



d. Realizar el plan del proyecto

<u>Nombre de la tarea</u>	Inicio	Fin	Entradas
Definición del proyecto	22 de abril	24 de abril	Lluvias de ideas.
Búsqueda de información	25 de abril	1 de mayo	Base de datos. Otros trabajos similares. Herramientas de trabajo.
Proceso de ETL	2 de mayo	4 de mayo	Reconocimiento de los datos. Limpieza. Formato
Visualización	5 de mayo	6 de mayo	Vista general de los datos a introducir al modelo.
Creación del modelo	6 de mayo	15 de mayo	R, Python
Reporte final	16 de mayo	20 de mayo	Documento PDF final

2. Comprensión de los Datos



a. Recolectar datos

- Los datos disponibles en la página del ayuntamiento de Madrid proviene en un archivo en formato CSV. El cual tiene las siguientes características:
 - Se encuentran almacenados por mes.
 - Están separados por coma, los texto por doble comilla y los separadores decimales en punto.

Ficheros de climatología	
Campo	Descripción
altitud	Altitud de la estación en m sobre el nivel del mar
dir	Dirección de la racha máxima
fecha	Fecha del día (AAAA-MM-DD)
horaPresMax	Hora de la presión máxima (redondeada a la hora entera más próxima)
horaPresMin	Hora de la presión mínima (redondeada a la hora entera más próxima)
horaracha	Hora y minuto de la racha máxima
horatmax	Hora y minuto de la temperatura máxima
horatmin	Hora y minuto de la temperatura mínima
indicativo	Indicativo climatológico (código de la estación meteorológica)
nombre	Nombre (ubicación) de la estación
prec	Precipitación diaria
presMax	Presión máxima al nivel de referencia de la estación
presMin	Presión mínima al nivel de referencia de la estación
provincia	Provincia de la estación
racha	Racha máxima del viento
tmax	Temperatura Máxima del día
tmed	Temperatura media diaria
tmin	Temperatura Mínima del día
velmedia	Velocidad media del viento en el día

Ficheros de calidad del aire		
Campo	Dígitos	Descripción
Código de estación	8	Código de la estación de calidad del aire
Código de parámetros	2	Código del contaminante medido
Código de técnica analítica	2	Técnica de medición de ese contaminante
Código periodo análisis	2	02 = Datos horarios
Año	2	Año de la medición
Mes	2	Mes de la medición
Día	2	Día de la medición
Hora 1	5	Valor horario de la medición (Hora 1 hasta 24)
Hora 2	5	Valor horario de la medición (Hora 1 hasta 24)
...	...	...
Hora 24	5	Valor horario de la medición (Hora 1 hasta 24)

b. Describir datos

Códigos de parámetros (contaminantes)				
Magnitud	Abreviatura o fórmula	Unidad medida	Técnica de medición	
Dióxido de Azufre	SO ₂	µg/m ³	38	Fluorescencia ultravioleta
Monóxido de Carbono	CO	mg/m ³	48	Absorción infrarroja
Monóxido de Nitrógeno	NO	µg/m ³	8	Quimioluminiscencia
Dióxido de Nitrógeno	NO ₂	µg/m ³	8	Id.
Partículas < 2.5 µm	PM _{2.5}	µg/m ³	47	Microbalanza
Partículas < 10 µm	PM ₁₀	µg/m ³	47	Id.
Óxidos de Nitrógeno	NO _x	µg/m ³	8	Quimioluminiscencia
Ozono	O ₃	µg/m ³	6	Absorción ultravioleta
Tolueno	TOL	µg/m ³	59	Cromatografía de gases
Benceno	BEN	µg/m ³	59	Id.
Etilbenceno	EBE	µg/m ³	59	Id.
Metaxileno	MXY	µg/m ³	59	Id.
Paraxileno	PXY	µg/m ³	59	Id.
Ortoxileno	OXY	µg/m ³	59	Id.
Hidrocarburos totales (hexano)	TCH	mg/m ³	2	Ionización de llama
Metano	CH ₄	mg/m ³	2	Id.
Hidrocarburos no metánicos (hexano)	NMHC	mg/m ³	2	Id.

3. Preparación de los Datos



a. Estructurar datos

- En los datos que describen la calidad del aire podemos ver que hay valores atípicos pero que son validos asi que no se descartarán.
- También dentro de los datos podemos encontrar valores vacíos que nos pueden perjudicar el modelo de predicción así que en los valores faltantes se les pondrá un valor que representa la mediana.

b. Integrar datos

De cada dataframe se realiza una selección de los datos útiles para construir el modelo y se integran en un solo dataframe que una los datos diarios de calidad del aire, climatología y calendario laboral.

Los campos seleccionados de cada dataframe son los siguientes:

- Dataframe calidadAire:

Campos: estacion, fecha, contaminante, hora1, hora2, hora3, hora4, hora5, hora6, hora7, hora8, hora9, hora10, hora11, hora12, hora13, hora14, hora15, hora16, hora17, hora18, hora19, hora20, hora21, hora22, hora23, hora24

- Dataframe clima:

Campos: fecha, prec, presMax, presMin, tmax, tmed, tmin, racha, velMedia

- Dataframe calendario:

Campos: fecha, tipoDia

c. Formatear datos

Se cambia el nombre del campo “tipoDia” por “laborable” y se codifica con valores 0/1 de la siguiente forma:

Valor = codificación:

“festivo” = 0

“sábado” = 0

“domingo” = 0

“laborable” = 1

4. Modelado



a. Seleccionar técnica de modelado



Una vez seleccionados, integrados, transformados y preprocesados los datos, el siguiente paso consiste en realizar el modelado, es decir, la búsqueda del modelo que cumpla con el objetivo y que mejor se adapte a los datos que se disponen.

Para este proyecto se han identificado varias técnicas de machine learning con el objetivo de crear un modelo de predicción de calidad del aire. Tres de ellas consisten en un modelo basado en redes neuronales de tipo Multilayer Perceptron (MLP), Long Short-Term Memory (LSTM), Convolutional Neural Network (CNN) y la última está basada en algoritmos de aprendizaje supervisado llamados Support Vector Machines (SVM).

b. Generar plan de prueba

Para probar la calidad y validez de cada modelo se utilizará como medida de evaluación la Raíz del Error Cuadrático Medio. La Raíz del Error Cuadrático Medio o RMSE por sus siglas en inglés es la medida más habitual para evaluar un modelo de regresión. Su cálculo proporciona las diferencias entre los valores pronosticados por el modelo y los valores reales a partir de los que se ha creado el modelo.

Para afinar la búsqueda de los parámetros que generan el mejor modelo, se programará un benchmark para cada uno de los modelos (Multilayer Perceptron (MLP), Long Short-Term Memory (LSTM), Convolutional Neural Network (CNN) y Support Vector Machines (SVM)) de forma que se prueben y combinen diferentes valores para los principales parámetros de cada modelo.

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}$$