

Proyecto – Fase 1

Metodología CRISP-DM

Programa Profesional en Inteligencia Artificial y Data Science


01 Metodología CRISP-DM

Cross Industry Standard Process for Data Mining


La sucesión de fases no es necesariamente rígida.

Cada fase es estructurada en varias tareas generales de segundo nivel.

Las tareas generales se proyectan a tareas específicas, donde finalmente se describen las acciones que deben ser desarrolladas para situaciones específicas




01 Metodología CRISP-DM



01 Metodología CRISP-DM

Fase 1: Conocimiento del negocio



01 Metodología CRISP-DM

Fase 1: Conocimiento del negocio

- **Determinar los objetivos del negocio:** cuál es el problema que se desea resolver, por qué la necesidad de utilizar IA (inicialmente utilizado sólo para Data Mining) y definir los criterios de éxito (de forma cualitativa o cuantitativa).
- **Evaluación de la situación:** se debe calificar el estado de la situación antes de iniciar el proceso de IA, considerando aspectos tales como: ¿cuál es el conocimiento previo disponible acerca del problema?, ¿se cuenta con la cantidad de datos requerida para resolver el problema?, ¿cuál es la relación coste beneficio de la aplicación de IA?, etc. Se definen los requisitos del problema, tanto en términos de negocio como en términos de IA (DM, Ciencia de Datos,...).
- **Determinación de los objetivos de DM (IA):** tiene como objetivo representar los objetivos del negocio en términos de las metas del proyecto de IA, será, por ejemplo, si el objetivo del negocio es el desarrollo de una campaña publicitaria para incrementar la asignación de créditos hipotecarios, la meta de IA será, por ejemplo, determinar el perfil de los clientes respecto de su capacidad de endeudamiento.
- **Producción de un plan del proyecto.** Finalmente, esta última tarea de la primera fase de CRISP-DM, tiene como meta desarrollar un plan para el proyecto, que describa los pasos a seguir y las técnicas a emplear en cada paso.


01 Metodología CRISP-DM

Fase 1: Conocimiento del negocio

- La familiarización con el dominio del problema y la obtención de conocimiento a priori disminuye el espacio de soluciones posibles
 - más eficiencia en el resto del proceso
- En problemas de IA se suele trabajar con datos de diferentes conjuntos de datos
 - es conveniente agrupar y unificar la información
- Unificación de la información en un Datawarehouse (DW) o DataLake como sistema analítico a partir de:
 - Información interna: distintas BBDD diseñadas para trabajo transaccional y de otro tipo (hojas de cálculo, informes,...)
 - Estudios publicados (demografía, catálogos, páginas, ...)
 - Otras bases de datos (compradas, industrias/empresas afines,...) y/o conjuntos de datos

01 Metodología CRISP-DM

Fase 2: Conocimiento de los datos



01 Metodología CRISP-DM

Fase 2: Conocimiento de los datos

- El DW/DL es conveniente. A veces se trabaja directamente con la BD o con las BBDD en formatos heterogéneos:
 - **Recolección de datos iniciales.** La primera tarea en esta segunda fase del proceso de CRISP-DM, es la recolección de los datos iniciales y su adecuación para el futuro procesamiento. Esta tarea tiene como objetivo, elaborar informes con una lista de los datos adquiridos, su localización, las técnicas utilizadas en su recolección y los problemas y soluciones inherentes a este proceso.
 - **Descripción de los datos.** Después de adquiridos los datos iniciales, estos deben ser descritos. Este proceso involucra establecer volúmenes de datos (número de registros y campos por registro), su identificación, el significado de cada campo y la descripción del formato inicial.
 - **Exploración de datos.** Se procede a su exploración, cuyo fin es encontrar una estructura general para los datos. Esto involucra la aplicación de pruebas estadísticas básicas, que revelen propiedades en los datos recién adquiridos, se crean tablas de frecuencia y se construyen gráficos de distribución. La salida de esta tarea es un informe de exploración de los datos.
 - **Verificación de la calidad de los datos.** Se efectúan verificaciones sobre los datos, para determinar la consistencia de los valores individuales de los campos, la cantidad y distribución de los valores nulos, y para encontrar valores fuera de rango, los cuales pueden constituirse en ruido para el proceso. La idea en este punto es asegurar la completitud y corrección de los datos.


01 Metodología CRISP-DM

Fase 2: Conocimiento de los datos

- Esta fase arranca con una colección inicial de datos. El analista procede a familiarizarse con los datos, identificar la calidad de los mismos, descubrir ideas iniciales en los datos o detectar subconjuntos para formar hipótesis sobre información escondida
- La calidad del conocimiento descubierto no depende sólo del algoritmo de IA sino de la calidad de los datos minados
- Incluye cuatro pasos:
 - recolección inicial de los datos
 - descripción de los mismos
 - exploración
 - verificación de su calidad

01 Metodología CRISP-DM

Fase 3: Preparación de los datos



01 Metodología CRISP-DM

Fase 3: Preparación de los datos

- **Estructuración de los datos.** incluye las operaciones de preparación de los datos tales como la generación de nuevos atributos a partir de atributos ya existentes, integración de nuevos registros o transformación de valores para atributos existentes..
- **Integración de los datos.** involucra la creación de nuevas estructuras, a partir de los datos seleccionados, por ejemplo, generación de nuevos campos a partir de otros existentes, creación de nuevos registros, fusión de tablas campos o nuevas tablas donde se resumen características de múltiples registros o de otros campos en nuevas tablas de resumen
- **Formateo de los datos.** realización de transformaciones sintácticas de los datos sin modificar su significado, esto, con la idea de permitir o facilitar el empleo de alguna técnica de IA en particular, como por ejemplo la reordenación de los campos y/o registros de la tabla o el ajuste de los valores de los campos a las limitaciones de las herramientas de modelación (eliminar comas, tabuladores, caracteres especiales, máximos y mínimos para las cadenas de caracteres, etc.).

01 Metodología CRISP-DM

Fase 3: Preparación de los datos

- Cubre todas las actividades para construir el conjunto final de los datos que serán utilizados en la(s) herramienta(s) de modelado. Las tareas incluyen la selección de tablas, registros y atributos, así como la transformación y limpieza de los datos para las herramientas de modelado.
- Las técnicas utilizadas para asegurar la calidad de los datos y que estén en la forma adecuada son:
 - limpieza
 - transformación
 - reducción de la dimensionalidad

01 Metodología CRISP-DM

Fase 3: Preparación de los datos

Técnica de Limpieza o 'data cleaning'

- Datos perdidos (*missing values*)
 - Pueden llevar a resultados poco precisos
 - Hay que analizar el motivo
 - Mal funcionamiento del dispositivo de recogida de datos
 - Cambios efectuados durante la recolección de datos
 - Datos que provienen de fuentes diversas
- Soluciones: rellenarlos manualmente, ignorarlos, eliminar la fila/columna, usar un valor especial (p.e. *unknown*, *undefined*...), inferirlos usando técnicas estadísticas,...
- Datos anómalos (*outliers*)
 - Valores que no se ajustan al comportamiento general de los datos
 - Pueden ser erróneos o correctos pero diferentes a los demás
 - Primero hay que identificarlos, y después, en función del problema se tratarán como valores perdidos o se sacará información de ellos
- Inconsistencias: registros duplicados, datos inconsistentes, ... Normalmente ya tratado en la elaboración del DW

01 Metodología CRISP-DM

Fase 3: Preparación de los datos

Técnica de Transformación

- Construcción de atributos: construir nuevos atributos aplicando alguna operación a los atributos originales (agrupamiento, separación, fecha a enteros, convertir en números los valores categóricos...)
 - cuando los atributos no tienen mucho poder predictivo por sí solos,
 - cuando los patrones dependen de variaciones lineales de las variables globales
- En ocasiones => almacenar meta-información sobre la información realmente almacenada por cada campo
- Discretización:
 - Pasar atributos continuos (o discretos con muchos valores) a casos discretos manejables o a categóricos
 - Hay diversas técnicas
 - Es imprescindible para muchos algoritmos de MD

01 Metodología CRISP-DM



Fase 3: Preparación de los datos

Técnica de Reducción de la dimensionalidad

- Reducción de casos / filas:
 - Puede hacer más eficiente el proceso de IA.
 - Las técnicas utilizadas van desde la compresión al muestreo de los datos, pasando por la elección de representantes (*clustering*).
- Selección de variables (**feature selection**): Seleccionar el conjunto de atributos adecuado para la tarea específica a realizar:
 - Se conoce también como proyección
 - Es uno de los pre-procesamientos más importantes
 - Técnicas utilizadas para esta tarea: estadísticas, basadas en búsqueda combinadas con métodos empíricos,...

01 Metodología CRISP-DM

Fase 4: Modelado de los datos



01 Metodología CRISP-DM

Fase 4: Modelado de los datos

- **Selección de la técnica de modelado.** Esta tarea consiste en la selección de la técnica de IA más apropiada al tipo de problema a resolver. Para esta selección, se debe considerar el objetivo principal del proyecto y la relación con las herramientas de IA existentes. Por ejemplo, si el problema es de clasificación, se podrá elegir de entre árboles de decisión...
- **Generación del plan de prueba.** procedimiento destinado a probar la calidad y validez del mismo. Por ejemplo, en una tarea supervisada típicamente se separan los datos en dos conjuntos, uno de entrenamiento y otro de prueba, para luego construir el modelo basado en el conjunto de entrenamiento y medir la calidad del modelo generado con el conjunto de prueba
- **Construcción del Modelo.** Después de seleccionada la técnica, se ejecuta sobre los datos previamente preparados para generar uno o más modelos. Todas las técnicas de modelado tienen un conjunto de parámetros que determinan las características del modelo a generar. La selección de los mejores parámetros es un proceso iterativo y se basa exclusivamente en los resultados generados. Estos deben ser interpretados y su rendimiento justificado.
- **Evaluación del modelo.** Se interpretan los modelos de acuerdo al conocimiento preexistente del dominio y los criterios de éxito preestablecidos. Expertos en el dominio del problema juzgan los modelos dentro del contexto del dominio y expertos en IA aplican sus propios criterios (seguridad del conjunto de prueba, pérdida o ganancia de tablas, etc...).

01 Metodología CRISP-DM

Fase 4: Modelado de los datos

- **Objetivo:** Producir nuevo conocimiento que pueda utilizar el usuario
- **¿Cómo? Construyendo** un modelo, basado en los datos recopilados, que sea una descripción de los patrones y relaciones entre los datos con los que se puedan hacer predicciones, entender mejor los datos o explicar situaciones pasadas
- **Decisiones a tomar:**
 - ¿Qué tipo de conocimiento buscamos?
 - Predictivo
 - Descriptivo
 - ¿Qué técnica es la más adecuada?
 - Clasificación / Regresión / Agrupamiento (clustering) / Asociaciones, ...
 - ¿Qué tipo de modelo?
 - Por ej.: Clasificación: reglas, redes neuronales, árboles de decisión,...
 - ¿Es necesaria la incertidumbre en el modelo resultante? Certeza, probabilidad, lógica difusa,...
 - ¿Qué algoritmo es el más adecuado? Por ej.: en clustering: duro, jerarquizado, k-means, iterativo, EM, ...

01 Metodología CRISP-DM


Fase 4: Modelado de los datos - Evaluación

- **Medidas de evaluación de modelos:** Dependen de la tarea:
 - ✓ **Clasificación:** precisión predictiva (%acierto)
 - ✓ **Regresión:** Error cuadrático medio
 - ✓ **Agrupamiento:** Medidas de cohesión y separación entre grupos
 - ✓ **Reglas de asociación:** cobertura, confianza...

- **Ejemplo Técnicas de evaluación:** Al menos se divide el conjunto de datos en dos (entrenamiento y test)
 - ✓ **Entrenamiento:** Para extraer el conocimiento
 - ✓ **Test:** Para probar la validez del conocimiento extraído
 - ✓ **Alternativas:**
 - o Validación simple
 - o n-validación cruzada
 - o *Bootstrapping, Bagging...*

01 Metodología CRISP-DM

Fase 5: Evaluación



01 Metodología CRISP-DM

Fase 5: Evaluación

- **Evaluación de los resultados.** Evaluación del modelo en relación a los objetivos del negocio y busca determinar si hay alguna razón de negocio para la cual, el modelo sea deficiente, o si es aconsejable probar el modelo, en un problema real si el tiempo y restricciones lo permiten.
Además de los resultados directamente relacionados con el objetivo del proyecto, ¿es aconsejable evaluar el modelo en relación a otros objetivos distintos a los originales?, esto podría revelar información adicional.
- **Proceso de revisión.** El proceso de revisión se refiere a calificar al proceso entero de IA, a objeto de identificar elementos que pudieran ser mejorados.
- **Determinación de futuras fases.** Si se ha determinado que las fases hasta este momento han generado resultados satisfactorios, podría pasarse a la fase siguiente, en caso contrario podría decidirse por otra iteración desde la fase de preparación de datos o de modelación.


01 Metodología CRISP-DM

Fase 5: Evaluación

- La fase de IA puede producir varias hipótesis de modelos
- Es necesario establecer qué modelos son los más válidos
- **Criterios:** los patrones descubiertos deben ser
 - precisos,
 - comprensibles, e
 - interesantes (útiles, novedosos)
- La interpretación de los mejores modelos (visualización, simplicidad, posibilidad de integración, ventajas colaterales, ...) ayuda a la selección del modelo(s) final(es)

01 Metodología CRISP-DM

Fase 6: Despliegue



01 Metodología CRISP-DM

Fase 6: Despliegue

- **Plan de implementación.**
 - Para implementar el resultado de DM en la organización, esta tarea toma los resultados de la evaluación y concluye una estrategia para su implementación.
 - Si un procedimiento general se ha identificado para crear el modelo, este procedimiento debe ser documentado para su posterior implementación.
- **Monitorización y Mantenimiento.**
 - Si los modelos resultantes del proceso de Data Mining son implementados en el dominio del problema, como parte de la rutina diaria es aconsejable preparar estrategias de monitorización y mantenimiento para ser aplicadas sobre los modelos.
 - La retroalimentación generada por la monitorización y mantenimiento pueden indicar si el modelo está siendo utilizado apropiadamente
- **Informe Final.**
 - Es la conclusión del proyecto de DM realizado.
 - Dependiendo del plan de implementación, este informe puede ser sólo un resumen de los puntos importantes del proyecto y la experiencia lograda o puede ser una presentación final que incluya y explique los resultados logrados con el proyecto.
- **Revisión del proyecto:** En este punto se evalúa qué fue lo correcto y qué lo incorrecto, qué es lo que se hizo bien y qué es lo que se requiere mejorar

01 Metodología CRISP-DM

Fase 6: Despliegue

Una vez construido y validado el modelo puede utilizarse:

- o para recomendar acciones
- o para aplicar el modelo a diferentes conjuntos de datos

En cualquier caso, es necesario:

- o **Difusión**: Elaboración de informes para su distribución.
- o **Utilización** del nuevo conocimiento de forma independiente
- o **Incorporación** a sistemas ya existentes
 - comprobar con el conocimiento ya utilizado para evitar inconsistencias y posibles conflictos

La monitorización del sistema en acción dará lugar a nuevos casos que realimentarán el ciclo de CRISP-DM.

Las conclusiones iniciales pueden variar, invalidando el modelo adquirido.