

UNIDAD FORMATIVA 6

L02.Principios Éticos en Inteligencia Artificial

Módulo 1. Modelos de Inteligencia Artificial

Índice

Ideas Clave	2
6.3 Deontología profesional en Inteligencia Artificial (IA)	3
6.4 Principios Éticos en IA	4
6.5. Mecanismos para cumplir legal y éticamente	6
6.5.1. Datos en las empresas	7
6.5.1. Amenazas del uso sin control de datos	9
6.5.2. Acercamiento al concepto de anonimización	10
6.5.2.1. El caso de código postal, fecha de nacimiento y sexo	11
6.6. Sesgos, legalidad y responsabilidad	14
6.6.1. Sesgos: el motivo por el que los algoritmos aprenden y su principal punto débil	15
6.6.2. Seguridad y tolerancia ante ataques	20
6.6.3. Explicabilidad de algoritmos	22
A fondo	24

Ideas Clave

Para estudiar este tema lee las **Ideas clave** propuestas en el tema y revisa los contenidos adicionales para mejorar la comprensión y aumentar los conocimientos sobre las materias tratadas.

Este tema aborda los principios de la deontología profesional y así como la ética en el ámbito de la Inteligencia Artificial.

Del mismo modo, en el campo formativo de la tecnología y sobre todo en el mundo de la Inteligencia Artificial que debemos formarnos en el conocimiento de la legislación en materia de uso y protección de esos datos porque serán parte componente en el desarrollo de los requisitos y funcionalidades de la aplicación práctica de la IA, es crítico **considerar los aspectos éticos y sociales que están asociados a criterios de creación de sistemas IA como puede ser la selección y desarrollo de algoritmos.**

Para ello Identificar nuevas tendencias regulatorias que implican cambios a la hora de trabajar con datos. Revisaremos en detalle un caso ampliamente conocido en la aplicación de los principios legales dentro de la IA, de forma que podamos ver en la práctica qué debemos tener en cuenta y cómo hacerlo.

Por último, nos introduciremos en uno de los problemas éticos más importantes en la actualidad: **los sesgos y su posible uso discriminatorio.** Un aspecto que ha pasado a ser cubierto por la legislación reguladora de la protección de datos.

6.3 Deontología profesional en Inteligencia Artificial (IA)

La **deontología profesional** (to deon = lo debido y logía = estudio) nos introduce en el ámbito de la ética, y hace referencia a la rama de ésta que tiene por objeto estudiar los fundamentos del deber y las normas morales.

Al desempeñar cualquier actividad profesional, debemos integrar nuestra actuación bajo una serie de normas y premisas, no sólo éticas sino también morales, que garanticen el buen hacer y la diligencia en el ejercicio de nuestra profesión. Esto es lo que se denomina **ética profesional**.

Para comprender de forma inicial el concepto de **deontología profesional**, vamos a acudir a alguna definición interesante, así como los conceptos relacionados en que nos introduce.

Deontología

1. f. Parte de la ética que trata de los deberes, especialmente de los que rigen una actividad profesional.
2. f. Conjunto de deberes relacionados con el ejercicio de una determinada profesión.

Diccionario de la Real Academia Española

Deontología profesional

1. Gral. Conjunto de reglas relacionadas con el ejercicio de cada profesión que, en su caso, pueden codificarse en un código deontológico.
2. Gral. Competencia colegial sancionadora de los ilícitos relacionados con el ejercicio de la profesión.

Diccionario panhispánico del español jurídico

En esta definición, dentro de su primera acepción, nos encontramos con un término, **código deontológico**, que nos introduce ya en un mundo de reglas y de buenas prácticas: "Conjunto estructurado de reglas de diversa naturaleza (disposiciones, costumbres, precedentes, etc.) que atienden a las buenas prácticas en el ejercicio de la profesión y en las actuaciones propias que se derivan de ella" (Diccionario panhispánico del español jurídico).

Como vemos, una característica fundamental es que la deontología profesional tiene un fuerte componente regulatorio interno y de carácter colectivo. Es decir, busca interiorizar normas propias de una profesión. Podemos entenderla a su vez en 2 sentidos:

- **Amplio:** Considera todas las normas que atañen a la profesión, tanto estatutos profesionales como convenios colectivos y otros.
- **Estricto:** Conjunto estructurado y sistemático de normas, reglas, usos, principios y deberes que no se respaldan en una sanción legal sino en una aceptación voluntaria de unos profesionales.

Este código deontológico se plasma en un documento que recoge un conjunto de principios, normas y valores que formulan en una determinada profesión y que asumen quienes llevan a cabo esa actividad profesional. Suele estar elaborado por los colegios profesionales que son corporaciones de derecho público, amparadas por la ley y reconocidas por el Estado, con personalidad jurídica propia y plena capacidad para el cumplimiento de sus fines.

Sus funciones principales son las de:

- Fijar criterios, de carácter científico-funcional para el ejercicio de la profesión.
- Consolidar y refundir orientaciones éticas para el ejercicio de la profesión.
- Posibilitar la imposición de sanciones disciplinarias.

Como podemos ver trata de establecer unos **valores que se han de aplicar de forma individual, pero que tienen un beneficio colectivo tanto profesional como en el ámbito social**. Por ello, no olvidemos que su objetivo es el **bien común**.

Es importante que el lector se acerque a la lectura del **código deontológico de la profesión Informática** si queremos contribuir a construir una sociedad sólida y con principios que consideren importante el respeto a los demás. Para contribuir a ello os proponemos la lectura del código y su reflexión en el capítulo “A fondo” que acompaña esta lección.

6.4 Principios Éticos en IA

Estamos asistiendo a un cambio de era tecnológico en el que el debate sobre la inteligencia artificial y las disciplinas que están unidas a ella, aprendizaje automático y robótica como máximos exponentes, está adquiriendo cada vez mayor relevancia social. No se trata tan sólo de una nueva tecnología, sino que sus productos impactan de forma directa en la economía, el empleo y la sociedad en su totalidad, así como en el ser humano en particular.

De un tiempo a esta parte, diferentes instituciones – estados y gobiernos, universidades, así como la industria – están comenzando a plantear también los dilemas éticos que serán la base de la legislación futura.

Podemos destacar 2 grupos diferentes, pero con finalidades comunes, que están trabajando en este sentido: por un lado, las aproximaciones institucionales europeas como el **Parlamento Europeo**; por otro lado, grupos de expertos del mundo anglosajón como por ejemplo el grupo de científicos reunidos en

Asilomar (California) o los trabajos e informes realizados por Universidades como Stanford, MIT o Harvard.

Todos ellos han desarrollado de manera paralela una serie de principios y valores éticos sobre la inteligencia artificial y la robótica. En ambos casos, la preocupación por la ética se basa en la creciente conciencia de la necesidad de regular, en un futuro próximo, los avances en este campo. Todo ello basado en preservar valores compartidos como son: **el respeto por la dignidad humana, la libertad, la seguridad, la privacidad, la búsqueda del bien común, la inclusión, la no utilización militar...**y que sean la base de las leyes y regulaciones futuras

Por un lado, el Parlamento en la legislación sobre inteligencia artificial trata de orientarlo a que Europa se convierta en el centro mundial de una inteligencia artificial que genere confianza. Para ellos se ha creado una [comisión especial sobre Inteligencia Artificial](#), que según su presidente traslada que: "Europa necesita desarrollar una inteligencia artificial que genere confianza, elimine cualquier tipo de sesgo y discriminación, contribuya al bien común al tiempo que asegure que las empresas y la industria prosperan y generan prosperidad económica".

Por otro lado, los grupos americanos se acercan a la problemática desde una consideración de fondo clara: un profundo cambio está llegando y afectará a toda la sociedad y las personas que tengan algún tipo de responsabilidad en esta transición tienen tanto una gran responsabilidad como la oportunidad de darle la mejor forma posible. En el caso del **encuentro en Asilomar**, tras meses de deliberaciones se concluyó con un acuerdo marco que incluía **23 principios** no exhaustivos, pero ampliamente respaldados que buscan que la IA mejore la vida del hombre y de la sociedad. Los agruparon en 3 consideraciones generales: **a) Principios relativos a la investigación; b) Ética y valores; y c) Temas a largo plazo.**

La forma de abordar estos principios nos lleva a encontrar 2 aproximaciones diferentes: **la europea más institucional** (o legalista) con comités, subcomités, informes, propuestas, libros blancos y marcos legales (más o menos obligatorios), frente al **modo de hacer americano** de construir a través de una discusión más flexible, abierta y voluntaria. En ambos casos podemos observar que existen una serie de puntos comunes de realizar esta aproximación a la ética de la IA y que podemos resumir en que:

- La IA debe realizarse por el **bien de la humanidad** y **beneficiar al mayor número**. Es necesario reducir el riesgo de exclusión.
- Los **estándares** con respecto a la IA deben ser **altísimos en lo que respecta a la seguridad de los humanos**: Para ello, es necesario un control ético y

finalista de investigación, transparencia y cooperación en el desarrollo de la Inteligencia Artificial.

- Los **investigadores y diseñadores tienen una responsabilidad** crucial: toda la investigación y desarrollo de la IA debe estar caracterizada por la transparencia, la reversibilidad y trazabilidad de los procesos.
- Se hace necesario el **control humano**: que en todo momento sean los humanos los que decidan qué pueden hacer o no los sistemas robóticos o basados en IA.
- **Gestionar el riesgo**: Cuanto más grave sea el riesgo potencial, más estrictos deberán ser los sistemas de control y gestión del riesgo.
- **Prohibir de forma taxativa** el desarrollo de la IA para realizar **armas de destrucción**.
- **Incertidumbre**: Se reconoce que los avances en estos campos son inciertos, en ámbitos y alcances que en ciertos casos son inimaginables. Por ello, las regulaciones y marcos deben repensarse en el medio plazo cuando otros avances se hayan hecho realidad.

6.5. Mecanismos para cumplir legal y éticamente

Actualmente, hay un amplio debate sobre la potencial amenaza que, desde el punto de vista de la protección de datos y el derecho a la intimidad, presenta esta acumulación ingente de datos y sus potenciales usos, vislumbrándose grandes y significativos riesgos.

No se cuestiona una tecnología que ya está ofreciendo importantes avances en áreas de amplio consenso, en relación con el beneficio que generan a la sociedad, como es el caso de la ciencia; **pero sí se cuestiona el uso que de las mismas se pueda derivar y la afectación que esto pueda tener para los ciudadanos.**

Es en este marco donde la presencia de gobiernos y empresas con ingentes cantidades de datos sobre los ciudadanos se perciben como una amenaza no solo sobre la privacidad sino sobre su libertad.

Potencialmente podrían facilitar un conocimiento amplio e íntimo de los individuos, a los que además se les podría someter a decisiones «automatizadas» en base a dicho conocimiento. La amenaza de un potencial Big Brother que sepa todo sobre nosotros, facilitado por un mundo híper conectado en el que el acceso a multitud de fuentes de datos y su tratamiento permita descubrir el perfil más íntimo de las personas – el yo más íntimo – en el que quedarían integrados: pensamientos, deseos, ilusiones, conductas, etc.

La amenaza se fundamentaría por un lado en la trazabilidad de nuestros actos y conductas en Internet, donde existe una continua captación de datos sobre nuestras interacciones, que además podría reflejar nuestras conductas más íntimas, gracias a una falsa percepción de anonimato por parte del individuo. En este contexto sería posible ligar las acciones del yo-virtual con el yo-real, algo que con la incorporación de altas capacidades de tratamiento y fuentes adicionales de información se presupone muy posible.

Esta amenaza se materializaría en las decisiones que en base a este conocimiento de las personas se podrían fundamentar, bien a través de un conocimiento particular de cada individuo o bien a través de la aplicación de patrones o perfiles. Una decisión que podría tener carácter predictivo, basada en un histórico de datos y su acomodo en perfiles establecidos, e incluso aplicar decisiones sobre hechos no realizados pero que por inferencia sí se producirían, lo que podríamos llamar una «seguridad preventiva», tal y como se trataba, por ejemplo, en la película *Minority Report*.

Este debate mediático se puede seguir fácilmente por los recurrentes artículos o entradas en blogs presentes en Internet.

Al margen de este debate «apocalíptico», la discusión habría que centrarla en cómo crear un equilibrio que garantice la privacidad y protección de datos de los ciudadanos, al mismo tiempo que da respuesta a las necesidades de las empresas.

El reto está en que estos usos se desarrollen sin comprometer los derechos de los ciudadanos, el derecho a la privacidad y a la protección de datos personales: sin atentar contra los derechos y libertades de los individuos.

6.5.1. Datos en las empresas

Las tecnologías de análisis de grandes datos son, sin duda, una gran oportunidad para las empresas, al facilitar la búsqueda de la obtención de patrones y correlaciones que pueden no ser evidentes y sí útiles para el negocio.

Un ámbito que adquiere especial protagonismo, como ya hemos comentado, es el área de *marketing*, en la búsqueda no solo de conocer mejor a los clientes en lo referente a sus preferencias y comportamientos de compra, sino también para facilitar la toma de decisiones sobre los mismos. Esto puede llegar a suponer una ventaja competitiva con relación a:

El desarrollo del producto

El desarrollo del mercado

La eficiencia operativa

La experiencia y lealtad
del cliente

Las predicciones de la
demanda del mercado

En este contexto los datos personales que manejan las empresas son:





Ilustración 1.Fuente: Big Data: impactos y beneficios (ISACA.org)

Estas fuentes dispares, tras lo expuesto en los temas anteriores, fácilmente nos van a llevar a pensar que el tratamiento de estos datos no es indiferente para las regulaciones en protección de datos y que cumplir con las obligaciones de la normativa debe ser un objetivo clave en los procesos de *Big Data*.

El incumplimiento de la normativa no solo puede tener **repercusiones económicas**, un riesgo económico importante mediante sanciones, sino también un **riesgo reputacional** que convierta una ventaja competitiva en una amenaza al ser una “ventaja” ilícita. Las empresas deberán, por tanto, gestionar los riesgos derivados del cumplimiento normativo en protección de datos.

Pero, es más, vivimos en un mundo que está ampliamente globalizado, Internet facilita que ciudadanos de un extremo del mundo interactúen con entidades ubicadas en el polo opuesto del planeta y, seguramente, sometidos a regulaciones en materia de privacidad y protección de datos muy diferentes. Por tanto, las empresas deberán gestionar esta disparidad legislativa y la potencial inseguridad jurídica que pueda introducir en sus operaciones

Esta disparidad de regulación en un ámbito capaz de generar ventajas **competitivas “sin fronteras”**, somete a obligaciones bien diferentes para sus actores, en función de la legislación aplicable. Esta desigualdad, en cuanto las reglas de juego, puede incidir negativamente sobre aquellas entidades que estén sometidas a marcos regulatorios más estrictos. Esta es una de las importantes críticas que se vierten sobre la legislación de la Unión Europea en materia de protección de datos.

6.5.1. Amenazas del uso sin control de datos

En el documento «*Opinion 03/2013 on purpose limitation*» elaborado por el WP29, identifica cinco importantes amenazas en materia de protección de datos derivadas del uso extensivo de los datos (mundo IA y Big Data):

- » **La magnitud de la recopilación de datos, la capacidad de seguimiento y elaboración de perfiles de los individuos**, teniendo en cuenta la variedad y el detalle de los datos recopilados y la combinación de los datos con diferentes fuentes pueden ser una importante amenaza a la privacidad de las personas y el derecho a la determinación informativa.
- » **La seguridad de los datos**, que no siempre responde a los riesgos de la información que es tratada, configurándose niveles de protección muy a la zaga de la expansión en el volumen; facilitando situaciones de potencial gran impacto sobre los ciudadanos como por ejemplo en el caso accesos no autorizados por «atacantes» cibernéticos.
- » **La transparencia**: la posible desprotección del ciudadano frente a unos usos sobre los que no se le proporciona suficiente información para poder ejercitar de manera adecuada sus derechos, el sometimiento de los ciudadanos a decisiones que no entienden y sobre las que no tienen ningún control.
- » **La inexactitud, la discriminación, la exclusión y el desequilibrio económico** entre las grandes corporaciones y el ciudadano, que limitan las capacidades del ciudadano en la defensa de sus intereses.

- » **El dramático aumento de las posibilidades de vigilancia del gobierno.** Que facilita una capacidad de supervisión y acceso a información sobre el comportamiento de los individuos, con la capacidad de generar inferencias sobre aspectos políticos, filosóficos, religiosos; nos disponibles hasta ahora.

En el texto se considera además que el **tipo de técnicas** de análisis empleado puede llevar a resultados que son **inexactos, discriminatorias o ilegítimos**. Por ejemplo: un algoritmo podría detectar una correlación «errónea» y, a continuación, dibujar una inferencia estadística, de manera que cuando se aplique para informar en acciones comerciales o en la toma de decisiones, estas podrían ser injustas y discriminatorias. Esto puede perpetuar los prejuicios y los estereotipos existentes y agravar los problemas de la exclusión social y la estratificación de clases.

Además, y en términos más generales, la disponibilidad de grandes conjuntos de datos y las herramientas de análisis sofisticadas utilizadas para examinar estos, **no están al alcance de todos y puede potenciar el desequilibrio económico entre las grandes empresas, por un lado, y los consumidores, por el otro**. Este desequilibrio económico puede dar lugar, por ejemplo, a una discriminación de precios injusta con respecto a los productos y servicios que se ofrecen, así como a anuncios y ofertas dirigidas altamente intrusivas, perturbadoras, y personalizadas.

También **podría dar lugar a otros efectos significativos adversos** en las personas, por ejemplo, con respecto a las oportunidades de empleo, préstamos bancarios, u opciones de seguro de salud.

6.5.2. Acercamiento al concepto de anonimización

En la RGPD la **seudonimización** se encuentra definida en el Art. 4.5) del Reglamento, como la información que, sin incluir los datos denominativos de un sujeto afectado permiten, a través de la asociación con información adicional, determinar quién es el individuo que está detrás de los datos seudonimizados.

Uno de los términos que más vamos a escuchar en el ámbito de la analítica de datos personales es la **anonimización**. Ya hemos visto en la lección anterior como se define por la AEPD como “la ruptura de la cadena de identificación de las personas.” Por ejemplo, si únicamente enviamos nombres de personas físicas (sin otra información adicional como dni, apellidos, etc.) que la puedan hacer identificable.

La generación de modelos a partir de algoritmos necesita del uso de datos, en muchos casos de gran cantidad de ellos, que deben cumplir con la legalidad. Debemos afirmar que siempre que tratemos **datos de carácter personal en el ámbito de la IA** deberemos aplicar de inicio la normativa en protección de datos personales.

Como es lógico en este punto, la **disociación** de datos puede ser una buena herramienta para facilitar el análisis y al mismo tiempo que garantice que no se toman decisiones sobre individuos concretos en base al análisis específico de sus datos o comportamientos.

Para estos casos la anonimización total o parcial puede ser de gran ayuda. ¿Por qué?

El RGPD no aplica, según su considerando 25, a datos anónimos:

«Los principios de protección de datos no deben aplicarse a la información anónima, es decir información que no guarda relación con una persona física identificada o identificable, ni a los datos convertidos en anónimos de forma que el interesado no sea identificable, o deje de serlo. En consecuencia, el presente Reglamento no afecta al tratamiento de dicha información anónima, inclusive con fines estadísticos o de investigación» (RGPD).

Es decir, mientras los datos no sean de carácter personal – ni vuelvan a serlo por combinaciones – esos datos no están sujetos a todas las obligaciones derivadas del RGPD.

Hay que tener en cuenta que existen 2 tipologías de técnicas de anonimización:

- 1. Anonimización parcial.** En los casos en los que tras el procesamiento necesitemos volver a identificar al sujeto de datos. El conjunto resultante no puede considerarse anonimizado y por tanto no sujeto a la norma. Eso sí, conseguiremos dificultar la identificación del individuo.
- 2. Anonimización total.** En este caso, se disocian totalmente los datos evitando la re-identificación del individuo mediante diferentes técnicas.

El estudio de estas técnicas es sumamente interesante aunque es objeto de este curso. Sí que vamos a **compartir un caso real**, muy interesante porque dio paso una técnica ampliamente utilizada y que nos permite ver la importancia de considerar todo el contexto asociado a los datos personales que hayamos anonimizado. Una importante conclusión: no sólo son nuestros datos sino los que podamos obtener externamente.

6.5.2.1. El caso de código postal, fecha de nacimiento y sexo

En Massachusetts una agencia gubernamental llamada *Insurance Group Comission* (GIC) que años antes había comprado un seguro de salud para los empleados del estado decidió (en la década de los 90) liberar registros de visitas al hospital para cualquier investigador que los solicitara sin coste alguno.

Para anonimizar los datos se habían procedido a eliminar los campos que contienen el nombre, dirección, número de la seguridad social, y otros identificadores. GIC asumía que con estos se garantizaba la privacidad de los pacientes, a pesar de que en los datos se incluían prácticamente un centenar

de atributos por paciente. Junto a la visita al hospital se mantuvieron el código postal, la fecha de nacimiento y el sexo.

Cuando se liberaron los datos se garantizaba por las instituciones que estos estaban perfectamente anonimizados y la privacidad de los empleados públicos estaba garantizada. Una estudiante sabía que el Gobernador residía en un municipio del estado denominado Cambridge. Cambridge entonces era una ciudad de más de 50.000 habitantes y con 7 códigos postales. Lantanya Sweeny que así se llamaba la estudiante compro por sólo 20 USD el censo electoral de la ciudad de Cambridge que contenía entre otros la información del nombre, dirección, código postal, fecha de nacimiento y sexo de cada votante.

Combinando los datos del censo electoral y los datos facilitados por el GIC no le resultó difícil acceder al conjunto de visitas hospitalarias y diagnósticos que había publicado GIC, referidos al Gobernador del Estado. En la ciudad solo seis personas compartían fecha de nacimiento, de ellos solo tres eran hombres y solo uno vivía en el código postal dónde residía el Gobernador. Sweeney envió registros de salud del gobernador (incluyendo diagnósticos y prescripciones) a su despacho. Para ello solo necesitó cruzar una fuente pública con datos de identificación, con una fuente de datos «teóricamente anonimizada».




Ilustración 2. Conjuntos de datos personales utilizados

Latanya Sweeny, profesora de Ciencias de la Computación, Tecnología y Política en la Universidad Carnegie Mellon, analizó el censo de los EEUU de 1996. En el año 2000 presentó un estudio para demostrar que en los EEUU simplemente con tres datos aparentemente inofensivos desde el punto de vista de su capacidad de identificar a las personas: código postal completo y la fecha nacimiento con el año incluido y el género o sexo, era posible identificar unívocamente al 87 % de la población de los EEUU.

Para ello solo necesitó cruzar una fuente pública con datos de identificación con una fuente de datos “teóricamente anonimizada”.

Es decir que un **87% de los casos**, cualquier entidad u organización que tuviera estos datos podría identificar al individuo a partir de los datos del censo. Pero iba más lejos, el **57% de la población era identificable con datos menos específicos como ciudad, fecha de nacimiento y sexo**. Y hasta el **18 % con los datos de estado de residencia, fecha de nacimiento y sexo**.

Y los datos obtenidos de su estudio fueron:




Ilustración 3. Fuente: <http://latanyasweeney.org/>

Más tarde, Philippe Golle revisó el estudio de Latanya y recalculando las estadísticas sobre el censo del año 2000 de la probabilidad de re-identificación contando solo con el código postal, la fecha de nacimiento y el sexo era del 63% y para el censo de 1996 (base del estudio de Latanya) era del 61%.

	5 digit ZIP code	County
Year of birth	0.2%	0.0%
Year and month of birth	4.2%	0.2%
Year, month and day of birth	63.3%	14.8%

Tabla 1. Fracción de la población de EE.UU. identificable unívocamente por género, domicilio, y año de nacimiento.

Detengámonos un momento en estos datos perfectamente extrapolables a cualquier región que disponga de un censo que incorpore junto a los datos de identificación de los individuos los tres datos referidos (no en los % pero sí en la posibilidad de re-identificación, pues un componente que tiene un impacto significativo es el grado de dispersión de la población).

CP	Fecha nacimiento	Sexo	Enfermedad
28001	12/01/2005	M	Hepatitis C
28002	14/03/1987	H	Lupus
28005	25/05/1936	M	Fibromialgia
28004	22/01/1950	H	Hipertensión
28001	11/07/1947	M	Cáncer de colon

Tabla 2. Tabla ejemplo con datos médicos.

Si pensamos en el ámbito hospitalario y en un conjunto de datos de-identificado tenemos que lejos de considerar este conjunto de datos anonimizado estaremos pensando en cuál es la probabilidad de identificar a un individuo, concluyendo:

- » Que la des-identificación de los datos no origina un conjunto de datos anonimizado.
- » Que es preciso aplicar técnicas adicionales para reducir o eliminar este riesgo.

Más adelante, Latanya Sweeney (profesora de gobierno y tecnología en la Universidad de Harvard y director del data privacy lab) desarrolló una técnica de anonimización de datos en un artículo publicado en el 2002 y que denominó **k-Anonymity (k-anónimo): A model for protecting privacy**. Además tiene patentado varios procedimientos y programas para generar conjuntos k-anónimos.

6.6. Sesgos, legalidad y responsabilidad

Lo que hace unos años era una cuestión ética, evitar la discriminación a la hora de emplear datos y algoritmos en la toma de decisiones, ahora se ha convertido en ley. En un entorno tecnológico y científico con una evolución tan rápida e impredecible, el entorno regulatorio no siempre es capaz de llegar a tiempo para proteger los derechos de los ciudadanos, por lo que el especialista, científico o técnico debe mantener altos estándares éticos en el día a día de su trabajo.

Hay una serie de puntos para tener en cuenta en este sentido:

1. Tener siempre presente la normativa de protección de datos.
2. Asegurarse que los algoritmos que empleamos no conllevan la toma de decisiones implicando la discriminación de algún colectivo por edad, sexo, raza, religión o cualquier otro aspecto.

3. Comprobar que los datos empleados no contienen sesgos que puedan llevar a tomar decisiones equivocadas.
4. Interpretar los resultados de los modelos científicamente, evitando interpretaciones interesadas y no ajustadas a la realidad.
5. Emplear los métodos de trabajo adecuados que garanticen la fiabilidad de los resultados.

Conceptos como inteligencia artificial y aprendizaje automático forman parte del vocabulario diario de comités de empresa y gobiernos de todo el mundo. Las decisiones que se toman en base a estos modelos afectan a millones de personas. Por tanto, es responsabilidad de los expertos asegurar que el objetivo final es aportar beneficio a la sociedad en general o los clientes de la compañía en particular, respetando los derechos fundamentales de la ciudadanía.

6.6.1. Sesgos: el motivo por el que los algoritmos aprenden y su principal punto débil

Como ya vimos anteriormente, **los sesgos son imposibles de eliminar ya que es el mecanismo por el que los algoritmos aprenden**. Crear sesgos y hacer suposiciones globales despreciando los detalles concretos es la base del aprendizaje y, por tanto, las excepciones siempre van a estar ahí. Lo importante en este caso es minimizarlos y que estos sesgos no aprendidos no sean sesgos inducidos por el entrenamiento debido a una mala elección de los datos de entrenamiento.

Es por tanto muy importante tener en cuenta este tipo de cuestiones en entornos sensibles y con sesgos que pueden incurrir en discriminaciones de cualquier tipo. Si no se puede discriminar a un individuo por razones ideológicas, de sexo, étnicos, etc., los algoritmos no pueden hacerlo tampoco.

¿Cómo evitar este hecho?

- ▶ Seleccionar cuidadosamente los datos de entrenamiento.
- ▶ Validar los algoritmos no solo con los datos provenientes del primer mundo o de nuestra área de influencia sino de otras partes del mundo con rasgos, culturas o éticas diferentes.
- ▶ Mantener una vigilancia continua de las decisiones que estos toman, para intervenir lo antes posible si se detectan estos sesgos.
- ▶ Tener evaluadores humanos que confirmen las decisiones tomadas por los algoritmos o al menos que los usuarios que se vean afectados por ellos puedan acudir para que se revise su caso particular.

Este va a ser uno de los retos más importante de aquí a unos años cuando los algoritmos de IA sean los que vayan controlando cada vez más y más procesos en los que la vida de los ciudadanos se vea afectada.

En cuanto a **la responsabilidad de los errores de estos algoritmos**, pues es bastante complicado establecerla y es algo en lo que debemos esforzarnos como sociedad. Obviamente, la responsabilidad siempre debe ser de la organización que use estos algoritmos que deben probarlos correctamente. Pero nada está exento de errores al 100 %. Así que hay que establecer cuál es el margen de error admisible para cada tarea que se delegue a la IA. Al fin y al cabo, los humanos también nos equivocamos. La diferencia aquí es que la cadena de responsabilidad entre los humanos es trazable y queda más o menos clara. Cuando entra dentro un algoritmo de IA ya no está tan clara, ¿es de los diseñadores del algoritmo?, ¿es de quien seleccionó los datos de entrenamiento? ¿Es de quien no revisó correctamente dicha decisión? Se entra en un terreno desde nuestro punto de vista pantanoso que tendremos que ir valorando con el tiempo y con leyes nuevas que probablemente lleguen tarde para algunos casos. Este es un reto importante a tener en cuenta en el futuro.

Implicaciones de la inteligencia artificial

La explosión de la inteligencia artificial ha marcado o marcará el inicio de una nueva revolución de dimensiones equivalentes a la Revolución Industrial. Como en toda gran transformación, y a pesar de las nuevas posibilidades que deslumbran, surgen también dudas y temores. Por ejemplo:

- ▶ ¿Perderán las personas su trabajo siendo reemplazadas por máquinas?
- ▶ ¿En qué trabajarán los humanos? ¿Cuánto tiempo?
- ▶ ¿Cómo se transformará nuestro tiempo de ocio?
- ▶ ¿Qué sucederá con nuestro derecho a la privacidad?
- ▶ ¿Cómo interactuaremos con los sistemas basados en inteligencia artificial?
¿Quién liderará la relación?
- ▶ ¿Podrán las máquinas sentir? ¿Cómo actuaremos entonces?
- ▶ ¿Dominarán los robots a la raza humana?

A la mayoría de estas preguntas no es posible responder en estos momentos. Sin embargo, el debate sobre las implicaciones laborales de la robótica y la inteligencia artificial ya ha empezado.

En primer lugar, la gran mayoría de flujos de trabajo serán automatizados y no requerirán intervención humana. Esto permitirá mejorar la eficiencia de los procesos y, quizá, reducir los costes.

Los algoritmos se convertirán en los principales agentes en ciertos escenarios.

Por ejemplo, muchas de las operaciones bursátiles que se llevan a cabo hoy en día son ejecutadas de forma automática mediante algoritmos que evalúan la evolución del mercado e incluso el contexto informativo analizando la información que circula sobre el contexto económico y social.

Los robots no solo han transformado las fábricas del siglo XXI, también están introduciéndose en el terreno sanitario e incluso militar.

El reto que tenemos por delante es **convertir los riesgos en oportunidades reales**.

Igual que sucedió con la Revolución Industrial, muchos trabajos desaparecerán porque ya no serán necesarios al poder realizarse de forma automática. Sin embargo, surgirán otros muchos nuevos trabajos y, por supuesto, los métodos de trabajo cambiarán radicalmente. La **educación adquiere una relevancia** especial para dirigir la transformación global de habilidades y conocimientos que permita la inmersión en el nuevo ecosistema. Algunos autores sugieren gravar mediante nuevos impuestos ciertos productos basados en inteligencia artificial, como los robots industriales para que el Estado reciba, al menos temporalmente, fuentes adicionales de financiación que permitan ayudar a aquellas personas que se queden sin trabajo debido a la automatización de sus posiciones y, además, pueda impulsar un nuevo sistema educativo que promueva la creatividad y genere el ecosistema humano que este nuevo paradigma necesita. A esto se le ha denominado que los **robots paguen impuestos**. Otros autores comentan que se debe crear una renta básica que permita la subsistencia mínima individual. En cualquier caso, es un reto muy importante que debemos abordar en los próximos años.

La inteligencia artificial redefinirá la economía del futuro impulsando la productividad y generando una oleada de productos personalizados basados en las necesidades del cliente. Este impacto se extenderá por todos los ámbitos de actividad.

Regulando la inteligencia artificial

En los últimos años, destacados y muy relevantes personajes públicos han planteado la necesidad de regular de forma más exigente el ámbito de la inteligencia artificial de cara a evitar un mal uso de esta.

Entre estos actores destaca especialmente la organización *Future of Life* (<https://futureoflife.org/>). Esta fundación propone medidas para mitigar los riesgos de un mal uso no solo de la inteligencia artificial, sino también de la biotecnología o de las armas nucleares. Además, contemplan acciones para mitigar el cambio climático.



Ilustración 4. Página web de Future of Life.

Fuente: <https://futureoflife.org/>

La lista de personalidades detrás de este proyecto es absolutamente espectacular. Entre sus fundadores podemos encontrar destacados científicos procedentes del MIT, DeepMind, Universidad de Santa Cruz o Boston, además de a Jaan Tallinn, cofundador de Skype. La labor de la institución está apoyada públicamente por figuras como Alan Alda, Erik Brynjolfsson (director del MIT Center for Digital Business), Morgan Freeman, Elon Musk (fundador de Tesla), Stuart Russell (autor del libro de referencia en esta asignatura) y un largo etcétera.

Una de las grandes preocupaciones de este grupo es la **aplicación de la inteligencia artificial con fines militares**. Atributos como la empatía, la justicia, la responsabilidad, la compasión..., son de momento atributos puramente humanos que las máquinas no tienen ocasión de contemplar.

Future of Life también se plantea romper con muchos de los mitos ligados a la inteligencia artificial:




Ilustración 5. Mitos asociados a la inteligencia artificial según Future of Life.

Fuente: <https://futureoflife.org/background/benefits-risks-of-artificial-intelligence/>

La imagen anterior podría resumirse en los siguientes puntos:

- ▶ No es preciso definir qué es lo que seremos capaces de conseguir y cuándo.
- ▶ Muchos y grandes expertos están muy preocupados sobre el uso que se podría hacer de la inteligencia artificial.
- ▶ En ocasiones la inteligencia artificial puede producir soluciones no alienadas con los objetivos adecuados.
- ▶ No es solo cuestión de preocuparse por los robots, los algoritmos autónomos son también una cuestión que hay que vigilar.
- ▶ Ciertas soluciones de inteligencia artificial podrían condicionar y controlar el comportamiento humano.
- ▶ Las máquinas pueden plantearse un objetivo de forma predefinida.
- ▶ Es mejor prevenir que curar. Actuemos antes de que sea tarde estableciendo las bases que permitan el desarrollo de una inteligencia artificial segura y alineada con las necesidades humanas.

Hay que destacar que este grupo no está en contra de la inteligencia artificial. De hecho, mucho de sus colaboradores forman parte de la élite investigadora de la materia. Lo que se pide no es abandonar el desarrollo de la inteligencia artificial, sino establecer **unas bases regulatorias adecuadas** que permitan asegurar que su desarrollo se produce de forma segura.

6.6.2. Seguridad y tolerancia ante ataques

Con el uso cada vez mayor de la inteligencia artificial y de la compartición de datos, las posibilidades de ataques en este tipo de sistemas están aumentando considerablemente. El uso intensivo de datos en los sistemas de IA hace que estos mejoren y se puedan aplicar a múltiples entornos que antes no eran posibles. Pero nos surge una duda, ¿cómo queda la seguridad y la privacidad de mis datos al adoptarla?

Ahora mismo muchas compañías están utilizando sistemas y modelos que van aprendiendo sobre la marcha y estos modelos no solo son usados por una compañía. Muchas veces, distintas compañías hacen uso de los mismos modelos debido a que la mayoría de estos modelos se enfocan al uso del software como servicio. De forma que, de una u otra forma, tus datos forman parte de una red que usa más gente. Por esta razón, ¿están seguros esos datos?

Por otro lado, con la creciente digitalización cada vez habrá más datos conectados a internet y, por tanto, más puertas abiertas que pueden ser aprovechadas por los **ciberatacantes**. Por eso, es muy importante que estos datos estén bien protegidos; sobre todo, si son datos sensibles.

También comienzan a verse ataques a los propios algoritmos de IA. Como todo sistema informático, estos sistemas pueden tener agujeros de seguridad. Pero también podemos ir más allá. Los sistemas de IA y de machine learning como sabemos tienen sesgos y los atacantes pueden utilizar esos sesgos a su favor. Por ejemplo, falseando los datos de entrada, aprovechando de alguna vulnerabilidad del algoritmo para que este falle en su beneficio. Por ejemplo, para conseguir que una IA descarte o acepte un préstamo en un banco.

Los sistemas de reconocimiento de texto y de lenguaje natural, por ejemplo, han avanzado enormemente en los últimos años, pero los programas de IA que analizan el texto pueden ser engañados por frases cuidadosamente elaboradas. Una frase que parece sencilla para un humano puede engañar a un algoritmo de IA. Esto puede implicar, por ejemplo, que un sistema que filtre noticias falsas sea engañado colando una noticia falsa sutilmente camuflada o que rechace o clasifique correctamente un posible candidato a un empleo. A este tipo de ejemplos que se le conoce con el nombre de **adversarial examples**.

Podemos definir, por tanto, un **adversarial example** como un caso con pequeñas perturbaciones intencionales de características que hacen que un modelo de aprendizaje de una máquina haga una predicción falsa.

Algunos ejemplos de este tipo de **adversarial examples** pueden ser:

- Un auto que se conduce a sí mismo choca con otro coche porque ignora una señal modificada para que el algoritmo lo identificara erróneamente.

- ▶ Armas diseñadas para engañar los sistemas de escaneo de un aeropuerto.
- ▶ Engañamos a un sistema recomendador para que recomiende nuestros productos cuando los usuarios buscan el de la competencia.

En la siguiente figura podemos ver un ejemplo de cómo se ha conseguido engañar a **AlexNet**, un conocido clasificador de imágenes. En las imágenes de la izquierda el algoritmo los reconoce, pero al aplicar el ruido de la imagen central, el algoritmo clasifica todas las imágenes como avestruces.




Ilustración 6. Algunas imágenes adversarias que engañan a Alexnet.
Fuente: <https://christophm.github.io/interpretable-ml-book/adversarial.html>

¿Cómo podemos defendernos de estos ataques? Es complicado, pero debemos ser conscientes de ello para intentar remediarlo. Podemos mitigar el riesgo con las siguientes medidas:

- ▶ Conocer a tu adversario. Conocer cuáles son las motivaciones que un atacante tiene para hacerlo.
- ▶ Ser proactivo, esto es, intentar engañar constantemente a los sistemas con tus propios ejemplos de adversario para intentar detectar los posibles errores.
- ▶ Protegerte a ti mismo con reentrenamientos activos con adversarios o utilizar varios clasificadores y decidir en mayoría.

6.6.3. Explicabilidad de algoritmos

Como hemos visto en el apartado anterior, es posible engañar a los algoritmos de machine learning entregando ejemplos preparados para que estos se equivoquen. Si podemos explicar el modelo que se genera en el proceso de aprendizaje es más fácil evitar o predecir estos errores. Pero esto no siempre es posible, debido a que no todos los algoritmos son explicables o fácilmente explicables.

Los **modelos que generan los algoritmos de machine learning podemos clasificarlos en función de su explicabilidad**: en modelos de caja negra y modelos de caja blanca.

Los **modelos de caja negra** son aquellos en los que conseguir entender el modelo para poder analizarlo es muy complejo o casi imposible. Potencialmente todos pueden ser de caja negra si el número de parámetros de configuración es muy alto. Pero, en general, son propensos a ser algoritmos que generan modelos de caja negra las redes de neuronas, los random forest, el razonamiento basado en casos con medidas de distancia compleja, etc.




Ilustración 7. Modelo de caja negra.

Los **modelos de caja blanca**, por el contrario, son más sencillos de explicar y, por tanto, de analizar. Los árboles de decisión simples son algoritmos que generan modelos de cajas blancas. También las redes bayesianas o cualquier sistema que utilice lógica de predicados, con encadenamiento hacia delante o hacia atrás.

La **explicabilidad** nos da una serie de ventajas que debemos tener en cuenta como, por ejemplo:

- **Confiabilidad.** Es muy importante poder confiar en las decisiones de un **algoritmo**, sobre todo si este está a cargo de algo importante. Por ejemplo, está conduciendo un vehículo por ti, tomando decisiones de compra en bolsa o manejando una central nuclear. Pero también para otros temas menores es importante saber qué decisión está tomando el algoritmo debido a que este puede incurrir en, como hemos visto durante este tema, sesgos, discriminaciones etc. Saber cómo llega a esa decisión puede ayudarnos a prevenir estos malos comportamientos de los algoritmos.
- **Adquirir nuevo conocimiento.** Los algoritmos a veces son capaces de resolver problemas o descubrir nuevas soluciones a problemas que antes no se

conocían. Pero estos problemas muchas veces no pueden ser analizados correctamente debido a que no sabemos cómo el algoritmo ha llegado a esa conclusión. Por lo tanto, perdemos los detalles de ese nuevo conocimiento adquirido.

- Detección de fallos. **Si el modelo tiene fallos y conocemos el modelo, podremos predecirlos, mitigarlos o reentrenarlo.** Hasta ahora, solo podemos saber si un algoritmo de caja negra tiene fallos probándolo exhaustivamente. Pero siempre puede haber casos que no se han contemplado en los que el algoritmo falle. Durante el tema hemos visto varios de ellos.

Pero eso no significa que dejemos de usar algoritmos de caja negra. Hay ciertos entornos donde no hay problema por usar algoritmos de caja negra debido a que la necesidad de verificación del modelo no es crítica. Pensemos en algoritmos que controlan la calidad de imagen en un videojuego (DLSS), el algoritmo de YouTube o el recomendador de Netflix, o en algoritmos que ayuden a los científicos de la NASA a encontrar nuevos exoplanetas. Si hay algún error en estos algoritmos que clasifica un exoplaneta como planeta que no lo es, el error no es de vital importancia. Con el tiempo se descubrirá que no lo es, pero no tiene un coste de error alto y es mayor el beneficio de poder haber encontrado cientos de exoplanetas que sin la IA no hubieran podido ser encontrados.

En resumen, hay que ser conscientes en qué dominios que el modelo no sea explicable no es un problema y que los beneficios de estos modelos compensen la falta de explicabilidad, y en qué dominios es recomendable usar algoritmos explicables, aunque obtengan peor rendimiento.

La aproximación, normalmente, a este tipo de dominios sensible es **tener soluciones híbridas entre algoritmos de caja negra y algoritmos de caja blanca.** Es decir, que parte del razonamiento esté inducido por algoritmos de caja blanca para que el cuerpo principal de la solución sea explicable y se use los algoritmos de caja negra en aquellas tareas donde la explicabilidad sea menos crítica. O también se busca intentar explicar los algoritmos de caja negra con otros métodos que ayuden a entenderlos.

A fondo

Orientaciones y garantías en los procedimientos de anonimización de datos personales

Agencia Española de Protección de Datos. (2016). Orientaciones y garantías en los procedimientos de anonimización de datos personales. [aepd.es](https://www.aepd.es/sites/default/files/2019-09/guia-orientaciones-procedimientos-anonimizacion.pdf). Recuperado de: <https://www.aepd.es/sites/default/files/2019-09/guia-orientaciones-procedimientos-anonimizacion.pdf>

En el siguiente enlace podemos consultar las orientaciones y garantías en los procedimientos de anonimización de datos personales en la Agencia Española de Protección de Datos.

Código de buenas prácticas en protección de datos para proyectos Big Data

Sáiz, A. (coord.). (2017). Código de buenas prácticas en protección de datos para proyectos Big Data. [aepd.es](https://www.aepd.es).

En el siguiente enlace podemos consultar el código de buenas prácticas en protección de datos para proyectos big data.

<https://www.aepd.es/sites/default/files/2019-09/guia-codigo-de-buenas-practicas-proyectos-de-big-data.pdf>

Código ético y deontológico de Ingeniería Informática del Consejo General de Colegios Profesionales (CCII)

En el siguiente enlace podemos consultar el código deontológico de Ingeniería Informática:

<https://ccii.es/servicios/area-de-descargas/send/12-etica/50-codigo-etico-y-deontologico-de-la-ingenieria-informatica>

Adversarial Examples

Molnar, C. (2020.). Adversarial Examples. En *Interpretable Machine Learning. A Guide for Making Black Box Models Explainable* (capítulo 6)

Este autor nos explica lo que son los *adversarial examples*. Recuperado de: <https://christophm.github.io/interpretable-ml-book/adversarial.html>