

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Actividad de refuerzo n°.7. HDFS

1. Arranca HDFS.

Descargar e Instalar docker:

- Descargas <https://www.docker.com/>
- Instalación Windows(Docker Desktop – Interfaz gráfica)
<https://docs.docker.com/desktop/setup/install/windows-install/>
- Instalación Mac <https://docs.docker.com/desktop/setup/install/mac-install/>
- Instalación Linux
<https://www.digitalocean.com/community/tutorials/how-to-install-and-use-docker-on-ubuntu-20-04-es>

Links con instrucciones levantar contenedor Apache Hadoop y poder interactuar con Apache HDFS

1. El contenedor se descarga desde la siguiente desde al campus . Descargar para este apartado el contenedor **docker-hadoop-master_interfaz.zip**

items seleccionados


+ Carpeta Cargar

Nombre ▲	Fecha de creación	Fecha de modificación	Modificado por	Tamaño	
 Actividad 7.pdf	15:55	15:55	SINESIO DAVID CA...	1.2 MB	✓
 docker-hadoop-master_comandos.zip	15:55	15:55	SINESIO DAVID CA...	216 KB	✓
 docker-hadoop-master_interfaz.zip	15:55	15:55	SINESIO DAVID CA...	217 KB	✓
 frankenstein.txt	15:55	15:55	SINESIO DAVID CA...	441 KB	✓
 Gui Práctica 7 con AWS.pdf	23:07	23:07	SINESIO DAVID CA...	1.4 MB	✓

Todos mis archivos

2. Pulsando en el botón verde Code , se descarga el contenedor en formato zip tal como viene en la anterior mensaje

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	



- Una vez descargado, lo descomprimos y nos crea una carpeta con todos los archivos de configuración del Docker(en este caso se trata de una aplicación de multi -container / multi contendores) . Lo vemos en la siguiente imagen:

Nombre	Fecha de modificación	Tipo	Tamaño
al principio de esta semana			
.gitignore	29/10/2024 17:46	Archivo GITIGNORE	1 KB
docker-compose.yml	29/10/2024 17:46	Archivo YML	2 KB
docker-compose-v3.yml	29/10/2024 17:46	Archivo YML	3 KB
hadoop.env	29/10/2024 17:46	Archivo ENV	3 KB
Makefile	29/10/2024 17:46	Archivo	2 KB
README.md	29/10/2024 17:46	Archivo MD	3 KB
nginx	29/10/2024 17:46	Carpeta de archivos	
nodemanager	29/10/2024 17:46	Carpeta de archivos	
resourcemanager	29/10/2024 17:46	Carpeta de archivos	
submit	29/10/2024 17:46	Carpeta de archivos	
base	29/10/2024 17:46	Carpeta de archivos	
datanode	29/10/2024 17:46	Carpeta de archivos	
historyserver	29/10/2024 17:46	Carpeta de archivos	
namenode	29/10/2024 17:46	Carpeta de archivos	

- Levantamos el contenedor. Para ello, abrimos aplicación de línea de comandos y nos situamos en la carpeta donde hayamos descargado y descomprimido el Docker. Luego levantamos el mismo con la siguiente instrucción (al tratarse de una aplicación multi-container) lo hacemos con Docker compose: **docker-compose up**. Tardará en levantarse unos 120 segundos(depdiendo equipo)

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

```

time="2024-10-31T21:14:44+01:00" level=warning msg="C:\\Users\\david\\Downloads\\docker-hadoop-master\\docker-hadoop-master\\docker-compose.yml: the attribute 'version' is obsolete, it will be ignored, please remove it to avoid potential confusion"
[+] Running 0/25
  - datanode [#####] 679B / 679B Pulling 7.0s
    - 13c9c87a46cb Downloading [=====] ... 5.2s
    - 3ca2ec07878c Downloading [=====] ... 5.2s
    - 26c2dd45430e Downloading [=====] ... 5.2s
  - resourcecmanager [#####] 166.6MB / 565.1MB Pulling 7.0s
    - 77920a3e82af Downloading [=====] ... 5.2s
    - a65640a64a76 Downloading [=====] ... 5.2s
    - f373218fec59 Downloading [=====] ... 5.2s
    - 3192219afd04 Downloading [=====] ... 5.2s
    - b04394ddb35d Downloading [=====] ... 5.2s
    - 883a89599900 Downloading [=====] ... 5.2s
    - b0d764123f3e Downloading [=====] ... 5.2s
    - c3a84a3e49c8 Downloading [=====] ... 5.2s
    - 92329e81aec4 Downloading [=====] ... 5.2s
    - 8b1800105b98 Downloading [=====] ... 5.2s
    - aa53513fe997 Downloading [=====] ... 5.2s
    - 7127a1d8cccd Downloading [=====] ... 5.2s
  - namenode [ ] Pulling 7.0s
    - 73b8c0ccb707 Pulling fs layer 5.1s
    - c71a6df73788 Pulling fs layer 5.1s
    - facffb3a6de3 Pulling fs layer 5.1s
  - historyserver Pulling 7.0s
  - nodemanager1 [ ] Pulling 7.0s
    - 50dda04de8a9 Pulling fs layer 5.1s
    - beaal71f32f6 Pulling fs layer 5.1s

```

- Una vez que el contenedor Docker este levantado nos aparecerá una ventana similar a la siguiente:

```

resourcecmanager | 2024-10-31 20:16:54,898 INFO util.JvmPauseMonitor: Starting JVM pause monitor
resourcecmanager | 2024-10-31 20:16:54,915 INFO ipc.CallQueueManager: Using callQueue: class java.util.concurrent.Linked
BlockingQueue, queueCapacity: 5000, scheduler: class org.apache.hadoop.ipc.DefaultRpcScheduler, ipcBackoff: false.
resourcecmanager | 2024-10-31 20:16:54,921 INFO ipc.Server: Starting Socket Reader #1 for port 8030
resourcecmanager | 2024-10-31 20:16:54,929 INFO pb.RpcServerFactoryPBImpl: Adding protocol org.apache.hadoop.yarn.api.Ap
plicationMasterProtocolPB to the server
resourcecmanager | 2024-10-31 20:16:54,930 INFO ipc.Server: IPC Server Responder: starting
resourcecmanager | 2024-10-31 20:16:54,930 INFO ipc.Server: IPC Server listener on 8030: starting
resourcecmanager | 2024-10-31 20:16:55,087 INFO ipc.CallQueueManager: Using callQueue: class java.util.concurrent.Linked
BlockingQueue, queueCapacity: 5000, scheduler: class org.apache.hadoop.ipc.DefaultRpcScheduler, ipcBackoff: false.
resourcecmanager | 2024-10-31 20:16:55,091 INFO ipc.Server: Starting Socket Reader #1 for port 8032
resourcecmanager | 2024-10-31 20:16:55,096 INFO pb.RpcServerFactoryPBImpl: Adding protocol org.apache.hadoop.yarn.api.Ap
plicationClientProtocolPB to the server
resourcecmanager | 2024-10-31 20:16:55,097 INFO ipc.Server: IPC Server Responder: starting
resourcecmanager | 2024-10-31 20:16:55,099 INFO ipc.Server: IPC Server listener on 8032: starting
resourcecmanager | 2024-10-31 20:16:55,160 INFO resourcecmanager.ResourceManager: Transitioned to active state
datanode | 2024-10-31 20:16:58,013 INFO impl.FsDatasetAsyncDiskService: Scheduling blk_1073741839_1015 replica F
inalizedReplica, blk_1073741839_1015, FINALIZED
datanode | getNumBytes() = 2
datanode | getBytesOnDisk() = 2
datanode | getVisibleLength() = 2
datanode | getVolume() = /hadoop/dfs/data
datanode | getBlockURI() = file:/hadoop/dfs/data/current/BP-2078250868-172.18.0.6-1730220583272/current/fi
nalized/subdir0/subdir0/blk_1073741839 for deletion
datanode | 2024-10-31 20:16:58,015 INFO impl.FsDatasetAsyncDiskService: Deleted BP-2078250868-172.18.0.6-1730220
583272 blk_1073741839_1015 URI file:/hadoop/dfs/data/current/BP-2078250868-172.18.0.6-1730220583272/current/finalized/su
bdir0/subdir0/blk_1073741839

```

- Podemos ahora trabajar en hdfs de dos maneras, o por la interfaz gráfica o por línea de comandos. Vamos a verlo por interfaz gráfica:
Entramos en la siguiente dirección

<http://localhost:9870/>

- Comprueba que todos los servicios de HDFS están funcionando.

Entramos en la dirección <http://localhost:9870> y comprobamos que está arrancado

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Hadoop	Overview	Datanodes	Datanode Volume Failures	Snapshot	Startup Progress	Utilities ▾
--------	----------	-----------	--------------------------	----------	------------------	-------------

Overview 'namenode:9000' (active)

Started:	Tue Apr 29 11:40:31 +0200 2025
Version:	3.2.1, rb3cbbb467e22ea829b3808f4b7b01d07e0bf3842
Compiled:	Tue Sep 10 17:56:00 +0200 2019 by rohithsharmaks from branch-3.2.1
Cluster ID:	CID-edd3c234-81cf-41a8-bfc6-c22064bc3b73
Block Pool ID:	BP-163918273-172.18.0.5-1745919479261

Summary

Security is off.

Safemode is off.

1 files and directories, 0 blocks (0 replicated blocks, 0 erasure coded block groups) = 1 total filesystem object(s).

Heap Memory used 47.09 MB of 158 MB Heap Memory. Max Heap Memory is 848 MB.

Non Heap Memory used 41.24 MB of 42.13 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	0 B
Configured Remote Capacity:	0 B

Entramos el web browser de archivos a través del menú superior

Hadoop	Overview	Datanodes	Datanode Volume Failures	Snapshot	Startup Progress	Utilities ▾
--------	----------	-----------	--------------------------	----------	------------------	-------------

Browse Directory

Browse the file system
Logs
Log Level
Metrics
Configuration
Process Thread Dump

Go!

Hadoop, 2019.

3. Crea el directorio books en el directorio raíz / de HDFS.

Pulsamos icono de crear archivo con forma de carpeta

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Browse Directory

/ Go!   

Show entries Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:45	0	0 B	rmstate	

Showing 1 to 1 of 1 entries

Previous **1** Next

Hadoop, 2019.

Ahora ponemos el nombre del archivo books y pusamos crear

Create Directory

/

Cancel Create

4. Crea un directorio con tu nombre en el directorio del usuario ubuntu de HDFS.

Hacemos los mismos pasos que n el apartado anterior (vamos a crear el archivo en raíz)

Create Directory

/

Cancel Create

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Browse Directory

Show 25 entries
Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:52	0	0 B	books
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:53	0	0 B	david
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:45	0	0 B	rmstate

Showing 1 to 3 of 3 entries
1

Hadoop, 2019.

5. Pasa los ficheros del directorio `./home/ubuntu/bigdata/examples/books` de la máquina virtual al directorio `/books` que has creado en HDFS.

Vamos a cargar dos archivos de libros `frankenstein.txt` y `Quijote.txt`. Lo hacemos de la siguiente manera:

- a) Pulsamos el botón subir archivos (con una flecha hacia arriba)

Browse Directory

Show 25 entries
Search:

- b) Pulsamos el botón elegir archivos y elegimos los dos archivos.txt en nuestro entorno local

Upload File



Elegir archivos Ningún archivo seleccionado

Close

Upload

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Upload File

Elegir archivos frankenstein.txt

Close

Upload

Pulsamos botón upload y ya se carga en el directorio elegido

Browse Directory

/books

Go!

Show

25

entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	root	supergroup	430.7 KB	Apr 29 12:02	3	128 MB	frankenstein.txt	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2019.

Hadoop, 2019.

- De la máquina virtual, descomprime el fichero: `'/home/ubuntu/bigdata/examples/hdfs/fichero_result.zip'` con el comando `'unzip'` y el fichero generado `'fichero_result.txt'` pásalo al directorio que creaste con tu nombre en HDFS (no debe quedar el `'fichero .txt'` en la máquina virtual y sin borrarlo obviamente).

En este caso es similar al apartado anterior copiando el txt que hay dentro del archivo `fichero_result.zip` en la carpeta creada con nuestro nombre. Así que primero nos metemos en el directorio que hemos creado con nuestro nombre y hacemos la carga del archivo

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Browse Directory

/david

Show entries Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
No data available in table								
Showing 0 to 0 of 0 entries								
								Previous Next

Hadoop, 2019.

Upload File

prueba.txt

Close

Uploading...

Browse Directory

/david

Show entries Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
☐	-rw-r--r--	root	supergroup	0 B	Apr 29 13:05	3	128 MB	prueba.txt
Showing 1 to 1 of 1 entries								
								Previous 1 Next

Hadoop, 2019.

- Mueve el fichero 'Frankenstein.txt' del directorio '/books' de HDFS al directorio home del usuario ubuntu del propio HDFS.

Aquí nos vamos al directorio books , y mediante el icono de cut & paste cortamos el archivo y lo pegamos en el directorio con nuestro nombre

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Browse Directory

/books

Go!

Cut

Paste

Show

25

▼

entries

Search:

☐	 Permission	 Owner	 Group	 Size	 Last Modified	 Replication	 Block Size	 Name	
☒	-rwxr-xr-x	root	supergroup	430.7 KB	Apr 29 12:02	3	128 MB	frankenstein.txt	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2019.

Browse Directory

/books

Go!

Show

25

▼

entries

Search:

Cut

Paste

☐	Permissions	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☒	-rwxr-xr-x	root	supergroup	430.7 KB	Apr 29 12:02	3	128 MB	frankenstein.txt	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2019.

Descarga el fichero 'Frankenstein.txt'(lo encuentras dentro de la carpeta de docker que has descargado del campus) . Para cargarlo a HDFS, simplemente pulsamos sobre el nombre del archivo y ya nos aparece una ventana para descargar

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

File information - frankenstein.txt

[Download](#)

[Head the file \(first 32K\)](#)

[Tail the file \(last 32K\)](#)

Block information --

Block 0 ▾

Block ID: 1073741830

Block Pool ID: BP-163918273-172.18.0.5-1745919479261

Generation Stamp: 1006

Size: 441034

Availability:

- localhost

Close

OPCION 2 REALIZAR ACTIVIDAD POR LINEA DE COMANDOS (COMANDOS COCKER Y HDFS)

8. Arranca HDFS.

Una vez hemos hecho el compose del docker , entramos en la Shell de HDFS mediante la siguiente sentencia **docker exec -it namenode bash**

```
C:\Users\david\Downloads\docker-hadoop-master\docker-hadoop-master>docker exec -it namenode bash
root@4bcebc5abb4c:/#
```

9. Crea el directorio books en el directorio raíz / de HDFS.Lo creamos con el comando

hdfs dfs -mkdir /cbooks

```
Simbolo del sistema - docker x + v
root@4bcebc5abb4c:/# hdfs dfs -mkdir /cbooks
root@4bcebc5abb4c:/#
```

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Podemos comprobar que se ha creado tanto por la línea de comandos como por interfaz gráfica:

Browse Directory

/										Go!			
Show	25	entries	Search:										
☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name					
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 13:28	0	0 B	books					
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:15	0	0 B	rmstate					
Showing 1 to 2 of 2 entries										Previous 1 Next			
Hadoop, 2019.													

```
root@4bcebc5abb4c:/# hdfs dfs -ls /
Found 2 items
drwxr-xr-x - root supergroup          0 2025-04-29 11:28 /books
drwxr-xr-x - root supergroup          0 2025-04-29 09:15 /rmstate
root@4bcebc5abb4c:/#
```

10. Crea un directorio con tu nombre en el directorio del usuario ubuntu de HDFS. (lo creamos en la raíz)

```
root@4bcebc5abb4c:/# hdfs dfs -mkdir /david
root@4bcebc5abb4c:/#
```

Browse Directory

/										Go!			
Show	25	entries	Search:										
☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name					
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 13:28	0	0 B	books					
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 13:33	0	0 B	david					
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 11:15	0	0 B	rmstate					
Showing 1 to 3 of 3 entries										Previous 1 Next			
Hadoop, 2019.													

11. Pasa los ficheros del directorio ./tmp/books de la máquina virtual al directorio /books que has creado en HDFS.

Vamos a cargar dos archivos de libros frankenstein.txt y Quijote.txt. Lo hacemos de la siguiente manera:

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

En este caso nos salimos primero de la shell de HDFS para copiar los archivos en la máquina del docker

```
root@4bcebc5abb4c:/# exit
exit

What's next:
Try Docker Debug for seamless, persistent debugging tools in any container or image → docker debug namenode
Learn more at https://docs.docker.com/go/debug-cli/

C:\Users\david\Downloads\docker-hadoop-master\docker-hadoop-master>
```

Y utilizamos la siguiente sentencia de docker cp para copiarlo en el namenode de hdfs (previamente tenemos que situarnos en la carpeta donde están los ficheros a copiar)

docker cp frankenstein.txt namenode:/tmp

```
C:\Users\david\Downloads\docker-hadoop-master\docker-hadoop-master>docker cp frankenstein.txt namenode:/tmp
Successfully copied 443kB to namenode:/tmp
```

Ahora volvemos a entrar en la shell de HDFS **docker exec -it namenode bash**

```
C:\Users\david\Downloads\docker-hadoop-master\docker-hadoop-master>docker exec -it namenode bash
root@4bcebc5abb4c:/#
```

Y utilizamos el comando put de HDFS para copiar los archivos en el directorio books

hdfs dfs -put /tmp/frankenstein.txt /books

```
C:\Users\david\Downloads\docker-hadoop-master (1)\docker-hadoop-master>docker exec -it namenode bash
root@e816eadc17ba:/# hdfs dfs -put /tmp/frankenstein.txt /books
2025-04-29 12:41:14,266 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteH
ostTrusted = false
root@e816eadc17ba:/#
```

- De la máquina virtual, descomprime el fichero: `'/home/ubuntu/bigdata/examples/hdfs/fichero_result.zip'` con el comando `'unzip'` y el fichero generado `'fichero_result.txt'` pásalo al directorio que creaste con tu nombre en HDFS (no debe quedar el `'fichero .txt'` en la máquina virtual y sin borrarlo obviamente).

En este caso es similar al apartado anterior copiando el txt que hay dentro del archivo fichero_result.zip en la carpeta creada con nuestro nombre. Primero utilizando docker cp para copiar en la máquina del docker

docker cp fichero_result namenode:/tmp

```
C:\Users\david\Downloads\docker-hadoop-master (1)\docker-hadoop-master> docker cp fichero_result namenode:/tmp
Successfully copied 2.56kB to namenode:/tmp
```

Y luego utilizando hdfs put para cargar en hdfs

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

hdfs dfs -put /tmp/fichero_result/ /david

```
root@e816eadc17ba:/# hdfs dfs -put /tmp/fichero_result/ /david
2025-04-29 12:48:43,192 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteH
ostTrusted = false
root@e816eadc17ba:/#
```

Browse Directory

/david

Go!



Show

25

entries

Search:

☐	 Permission	 Owner	 Group	 Size	 Last Modified	 Replication	 Block Size	 Name	
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 14:48	0	0 B	fichero_result	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2019.

Browse Directory

/david/fichero_result

Go!

Show

25

entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	root	supergroup	4 B	Apr 29 14:48	3	128 MB	prueba.txt	

Showing 1 to 1 of 1 entries

Previous

1

Next

Hadoop, 2019.

- Mueve el fichero 'Frankenstein.txt' del directorio '/books' de HDFS al directorio david del propio HDFS.

```
root@e816eadc17ba:/# hdfs dfs -put /tmp/fichero_result/ /david
2025-04-29 12:48:43,192 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteH
ostTrusted = false
root@e816eadc17ba:/# hdfs dfs -cp /books/frankenstein.txt /david/
2025-04-29 12:54:12,406 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteH
ostTrusted = false
2025-04-29 12:54:13,235 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteH
ostTrusted = false
root@e816eadc17ba:/#
```

Asignatura	Datos del alumno	Fecha
Programa Profesional en Inteligencia Artificial y Data Science	Apellidos:	
	Nombre:	

Browse Directory

Show 25 entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	drwxr-xr-x	root	supergroup	0 B	Apr 29 14:48	0	0 B	fichero_result	
☐	-rw-r--r--	root	supergroup	430.7 KB	Apr 29 14:54	3	128 MB	frankenstein.txt	

Showing 1 to 2 of 2 entries

Previous

1

Next

Hadoop, 2019.