



1. Entrar en EMR desde la barra de búsqueda



2. Pulsar el botón naranja Crear Cluster



3. Ahora , debemos configurar el cluster

- Indicamos el nombre que quereamos dar al cluster

Dejamos la versión de EMR que aparece por defecto. Seleccionamos las aplicaciones que queremos tener instaladas en el cluster. Dejamos seleccionadas las que aparecen en la imagen:

c. Seleccionamos el tipo de instancia de los tres nodos. En este caso como estamos en lab tenemos que escoger m4.large como se ve en la imagen(RECUERDA HAY QUE HACERLO EN LOS TRES NODOS)

▼ Configuración del clúster - obligatorio [Información](#)
Elija un método de configuración para los grupos principales, centrales y de nodos tareas para su clúster.

☒ **Grupos de instancias uniformes**
Elija el mismo tipo de instancia de EC2 y la misma opción de compra (bajo demanda o de spot) para todos los nodos de su grupo de nodos. [Más información](#)

☐ **Flotas de instancias flexibles**
Elija entre la más amplia variedad de opciones de aprovisionamiento para las instancias de EC2 de su clúster. Diversifique los tipos de instancias y las opciones de compra, y utilice una estrategia de asignación. [Más información](#)

m4

m4.large
2 vCore 8 GiB memoria Únicamente EBS almacenamiento
Precio bajo demanda: - Precio de spot más bajo: -

m4.large

2 vCore 8 GiB memoria
Únicamente EBS almacenamiento
Precio bajo demanda: -
Precio de spot más bajo: -

Acciones ▼

☐ **Utilice la alta disponibilidad**
Lance un clúster más resiliente y de alta disponibilidad con tres nodos principales en instancias bajo demanda. Esta configuración se aplica durante toda la vida útil del clúster. [Más información](#)

► Configuración de nodo - opcional

Central

Elegir tipo de instancia de EC2

m4.large

2 vCore 8 GiB memoria
Únicamente EBS almacenamiento
Precio bajo demanda: -
Precio de spot más bajo: -

Acciones ▼

► Configuración de nodo - opcional

- d. Ahora debemos configurar la claves de seguridad para conectarnos a las máquinas, pero antes hay que crear el par de claves. Para ello, pulsamos el botón Crear par de Claves

Par de claves de Amazon EC2 para el protocolo SSH al clúster [Información](#)

Examinar

Crear par de claves [↗](#)

⚠ No ha especificado una clave EC2. Si está fuera de una VPN y desea habilitar SSH o utilizar el asistente Hue SQL con este clúster, debe escribir una clave EC2.

- e. Nos aparece la ventana de creación del par de claves, en ella, debemos de hacer lo siguiente:
1. Introducir el nombre del par de claves(el que queramos)
 2. Elegir el tipo .pem (para conectarnos por ssh)
 3. Pulsar botón naranja Crear par de claves

Par de claves
Un par de claves, compuesto por una clave privada y una clave pública, es un conjunto de credenciales de seguridad que se utilizan para demostrar su identidad cuando se conecta a una instancia.

Nombre

El nombre puede incluir hasta 255 caracteres ASCII. No puede incluir espacios al principio ni al final.

Tipo de par de claves [Información](#)
☒ RSA ☐ ED25519

Formato de archivo de clave privada
☒ .pem
Para usar con OpenSSH
☐ .ppk
Para usar con PuTTY

Etiquetas: opcional
 No hay etiquetas asociadas a este recurso.
[Agregar nueva etiqueta](#)
Puede agregar hasta 50 etiquetas más.

[Cancelar](#) [Crear par de claves](#)

f. Ahora volvemos a la pantalla de creación de cluster y seleccionamos el par de claves pulsando Examinar

Par de claves de Amazon EC2 para el protocolo SSH al clúster [Información](#)

[Examinar](#) [Crear par de claves](#)

⚠ No ha especificado una clave EC2. Si está fuera de una VPN y desea habilitar SSH o utilizar el asistente Hue SQL con este clúster, debe escribir una clave EC2.

g. Elegimos el par de claves creado anteriormente y pulsamos elegir

Elegir una clave de Amazon EC2 para el protocolo SSH al clúster

Pares de claves (3)

ID	Name	Fingerprint
☒ key-02b665bd4c1ce5bc6	david29clase	89:d2:d1:bc:aa:11:aa:ff:02:b5:9a:b9:3f:ef:ed:7c:f1:45:7b:9b
☐ key-0f6c744eb3559dab5	davidunir29	f3:cf:9a:04:b9:c3:b3:f2:4b:2a:4d:11:8b:af:15:c1:07:45:80:34
☐ key-078876a74152cc367	vockey	1a:ef:43:6d:a0:10:8b:ca:7e:60:14:8a:02:c3:d1:a8:b1:83:a8:4f

[Cancelar](#) [Elegir](#)

h. Ahora , seleccionamos el rol de servicio EMR , EMR_Default_Role

▼ Roles de Identity and Access Management (IAM) - obligatorio [Información](#)
 Elija o cree un rol de servicio y un perfil de instancia para las instancias de EC2 del clúster.

Rol de servicio de Amazon EMR [Información](#)
 El rol de servicio es un rol de IAM que Amazon EMR asume para aprovisionar recursos y realizar acciones de nivel de servicio con otros servicios de AWS.

☒ **Elegir un rol de servicio existente**
 Seleccione un rol de servicio predeterminado o un rol personalizado con políticas de IAM asociadas para que el clúster pueda interactuar con otros servicios de AWS.

☐ **Crear un rol de servicio**
 Deje que Amazon EMR cree un nuevo rol de servicio para que pueda conceder y restringir el acceso a los recursos de otros servicios de AWS.

Rol de servicio
 [↻](#)

i. Ahora , seleccionamos el rol de instancia de EC2 para EMR , EMR_EC2_DefaultRole

Perfil de instancia de EC2 para Amazon EMR

El perfil de instancia asigna un rol a cada instancia de EC2 de un clúster. El perfil de instancia debe especificar un rol que pueda acceder a los recursos de los pasos y las acciones de arranque.



Elegir un perfil de instancia existente

Seleccione un rol predeterminado o un perfil de instancia personalizado con políticas de IAM asociadas para que el clúster pueda interactuar con sus recursos de Amazon S3.



Crear un perfil de instancia

Deje que Amazon EMR cree un nuevo perfil de instancia para que pueda especificar un conjunto personalizado de recursos a los que tendrá acceso en Amazon S3.

Perfil de instancia

EMR_EC2_DefaultRole



- j. Ahora , seleccionamos el rol de escalamiento automático
EMR_AutoScaling_DefaultRole

Rol de escalamiento automático personalizado - *opcional*

Cuando se activa una regla de escalamiento automático personalizada, Amazon EMR asume esta función para agregar y finalizar instancias de EC2. [Más información](#)

Rol de escalamiento automático personalizado

EMR_AutoScaling_DefaultRole



[Crear rol de IAM](#)

- k. Finalmente , pulsamos Crear Cluster y esperamos se inicie y quede en
Estado En Ejecución (en verde)

Resumen

Información

Nombre y aplicaciones - obligatorio

Nombre

clusterclase29

Versión de Amazon EMR

emr-7.8.0

Paquete de aplicaciones

Custom (Hadoop 3.4.1, Hive 3.1.3, Hue 4.11.0, JupyterEnterpriseGateway 2.6.0, JupyterHub...)

Configuración del clúster - obligatorio

Grupos de instancias uniformes

Principal (m4.large), Central (m4.large), Tarea (m4.large)

Aprovisionamiento y escalado de clústeres - obligatorio

Configuración de aprovisionamiento

Tamaño del núcleo: 1 instancia

Tamaño de la tarea: 1 instancia

Cancelar

Crear clúster

[j-3FGXTAG6DDYJS](#)

clase29

Esperando

Listo para ejecutar pasos

29 de abril de 2025 20:29

1 hora, 6 minutos

0

4. Ahí debemos habilitar que el puerto 22, para conectarnos vía SSH. Para ello, pulsamos sobre el ID del cluster, nos aparece la ventana de propiedades del cluster, nos vamos al apartado Red y seguridad, y pulsamos sobre el ID del grupo de seguridad (sg-xxxx):

Red y seguridad

Información

Red

Virtual Private Cloud (VPC)
vpc-04c49554a174f0eeb8

Subredes y zonas de disponibilidad (AZ)
subnet-01b66d41c0dcb6c08 us-east-1d

▼ Grupos de seguridad de EC2 (firewall)

Grupo principal

Grupos de seguridad administrados de EMR
sg-03a22546da3f548b4

Grupos de seguridad adicionales

-

Nodos principales y de tareas

Grupos de seguridad administrados de EMR
sg-0694c61e0740eabaf

Grupos de seguridad adicionales

Configuración de seguridad

Configuración de seguridad

Ninguna

Par de claves de EC2

david29clase

Permisos

Rol de servicio para Amazon EMR
EMR_DefaultRole

Perfil de instancia EC2
EMR_EC2_DefaultRole

Rol de escalamiento automático personalizado
EMR_AutoScaling_DefaultRole

Nos aparece la ventana de reglas de seguridad, pulsamos botón Editar Reglas de Entrada

sg-09e22546da3fb48b4 - ElasticMapReduce-master Acciones ▾

Detalles

Nombre del grupo de seguridad
ElasticMapReduce-master

ID del grupo de seguridad
sg-09e22546da3fb48b4

Descripción
Master group for Elastic MapReduce created on 2025-04-18T11:23:38.861Z

ID de la VPC
vpc-04c49554a174fee08

Propietario
441173487216

Número de reglas de entrada
7 Entradas de permisos

Número de reglas de salida
1 Entrada de permiso

[Reglas de entrada](#) | [Reglas de salida](#) | [Compartiendo : novedad](#) | [Asociaciones de VPC : novedad](#) | [Etiquetas](#)

Reglas de entrada (7) Administrar etiquetas Editar reglas de entrada

Q	Buscar		Name	ID de la regla del gr...	Versión de IP	Tipo	Protocolo	Intervalo de puertos	Origen	Descripción
☐		-		sg-03421072770431686	-	Todos los TCP	TCP	0 - 65535	sg-0694c61e0740eabf...	-
☐		-		sg-0e81d3fc0ef9cc92	-	Todos los ICMP IPv4	ICMP	Todo	sg-0694c61e0740eabf...	-
☐		-		sg-01be0739841ed399c	-	Todos los UDP	UDP	0 - 65535	sg-0694c61e0740eabf...	-
☐		-		sg-01fc098feff7f369	-	TCP personalizado	TCP	8443	pl-f8bd5e91	-
☐		-		sg-08b162b4cfa5d55cc	-	Todos los TCP	TCP	0 - 65535	sg-09e22546da3fb48b...	-
☐		-		sg-00712ddb8f66a4375	-	Todos los UDP	UDP	0 - 65535	sg-09e22546da3fb48b...	-
☐		-		sg-01c57ea2d815797f5	-	Todos los ICMP IPv4	ICMP	Todo	sg-09e22546da3fb48b...	-

Para agregar la regla de permisos de conexión por SSH (puerto 22) hacemos lo siguiente:

- Pulsar botón Agregar Regla de entrada
- En el apartado Tipo, elegir protocolo SSH de la lista desplegable
- En el apartado Origen, elegir MiIP
- Pulsar botón Guardar Reglas

sg-0e81d3fc0ef9cc92

sg-01be0739841ed399c

sg-01fc098feff7f369

sg-08b162b4cfa5d55cc

sg-00712ddb8f66a4375

sg-01c57ea2d815797f5

-

Todos los ICMP IPv4

TCP personalizado

UDP personalizado

Regla ICMP personalizada - IPv4

Protocolo personalizado

Todos los TCP

Todos los UDP

Todos los ICMP IPv4

Todos los ICMP IPv6

Todo el tráfico

SSH

SMTP

SSH

ICMP

UDP

TCP

TCP

UDP

ICMP

TCP

Todo

0 - 65535

8443

0 - 65535

0 - 65535

Todo

22

Persona...

Persona...

Persona...

Persona...

Persona...

Persona...

Mi IP

Q

sg-0694c61e0740eabf

Q

sg-0694c61e0740eabf

Q

pl-f8bd5e91

Q

sg-09e22546da3fb48b4

Q

sg-09e22546da3fb48b4

Q

sg-09e22546da3fb48b4

Q

81.34.207.208/32

Eliminar

Eliminar

Eliminar

Eliminar

Eliminar

Eliminar

Eliminar

Agregar regla

Quando hace referencia a una lista de prefijos en una regla de grupo de seguridad, el número máximo de entradas de las listas de prefijos se descuenta de la cuota del número de entradas del grupo de seguridad. Por ejemplo, si crea una lista de prefijos con un máximo de 20 entradas y hace referencia a esa lista de prefijos en una regla de grupo de seguridad, esto cuenta como 20 reglas de grupo de seguridad.

Cancelar

Previsualizar los cambios

Guardar reglas

sg-09e22546da3fb48b4 - ElasticMapReduce-master Acciones ▾

Detalles

Nombre del grupo de seguridad
ElasticMapReduce-master

ID del grupo de seguridad
sg-09e22546da3fb48b4

Descripción
Master group for Elastic MapReduce created on 2025-04-18T11:23:38.861Z

ID de la VPC
vpc-04c49554a174fee08

Propietario
441173487216

Número de reglas de entrada
8 Entradas de permisos

Número de reglas de salida
1 Entrada de permiso

[Reglas de entrada](#) | [Reglas de salida](#) | [Compartiendo : novedad](#) | [Asociaciones de VPC : novedad](#) | [Etiquetas](#)

Reglas de entrada (8) Administrar etiquetas Editar reglas de entrada

Q	Buscar		Name	ID de la regla del gr...	Versión de IP	Tipo	Protocolo	Intervalo de puertos	Origen	Descripción
☐		-		sg-03421072770431686	-	Todos los TCP	TCP	0 - 65535	sg-0694c61e0740eabf...	-
☐		-		sg-0e81d3fc0ef9cc92	-	Todos los ICMP IPv4	ICMP	Todo	sg-0694c61e0740eabf...	-
☐		-		sg-01be0739841ed399c	-	Todos los UDP	UDP	0 - 65535	sg-0694c61e0740eabf...	-
☐		-		sg-01fc098feff7f369	-	TCP personalizado	TCP	8443	pl-f8bd5e91	-
☐		-		sg-08b162b4cfa5d55cc	-	Todos los TCP	TCP	0 - 65535	sg-09e22546da3fb48b...	-
☐		-		sg-0008d3a10476d9dbf	IPv4	SSH	TCP	22	81.34.207.208/32	-
☐		-		sg-00712ddb8f66a4375	-	Todos los UDP	UDP	0 - 65535	sg-09e22546da3fb48b...	-
☐		-		sg-01c57ea2d815797f5	-	Todos los ICMP IPv4	ICMP	Todo	sg-09e22546da3fb48b...	-

Debemos agregar otra regla mediante los siguientes pasos:

- Pulsar botón Agregar Regla de entrada
- En el apartado Tipo, elegir Todos los TCP de la lista desplegable
- En el apartado Origen, elegir MiIP

- Pulsar botón Guardar Reglas

Reglas de entrada (9)									
Buscar									
☐	Nombre	ID de la regla del grupo	Versión de IP	Tipo	Protocolo	Intervalo de puertos	Origen		Descripción
☐	-	sg-03421072770431686	-	Todos los TCP	TCP	0 - 65535	sg-0694dc61e0740eabaf...	-	-
☐	-	sg-0e81d3fc0ef9cc2	-	Todos los ICMP IPv4	ICMP	Todo	sg-0694dc61e0740eabaf...	-	-
☐	-	sg-011be0739841ed399c	-	Todos los UDP	UDP	0 - 65535	sg-0694dc61e0740eabaf...	-	-
☐	-	sg-011fc0981efff7f369	-	TCP personalizado	TCP	8443	pl-f8bd5e91f	-	-
☐	-	sg-08b162b4cfa5d55cc	-	Todos los TCP	TCP	0 - 65535	sg-09e22546da3fb48b...	-	-
☐	-	sg-0d875aa3502f521f4	IPv4	Todos los TCP	TCP	0 - 65535	0.0.0.0/0	-	-
☐	-	sg-0008d3a10476d9dbf	IPv4	SSH	TCP	22	0.0.0.0/0	-	-
☐	-	sg-00712dd8b166a4375	-	Todos los UDP	UDP	0 - 65535	sg-09e22546da3fb48b...	-	-
☐	-	sg-01c57ea2d815797f5	-	Todos los ICMP IPv4	ICMP	Todo	sg-09e22546da3fb48b...	-	-

6. Ahora necesitamos copiar el DNS que aparece en el apartado Administración cluster , pulsamos en el icono de dos cuadraditos para Copiar

Resumen

Información del clúster

ID del clúster
j-3FGxTAG6DDY5

ARN del clúster
arn:aws:elasticmapreduce:us-east-1:441173487216:cluster/j-3FGxTAG6DDY5

Configuración del clúster
Grupos de instancias

Capacidad
1 Primary (Principal) | 1 Principal | 1 Tarnea

Aplicaciones

Versión de Amazon EMR
emr-7.8.0

Aplicaciones instaladas
Hadoop 3.4.1, Hive 3.13, Hue 4.11.0, JupyterEnterpriseGateway 2.6.0, JupyterHub 1.5.0, Livy 0.8.0, Spark 3.5.4

Administración de clústeres

Destino del registro en Amazon S3
aws-logs-441173487216-us-east-1:elasticmapreduce

IU de aplicación persistente
Servidor de historial de Spark [↗](#)
Servidor de línea de tiempo de YARN [↗](#)

DNS público del nodo principal copiado
ec2-3-222-188-148.compute-1.amazonaws.com
Conectarse al nodo principal mediante SSH
Conectarse al nodo principal mediante SSM [↗](#)

Estado y hora

Estado
Esperando

Hora de creación
29 de abril de 2025 20:29 (UTC+02:00)

Tiempo transcurrido
1 hora, 19 minutos

Propiedades
Acciones de arranque
Instancias (hardware)
Pasos
Aplicaciones
Configuraciones
Monitorización
Eventos
Etiquetas (0)

Sistema operativo [Información](#)

Versión de Amazon Linux
2023.7.20250331.0

Registros de clúster [Información](#)

Archivar los archivos de registro en Amazon S3
Activado

Ubicación de Amazon S3
s3://aws-logs-441173487216-us-east-1:elasticmapreduce/ [↗](#)

Cifrado para registros
Desactivado

Terminación del clúster y reemplazo de nodos [Información](#)

Opción de terminación
Terminar automáticamente el clúster después del tiempo de inactividad

Protección contra la terminación
Desactivado

Tiempo de inactividad
1 hora

Reemplazo de nodos en mal estado
Activado

7. Para realizar la conexión a la interfaz web de HDFS , primero debemos hacer un tunel SSH que nos redirija los puertos . Lo hacemos mediante la siguiente instrucción `ssh -i definitivouaxda.pem -L 9000:ec2-3-80-118-75.compute-1.amazonaws.com:9870 hadoop@ec2-3-80-118-75.compute-1.amazonaws.com`


Donde tu debes sustituir por tu nombre de clave .pem (lo que está en azul) y por tu nombre DNS copiado anteriormente , lo que está en verde

[illegible]


8. Ahora vamos a dar permisos de escritura con la siguiente instrucción:

```
[hadoop@ip-172-31-8-160 /]$ hdfs dfs -chmod 777 /
```

9. Ya podemos entrar vía navegador web con la dirección de localhost/9000 como podemos ver en la imagen:



10. Y podemos crear directorios y subir archivos como se explica en el documento Guía de realización Actividad 7.pdf subido en el campus



IMPORTANTE!! Si al intentar subir un archivo aparece el error Couldn't upload file Frankenstein.txt

Haz lo siguiente:

- Utilizamos scp para copiar el archivo desde local a la máquina del cluster. Para ello, nos debemos situar en la carpeta local donde está guardado el archivo frankenstein.txt (en mi caso en mi carpeta descargas) y ejecutar la instrucción `scp -i definitivuaxda.pem frankenstein.txt hadoop@ec2-3-80-118-75.compute-1.amazonaws.com:/home/hadoop/`

Donde tu debes sustituir por tu nombre de clave .pem (lo que está en azul) y por tu nombre DNS copiado anteriormente , lo que está en verde

```
C:\Users\david\Downloads>scp -i definitivouaxda.pem frankenstein.txt hadoop@ec2-3-80-118-75.compute-1.amazonaws.com:/home/hadoop/frankenstein.txt
100% 431KB 561.5KB/s 00:00
```

Luego hay que entrar en hdfs con el comando:

```
ssh -i definitivouaxda.pem hadoop@ec2-3-80-118-75.compute-1.amazonaws.com
```

[illegible]

Y ejecutar las siguiente sentencia: `hdfs dfs -put /home/hadoop/archivo.txt /user/hadoop/`

```
[hadoop@ip-172-31-31-106 ~]$ hdfs dfs -put /home/hadoop/frankenstein.txt /books
```

Con esto ya podrás comprobar que se ha cargado el archivo Frankenstein.txt correctamente!!

Hadoop
Overview
Datanodes
Datanode Volume Failures
Snapshot
Startup Progress
Utilities

Browse Directory

Show
25
entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	hadoop	hdfsadmin	430.7 KB	May 03 00:46	1	128 MB	frankenstein.txt	

Showing 1 to 1 of 1 entries

Previous
1
Next

Hadoop, 2024.