

INSTRUCCIÓN CREATE MODEL DE REDSHIFT Y PARAMETROS DE LA MISMA

La instrucción CREATE MODEL en Amazon Redshift ML se utiliza para crear y entrenar modelos de machine learning directamente dentro de tu almacén de datos Redshift. Su estructura y parámetros son los siguientes:

SQL

```
CREATE MODEL model_name
FROM (
    SELECT column1, column2, ...
    FROM table_name
    WHERE condition
)
TARGET target_column
FUNCTION model_function_name
MODEL_TYPE model_type
[PROBLEM_TYPE problem_type]
[OBJECTIVE objective]
[PREPROCESSORS preprocessor_defs]
[TRANSFORMERS transformer_defs]
[HYPERPARAMETERS json_map]
[SAGEMAKER_ROLE iam_role]
[SETTINGS json_map]
[AUTO ON | AUTO OFF]
[MAX_RUNTIME_MINUTES integer]
[S3_GARBAGE_COLLECT_S3_URI 's3://bucket/prefix/']
;
```

Desglosamos cada parte de la instrucción CREATE MODEL:

1. CREATE MODEL model_name

- **model_name:** Especifica un nombre único para el modelo que se creará en Redshift. Este nombre se utilizará posteriormente para referirse al modelo, por ejemplo, al realizar predicciones.

2. FROM (SELECT column1, column2, ... FROM table_name WHERE condition)

- Esta cláusula define la **consulta SQL** que se utilizará para seleccionar los datos de entrenamiento.
 - Puedes seleccionar columnas específicas (column1, column2, ...) que se utilizarán como *features* (características) para entrenar el modelo.
 - table_name es la tabla de Redshift que contiene los datos de entrenamiento.
 - La cláusula WHERE condition es opcional y permite filtrar las filas que se utilizarán para el entrenamiento.

3. TARGET target_column

- **target_column:** Especifica la columna en la tabla de entrenamiento que contiene la variable objetivo (la variable que quieres predecir).

4. FUNCTION model_function_name

- **model_function_name:** Define el nombre de la función SQL que se creará automáticamente después de que el modelo se haya entrenado con éxito. Puedes utilizar esta función en tus consultas SQL para realizar predicciones utilizando el modelo entrenado.

5. MODEL_TYPE model_type

- **model_type:** Especifica el algoritmo de machine learning que se utilizará para entrenar el modelo. Redshift ML utiliza Amazon SageMaker bajo el capó. Algunos valores comunes incluyen:
 - LINEAR_REGRESSION
 - LOGISTIC_REGRESSION
 - RANDOM_FOREST
 - XGBOOST
 - KMEANS (para clustering)
 - PCA (para reducción de dimensionalidad)
 - AUTOGLUEON (para selección automática de modelos)

Parámetros Opcionales:

- **PROBLEM_TYPE problem_type:** Especifica el tipo de problema de machine learning. Si no se especifica, Redshift ML intentará inferirlo del MODEL_TYPE y el tipo de datos de la columna objetivo. Valores comunes:
 - REGRESSION
 - BINARY_CLASSIFICATION
 - MULTICLASS_CLASSIFICATION

- CLUSTERING
- **OBJECTIVE objective:** Especifica la métrica que se utilizará para optimizar el modelo durante el entrenamiento. Si no se especifica, Redshift ML utilizará una métrica predeterminada basada en el `PROBLEM_TYPE`. Ejemplos:
 - Para regresión: `rmse` (root mean squared error), `mae` (mean absolute error)
 - Para clasificación binaria: `accuracy`, `f1`, `auc` (area under the ROC curve)
 - Para clasificación multiclase: `accuracy`
- **PREPROCESSORS preprocessor_defs:** Especifica una lista de preprocesadores para aplicar a las columnas de entrada antes del entrenamiento. Los preprocesadores se definen como una lista JSON de diccionarios, donde cada diccionario especifica el nombre de la columna y el tipo de preprocesador (por ejemplo, `{"column": "numeric_column", "preprocessor": "standard_scaler"}`).
- **TRANSFORMERS transformer_defs:** Similar a **PREPROCESSORS**, pero para transformaciones de características más complejas.
- **HYPERPARAMETERS json_map:** Un mapa JSON que especifica los hiperparámetros para el algoritmo de machine learning seleccionado en `MODEL_TYPE`. Los hiperparámetros controlan el proceso de aprendizaje del modelo.
- **SAGEMAKER_ROLE iam_role:** El nombre o ARN de un rol de IAM que Redshift utilizará para acceder a Amazon SageMaker y a los datos en S3 durante el entrenamiento del modelo. Este rol debe tener los permisos necesarios.
- **SETTINGS json_map:** Un mapa JSON que permite configurar opciones adicionales para el proceso de entrenamiento.
- **AUTO ON | AUTO OFF:** Controla si Redshift ML debe utilizar AutoML (a través de SageMaker Autopilot) para seleccionar automáticamente el mejor modelo y optimizar los hiperparámetros. Por defecto es **AUTO OFF**. Si se establece en **AUTO ON**, se ignorará el parámetro `MODEL_TYPE` y otros parámetros específicos del modelo.
- **MAX_RUNTIME_MINUTES integer:** Especifica el tiempo máximo en minutos que se permitirá para el entrenamiento del modelo. Si se alcanza este límite, el entrenamiento se detendrá.
- **S3_GARBAGE_COLLECT_S3_URI 's3://bucket/prefix/':** Especifica la ubicación en S3 donde Redshift ML puede almacenar artefactos temporales y luego eliminarlos automáticamente después del entrenamiento.

Ejemplo Básico:

SQL

```
CREATE MODEL customer_churn_model
```

```
FROM (  
    SELECT age, income, usage_frequency, contract_length, churned  
    FROM customer_data  
)  
TARGET churned  
FUNCTION predict_churn  
MODEL_TYPE LOGISTIC_REGRESSION  
SAGEMAKER_ROLE 'arn:aws:iam::123456789012:role/RedshiftMLRole';
```

Este ejemplo crearía un modelo de regresión logística llamado `customer_churn_model` para predecir la columna `churned` basándose en las columnas `age`, `income`, `usage_frequency` y `contract_length` de la tabla `customer_data`. Se crearía una función SQL llamada `predict_churn` para realizar las predicciones. El entrenamiento se realizará utilizando el rol de IAM especificado.

Entender la estructura y los parámetros de `CREATE MODEL` es fundamental para aprovechar las capacidades de machine learning directamente dentro de tu entorno de Amazon Redshift. Te permite entrenar modelos personalizados para tus necesidades de análisis predictivo sin necesidad de mover datos ni interactuar con servicios de ML externos de forma directa.