



Día de inmersión en lienzo de Amazon SageMaker

- ▶ Initial Labs
- ▶ ✂ Requisitos previos
- ▼ 📁 Laboratorios de casos de uso
 - Laboratorio 1: Pérdida de clientes (marketing)**
 - Laboratorio 2 - Precios de la Vivienda (Bienes Raíces)
 - Laboratorio 3: Previsión de la demanda (comercio minorista)
 - Laboratorio 4: Predicción del incumplimiento de los préstamos (servicios financieros)
 - Laboratorio 5 - Predicción de Readmisión de Pacientes Diabéticos (Atención Médica y Ciencias Biológicas)
 - Laboratorio 6 - Predicción de Tipos de Fallos de Máquinas (Manufacturación)
 - Laboratorio 7: Entrega puntual de la cadena de suministro (transporte y logística)
 - Laboratorio 8: Predicción de la conversión de ventas de los compradores de sitios web (venta minorista)
 - Laboratorio 9: Predicción del consumo de energía eléctrica (Energía y servicios públicos)
 - Laboratorio 10: Abandono estudiantil o éxito académico (EdTech)
 - Laboratorio 11: Predicción de abandono de jugadores (AWS para juegos)
- ▶ 🛠 Laboratorios de tecnología
 - 🚀 Registro de cambios y actualizaciones

▼ Content preferences

Language

Español ▼

[Día de inmersión en lienzo de Amazon...](#) > [Laboratorios de casos...](#) > Laboratorio 1: Pérdida de clientes (...)

Laboratorio 1: Pérdida de clientes (marketing)

⚠ Asegúrese de haber realizado los pasos descritos en la sección **Prerequisites** antes de comenzar este laboratorio.

Orden del día

1. [Descripción general](#)
2. [El conjunto de datos](#)
3. [Creación del modelo ML](#)
 1. [Importar el conjunto de datos](#)
 2. [Configuración del modelo de entrenamiento](#)
 3. [Análisis exploratorio de datos y preparación de datos](#)
 4. [Entrenando al modelo](#)
4. [Uso del modelo para generar predicciones](#)
 1. [Predicción única](#)
 2. [Predicción por lotes](#)
5. [Opcional: implementación del modelo](#)
6. [Opcional: Ver cuaderno](#)
7. [Próximos pasos](#)

Descripción general

En este laboratorio, asumimos la función de analista de marketing en el departamento de marketing de un operador de telefonía móvil. Se nos ha encomendado la tarea de identificar a los clientes que podrían correr el riesgo de perder clientes. Tenemos acceso al uso del servicio y a otros datos sobre el comportamiento de los clientes, y queremos saber si estos datos pueden ayudar a explicar por qué un cliente se iría. Si podemos identificar los factores que explican la pérdida de clientes, podemos tomar medidas correctivas para cambiar el comportamiento previsto, como llevar a cabo campañas de retención específicas.

El conjunto de datos

[Descargar el conjunto de datos](#) ⬇


Para nuestro conjunto de datos, utilizamos un conjunto de datos sintético de un operador de telefonía móvil de telecomunicaciones. Este conjunto de datos de muestra contiene 5000 registros, donde cada registro usa 21 atributos para describir el perfil del cliente.

Tu equipo de marketing te ha informado de que esta columna indica si el cliente abandonó el servicio (verdadero o falso). El último atributo, **Churn**, es el atributo que queremos que prediga el modelo de aprendizaje automático. El atributo objetivo es binario, lo que significa que nuestro modelo predice la salida en una de dos categorías (verdadera o falsa).

▶ Overview of the dataset fields

Creación y entrenamiento del modelo ML

El primer paso para crear un modelo con SageMaker Canvas es empezar por cargar el conjunto de datos. Vayamos a la sección **My models** haciendo clic en el segundo botón del menú de navegación de la izquierda y, a continuación, en **+ New model**.




En el modal que se rellena, asigne un nombre al modelo (por ejemplo, *Churn*) y, a continuación, asegúrese de que el tipo de problema seleccionado sea **Predictive analysis**. Por último, haz clic en **Create**.

Una vez creada la versión del modelo, se le mostrarán los 5 pasos que componen el ciclo de vida integral del aprendizaje automático: **select** un conjunto de datos, **build** y **analyze** el modelo, **predict** valores nuevos y **deploy** el modelo.

Importar el conjunto de datos

Empecemos por seleccionar el conjunto de datos. En nuestro caso, aún no tenemos uno en SageMaker Canvas, así que vamos a usar uno en **create**.



Asigne un nombre al conjunto de datos (por ejemplo, *CustomerData*) y continúe. En la nueva pantalla que aparece, se te pedirá que subas un archivo CSV o Parquet desde tu ordenador local, un proceso conocido como *Local Upload*. Arrastraremos y soltaremos el archivo CSV que hemos descargado anteriormente en esta ventana y esperaremos a que se cargue. Una vez completado (puede tardar hasta un minuto), podemos hacer clic en **Create Dataset**.

CustomerData: Create Tabular dataset

Data Source: Local upload

Upload files to import

Drag a CSV or Parquet file here

or

Select files from your computer

- Dataset size must be smaller than 5 GB
- Dataset can't contain both CSV and Parquet files

Cancel Create dataset

- ✓ Tenga en cuenta que SageMaker Canvas también le permite utilizar datos de más de 50 fuentes de datos, como Amazon S3, Amazon Redshift, Amazon Athena, Amazon RDS, Snowflake, SAP, Databricks, etc., con varios medios de conexión, por ejemplo, OAuth, Secret Manager, nombre de usuario/contraseña...

Tras confirmar que el conjunto de datos importado está listo, creamos nuestro modelo.

Configuración del modelo de entrenamiento

Una vez que haya seleccionado el conjunto de datos, SageMaker Canvas lo redirigirá a la segunda pestaña, **Build**. Aquí es donde debemos seleccionar cuál es nuestra columna objetivo, analizar y transformar nuestro conjunto de datos, definir el tipo de problema del modelo e iniciar el progreso del entrenamiento. No te preocupes, ¡te guiaremos durante todo el proceso!

En primer lugar, puede identificar dos partes de esta pantalla:

1. la parte superior, que contiene información sobre el proceso **model training**
2. la parte inferior, que muestra información sobre su **dataset**

My models / Churn / Version 1

+ Add version

Select Build Analyze Predict Deploy

Select a column to predict

Choose the target column. The model that you build predicts values for the column that you select.

Target column

Model type

SageMaker Canvas automatically recommends the appropriate model type for your analysis.

Quick build

To see a recommended model type, specify a value for the target column.

Preview model

1

CustomerData(3)

Full dataset: 5.0k rows

View all

Data visualizer

Column name	Data type	Feature type	Missing	Mismatched	Unique
Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)	2
Vmail_Message	Numeric	-	0.00% (0)	0.00% (0)	14
State	Text	-	0.00% (0)	0.00% (0)	51
Phone	Text	-	0.00% (0)	0.00% (0)	4,999

Total columns: 21 Total rows: 5,000 Total cells: 105,000 Show dropped columns

2

Centrémonos en la parte superior de la pantalla. Aquí es donde comenzamos nuestro viaje de preparación de datos y entrenamiento de modelos. Tenemos ante nosotros tres secciones:

1. **Select a column to predict:** esta es nuestra columna objetivo y el modelo que cree intentará predecir los valores de esta columna. En la sección [Descripción general](#), ya sabemos que nuestro objetivo es la variable Churn.

- En esta sección, ya podemos ver que la variable objetivo está bien distribuida: aproximadamente el 50% de las filas pertenecen a la clase «False» y el resto a la clase «True». Esto significa que no tenemos que realizar ninguna operación adicional de submuestreo o sobremuestreo en nuestro conjunto de datos, y nuestro modelo aprenderá por igual de ambas clases.
2. **Model type** - Una vez seleccionada la columna en la que entrenar, SageMaker Canvas detectará y recomendará automáticamente el tipo de modelo adecuado para el análisis. Para este laboratorio, la columna `churn` puede ser `True` o `False`. Por lo tanto, SageMaker Canvas detectará automáticamente que se trata de un problema de **2 Category** (también conocido como **binary classification**).
- SageMaker Canvas también le permite cambiar el tipo de problema si se detecta uno incorrecto, y también puede editar manualmente parte de la configuración de AutoML haciendo clic en el enlace **Configure model** de esta sección.
 - La configuración del modelo le permite:
 - Cambie el tipo de modelo, en caso de que se detecte uno incorrecto
 - Configure opciones avanzadas, como la métrica objetiva, el método de entrenamiento y los algoritmos que se van a utilizar, la división de entrenamiento/validación y el número máximo de candidatos y el tiempo de ejecución.

i Por el bien de este laboratorio, dejaremos todo como predeterminado. Sin embargo, dedique un minuto a revisar los ajustes avanzados que se pueden configurar. Comprueba, en particular, la variedad de algoritmos que puedes utilizar cambiando el tipo de entrenamiento de automático a por conjunto y, por tanto, a la optimización de hiperparámetros

Column name	Data type	Feature type	Missing	Mismatched	Unique
Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)	2
Vmail_Message	Numeric	-	0.00% (0)	0.00% (0)	14
State	Text	-	0.00% (0)	0.00% (0)	51
Phone	Text	-	0.00% (0)	0.00% (0)	4,999

3. Por último, tenemos la opción de cómo queremos **train the model**. Aquí tenemos tres opciones: compilación rápida, compilación estándar y modelo de vista previa. No te preocupes por esta sección por ahora, volveremos a tratarla más adelante en este laboratorio.

Análisis exploratorio de datos y preparación de datos


Incluso antes de empezar a entrenar nuestro modelo, echemos un vistazo más de cerca a nuestro conjunto de datos de predicción de abandono.

En la pestaña **Build**, puede comenzar a analizar visualmente su conjunto de datos. Las dos vistas disponibles son **Column View** (predeterminada) y **Grid View**.

CustomerData(3) Full dataset: 5.0k rows						Data visualizer
Column name	Data type	Feature type	Missing	Mismatched	Unique	
Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)	2	
Vmail_Message	Numeric	-	0.00% (0)	0.00% (0)	14	

En la vista de columnas, puede visualizar estadísticas descriptivas para su conjunto de datos, que incluyen (de izquierda a derecha) el nombre de la columna, el tipo de datos mayoritario de esa columna, el recuento y el porcentaje de valores faltantes y no coincidentes, la cantidad de valores únicos, la media o el modo de esa columna y, si ha seleccionado un objetivo, la correlación objetivo.

Desde esta vista, puede «soltar» fácilmente una columna desmarcándola en el lado izquierdo de la pantalla o cambiándole el nombre haciendo doble clic en el nombre de una función.




En la vista de cuadrícula, puede comprobar la distribución de los datos y algunas muestras de datos del conjunto de datos.

Para obtener visualizaciones más avanzadas, Amazon SageMaker Canvas ofrece **Data Visualizer**, que puede ayudarle a obtener información avanzada sobre sus datos antes de crear sus modelos de aprendizaje automático. Puede realizar la visualización mediante **scatter plots**, **bar charts** y **box plots**, que le ayudarán a comprender sus datos y a descubrir las relaciones entre las funciones que podrían afectar a la precisión del modelo. Para usarlo, elija **Data visualizer** para comenzar a crear sus visualizaciones.

CustomerData(3) Full dataset: 5.0k rows					
View all					
Column name	Data type	Feature type	Missing	Mismatched	Unique
Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)	2
Vmail_Message	Numeric	-	0.00% (0)	0.00% (0)	14

Si no puedes visualizar correctamente los gráficos siguientes al crearlos, es probable que tengas una pantalla pequeña o que tu interfaz de usuario esté demasiado ampliada. Puedes reducir la imagen pulsando **CMD and -** en macOS o **CTRL and -** en Windows. También puedes usar los controles de zoom de tu navegador.

Empecemos por crear un diagrama de dispersión simple. Supongamos que nos gustaría ver cómo el hecho de cobrar más afecta a la cantidad de minutos que un cliente llama por teléfono. Para crear esta visualización, arrastre y suelte las entidades en el eje de la gráfica. Vamos a utilizar «Day_Mins» en el eje X, «Day_Charge» en el eje Y y «Churn» en la función «Colorear por». Vemos que los clientes que abandonan el servicio son aquellos a los que se les cobra más, especialmente si llaman durante más tiempo (en lugar de «Day_Mins»).



Intentemos trazar la frecuencia de las llamadas al servicio de atención al cliente según el estado y cómo afectan a la pérdida de clientes. Para ello, crearemos un gráfico de barras con «State» en el eje X, «CustServ_calls» en el eje Y y apilados por «Churn».




i Si lo desea, siga adelante y cree un diagrama de caja: ¿qué estado tiene los clientes más antiguos? ¿Cómo se distribuyen?

SageMaker Canvas también admite matrices de correlación que permiten resumir un conjunto de datos en una matriz que muestra las correlaciones entre dos o más valores y cómo se relacionan entre sí. Esto le ayuda a identificar y visualizar los patrones de un conjunto de datos determinado para realizar análisis avanzados. El resultado de estas matrices se puede utilizar para imputar los datos faltantes, asignar ponderaciones a los valores para comprender la varianza y realizar otros análisis avanzados.

Las matrices de correlación se pueden usar con variables numéricas, categóricas y con una combinación de ambas variables. Los conjuntos de datos se pueden analizar utilizando las correlaciones de Pearson o Spearman para los valores numéricos, o la información mutua para los valores categóricos.

Para crear una matriz de correlación:


1. Haz clic en la pestaña **Analytics** situada justo al lado de la pestaña **Visualizations** (ambas están justo encima de los iconos de dispersión, de barras y de diagrama de caja).



Aparecerá una matriz de correlación predeterminada con todas las columnas seleccionadas de forma predeterminada.


Para añadir o eliminar columnas de la matriz de correlación, seleccione y deseleccione las columnas del panel Columnas, o arrastre y suelte las columnas del panel directamente en la matriz. Para filtrar las columnas por tipo de datos, elija el menú desplegable y seleccione Todas, Numéricas o Categóricas.

Por ejemplo, al seleccionar los minutos diurnos, vísperas y nocturnos, junto con las llamadas al servicio de atención al cliente, podemos ver que existe una correlación moderada (0,49) entre los minutos diurnos y vespertinos de los clientes. También parece haber una correlación inversa (-0,33) entre los clientes que utilizan muchos minutos nocturnos y que también hacen llamadas al servicio de atención al cliente.



Siéntase libre de añadir y eliminar columnas por su cuenta para observar cualquier correlación de interés.

Ahora que hemos analizado un poco nuestro conjunto de datos, una buena práctica es tener una base de referencia de qué esperar del entrenamiento de tu modelo de aprendizaje automático. Puede considerarlo como una «puntuación a superar» después de explorar y preparar los datos. Amazon SageMaker Canvas le permite obtener información a partir de sus datos antes de crear un modelo; para ello, elija **Preview model**. Queremos ver rápidamente si las demás columnas pueden predecir nuestra columna objetivo. Podemos obtener una visión rápida de la precisión estimada del modelo y el impacto de la columna (la importancia estimada de cada columna para predecir la columna objetivo).



❗ Para nuestro caso de uso, el modelo de vista previa tarda aproximadamente 1 minuto en crearse. Después de 1 minuto, debería obtener un número de precisión similar al que se muestra a continuación. No te preocupes si el número no es exactamente el mismo, el aprendizaje automático introduce cierta estocasticidad que puede hacer que el número varíe ligeramente.

Preview model



Estimated accuracy ⓘ

95.6%

The model predicts the correct target
(Churn) 95.6% of the time.

En este caso, nuestra línea base será un modelo con una precisión del 95,6%. Esto significa que el modelo predice el objetivo correcto (pérdida de clientes) el 95,6% de las veces. ¡Eso es bastante bueno para una línea de base! Esperemos un par de minutos más para que se complete el análisis.

❗ Ten en cuenta que, si bien el entrenamiento suele tardar menos de un minuto, la generación de la importancia de las funciones puede tardar hasta 5 minutos. ¡Tenga paciencia mientras se genera el análisis!

Column impact ⓘ

Search columns...

Night_Calls	3.85
Eve_Mins	2.73
Night_Charge	1.411
Day_Mins	0.888
Eve_Charge	0.859
Night_Mins	0.795
CustServ_Calls	0.784
Intl_Calls	0.627
Day_Calls	0.621

SageMaker Canvas también genera **feature importances** para usted. Son muy útiles para comprender el impacto que tienen las funciones en nuestras predicciones. Cuanto mayor sea el valor, mayor será el impacto. Si una sola función tiene un gran impacto en el resultado de un modelo, es un indicador principal de la fuga objetivo y es muy probable que la función no esté disponible en el momento de la predicción. Si te desplazas hacia abajo, verás que las columnas Teléfono y Estado tienen un impacto mucho menor en nuestra predicción.

Area_Code	0.196
Eve_Calls	0.109
State	0.08
Intl_Plan	0.046
VMail_Plan	0.02
Phone	0.02

Es posible que el conjunto de datos de aprendizaje automático requiera la preparación de datos antes de crear el modelo. Es posible que desee limpiar los datos debido a varios problemas, como valores faltantes o valores atípicos, y realizar una ingeniería de características para mejorar la precisión del modelo. Amazon SageMaker Canvas proporciona transformaciones de datos de aprendizaje automático con las que puede limpiar, transformar y preparar los datos para la creación de modelos. Puede utilizar estas transformaciones en sus conjuntos de datos sin ningún código. SageMaker Canvas agrega las transformaciones que utiliza a **Model recipe**, que es un registro de la preparación de los datos realizada en los datos antes de crear el modelo. Todas las transformaciones de datos que utilice solo modifican los datos de entrada para la creación del modelo y no modifican la fuente de datos original.


Las siguientes transformaciones están disponibles en SageMaker Canvas para que pueda preparar los datos para la construcción:

- Cambiar los tipos de datos
- Fórmula personalizada (funciones y operadores)
- Reemplazar valores faltantes y valores atípicos
- Eliminar filas (duplicados, por fórmula, por valores faltantes, por valor atípico)
- Mezclar/ordenar/filtrar filas
- Cambiar el nombre de las columnas
- Transformaciones específicas de series temporales, como el remuestreo y la extracción de fecha y hora

Empecemos por lo fácil, eliminando las columnas que hemos descubierto que no tienen ningún impacto en nuestra predicción.

Nota: ¡tener un impacto bajo en la predicción no significa que las funciones sean automáticamente inútiles! Si bien es cierto que las funciones de bajo impacto pueden añadir ruido a nuestro modelo, a veces pueden resultar útiles para describir situaciones específicas en tu caso práctico. Combina siempre la capacidad predictiva con tus conocimientos empresariales para determinar qué funciones son realmente importantes o no.

Por ejemplo, en este conjunto de datos, el número de teléfono es simplemente el equivalente a un número de cuenta, algo inútil o incluso perjudicial para predecir la probabilidad de pérdida de otras cuentas, y el estado del cliente no afecta demasiado a nuestro modelo. Eliminemos las columnas Teléfono y Estado, desmarcando y desmarcando esas funciones en la vista por columnas.



Column name	Data type	Feature type	Missing	Mismatch
☒ Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)
☒ Vmail_Message	Numeric	-	0.00% (0)	0.00% (0)
☐ State	Text	-	0.00% (0)	0.00% (0)
☐ Phone	Text	-	0.00% (0)	0.00% (0)

Realicemos también una transformación de datos adicional. Por ejemplo, en nuestro análisis anterior observamos que el importe cobrado a los clientes tiene un impacto directo en la pérdida de clientes. Por lo tanto, vamos a crear una nueva columna que calcule los cargos totales a nuestros clientes combinando los valores «Cobro», «Minutos» y «Llamadas» para indicar «Día», «Fin», «Noche» e «Internacional». Para ello, utilizaremos **Custom Formulas** en Amazon SageMaker Canvas:

1. Haga clic en el botón de transformaciones **View all**
2. Seleccione **Custom Formula**
3. Usa la siguiente fórmula:

$(\text{Day_Calls_Day_Charge_Day_Mins}) + (\text{Eve_Calls_Eve_Charge_Eve_Mins}) + (\text{Night_Calls_Night_Charge_Night_Mins}) +$



4. Ponle un nombre como **Total_Charges**, luego haz clic en **Preview** y, a continuación, **Add**
5. Puede comprobar que la transformación se ha realizado después de hacer clic en Vista previa desplazándose hacia la derecha para buscar la nueva columna, así como en la receta del modelo después de hacer clic en Agregar.

Column name	Data type	Feature type	Missing	Mismatched	Unique	Mode
☒ Vmail_Plan	Text	Binary	0.00% (0)	0.00% (0)	2	yes
☒ Vmail_Message	123 Numeric	-	0.00% (0)	0.00% (0)	14	0
☐ State	Text	-	0.00% (0)	0.00% (0)	51	RI
☐ Phone	Text	-	0.00% (0)	0.00% (0)	4,999	614-566
☒ Night_Mins	123 Numeric	-	0.00% (0)	0.00% (0)	5,000	0.01
☒ Night_Charge	123 Numeric	-	0.00% (0)	0.00% (0)	5,000	0.06
☒ Night_Calls	123 Numeric	-	0.00% (0)	0.00% (0)	12	200
☒ Intl_Plan	Text	Binary	0.00% (0)	0.00% (0)	2	no
☒ Intl_Mins	123 Numeric	-	0.00% (0)	0.00% (0)	5,000	1.65
☒ Intl_Charge	123 Numeric	-	0.00% (0)	0.00% (0)	5,000	0
☒ Intl_Calls	123 Numeric	-	0.00% (0)	0.00% (0)	13	5
☒ Eve_Mins	123 Numeric	-	0.00% (0)	0.00% (0)	5,000	0.01

Vamos a ejecutar la vista previa de nuevo. Seleccione **Preview Model** y, a continuación, haga clic en **Update**. Como se muestra en la siguiente captura de pantalla, la precisión del modelo aumentó un 0,4%.

Preview model
✕

Estimated accuracy ⓘ

96% ▲ +0.4%
 from 95.6%

The model predicts the correct target
 (Churn) 96% of the time.

❗ No dude en dedicar un tiempo a explorar los pasos de preparación de datos y cómo afectan al rendimiento del modelo.

Una vez que hayas explorado esta sección, ¡es hora de entrenar por fin a la modelo! Canvas ofrece dos opciones de construcción:

- **Quick build:** crea un modelo en una fracción del tiempo en comparación con una construcción estándar; la precisión potencial se intercambia por velocidad.
- **Standard build:** construye el mejor modelo a partir de un proceso optimizado impulsado por AutoML; la velocidad se intercambia por la mayor precisión


Entrenando al modelo

❗ Para este laboratorio, entrenaremos el modelo con **Standard Build**. Con este conjunto de datos, este proceso toma **30~45 minutos**. Si tienes prisa, puedes ejecutar en su lugar el entrenamiento de Quick Build, que tardará unos 5 minutos con este conjunto de datos. Tenga en cuenta que, cuando se entrene con Quick Build, NO podrá probar las funciones de colaboración de SageMaker Canvas: compartir el modelo con Amazon SageMaker Studio, enviar el modelo a Amazon QuickSight e implementarlo en un punto de conexión de Amazon SageMaker.

Un modelo rápido entrena menos combinaciones de modelos e hiperparámetros para priorizar la velocidad por encima de la precisión, especialmente en casos como el nuestro, en los que queremos demostrar el valor de entrenar un modelo de aprendizaje automático para nuestro caso de uso. Ten en cuenta que la creación rápida no está disponible para modelos de más de 50 000 filas. Sigamos y hagamos clic en **Standard build**.

Antes de crear el modelo, SageMaker Canvas comprueba el conjunto de datos en busca de problemas que puedan provocar un error en la compilación. Si SageMaker Canvas encuentra algún problema, le avisará en la página de creación antes de intentar crear un modelo. Los problemas que Canvas SageMaker Canvas comprueba en su conjunto de datos y cómo resolverlos se describen en [la documentación de SageMaker Canvas](#). Para realizar la validación de los datos, simplemente haga clic en el botón **Validate data** situado en la esquina superior derecha de la pantalla.

Ahora, esperaremos. Dado que el conjunto de datos es pequeño, este proceso debería realizarse en **30~45 minutes**.



SageMaker Canvas separa el conjunto de datos en conjuntos de entrenamiento y validación. El conjunto de datos de entrenamiento son los datos que Canvas utiliza para crear el modelo. El conjunto de validación se usa para ver si el modelo funciona bien con los datos nuevos. Para obtener más información, puede consultar [Sección «Evaluación del rendimiento de su modelo en Amazon SageMaker Canvas»](#) de la documentación de Canvas, así como la página de [Líneas de base de SHAP para la explicabilidad](#).

❗ No te preocupes si los números de las imágenes de abajo difieren de los tuyos. El aprendizaje automático introduce cierta estocasticidad en el proceso de entrenamiento de los modelos, lo que puede llevar a resultados diferentes según las configuraciones.

Model status

Accuracy ⓘ


96.803%

F1 ⓘ Optimization metric


0.968

The model predicts the correct Churn 96.803% of the time. ⓘ


Cuando se completa el proceso de creación del modelo, el modelo predijo correctamente la pérdida de clientes aproximadamente el 97% de las veces. También obtenemos información sobre métricas adicionales, como la puntuación F1, que es nuestra métrica de optimización. Esto parece correcto, pero como analistas queremos profundizar más y ver si podemos confiar en el modelo para tomar decisiones basadas en él.



Centrámonos en la primera pestaña, **Overview**. Esta es la pestaña que nos muestra el **Column impact**, o la importancia estimada de cada columna para predecir la columna objetivo. En este ejemplo, la columna *Night_calls* es la que tiene un impacto más significativo a la hora de predecir si un cliente abandonará el negocio. Esta información puede ayudar al equipo de marketing a obtener información que le permita tomar medidas para reducir la pérdida de clientes. Por ejemplo, podemos ver que tanto los niveles bajos como los altos en *CustServ_Calls* aumentan la probabilidad de pérdida de clientes. El equipo de marketing puede tomar medidas para evitar la pérdida de clientes en función de estos datos. Algunos ejemplos son la creación de preguntas frecuentes detalladas en los sitios web para reducir las llamadas al servicio de atención al cliente y la organización de campañas informativas con los clientes sobre las preguntas frecuentes para mantener la interacción.



En la pestaña **Scoring**, podemos visualizar una gráfica de Sankey (o cinta) de la distribución de los valores pronosticados con respecto a los valores reales. Esto nos permite comprender el rendimiento del modelo en el conjunto de datos de validación.



Para obtener información más detallada que vaya más allá de lo que se muestra en el diagrama de Sankey, podemos ir a la pestaña **Advanced metrics**. Aquí podemos obtener información, como métricas adicionales calculadas durante el entrenamiento, visualizar la matriz de confusión y la curva de recuperación precisa.

Las métricas avanzadas se ven bien. Podemos confiar en el resultado del modelo. Vemos muy pocos falsos positivos y falsos negativos. Esto ocurre si el modelo cree que un cliente del conjunto de datos va a perder clientes y, en realidad, no lo hace (falsos positivos), o si el modelo cree que el cliente abandonará clientes y realmente lo hace (falsos negativos). Los números altos en cualquiera de los dos podrían hacernos pensar más en si podemos usar el modelo para tomar decisiones.

Select Build **Analyze** Predict Deploy

Model leaderboard

Search leaderboard

Model name	F1 Optimization	Accuracy	AUC	Balanced Accuracy	Precision	Recall	Log Loss	Inference lat
WeightedEnsemble-L2-FULL-t8 Default model	96.825%	96.803%	0.993	96.804%	96.063%	97.600%	0.099	0.109
WeightedEnsemble-L2-FULL-t9	93.148%	93.107%	0.977	93.108%	92.505%	93.800%	0.218	0.195
WeightedEnsemble-L2-FULL-t7	94.985%	94.905%	0.985	94.907%	93.424%	96.600%	0.158	0.148
WeightedEnsemble-L2-FULL-t6	94.685%	94.605%	0.986	94.607%	93.217%	96.200%	0.149	0.091

Dado que SageMaker Canvas entrena a varios candidatos como parte del proceso de AutoML, también podemos revisar cada uno de esos candidatos consultando **Model Leaderboard**. En la tabla de clasificación de modelos, puede revisar todos los modelos que se han entrenado durante el proceso de AutoML, sus prestaciones, métricas y detalles, e incluso cambiar el modelo predeterminado en caso de que prefiera priorizar otra métrica o una latencia de inferencia más rápida.

En este laboratorio, no cambiaremos el modelo predeterminado. Sin embargo, puede dedicar un tiempo a revisar los demás modelos de la tabla de clasificación de modelos, generar un informe detallado para ellos comprobando los detalles del modelo y cambiar el modelo predeterminado por uno nuevo. Vuelve aquí una vez que hayas terminado de explorar.

Nuestro modelo parece bastante preciso. Podemos realizar directamente una predicción interactiva en la pestaña Predecir, ya sea por lotes o por lotes (en tiempo real).

Uso del modelo para generar predicciones

Ahora que el modelo está entrenado, usémoslo para generar predicciones. Selecciona **Predict** en la parte inferior de la página **Analyze** o elige la pestaña **Predict**. SageMaker Canvas le permite generar predicciones en dos modalidades:

- Predicción única («escenarios hipotéticos»)
- Predicción por lotes (varios escenarios a la vez mediante un archivo CSV)

Predicción única

Para probar las predicciones individuales, seleccione el botón **Single prediction**. Espere de 15 a 20 segundos y el modelo debería cargarse en la memoria de la aplicación SageMaker Canvas. ¡Ya está lista para generar nuevas inferencias!

En esta interfaz de usuario, puede continuar y cambiar el valor con el que desea generar una predicción. ¿Qué ocurre cuando *Account_Length* es más pequeño? ¿Qué pasa si el cliente genera muchas llamadas durante el día o la noche?

The screenshot shows the 'Predict target values' interface in SageMaker Canvas. It has two tabs: 'Batch prediction' and 'Single prediction', with 'Single prediction' selected. Below the tabs is a text input field for 'Filter columns'. A table lists features with their importance and current values: State (RI), Account_Length (169), Area_Code (777), Phone (614-5668), Intl_Plan (no), VIntl_Plan (yes), VIntl_Message (0), Day_Mins (0.00021480176744415), and Day_Calls (4). To the right, the 'Churn Prediction' result is displayed as 'False.' with a 'Copy' button. Below this, a bar chart shows the 'Average prediction' with 'False' at 99.984% and 'True' at 0.016%.

Como siempre, tómate un momento para jugar con estos valores y comprobar el impacto de cada función en la predicción.

Predicción por lotes

[Descargar el conjunto de datos de inferencia](#)

Para probar las predicciones por lotes, seleccione el botón **Batch prediction**. SageMaker Canvas le permite generar predicciones por lotes de forma manual o automática según un cronograma. Para este laboratorio, elegiremos **Manual**. Sube el archivo que acabas de descargar. A continuación, elige **Generate predictions** en la parte inferior de la página. Después de unos segundos, la predicción estará lista y podrás hacer clic en **View** para verla.

The screenshot shows the 'Predict' tab in SageMaker Canvas. It has sub-tabs: 'Select', 'Build', 'Analyze', 'Predict' (selected), and 'Deploy'. Under 'Predict', there are 'Batch prediction' and 'Single prediction' buttons, with 'Batch prediction' selected. Below are 'Manual' and 'Automatic' buttons. A 'Predictions' section shows a table with columns: Job name, Created, Input dataset, Prediction type, Configuration name, Rows, QuickSight, and Status. The table is currently empty, and a message at the bottom says 'Select a dataset to generate predictions'.

Si lo desea, haga clic en el botón de descarga para descargar un archivo CSV que contenga el resultado completo. SageMaker Canvas devolverá una predicción para cada fila de datos y la probabilidad de que


la predicción sea correcta.

 Si quieres aprender a automatizar las predicciones de lotes según un cronograma, te sugerimos que ejecute [Automatice el laboratorio de predicciones de lotes](#)

Opcional: implementación del modelo

El paso final (pero opcional) del flujo de trabajo de SageMaker Canvas para modelos de aprendizaje automático es **deployment of the model**. Esta función utiliza puntos de conexión en tiempo real de Amazon SageMaker (obtenga más información aquí) para cargar el modelo de SageMaker Canvas junto con las transformaciones realizadas durante la fase de preparación de los datos, y presenta un punto de enlace HTTPS que los desarrolladores pueden consultar en sus aplicaciones mediante dos líneas de código.

Para implementar un modelo, vaya a la pestaña **Deploy** y, a continuación, haga clic en **+ Create Deployment**. Cambia el recuento de instancias a 1 y el tipo de instancia a `m1.m5.2xlarge`. Aunque se recomiendan instancias más grandes y con un mayor número de instancias para las cargas de trabajo de producción, esto será más que suficiente para nuestras demostraciones. Tenga en cuenta que siempre puede cambiar la configuración más adelante desde la interfaz de usuario de SageMaker Canvas o mediante las API de SageMaker.



My models / Churn / Version 1 + Add version

Select Build Analyze Predict **Deploy**

Deployments

Filter by status: In service Failed Creating Search deployments + Create Deployment

Deployment name	Status	Deployment URL	Created
No result found			

Puede copiar el nombre de la implementación y usarlo con el SDK de Python de SageMaker o con Boto3, o copiar la URL de la implementación y usarla con solicitudes HTTPS, por ejemplo, con Postman. Recuerde que, en ambos casos, tendrá que proporcionar credenciales de AWS válidas para poder consultar el punto final.

 ¡Recuerde eliminar el punto final implementado una vez que haya terminado de probar con él! Los terminales en tiempo real tienen un precio fijo por hora y no se cancelan automáticamente.

 ¿Desea obtener más información sobre la implementación de modelos? Diríjase a [Laboratorio de implementación directa \(actualmente WIP\)](#)

Opcional: Ver cuaderno

Si quiere echar un vistazo al código del proceso de AutoML, puede hacerlo directamente desde SageMaker Canvas. Simplemente haga clic en el icono **options** en la esquina superior derecha de la pantalla (tres puntos) y, a continuación, haga clic en **View Notebook**.

My models / Churn / Version 1

Add version

Select

Build

Analyze

Predict

Deploy

Deployments

Filter by status:

in service

Failed

Creating

Search deployments

+ Create Deployment

Deployment name	Status	Deployment URL	Created
canvas-new-deployment-11-10-2023-7-3...	in service	https://runtime.sagemaker-us-east-1.amazonaws.com/endpoints/canvas-new-deploy...	11/10/23 07:34 PM

Este cuaderno contiene información sobre el conjunto de datos, los pasos de preparación de los datos que se aplicaron durante el proceso de EDA, el código que condujo a la generación del candidato y la implementación del modelo. Este código se puede descargar para que pueda ejecutarlo donde quiera, ya sea en SageMaker Studio o en el editor de cuadernos que prefiera.

Próximos pasos

✓ **Congratulations!** Ya ha completado el laboratorio 1.

Como pasos siguientes, puede elegir ejecutar:

- otro [Laboratorio de casos de uso](#) de una industria diferente;
- pruebe con [Laboratorio centrado en la tecnología](#); en particular, le sugerimos que ejecute [Laboratorio Amazon QuickSight](#), que aprovecha el modelo que acaba de crear (si ha elegido la versión estándar);
- prueba uno de los [Laboratorios de IA generativa](#).

[Previous](#)[Next](#)